

Shor's Algorithm under Noise: Machine-Learning Ablation, Quantum Error Correction, and Approximate QFT

Laureando: Claudio Dragotta

Relatore: Prof. Paolo Soda

Correlatore: Ing. Floriano Caprio

Sessione di Laurea: Ottobre — A.A. 2025/2026

1 Introduzione e obiettivi

L'algoritmo di Shor consente di fattorizzare numeri interi in tempo polinomiale rispetto alla lunghezza binaria dell'input, con implicazioni per la sicurezza dei sistemi crittografici fondati sulla difficoltà della fattorizzazione [1–3]. La realizzazione di questo vantaggio teorico richiede tuttavia un controllo degli errori compatibile con la profondità dei circuiti. Errori nelle operazioni, decoerenza e lettura imperfetta possono alterare la distribuzione delle misure e compromettere l'informazione necessaria alla ricerca dell'ordine moltiplicativo [4].

La tesi sviluppa uno studio simulativo volto a stabilire quali interventi migliorino effettivamente l'affidabilità della computazione e rispetto a quali riferimenti. Il percorso comprende due fasi principali: la valutazione del post-processing classico degli esiti di Shor, con uno studio di ablazione del contributo del machine learning, e la caratterizzazione di codici di correzione quantistica e decoder delle sindromi. Completano il lavoro un'analisi separata della sensibilità di Shor agli errori di porta e una campagna sull'ottimizzazione circuitale mediante trasformata di Fourier quantistica approssimata, o AQFT.

I tre ambiti di intervento — selezione degli esiti, protezione dell'informazione e riduzione del costo circuitale — sono collegati da un criterio comune: confrontare ogni soluzione con un riferimento esplicito, isolare il contributo dei singoli componenti e misurare il beneficio mediante indicatori coerenti con il compito. Le campagne rimangono distinte: non costituiscono un'esecuzione integrata di Shor protetta da correzione d'errore.

2 Materiali e metodi

2.1 Implementazione, validazione e definizione del successo

Scelta una base a coprime con il numero N da fattorizzare, la successione $a^x \bmod N$ è periodica; il periodo, detto ordine r , è il minimo intero positivo per cui $a^r \equiv 1 \pmod{N}$. La parte quantistica lo stima con stima di fase e QFT inversa; la parte classica ricava i fattori per approssimazione razionale e massimo comune divisore, e li verifica.

L'istanza principale è $N = 15$, $a = 7$, con otto qubit di controllo e quattro di lavoro; l'ordine è $r = 4$ e gli esiti ideali del registro di controllo sono 0, 64, 128 e 192. Ogni esecuzione con misura, detta *shot*, restituisce un solo esito; molti shot formano l'istogramma su cui opera il post-processing. Il successo è il recupero di fattori non banali, non la ricostruzione esatta dell'ordine. Vi conducono tre dei quattro picchi ideali, con probabilità complessiva del 75%. La verifica classica è però permissiva

e accetta 63 dei 256 valori, tanto che esiti del tutto uniformi darebbero comunque un successo di $63/256 \approx 24,61\%$. Questo riferimento dipende dall'istanza e dal post-processing, non misura la fedeltà dello stato quantistico e ricorda che fattorizzazioni corrette sopravvivono anche a una distribuzione che ha perso gran parte della propria struttura [5].

La correttezza dei circuiti è verificata indipendentemente dal successo della fattorizzazione, controllando operatori modulari, ripristino dei qubit ausiliari e accordo con le distribuzioni teoriche. Le istanze $N = 21$, $a = 2$ e $N = 35$, $a = 6$, validate idealmente, usano l'aritmetica reversibile di Beauregard [6]; solo $N = 21$ entra nelle prove rumorose esplorative sull'AQFT. Si impiegano Qiskit/Aer, scikit-learn, Stim e PyMatching, registrando versioni, parametri, semi casuali e identificativi dei circuiti.

2.2 Post-processing, classificazione e mitigazione

Tre strategie, con estrattore dei fattori e regola dei pareggi comuni, operano sugli stessi istogrammi, uno per iterazione quantistica, da 1.024 shot ciascuno. TOP-1 (Metodo 1) verifica il solo esito più frequente; TOP-4 fino a quattro candidati ordinati per frequenza; il Metodo 2 applica TOP-4 solo se un classificatore predice il successo del candidato dominante. Il confronto fra Metodo 2 e TOP-4 senza filtro è lo studio di ablazione, che stabilisce se il vantaggio venga dal modello appreso o dal semplice provare più candidati. Due scenari illustrativi, UC1 di riferimento e UC2 di stress, includono depolarizzazione, rilassamento termico ed errori di lettura; per ciascuno, 2.000 istogrammi con parametri variati entro $\pm 50\%$ del nominale sono divisi 60%/20%/20% fra addestramento, selezione e verifica. Random forest, support vector machine (SVM) e perceptron multistrato sono confrontati su F1; il modello scelto è valutato su 400 istogrammi indipendenti per scenario. La metrica primaria è il numero di iterazioni per ottenere i fattori, non l'accuratezza del classificatore né il tempo di calcolo. Si usano 30 repliche appaiate per scenario e al massimo 50 iterazioni, con valore convenzionale 51 se i fattori non arrivano entro il limite, e test di Wilcoxon–Pratt con correzione di Holm. La zero-noise extrapolation (ZNE) a due e tre livelli scala in simulazione i soli parametri depolarizzanti [7, 8].

2.3 Correzione quantistica e decodifica delle sindromi

Nella correzione quantistica l'informazione di un qubit logico è distribuita su più qubit fisici; si misurano parità, dette sindromi, che segnalano gli errori senza leggere l'informazione logica, e un decoder sceglie la correzione. Si studiano codice a ripetizione, Steane [[7, 1, 3]] e surface code [9–11] in circuiti di memoria, misurando la probabilità di fallimento logico p_L , cioè che l'informazione resti errata dopo la decodifica.

Il surface code ruotato usa le distanze $d = 3, 5, 7, 9$ (la distanza indica quanti errori il codice tollera), memorie in base X e Z e d cicli di sindrome, con rumore su operazioni, preparazione e misura. Il decoder di riferimento, minimum-weight perfect matching (MWPM), è confrontato sugli stessi eventi di rilevazione con una rete neurale autonoma

e un decoder ibrido, che non decodifica da zero ma apprende quando la decisione del matching è probabilmente errata e la inverte, con soglia d'intervento scelta in validazione e fissata sul test. Al rumore nominale si aggiunge crosstalk fra qubit adiacenti; si controllano calibrazione del modello, dimensione dell'ingresso della rete e confronto con il decoder analitico BP+OSD (belief propagation e ordered statistics decoding) [12, 13].

2.4 Sensibilità di Shor agli errori di porta

Un esperimento distinto applica errori di Pauli indipendenti dopo le porte compilate, escluse le rotazioni virtuali RZ, con 20 repliche da 4.096 shot per valore. La probabilità totale di errore non identità, p_g , è un proxy per porta, non convertibile nel fallimento logico p_L dei circuiti di memoria senza compilazione fault-tolerant completa.

2.5 Ottimizzazione mediante QFT approssimata

L'AQFT elimina le rotazioni controllate di piccolo angolo della QFT, perdendo precisione ma riducendo porte e profondità, e con esse le occasioni in cui il rumore agisce [14]. Si distingue il troncamento della QFT inversa finale di Shor per $N = 15$ da quello delle trasformate interne all'aritmetica modulare per $N = 21$; benchmark separati di stima di fase usano registri da sei, otto e dieci qubit, con tre fasi per dimensione. Il rumore usa infedeltà delle porte ed errori di lettura della calibrazione offline FakeSherbrooke, senza T_1/T_2 aggiuntivi, a parità di layout e semi casuali. Il grado di troncamento è scelto su campioni di selezione e valutato su campioni di verifica disgiunti (nel pilota $N = 15$, 8.192 shot per configurazione, divisi a metà).

3 Risultati

3.1 Validazione e contributo del post-processing

Le verifiche ideali dell'aritmetica danno una distanza di variazione totale dalla distribuzione teorica di $1,38 \times 10^{-9}$ per $N = 21$ e $2,50 \times 10^{-13}$ per $N = 35$, e attestano la correttezza funzionale, non le prestazioni sotto rumore.

In UC1/UC2 le SVM selezionate raggiungono F1 pari a 0,919/0,923 e area sotto la curva ROC pari a 0,965/0,958, ma la capacità predittiva non riduce il costo operativo. TOP-4 richiede in media 1,00 iterazioni in entrambi gli scenari, contro 1,37/1,50 di TOP-1 ($p_{Holm} = 0,0024/0,0015$); il Metodo 2 richiede 1,50/1,37 iterazioni, non migliora significativamente TOP-1 ed è peggiore della propria ablazione TOP-4 ($p_{Holm} = 0,0033/0,0096$). Il beneficio appartiene quindi alla ricerca multi-candidato. Il filtro interviene su dati già acquisiti e può scartare istogrammi che TOP-4 avrebbe utilizzato con successo. Nemmeno la ZNE migliora lo scenario di riferimento e, a due e tre livelli, richiede in media 3.072 e 4.813 shot, contro 1.399 di TOP-1 e 1.024 di TOP-4. Questi esiti valgono per metodi, istanza e rumore esaminati e non provano un'inefficacia generale del machine learning o della mitigazione.

3.2 Protezione della memoria e decodifica ibrida

Il codice a ripetizione riproduce, entro l'incertezza Monte Carlo, la legge $p_L = 3p^2 - 2p^3$. Per Steane la dipendenza dall'errore fisico è circa quadratica (pendenza logaritmica 1,94) e l'intersezione fra p_L e p cade intorno a 0,08, una pseudo-soglia del modello con errori sui dati e sindrome ideale e non la soglia operativa di un'architettura fault-tolerant. Nel surface code, sotto soglia aumentare la distanza riduce l'errore logico, sopra soglia lo aumenta; il fit sotto soglia dà circa 0,86% in base Z e 0,81% in base X, per il circuito di memoria, il rumore e il decoder adottati.

Con rumore nominale la rete autonoma non supera significativamente MWPM nelle quattordici configurazioni iniziali. Il quadro cambia con correlazioni fra qubit adiacenti che il grafo del matching non rappresenta adeguatamente, e in questo regime il decoder ibrido riduce l'errore logico. Per esempio, a $d = 3$, $p = 0,003$ e intensità di crosstalk 0,01, p_L passa da 0,05829 con MWPM a 0,04851 con l'ibrido, una riduzione relativa di circa il 16,8% (Tabella 5.9 della tesi), significativa al test appaiato di McNemar; con d cicli il beneficio è più contenuto a distanza 5 e non significativo a distanza 7. A distanza 5, nelle configurazioni considerate, BP+OSD supera l'ibrido basato su MWPM, e le prove che variano separatamente distanza e cicli mostrano il ruolo della dimensione dell'ingresso della rete. Il contributo appreso dipende quindi da struttura del rumore, riferimento analitico e rappresentazione dei dati, non dalla sola distanza del codice.

3.3 Successo di fattorizzazione e riferimento uniforme

Senza rumore il successo per singolo shot è 74,89% (intervallo di confidenza al 95% [74,59%; 75,18%]), coerente con il 75% atteso. Al crescere di p_g l'andamento è compatibile con una funzione non crescente e, per $p_g = 0,5$, il successo è 24,59%, prossimo al riferimento uniforme del 24,61% (Sezione 2.1). Il solo numero di fattorizzazioni corrette non dice perciò quanta informazione quantistica resti nel circuito.

3.4 Efficacia e limiti della QFT approssimata

Nel pilota di Shor per $N = 15$, l'AQFT selezionata aumenta la probabilità di successo per shot dal 47,92% al 62,79% (+14,87 punti percentuali sui dati indipendenti di verifica, intervallo di confidenza Newcombe al 95% [12,73; 16,99] punti), mentre le porte a due qubit ECR scendono da 362 a 279 e la profondità da 1.351 a 1.141. Il beneficio riguarda la fattorizzazione, non solo la stima di fase isolata.

Per $N = 21$ il troncamento delle QFT interne all'aritmetica riduce le porte ECR da 49.661 a 23.178, ma il successo ideale scende dal 46,67% al 40,13%; nei tre confronti rumorosi tutti gli intervalli delle differenze comprendono lo zero. Con 128 shot di verifica per variante e livello di rumore la capacità di rilevare effetti piccoli è limitata, e l'assenza di vantaggio non dimostra l'inefficacia dell'approssimazione. Nei nove benchmark di stima di fase le differenze sono tutte favorevoli alla variante selezionata e sei intervalli individuali al 95% escludono lo zero; il massimo incremento è 12,55 punti percentuali su dieci qubit ([9,77; 15,30]). I confronti sono esplorativi, senza correzione

simultanea dei nove intervalli; il grado di troncamento migliore fra quelli provati è due o tre, non necessariamente costante per registri arbitrariamente grandi.

4 Discussione e conclusioni

Il post-processing usa meglio l'informazione delle misure, ma non modifica lo stato quantistico. L'ablazione del classificatore è un risultato metodologico: metriche predittive elevate non garantiscono un minor costo di fattorizzazione. Nella decodifica accade il contrario, perché la sindrome contiene informazione strutturata sugli errori e l'approccio ibrido funziona proprio dove il decoder analitico non rappresenta alcune correlazioni del rumore, benché il beneficio vada confrontato con altri decoder analitici. Il valore di un modello appreso dipende dunque dall'informazione che riceve e da ciò che la baseline lascia inutilizzato; poiché i due impieghi riguardano compiti e dati diversi, la differenza non è attribuibile alla sola fase in cui interviene il machine learning.

Per $N = 15$ l'AQFT dà un risultato positivo distinto, con meno porte associate a un maggior successo. L'ordine $r = 4$ produce fasi rappresentabili esattamente con due bit del registro di controllo, perciò le rotazioni eliminate non veicolano informazione utile e il troncamento costa poco in precisione. Per $N = 21$, con $r = 6$, le fasi non sono esattamente rappresentabili e l'aritmetica è più complessa, per cui il beneficio non si trasferisce automaticamente. Il grado di approssimazione va scelto secondo istanza e regime di rumore, e verificato su dati distinti da quelli usati per sceglierlo.

Le conclusioni restano circoscritte alle simulazioni. Il post-processing riguarda $N = 15$ con rumore uniforme e stazionario, la QEC circuiti di memoria separati, le prove AQFT una sola calibrazione offline e poche istanze e fasi. Non si dimostra un'esecuzione fault-tolerant completa di Shor, né si prevedono le risorse per la fattorizzazione su scala crittografica. Il contributo è una caratterizzazione quantitativa e riproducibile delle condizioni di utilità dei componenti studiati, da estendere con verifica su hardware, variazione indipendente di N e dell'ordine r e integrazione fra operazioni logiche protette, decodifica e ottimizzazione aritmetica. Nel perimetro studiato emerge una regola comune: aggiungere complessità ha senso solo se permette di sfruttare informazione che la baseline non usa, o se riduce un costo del circuito maggiore della perdita introdotta.

5 Riferimenti bibliografici essenziali

- [1] P. W. Shor, "Algorithms for Quantum Computation: Discrete Logarithms and Factoring", *Proc. 35th Annual Symposium on Foundations of Computer Science (FOCS)*, pp. 124–134, 1994.
- [2] National Institute of Standards and Technology, *FIPS 203, FIPS 204 e FIPS 205*, 2024.
- [3] C. Gidney e M. Ekerå, "How to Factor 2048 Bit RSA Integers in 8 Hours Using 20 Million Noisy Qubits", *Quantum*, 5, 433, 2021.
- [4] J. Preskill, "Quantum Computing in the NISQ Era and Beyond", *Quantum*, 2, 79, 2018.
- [5] J. A. Smolin, G. Smith e A. Vargo, "Oversimplifying Quantum Factoring", *Nature*, 499, pp. 163–165, 2013.
- [6] S. Beauregard, "Circuit for Shor's Algorithm Using $2n + 3$ Qubits", *Quantum Inf. Comput.*, 3(2), pp. 175–185, 2003.
- [7] K. Temme, S. Bravyi e J. M. Gambetta, "Error Mitigation for Short-Depth Quantum Circuits", *Phys. Rev. Lett.*, 119, 180509, 2017.
- [8] R. Takagi, H. Tajima e M. Gu, "Universal Sampling Lower Bounds for Quantum Error Mitigation", *Phys. Rev. Lett.*, 131, 210602, 2023.
- [9] A. M. Steane, "Error Correcting Codes in Quantum Theory", *Phys. Rev. Lett.*, 77(5), pp. 793–797, 1996.
- [10] A. G. Fowler et al., "Surface Codes: Towards Practical Large-Scale Quantum Computation", *Phys. Rev. A*, 86, 032324, 2012.
- [11] Google Quantum AI and Collaborators, "Quantum Error Correction below the Surface Code Threshold", *Nature*, 638, pp. 920–926, 2025.
- [12] J. Bausch et al., "Learning High-Accuracy Error Decoding for Quantum Processors", *Nature*, 635, pp. 834–840, 2024.
- [13] J. Roffe et al., "Decoding Across the Quantum Low-Density Parity-Check Code Landscape", *Phys. Rev. Research*, 2, 043423, 2020.
- [14] A. Barenco, A. Ekert, K.-A. Suominen e P. Törmä, "Approximate Quantum Fourier Transform and Decoherence", *Phys. Rev. A*, 54, pp. 139–146, 1996.

Shor's Algorithm under Noise: Machine-Learning Ablation, Quantum Error Correction, and Approximate QFT

Candidate: Claudio Dragotta

Supervisor: Prof. Paolo Soda

Co-supervisor: Ing. Floriano Caprio

Graduation Session: Ottobre — A.A. 2025/2026

1 Introduction and objectives

Shor's algorithm factors integers in time polynomial in the input bit length, with implications for cryptographic systems whose security relies on the difficulty of factorization [1–3]. Realizing this advantage requires error control compatible with circuit depth: gate errors, decoherence, and imperfect readout can alter the measurement distribution and compromise multiplicative-order finding [4].

This simulation study determines which interventions improve computational reliability and relative to which baselines. Its two main phases evaluate classical post-processing of Shor's outcomes, including an ablation of the machine-learning contribution, and characterize quantum error-correction codes and syndrome decoders. A separate analysis examines Shor's sensitivity to gate errors and circuit optimization through the approximate quantum Fourier transform (AQFT).

The three areas—outcome selection, information protection, and circuit cost reduction—share one criterion: compare each solution with an explicit baseline, isolate each component's contribution, and use task-relevant benefit metrics. The campaigns remain separate; they are not an integrated, error-corrected execution of Shor's algorithm.

2 Materials and methods

2.1 Implementation, validation, and definition of success

For a base a coprime to the number N , the sequence $a^x \bmod N$ is periodic; its order r is the smallest positive integer satisfying $a^r \equiv 1 \pmod{N}$. The quantum part estimates it by phase estimation and inverse QFT; the classical part derives and verifies the factors through rational approximation and greatest common divisors.

The main instance is $N = 15$, $a = 7$, with eight control and four work qubits. Its order is $r = 4$, and the ideal control-register outcomes are 0, 64, 128, and 192. Each measured execution, or *shot*, returns one outcome; multiple shots form the post-processing histogram. Success means recovering non-trivial factors, not reconstructing the exact order. Three ideal peaks yield the factors, for 75% overall probability. Classical verification is permissive, however: it accepts 63 of 256 values, so uniform outcomes still succeed with probability $63/256 \approx 24.61\%$. This instance- and post-processing-specific reference is not quantum-state fidelity; it shows that correct factorizations can survive after the distribution loses much of its structure [5].

Circuit correctness is validated independently of factorization success by checking modular operators, restored ancillas, and theoretical distributions. The ideally validated

instances $N = 21$, $a = 2$ and $N = 35$, $a = 6$ use Beauregard's reversible arithmetic [6]; only $N = 21$ enters the exploratory noisy AQFT tests. Qiskit/Aer, scikit-learn, Stim, and PyMatching are used, recording versions, parameters, random seeds, and circuit identifiers.

2.2 Post-processing, classification, and mitigation

Three strategies share the same factor extractor, tie-breaking rule, and 1,024-shot histograms, one per quantum iteration. TOP-1 (Method 1) checks only the most frequent outcome; TOP-4 checks up to four frequency-ranked candidates; Method 2 applies TOP-4 only when a classifier predicts success for the dominant candidate. Comparing Method 2 with unfiltered TOP-4 ablates the classifier and separates its contribution from that of testing more candidates.

Two illustrative scenarios, reference UC1 and stress case UC2, include depolarization, thermal relaxation, and readout errors. For each, 2,000 histograms with parameters varied within $\pm 50\%$ of nominal are split 60%/20%/20% into training, selection, and test sets. Random forests, support vector machines (SVMs), and multilayer perceptrons are compared on F1; the selected model is tested on 400 independent histograms per scenario. The primary metric is iterations to obtain the factors, not classifier accuracy or runtime. Thirty paired replicates per scenario run for at most 50 iterations; failures receive the conventional value 51. The analysis uses Wilcoxon–Pratt tests with Holm correction. Two- and three-level zero-noise extrapolation (ZNE) scales only depolarizing parameters in simulation [7, 8].

2.3 Quantum error correction and syndrome decoding

Quantum error correction distributes one logical qubit across several physical qubits. Parity checks, called syndromes, reveal errors without reading the logical information; a decoder selects the correction. Repetition, Steane [[7, 1, 3]], and surface codes [9–11] are studied in memory circuits through the logical failure probability p_L , the probability that information remains wrong after decoding.

The rotated surface code uses distances $d = 3, 5, 7, 9$ (the number of errors the code can tolerate), X - and Z -basis memories, and d syndrome rounds, with noise on gates, preparation, and measurement. On the same detection events, reference minimum-weight perfect matching (MWPM) is compared with a stand-alone neural network and a hybrid decoder. The hybrid learns when to flip a likely-wrong matching decision, with an intervention threshold chosen in validation and fixed for testing. Crosstalk between adjacent qubits is added to nominal noise; model calibration, network input size, and the analytical BP+OSD decoder (belief propagation and ordered statistics decoding) are also examined [12, 13].

2.4 Sensitivity of Shor's algorithm to gate errors

A separate experiment applies independent Pauli errors after compiled gates, excluding virtual RZ rotations, using 20 replicates of 4,096 shots per value. The total non-identity error probability p_g is a per-gate proxy; without complete fault-tolerant compilation, it cannot be converted into the memory circuits' logical failure probability p_L .

2.5 Optimization through the approximate QFT

The AQFT removes small-angle controlled rotations, trading precision for fewer gates, lower depth, and fewer opportunities for noise [14]. Truncation of Shor's final inverse QFT for $N = 15$ is distinguished from truncation of transforms inside the modular arithmetic for $N = 21$. Separate phase-estimation benchmarks use six-, eight-, and ten-qubit registers with three phases per size. The noise model uses gate infidelities and readout errors from an offline FakeSherbrooke calibration, without additional T_1/T_2 contributions and with common layouts and random seeds. The truncation degree is chosen on selection samples and assessed on disjoint test samples (in the $N = 15$ pilot, 8,192 shots per configuration, split equally).

3 Results

3.1 Validation and contribution of post-processing

Ideal arithmetic checks yield total variation distances from theory of 1.38×10^{-9} for $N = 21$ and 2.50×10^{-13} for $N = 35$, establishing functional correctness, not performance under noise.

In UC1/UC2, the selected SVMs achieve F1 scores of 0.919/0.923 and ROC areas of 0.965/0.958, but do not reduce operational cost. TOP-4 averages 1.00 iterations in both scenarios versus 1.37/1.50 for TOP-1 ($p_{\text{Holm}} = 0.0024/0.0015$); Method 2 requires 1.50/1.37, does not significantly improve TOP-1, and is worse than its TOP-4 ablation ($p_{\text{Holm}} = 0.0033/0.0096$). The benefit therefore comes from multi-candidate search. Acting on already-acquired data, the filter can discard histograms that TOP-4 would use successfully. ZNE also fails to improve the reference scenario: two and three levels average 3,072 and 4,813 shots, versus 1,399 for TOP-1 and 1,024 for TOP-4. These findings concern the tested methods, instance, and noise model; they do not establish the general ineffectiveness of machine learning or mitigation.

3.2 Memory protection and hybrid decoding

Within Monte Carlo uncertainty, the repetition code reproduces $p_L = 3p^2 - 2p^3$. Steane's physical-to-logical error relation is approximately quadratic (logarithmic slope 1.94), and p_L intersects p near 0.08. This is a pseudo-threshold for data-qubit errors with ideal syndromes, not the operational threshold of a fault-tolerant architecture. In the surface code, increasing distance reduces logical error below threshold and increases it above threshold; the sub-threshold fit yields about 0.86% in the Z basis and 0.81% in the X

basis for the adopted memory circuit, noise, and decoder.

Under nominal noise, the stand-alone network does not significantly outperform MWPM in the initial fourteen configurations. With adjacent-qubit correlations poorly represented by the matching graph, however, the hybrid reduces logical error. At $d = 3$, $p = 0.003$, and crosstalk intensity 0.01, p_L falls from 0.05829 with MWPM to 0.04851 with the hybrid: a 16.8% relative reduction (Table 5.9 of the thesis), significant by paired McNemar test. With d rounds, the benefit is smaller at distance 5 and not significant at distance 7. In the tested distance-5 configurations, BP+OSD outperforms the MWPM-based hybrid; varying distance and rounds separately also reveals the role of network input size. The learned contribution thus depends on noise structure, analytical baseline, and data representation, not distance alone.

3.3 Factorization success and the uniform reference

Without noise, single-shot success is 74.89% (95% confidence interval [74.59%; 75.18%]), consistent with 75%. As p_g grows, the trend is compatible with a non-increasing function; at $p_g = 0.5$, success is 24.59%, near the 24.61% uniform reference (Section 2.1). Correct factorizations alone therefore do not reveal how much quantum information remains.

3.4 Effectiveness and limitations of the approximate QFT

In the Shor pilot for $N = 15$, the selected AQFT raises single-shot success from 47.92% to 62.79% (+14.87 percentage points on independent test data; 95% Newcombe interval [12.73; 16.99]), while two-qubit ECR gates fall from 362 to 279 and depth from 1,351 to 1,141. The benefit concerns factorization, not only isolated phase estimation. For $N = 21$, truncating QFTs inside the arithmetic reduces ECR gates from 49,661 to 23,178, but ideal success falls from 46.67% to 40.13%; all three noisy-comparison intervals include zero. With 128 test shots per variant and noise level, sensitivity to small effects is limited, so no observed advantage does not prove ineffectiveness. All nine phase-estimation differences favor the selected variant and six individual 95% intervals exclude zero; the largest increase is 12.55 percentage points with ten qubits ([9.77; 15.30]). These comparisons are exploratory, without simultaneous correction of the nine intervals. The best tested truncation degree is two or three and need not remain constant for arbitrarily large registers.

4 Discussion and conclusions

Post-processing uses measurement information more effectively but does not modify the quantum state. The classifier ablation gives a methodological result: strong predictive metrics do not guarantee lower factorization cost. Decoding differs because syndromes contain structured error information, and the hybrid works where the analytical decoder misses noise correlations, although it must also be compared with other analytical decoders. A learned model's value thus depends on its input and on what the baseline

leaves unused; the two applications involve different tasks and data, so their difference cannot be attributed only to when machine learning intervenes.

For $N = 15$, the AQFT gives a separate positive result: fewer gates accompany higher success. The order $r = 4$ yields phases exactly represented by two control-register bits, so removed rotations carry no useful information and cost little precision. For $N = 21$, where $r = 6$, phases are not exact and arithmetic is more complex, so the benefit does not transfer automatically. Approximation must be chosen for each instance and noise regime, then tested on data separate from selection.

The conclusions remain limited to simulation: post-processing uses $N = 15$ with uniform, stationary noise; QEC uses separate memory circuits; and AQFT tests use one offline calibration and few instances and phases. The work demonstrates neither complete fault-tolerant Shor nor the resources for cryptographic-scale factorization. It provides a quantitative, reproducible characterization of when the studied components help, to be extended through hardware validation, independent variation of N and r , and integration of protected logical operations, decoding, and arithmetic optimization. A common rule emerges: complexity is justified only if it exploits information unused by the baseline or reduces circuit cost by more than the loss introduced.

5 Essential references

- [1] P. W. Shor, "Algorithms for Quantum Computation: Discrete Logarithms and Factoring", *Proc. 35th Annual Symposium on Foundations of Computer Science (FOCS)*, pp. 124–134, 1994.
- [2] National Institute of Standards and Technology, *FIPS 203, FIPS 204, and FIPS 205*, 2024.
- [3] C. Gidney and M. Ekerå, "How to Factor 2048 Bit RSA Integers in 8 Hours Using 20 Million Noisy Qubits", *Quantum*, 5, 433, 2021.
- [4] J. Preskill, "Quantum Computing in the NISQ Era and Beyond", *Quantum*, 2, 79, 2018.
- [5] J. A. Smolin, G. Smith, and A. Vargo, "Oversimplifying Quantum Factoring", *Nature*, 499, pp. 163–165, 2013.
- [6] S. Beauregard, "Circuit for Shor's Algorithm Using $2n + 3$ Qubits", *Quantum Inf. Comput.*, 3(2), pp. 175–185, 2003.
- [7] K. Temme, S. Bravyi, and J. M. Gambetta, "Error Mitigation for Short-Depth Quantum Circuits", *Phys. Rev. Lett.*, 119, 180509, 2017.
- [8] R. Takagi, H. Tajima, and M. Gu, "Universal Sampling Lower Bounds for Quantum Error Mitigation", *Phys. Rev. Lett.*, 131, 210602, 2023.
- [9] A. M. Steane, "Error Correcting Codes in Quantum Theory", *Phys. Rev. Lett.*, 77(5), pp. 793–797, 1996.
- [10] A. G. Fowler et al., "Surface Codes: Towards Practical Large-Scale Quantum Computation", *Phys. Rev. A*, 86, 032324, 2012.
- [11] Google Quantum AI and Collaborators, "Quantum Error Correction below the Surface Code Threshold", *Nature*, 638, pp. 920–926, 2025.
- [12] J. Bausch et al., "Learning High-Accuracy Error Decoding for Quantum Processors", *Nature*, 635, pp. 834–840, 2024.
- [13] J. Roffe et al., "Decoding Across the Quantum Low-Density Parity-Check Code Landscape", *Phys. Rev. Research*, 2, 043423, 2020.
- [14] A. Barenco, A. Ekert, K.-A. Suominen, and P. Törmä, "Approximate Quantum Fourier Transform and Decoherence", *Phys. Rev. A*, 54, pp. 139–146, 1996.