

Matr. N INLM03/23286



**UNIVERSITÀ CAMPUS BIO-MEDICO DI ROMA**

**FACOLTÀ DIPARTIMENTALE DI INGEGNERIA  
CORSO DI LAUREA MAGISTRALE IN INGEGNERIA DEI SISTEMI  
INTELLIGENTI**

**IMPLEMENTAZIONE E  
OTTIMIZZAZIONE DELL'ALGORITMO  
DI SHOR IN AMBIENTI QUANTISTICI  
RUMOROSI MEDIANTE MODELLI DI  
INTELLIGENZA ARTIFICIALE**

*Relatore*

*Prof. Paolo Soda*

*Laureando*

*Claudio Dragotta*

*Correlatore*

*Ing. Floriano Caprio*

**ANNO ACCADEMICO 2025/2026**



*Alla mia famiglia,  
per il sostegno incondizionato e l'amore che non è mai venuto meno.  
A me stesso, per la determinazione e la perseveranza con cui ho affrontato questo  
percorso.*

# Indice

|                                                            |             |
|------------------------------------------------------------|-------------|
| <b>Elenco delle figure</b>                                 | <b>vii</b>  |
| <b>Elenco delle tabelle</b>                                | <b>ix</b>   |
| <b>Elenco degli Acronimi</b>                               | <b>xiii</b> |
| <b>1 Introduzione</b>                                      | <b>2</b>    |
| 1.1 Il Limite del Calcolo Classico . . . . .               | 2           |
| 1.2 Motivazione e Contributo del Presente Lavoro . . . . . | 3           |
| 1.3 Struttura della Tesi . . . . .                         | 6           |
| <b>2 Obiettivi e Piano Sperimentale</b>                    | <b>9</b>    |
| 2.1 Obiettivi Generali . . . . .                           | 9           |
| 2.2 Obiettivi Specifici . . . . .                          | 10          |
| 2.3 Ipotesi di Lavoro . . . . .                            | 12          |
| 2.4 Contributo Originale . . . . .                         | 13          |
| 2.5 I Quattro Use Case . . . . .                           | 15          |
| 2.5.1 Parametri dei Use Case . . . . .                     | 16          |
| 2.5.2 Razionale per la Scelta delle Istanze . . . . .      | 16          |
| 2.6 Metriche di Valutazione . . . . .                      | 17          |
| 2.6.1 Metriche del Metodo 1 . . . . .                      | 17          |
| 2.6.2 Metriche del Metodo 2 . . . . .                      | 18          |
| 2.6.3 Metrica di Confronto . . . . .                       | 18          |
| 2.6.4 Metriche della Parte QEC . . . . .                   | 19          |
| 2.6.5 Parametri di Error Mitigation Applicati . . . . .    | 19          |
| 2.7 Approccio Metodologico . . . . .                       | 20          |
| <b>3 L'Algoritmo di Shor</b>                               | <b>21</b>   |
| 3.1 Richiami di Calcolo Quantistico . . . . .              | 22          |



|          |                                                                |           |
|----------|----------------------------------------------------------------|-----------|
| 3.1.1    | Qubit, Sovrapposizione e Sfera di Bloch . . . . .              | 22        |
| 3.1.2    | Sistemi Multi-Qubit ed Entanglement . . . . .                  | 22        |
| 3.1.3    | Porte, Misura e Interferenza . . . . .                         | 23        |
| 3.2      | Il Problema della Fattorizzazione Intera . . . . .             | 23        |
| 3.2.1    | Perché la Fattorizzazione Conta . . . . .                      | 24        |
| 3.3      | Riduzione alla Ricerca del Periodo . . . . .                   | 24        |
| 3.4      | La Quantum Fourier Transform . . . . .                         | 25        |
| 3.4.1    | Definizione . . . . .                                          | 25        |
| 3.4.2    | Implementazione Efficiente . . . . .                           | 26        |
| 3.4.3    | Phase Estimation . . . . .                                     | 26        |
| 3.5      | L'Algoritmo di Shor: Schema Completo . . . . .                 | 29        |
| 3.5.1    | Il Ruolo dell'Entanglement nel Period Finding . . . . .        | 31        |
| 3.6      | Analisi della Complessità . . . . .                            | 32        |
| 3.7      | Stato dell'Arte e Confronto con Altri Algoritmi . . . . .      | 32        |
| <b>4</b> | <b>Rumore Quantistico nei Sistemi NISQ</b>                     | <b>33</b> |
| 4.1      | Introduzione al Rumore Quantistico . . . . .                   | 33        |
| 4.2      | La Macchina Fisica: i Tre Fatti che Contano . . . . .          | 35        |
| 4.3      | Le Quattro Fonti Fisiche di Rumore . . . . .                   | 35        |
| 4.3.1    | Decoerenza ( $T_1$ e $T_2$ ) . . . . .                         | 36        |
| 4.3.2    | Errori di Gate . . . . .                                       | 37        |
| 4.3.3    | Errori di Misura (Readout Errors) . . . . .                    | 37        |
| 4.3.4    | Crosstalk . . . . .                                            | 38        |
| 4.4      | Dal Fenomeno Fisico al Modello Matematico . . . . .            | 38        |
| 4.5      | I Quattro Canali Matematici del Rumore . . . . .               | 40        |
| 4.5.1    | Il Canale Depolarizzante . . . . .                             | 40        |
| 4.5.2    | Gli Altri Tre Canali . . . . .                                 | 41        |
| 4.6      | Impatto del Rumore sull'Algoritmo di Shor . . . . .            | 42        |
| 4.6.1    | Errori nella Quantum Fourier Transform . . . . .               | 43        |
| 4.6.2    | Errori nella Phase Estimation . . . . .                        | 43        |
| 4.6.3    | Errori nella Modular Exponentiation . . . . .                  | 44        |
| 4.7      | Sfide Pratiche su Hardware NISQ . . . . .                      | 45        |
| <b>5</b> | <b>Strategie per la Riduzione del Rumore Quantistico</b>       | <b>46</b> |
| 5.1      | Le Quattro Strategie: Panoramica e Scelta . . . . .            | 46        |
| 5.2      | Quantum Machine Learning per la Robustezza al Rumore . . . . . | 48        |

|          |                                                                      |           |
|----------|----------------------------------------------------------------------|-----------|
| 5.3      | La Correzione degli Errori Quantistici come Sottocategoria del QML . | 49        |
| 5.3.1    | Il Problema Fondamentale . . . . .                                   | 49        |
| 5.3.2    | Il Paradigma in Tre Fasi . . . . .                                   | 49        |
| 5.3.3    | I Principali Codici Quantistici . . . . .                            | 50        |
| 5.3.4    | Perché la QEC è una Sottocategoria del QML . . . . .                 | 50        |
| 5.4      | Motivazione Pratica: il Contributo di questa Tesi . . . . .          | 51        |
| <b>6</b> | <b>Metodo e Implementazione</b>                                      | <b>53</b> |
| 6.1      | Strumenti e Ambiente di Simulazione . . . . .                        | 53        |
| 6.2      | Obiettivi della Parte Sperimentale . . . . .                         | 55        |
| 6.3      | Architettura del Pipeline Sperimentale . . . . .                     | 56        |
| 6.4      | Tecniche di Mitigazione del Rumore: Analisi e Scelte Implementative  | 57        |
| 6.4.1    | Livello di Circuito: Transpilazione e Riduzione della Profondità     | 57        |
| 6.4.2    | Livello di Misura: Mitigazione degli Errori di Readout . . . .       | 58        |
| 6.4.3    | Livello di Post-processing: Zero-Noise Extrapolation . . . . .       | 58        |
| 6.4.4    | Che Cosa Conta Davvero: l'Analisi di Sensibilità . . . . .           | 59        |
| 6.4.5    | Scelta Adottata: Classificatore ML come Filtro Adattivo . . .        | 60        |
| 6.5      | Il Metodo 1: Approccio Statistico Classico . . . . .                 | 61        |
| 6.6      | Il Metodo 2: Classificatore ML . . . . .                             | 61        |
| 6.7      | Setup dell'Ambiente di Esecuzione . . . . .                          | 63        |
| 6.7.1    | Dipendenze e Virtual Environment . . . . .                           | 63        |
| 6.7.2    | Accelerazione GPU: Tentativo e Limitazione WSL . . . . .             | 63        |
| 6.8      | L'Algoritmo di Shor: Implementazione di Riferimento . . . . .        | 64        |
| 6.8.1    | La Quantum Fourier Transform . . . . .                               | 64        |
| 6.8.2    | La Moltiplicazione Modulare Controllata . . . . .                    | 64        |
| 6.8.3    | Circuito Completo e Post-Processing . . . . .                        | 64        |
| 6.9      | Configurazione del Noise Model . . . . .                             | 65        |
| 6.10     | Implementazione del Metodo 1 . . . . .                               | 65        |
| 6.11     | Implementazione del Metodo 2 . . . . .                               | 66        |
| 6.11.1   | Generazione del Dataset e Definizione dell'Etichetta . . . . .       | 66        |
| 6.11.2   | Addestramento e Selezione del Modello . . . . .                      | 66        |
| 6.11.3   | Inferenza: Classificatore + Ricerca TOP-K . . . . .                  | 67        |
| 6.12     | Infrastruttura di Test e Raccolta Dati . . . . .                     | 67        |
| 6.13     | Implementazione della Correzione d'Errore . . . . .                  | 68        |
| 6.13.1   | Organizzazione del codice e divisione degli strumenti . . . . .      | 68        |
| 6.13.2   | Il codice a ripetizione: sindrome senza collasso . . . . .           | 68        |

|          |                                                                                                |           |
|----------|------------------------------------------------------------------------------------------------|-----------|
| 6.13.3   | Il codice di Steane . . . . .                                                                  | 69        |
| 6.13.4   | Il surface code e l'iniezione del crosstalk . . . . .                                          | 69        |
| 6.13.5   | Lo Shor logico e il decoder appreso . . . . .                                                  | 70        |
| 6.13.6   | Riproducibilità . . . . .                                                                      | 70        |
| <b>7</b> | <b>Verifica Sperimentale dell'Ipotesi Iniziale: dal Classificatore ML alla Strategia TOP-K</b> | <b>71</b> |
| 7.1      | Setup Sperimentale . . . . .                                                                   | 71        |
| 7.2      | Analisi del Circuito e Barriera di Scalabilità . . . . .                                       | 72        |
| 7.3      | La Baseline: Metodo 1 (TOP-1) . . . . .                                                        | 77        |
| 7.4      | L'Ipotesi ML alla Prova . . . . .                                                              | 79        |
| 7.5      | Il Verdetto dell'Ablazione . . . . .                                                           | 80        |
| 7.6      | Robustezza della Strategia TOP-4 . . . . .                                                     | 82        |
| 7.6.1    | Perché $P_{\text{surv}}$ sbaglia: la frazione coerente efficace . . . . .                      | 83        |
| 7.6.2    | Confronto con la Zero-Noise Extrapolation . . . . .                                            | 85        |
| 7.7      | Bilancio della Verifica e Ponte verso il Nucleo della Tesi . . . . .                           | 86        |
| <b>8</b> | <b>La Correzione d'Errore Quantistico: dal Codice a Ripetizione al Codice di Steane</b>        | <b>87</b> |
| 8.1      | Dalla Ridondanza Ingenua alla Codifica . . . . .                                               | 87        |
| 8.2      | Il Ciclo della Correzione: Stabilizzatori, Sindrome, Decoder . . . . .                         | 88        |
| 8.3      | Il Panorama dei Codici e la Scelta Metodologica . . . . .                                      | 90        |
| 8.4      | Laboratorio I: il Codice a Ripetizione . . . . .                                               | 90        |
| 8.4.1    | Il codice bit-flip a 3 qubit . . . . .                                                         | 90        |
| 8.4.2    | Risultati del laboratorio repetition . . . . .                                                 | 91        |
| 8.5      | Laboratorio II: il Codice di Steane $[[7, 1, 3]]$ . . . . .                                    | 93        |
| 8.5.1    | Struttura del codice . . . . .                                                                 | 93        |
| 8.5.2    | Protocollo di laboratorio . . . . .                                                            | 93        |
| 8.5.3    | Risultati del laboratorio Steane . . . . .                                                     | 94        |
| <b>9</b> | <b>Il Surface Code e la Stima dell'Errore Logico</b>                                           | <b>97</b> |
| 9.1      | Il Codice su Griglia: Concetto Operativo . . . . .                                             | 98        |
| 9.2      | La Decodifica: Minimum Weight Perfect Matching . . . . .                                       | 98        |
| 9.3      | Disegno Sperimentale . . . . .                                                                 | 99        |
| 9.4      | Risultati . . . . .                                                                            | 100       |
| 9.5      | Oltre il Modello di Pauli: Errori Coerenti e Leakage . . . . .                                 | 103       |
| 9.6      | La Decodifica Appresa: Sintesi della Campagna . . . . .                                        | 106       |

|           |                                                                    |            |
|-----------|--------------------------------------------------------------------|------------|
| <b>10</b> | <b>Integrazione: lo Shor Logico e i Requisiti di Correzione</b>    | <b>109</b> |
| 10.1      | L'Architettura a Quattro Livelli . . . . .                         | 109        |
| 10.2      | Il Modello di Shor Logico . . . . .                                | 110        |
| 10.3      | Il Contesto: le Stime di Risorse per Shor Fault-Tolerant . . . . . | 111        |
| 10.4      | Risultati del Confronto . . . . .                                  | 112        |
| 10.4.1    | Discussione . . . . .                                              | 117        |
| <b>11</b> | <b>Sviluppi Futuri</b>                                             | <b>119</b> |
| 11.1      | Scalabilità a Istanze di Maggiore Dimensione . . . . .             | 120        |
| 11.2      | Test e Validazione su Hardware Quantistico Reale . . . . .         | 121        |
| 11.3      | Generalizzazione ad Altri Algoritmi Quantistici NISQ . . . . .     | 123        |
| 11.4      | Integrazione con la Quantum Error Correction Strutturale . . . . . | 124        |
| 11.5      | Evoluzione del Classificatore ML . . . . .                         | 126        |
| <b>12</b> | <b>Conclusioni</b>                                                 | <b>128</b> |
| 12.1      | Il Problema e il Percorso . . . . .                                | 128        |
| 12.2      | Le Domande di Ricerca . . . . .                                    | 129        |
| 12.3      | Verifica delle Ipotesi . . . . .                                   | 131        |
| 12.4      | I Contributi del Lavoro . . . . .                                  | 133        |
| 12.5      | Limiti . . . . .                                                   | 135        |
| 12.6      | Il Criterio che Unifica il Lavoro . . . . .                        | 135        |
| <b>A</b>  | <b>Trattazione Teorica Estesa</b>                                  | <b>138</b> |
| A.1       | Fondamenti del Calcolo Quantistico . . . . .                       | 138        |
| A.1.1     | Dalla Meccanica Classica alla Meccanica Quantistica . . . . .      | 138        |
| A.1.2     | I Postulati della Meccanica Quantistica . . . . .                  | 139        |
| A.1.3     | Il Qubit . . . . .                                                 | 141        |
| A.1.4     | Sistemi Multi-Qubit e Prodotto Tensoriale . . . . .                | 142        |
| A.1.5     | Porte Quantistiche . . . . .                                       | 144        |
| A.1.6     | Circuiti Quantistici . . . . .                                     | 147        |
| A.1.7     | Misura Quantistica . . . . .                                       | 147        |
| A.1.8     | Interferenza Quantistica . . . . .                                 | 147        |
| A.1.9     | Modello di Complessità Quantistica . . . . .                       | 148        |
| A.2       | L'Anatomia Fisica di una QPU . . . . .                             | 149        |
| A.2.1     | L'Anatomia Fisica di una QPU . . . . .                             | 149        |
| A.3       | L'Algoritmo di Shor — Approfondimenti e Stato dell'Arte . . . . .  | 154        |
| A.3.1     | Sviluppi Recenti e Stato dell'Arte . . . . .                       | 155        |

|          |                                                                                         |            |
|----------|-----------------------------------------------------------------------------------------|------------|
| A.3.2    | Contesto: Confronto con l'Algoritmo di Grover . . . . .                                 | 157        |
| A.4      | I Canali di Rumore: Derivazioni Complete . . . . .                                      | 158        |
| <b>B</b> | <b>Strumenti, Ambiente e Codice</b>                                                     | <b>160</b> |
| B.1      | Strumenti e Ambiente di Simulazione — Trattazione Estesa . . . . .                      | 160        |
| B.1.1    | Qiskit: il Framework Quantistico di Riferimento . . . . .                               | 160        |
| B.1.2    | Qiskit Aer: il Simulatore . . . . .                                                     | 162        |
| B.1.3    | Accelerazione GPU con Qiskit Aer . . . . .                                              | 164        |
| B.1.4    | scikit-learn: la Libreria per il Classificatore . . . . .                               | 165        |
| B.1.5    | Ambiente di Esecuzione: WSL con Ubuntu . . . . .                                        | 165        |
| B.2      | Codice Sorgente dei Componenti Implementati . . . . .                                   | 165        |
| <b>C</b> | <b>Contesto e Motivazione</b>                                                           | <b>176</b> |
| C.1      | Contesto Esteso dell'Introduzione . . . . .                                             | 176        |
| C.1.1    | Dal Bit al Qubit: i Principi Fisici del Calcolo Quantistico . . .                       | 176        |
| C.1.2    | La Rivoluzione Algoritmica degli Anni Novanta . . . . .                                 | 180        |
| C.1.3    | RSA e le Implicazioni Crittografiche dell'Algoritmo di Shor . .                         | 181        |
| C.1.4    | Crittografia Post-Quantistica: la Risposta dell'Industria . . .                         | 184        |
| C.1.5    | Lo Stato dell'Arte: dall'Era NISQ ai Computer Fault-Tolerant                            | 186        |
| C.2      | Dettaglio degli Obiettivi e del Piano Sperimentale . . . . .                            | 187        |
| C.2.1    | Motivazione: la Vulnerabilità della Crittografia Attuale . . .                          | 188        |
| C.2.2    | Requisiti Funzionali . . . . .                                                          | 189        |
| C.2.3    | Parametri di Input e Output . . . . .                                                   | 190        |
| <b>D</b> | <b>Fase 1: la Campagna Classica nel Dettaglio</b>                                       | <b>192</b> |
| D.1      | Campagna Parametrica e Confronto con la Zero-Noise Extrapolation                        | 192        |
| D.1.1    | Variazione di $K$ (numero di candidati per iterazione) . . . . .                        | 192        |
| D.1.2    | Variazione di $\varepsilon_{2q}$ (tasso di errore a due qubit) . . . . .                | 193        |
| D.1.3    | Variazione di $M_{\text{shots}}$ (shot per iterazione) . . . . .                        | 194        |
| D.1.4    | Analisi Congiunta $K \times \varepsilon_{2q}$ . . . . .                                 | 194        |
| D.1.5    | Parametri Secondari: $T_1/T_2$ , $\varepsilon_{1q}$ e $p_{\text{ro}}$ . . . . .         | 195        |
| D.1.6    | Dettaglio del Confronto con Zero-Noise Extrapolation . . . . .                          | 196        |
| D.1.7    | Analisi di Sensibilità ai Parametri e Scelta del Livello di<br>Ottimizzazione . . . . . | 197        |
| D.2      | Il Classificatore ML: Architettura, Addestramento e Metriche . . . . .                  | 201        |
| D.2.1    | L'Ipotesi alla Prova: il Classificatore ML . . . . .                                    | 201        |

|          |                                                                                       |            |
|----------|---------------------------------------------------------------------------------------|------------|
| D.2.2    | Audit delle Etichette: che Cosa il Classificatore ha Effettivamente Appreso . . . . . | 203        |
| <b>E</b> | <b>Fase 2: la Campagna QEC nel Dettaglio</b>                                          | <b>211</b> |
| E.1      | La Decodifica Appresa: la Campagna Completa . . . . .                                 | 211        |
| E.1.1    | Disegno sperimentale . . . . .                                                        | 212        |
| E.1.2    | E1 — la sostituzione a parità di modello . . . . .                                    | 212        |
| E.1.3    | E2 — quando il rumore esce dal modello del decoder . . . . .                          | 213        |
| E.1.4    | E3 — la rete come validatore della correzione . . . . .                               | 215        |
| E.1.5    | E4 — il decoder ibrido . . . . .                                                      | 216        |
| E.1.6    | E6 — e se il modello del decoder fosse semplicemente sbagliato? 222                   |            |
| E.1.7    | E7 — e se si scegliesse semplicemente un decoder analitico migliore? . . . . .        | 224        |
| E.1.8    | E8 — le due sorgenti si sommano davvero? E10 — il pavimento comune . . . . .          | 227        |
| E.1.9    | E5 — il decoder è trasferibile fra dispositivi? . . . . .                             | 231        |
| E.1.10   | Bilancio . . . . .                                                                    | 232        |
| E.2      | Compilazione Consapevole della Struttura: un'Esplorazione . . . . .                   | 233        |
| E.2.1    | La Previsione e il suo Fondamento . . . . .                                           | 234        |
| E.2.2    | Primo Esperimento: la Fedeltà è un Buon Criterio di Scelta? .                         | 235        |
| E.2.3    | Secondo Esperimento: Conta il Ruolo Assegnato ai Qubit? . .                           | 236        |
| E.2.4    | Un Terzo Caso: la Ricerca Multi-Candidato a Livello Logico .                          | 238        |
| E.2.5    | Conclusione: il Criterio va Precisato . . . . .                                       | 239        |
|          | <b>Bibliografia</b>                                                                   | <b>241</b> |

# Elenco delle figure

|      |                                                                                           |     |
|------|-------------------------------------------------------------------------------------------|-----|
| 3.1  | Periodicità di $f(x) = 7^x \bmod 15$ . . . . .                                            | 25  |
| 3.2  | Circuito della QFT su 3 qubit . . . . .                                                   | 26  |
| 3.3  | Circuito QPE per $N = 15$ , $a = 2$ . . . . .                                             | 27  |
| 3.4  | Blocco di moltiplicazione modulare $U_2$ per $N = 15$ . . . . .                           | 28  |
| 3.5  | Blocco di moltiplicazione modulare $U_4$ per $N = 15$ . . . . .                           | 28  |
| 3.6  | Istogramma QPE ideale per $N = 15$ . . . . .                                              | 29  |
| 3.7  | Schema a due registri dell'algoritmo di Shor . . . . .                                    | 30  |
| 4.1  | Effetto dei canali di rumore sulla sfera di Bloch . . . . .                               | 42  |
| 4.2  | Dove colpiscono le quattro fonti di rumore nella pipeline di Shor . . . .                 | 43  |
| 4.3  | Probabilità di successo di Shor in presenza di rumore . . . . .                           | 44  |
| 6.1  | Pipeline sperimentale . . . . .                                                           | 56  |
| 7.1  | Circuito QPE per $N = 21$ . . . . .                                                       | 77  |
| 7.2  | Istogramma QPE per $N = 21$ — distribuzione piatta . . . . .                              | 77  |
| 7.3  | Confronto istogrammi QPE con segnale strutturato e dominato dal<br>rumore (UC1) . . . . . | 78  |
| 7.4  | Analisi di ablazione: M1, $M_{\text{TOP4}}$ e M2 su UC1 ( $K = 30$ ) . . . . .            | 81  |
| 7.5  | Frazione coerente efficace contro $P_{\text{surv}}$ . . . . .                             | 84  |
| 8.1  | Errore logico del codice a ripetizione a 3 qubit . . . . .                                | 92  |
| 8.2  | Errore logico del codice di Steane $[[7, 1, 3]]$ . . . . .                                | 96  |
| 9.1  | Comportamento a soglia del surface code . . . . .                                         | 100 |
| 9.2  | Errore coerente vs errore di Pauli . . . . .                                              | 104 |
| 10.1 | Figura conclusiva: Shor fisico vs Steane vs surface code . . . . .                        | 113 |
| 10.2 | Probabilità di successo cumulativa di Shor dopo $k$ esecuzioni . . . . .                  | 115 |
| 11.1 | Simulation gap: simulatore vs hardware reale per $N = 15$ . . . . .                       | 122 |

|     |                                                                                      |     |
|-----|--------------------------------------------------------------------------------------|-----|
| A.1 | La sfera di Bloch . . . . .                                                          | 142 |
| A.2 | Circuito per lo stato di Bell $ \Phi^+\rangle$ . . . . .                             | 143 |
| A.3 | Porte quantistiche a singolo e due qubit . . . . .                                   | 146 |
| A.4 | Gerarchia delle classi di complessità quantistica . . . . .                          | 149 |
| A.5 | Anatomia di una QPU superconduttiva a 5 qubit (topologia a catena)                   | 150 |
| A.6 | La QPU reale: sistema integrato e criostati con cablaggio . . . . .                  | 151 |
| A.7 | Chip quantistico superconduttivo a 6 transmon con giunzioni di test .                | 152 |
| A.8 | Il bordo di coerenza: budget di operazioni e rischio di misura . . . . .             | 154 |
| D.1 | Curve ROC dei classificatori selezionati (UC1: Random Forest, UC2:<br>SVM) . . . . . | 202 |
| D.2 | Un istogramma etichettato “negativo” nel dataset . . . . .                           | 205 |
| D.3 | Tetto combinatorio alla classe negativa . . . . .                                    | 209 |
| E.1 | Decodifica appresa a parità di modello di rumore . . . . .                           | 213 |
| E.2 | Decodifica appresa in presenza di rumore correlato . . . . .                         | 215 |
| E.3 | Precisione e copertura del flag di validazione . . . . .                             | 216 |
| E.4 | Il decoder ibrido a confronto con matching e rete . . . . .                          | 218 |
| E.5 | Ortogonalità delle due sorgenti di guadagno . . . . .                                | 226 |



# Elenco delle tabelle

|     |                                                                                                                                                                                                                                                                       |    |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1 | Configurazione completa dei quattro use case. I parametri di rumore del livello NISQ-realistico sono derivati dalle specifiche di <code>ibm_marrakesh</code> [4, 5]. Il livello NISQ-degradato scala i tassi di errore di $5\times$ e dimezza $T_1$ e $T_2$ . . . . . | 16 |
| 4.1 | Riepilogo delle quattro fonti fisiche di rumore nei processori quantistici superconduttori. . . . .                                                                                                                                                                   | 38 |
| 4.2 | Corrispondenza tra fonti fisiche di rumore e canali quantistici. . . . .                                                                                                                                                                                              | 38 |
| 4.3 | I quattro canali matematici fondamentali del rumore quantistico [15].                                                                                                                                                                                                 | 42 |
| 5.1 | Confronto delle quattro strategie anti-rumore per il contesto di questa tesi. . . . .                                                                                                                                                                                 | 47 |
| 6.1 | Organizzazione del codice della parte QEC . . . . .                                                                                                                                                                                                                   | 68 |
| 7.1 | Caratteristiche del circuito traspilato per ciascun use case . . . . .                                                                                                                                                                                                | 73 |
| 7.2 | Costo di simulazione per iterazione . . . . .                                                                                                                                                                                                                         | 75 |
| 7.3 | Risultati del Metodo 1 sui quattro use case . . . . .                                                                                                                                                                                                                 | 78 |
| 7.4 | Riepilogo comparativo M1, $M_{\text{TOP4}}$ e M2 — risultato principale con analisi di ablazione ( $K = 30$ , $M_{\text{max}} = 50$ ) . . . . .                                                                                                                       | 80 |
| 7.5 | Sintesi della campagna parametrica su $M_{\text{TOP4}}$ : impatto atteso, osservato e raccomandazioni . . . . .                                                                                                                                                       | 82 |
| 7.6 | Frazione coerente efficace contro $P_{\text{surv}}$ . . . . .                                                                                                                                                                                                         | 83 |
| 7.7 | Confronto M1, ZNE-2, ZNE-3 e $M_{\text{TOP4}}$ su UC1 ( $K_{\text{rep}} = 30$ , $M_{\text{shots}} = 1024$ per livello) . . . . .                                                                                                                                      | 85 |
| 8.1 | Confronto tra codici correttori quantistici . . . . .                                                                                                                                                                                                                 | 90 |
| 8.2 | Verifica della sindrome del codice a ripetizione . . . . .                                                                                                                                                                                                            | 91 |
| 8.3 | Parametri del codice di Steane . . . . .                                                                                                                                                                                                                              | 93 |
| 8.4 | Syndrome table del codice di Steane . . . . .                                                                                                                                                                                                                         | 95 |

|      |                                                                                                                                                                                                                                        |     |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 9.1  | Disegno sperimentale surface code . . . . .                                                                                                                                                                                            | 99  |
| 9.2  | Distanza e costo in qubit richiesti dalla legge di scala . . . . .                                                                                                                                                                     | 102 |
| 9.3  | Sintesi della campagna sulla decodifica appresa . . . . .                                                                                                                                                                              | 107 |
| 10.1 | Architettura a quattro livelli della parte sperimentale . . . . .                                                                                                                                                                      | 110 |
| 10.2 | Effetto del decoder appreso sulla probabilità di successo di Shor . . .                                                                                                                                                                | 116 |
| 12.1 | Esito delle ipotesi di lavoro . . . . .                                                                                                                                                                                                | 132 |
| A.1  | Confronto tra tecnologie di QPU: superconduttori vs ioni intrappolati                                                                                                                                                                  | 153 |
| A.2  | Confronto tra l'algoritmo di Shor e l'algoritmo di Grover . . . . .                                                                                                                                                                    | 157 |
| B.1  | Confronto tra i principali framework per la simulazione quantistica<br>con rumore. . . . .                                                                                                                                             | 162 |
| C.1  | Parametri di input del sistema sperimentale. I valori di $\epsilon_{1q}$ , $\epsilon_{2q}$ , $T_1$ ,<br>$T_2$ e $p_{ro}$ definiscono il noise model e vengono variati tra i use case per<br>coprire scenari di rumore diversi. . . . . | 191 |
| D.1  | Effetto del parametro $K$ su $\bar{M}$ , tasso di successo e $\rho$ vs M1 ( $N = 15$ ,<br>UC1, $K_{rep} = 30$ ) . . . . .                                                                                                              | 193 |
| D.2  | Effetto di $\epsilon_{2q}$ su $M_{TOP4}$ ( $K = 4$ , $K_{rep} = 30$ , altri parametri fissi a UC1)                                                                                                                                     | 193 |
| D.3  | Effetto di $M_{shots}$ su $M_{TOP4}$ ( $K = 4$ , $K_{rep} = 30$ , UC1) . . . . .                                                                                                                                                       | 194 |
| D.4  | $\bar{M}_{TOPK}$ per combinazioni di $K$ e $\epsilon_{2q}$ ( $K_{rep} = 30$ ). In grassetto: $\rho > 2$<br>con $p < 0.05$ . . . . .                                                                                                    | 195 |
| D.5  | Effetto di $T_1$ su $M_{TOP4}$ ( $K = 4$ , $\epsilon_{2q} = 10^{-2}$ , $K_{rep} = 30$ , $T_2 = 0.8 T_1$ ) . .                                                                                                                          | 195 |
| D.6  | Effetto di $\epsilon_{1q}$ su $M_{TOP4}$ ( $K = 4$ , $\epsilon_{2q} = 10^{-2}$ , $K_{rep} = 30$ ) . . . . .                                                                                                                            | 196 |
| D.7  | Effetto di $p_{ro}$ su $M_{TOP4}$ ( $K = 4$ , $\epsilon_{2q} = 10^{-2}$ , $K_{rep} = 30$ ) . . . . .                                                                                                                                   | 196 |
| D.8  | Risultati dell'analisi di sensibilità ai parametri di rumore per $N=15$ ,<br>$a=7$ , $n\_count=8$ . Solo $\epsilon_{2q}$ influenza le prestazioni di M1. . . . .                                                                       | 198 |
| D.9  | Sweep di $\epsilon_{2q}$ su UC1 . . . . .                                                                                                                                                                                              | 198 |
| D.10 | Sweep di <code>optimization_level</code> . . . . .                                                                                                                                                                                     | 200 |
| D.11 | Metriche dei classificatori sul test set (20% del dataset) . . . . .                                                                                                                                                                   | 202 |
| D.12 | Audit delle etichette del dataset di addestramento . . . . .                                                                                                                                                                           | 203 |
| D.13 | Struttura degli istogrammi etichettati come negativi . . . . .                                                                                                                                                                         | 204 |
| D.14 | Frazione di negativi in funzione del rumore . . . . .                                                                                                                                                                                  | 207 |
| D.15 | Tetto combinatorio alla classe negativa in funzione di $K$ . . . . .                                                                                                                                                                   | 208 |
| E.1  | Disegno sperimentale della decodifica appresa . . . . .                                                                                                                                                                                | 212 |

|      |                                                                        |     |
|------|------------------------------------------------------------------------|-----|
| E.2  | Decodifica in presenza di rumore correlato . . . . .                   | 214 |
| E.3  | La rete come validatore della correzione del matching . . . . .        | 216 |
| E.4  | Prestazioni del decoder ibrido . . . . .                               | 217 |
| E.5  | Larghezza dell'ingresso contro distanza del codice . . . . .           | 219 |
| E.6  | Discriminazione e guadagno al crescere della larghezza dell'ingresso . | 220 |
| E.7  | Effetto di un modello di rumore mis-calibrato sul MWPM . . . . .       | 223 |
| E.8  | BP+OSD contro MWPM e contro il decoder ibrido . . . . .                | 225 |
| E.9  | Il residuo appreso costruito sopra BP+OSD . . . . .                    | 228 |
| E.10 | Sei decoder, un solo pavimento . . . . .                               | 229 |
| E.11 | Il pavimento alla prova di modelli più potenti . . . . .               | 230 |
| E.12 | Trasferibilità del decoder appreso fra profili di rumore . . . . .     | 231 |
| E.13 | Fedeltà stimata contro successo misurato nella scelta del layout . . . | 235 |
| E.14 | Potere predittivo delle singole grandezze del layout . . . . .         | 236 |
| E.15 | Effetto del ruolo dei qubit, a sottografo fissato . . . . .            | 237 |
| E.16 | Prestazione media per strategia di assegnazione dei ruoli . . . . .    | 238 |
| E.17 | Comportamento della ricerca multi-candidato a livello logico . . . . . | 238 |

# Elenco degli Acronimi

**AUC** Area Sotto la Curva ROC (*Area Under the Curve*)

**BQP** *Bounded-error Quantum Polynomial time*

**CCNOT** Controlled-Controlled NOT (porta di Toffoli)

**CNOT** Controlled-NOT

**CPTP** *Completely Positive Trace-Preserving*

**CPU** Unità di Elaborazione Centrale (*Central Processing Unit*)

**CSS** Calderbank-Shor-Steane

**CX** Controlled-X (porta CNOT)

**DEM** *Detector Error Model*

**DFT** Trasformata Discreta di Fourier (*Discrete Fourier Transform*)

**ECDSA** *Elliptic Curve Digital Signature Algorithm*

**GCD** Massimo Comune Divisore (*Greatest Common Divisor*)

**GNFS** *General Number Field Sieve*

**GPU** Unità di Elaborazione Grafica (*Graphics Processing Unit*)

**HTTPS** *HyperText Transfer Protocol Secure*

**IBM** International Business Machines

**ML** Apprendimento Automatico (*Machine Learning*)

**MLP** Percettrone Multistrato (*Multi-Layer Perceptron*)

**MWPM** *Minimum Weight Perfect Matching*

**NISQ** *Noisy Intermediate-Scale Quantum*

**NIST** *National Institute of Standards and Technology*

**NMR** *Risonanza Magnetica Nucleare (Nuclear Magnetic Resonance)*

**PEC** *Probabilistic Error Cancellation*

**PQC** *Post-Quantum Cryptography*

**QEC** *Correzione degli Errori Quantistici (Quantum Error Correction)*

**QFT** *Trasformata di Fourier Quantistica (Quantum Fourier Transform)*

**QMA** *Quantum Merlin-Arthur*

**QML** *Quantum Machine Learning*

**QPE** *Quantum Phase Estimation*

**QPU** *Unità di Elaborazione Quantistica (Quantum Processing Unit)*

**RSA** *Rivest-Shamir-Adleman*

**SDK** *Software Development Kit*

**SSH** *Secure Shell*

**SVM** *Support Vector Machine*

**WSL** *Windows Subsystem for Linux*

**ZNE** *Zero-Noise Extrapolation*

# Capitolo 1

## Introduzione

### 1.1 Il Limite del Calcolo Classico

Per oltre cinquant'anni, lo sviluppo dell'informatica è stato guidato da una legge empirica enunciata nel 1965 da Gordon Moore<sup>1</sup>: il numero di transistor per chip raddoppia ogni due anni, e con esso la potenza di calcolo disponibile. Questa crescita esponenziale ha permesso di trasformare calcolatori grandi quanto un'intera stanza nei dispositivi tascabili di oggi. Tuttavia, la Legge di Moore si sta scontrando con i limiti fisici fondamentali della materia: i transistor moderni hanno dimensioni di pochi nanometri, avvicinandosi alla scala atomica oltre la quale gli effetti quantistici – lo stesso fenomeno che si vorrebbe evitare – diventano incontrollabili e inevitabili.

Parallelamente al problema fisico dell'hardware, esiste una barriera di natura puramente matematica: esistono classi di problemi computazionali per i quali nessun algoritmo classico è in grado di fornire una soluzione in tempi ragionevoli, *indipendentemente* dalla potenza di calcolo disponibile. Questi problemi – fattorizzazione di grandi interi, ricerca in spazi combinatoriali enormi, simulazione di sistemi molecolari complessi – resistono a qualunque approccio classico non perché i computer non siano abbastanza veloci, ma perché la complessità intrinseca del problema cresce più rapidamente di qualunque risorsa classica concepibile.

È in questo contesto che nasce il **calcolo quantistico**: la visione radicale che i principi della meccanica quantistica – *sovrapposizione*, *entanglement* e *interferenza* –

---

<sup>1</sup>**Gordon Earle Moore** (1929–2023), cofondatore di Intel, osservò nel 1965 che il numero di transistor integrabili su un chip raddoppiava approssimativamente ogni due anni, con un conseguente aumento esponenziale delle prestazioni computazionali. La Legge di Moore non è una legge fisica, ma una previsione industriale che ha orientato decenni di investimenti tecnologici.

possano essere sfruttati non come ostacoli da evitare, ma come risorse computazionali di straordinaria potenza. L'intuizione originale fu di Richard Feynman<sup>2</sup>, che nel 1982 osservò come la simulazione di sistemi quantistici richiedesse risorse esponenziali su macchine classiche, e propose che un computer basato sugli stessi principi fisici potesse simulare la natura stessa in modo efficiente [1]. David Deutsch formalizzò nel 1985 il primo modello teorico rigoroso di computer quantistico universale [2], aprendo la strada a un nuovo paradigma computazionale.

I principi fisici che rendono possibile questo paradigma — il qubit e la sovrapposizione, la sfera di Bloch, l'entanglement e l'interferenza — insieme alla loro realizzazione sui qubit superconduttori di IBM, sono ripresi nella Sezione C.1 (Sez. C.1.1); la trattazione formale completa è nella Sezione 3.1. La rivoluzione algoritmica degli anni Novanta — da Simon fino all'algoritmo di Shor (1994) e a quello di Grover (1996) — è ripercorsa nella Sez. C.1.2. La portata dirompente di Shor si misura sulla crittografia che minaccia: la struttura del protocollo RSA e il motivo per cui Shor lo rompe (Sez. C.1.3), la risposta della crittografia post-quantistica con gli standard NIST 2024 (Sez. C.1.4) e lo stato dell'arte dell'hardware dall'era NISQ verso i sistemi fault-tolerant (Sez. C.1.5) delineano il contesto strategico in cui si colloca questo lavoro: comprendere i limiti reali dell'algoritmo di Shor su hardware rumoroso.

## 1.2 Motivazione e Contributo del Presente Lavoro

In questo contesto scientifico e tecnologico si inserisce il presente lavoro di tesi. L'algoritmo di Shor rappresenta uno dei risultati più significativi e dirompenti dell'informatica quantistica: la sua capacità di fattorizzare interi in tempo polinomiale minaccia direttamente le fondamenta della crittografia moderna. Tuttavia, la sua esecuzione su hardware NISQ è ostacolata da requisiti stringenti in termini di profondità del circuito, numero di qubit e fedeltà delle porte — rendendo il rumore quantistico il principale ostacolo alla sua realizzazione pratica.

Questo lavoro affronta tale sfida in due fasi. La **prima fase** è una verifica sperimentale sistematica: eseguire l'algoritmo di Shor su simulatori quantistici con noise model calibrati sull'hardware IBM e mettere alla prova l'ipotesi che

---

<sup>2</sup>**Richard Phillips Feynman** (1918–1988), fisico teorico statunitense, Premio Nobel per la Fisica nel 1965. Nel suo celebre articolo del 1982 *“Simulating Physics with Computers”* [1], Feynman argomentò che un computer classico non può simulare efficientemente un sistema quantistico senza un overhead esponenziale, e propose che un “computer quantistico” — uno che segua le leggi della meccanica quantistica — potrebbe farlo in modo naturalmente efficiente.

un classificatore Apprendimento Automatico (*Machine Learning*) (ML) applicato all’output rumoroso riduca il numero di iterazioni necessarie. La verifica confronta tre configurazioni:

- **Metodo 1** (baseline classico, TOP-1): la misura più frequente dell’istogramma viene usata come candidato. Richiede in media  $\bar{M}_1 = 1.97$  esecuzioni per  $N = 15$  in condizioni NISQ-realistiche.
- **Metodo 2** (classificatore ML + TOP-4): un classificatore binario (Random Forest) pre-addestrato su 2000 istogrammi sintetici filtra le iterazioni che giudica prive di segnale *Quantum Phase Estimation* (QPE) recuperabile; la ricerca è poi estesa ai 4 candidati più frequenti. Ottiene  $\bar{M}_2 = 1.03$ , con fattore di riduzione  $\rho = 1.90$ .
- **Analisi di ablazione** ( $M_{\text{TOP4}}$ , TOP-4 senza classificatore): isola il contributo della ricerca multi-candidato da quello del filtro ML. L’ablazione mostra che  $M_{\text{TOP4}}$  ottiene  $\bar{M} = 1.00$  — ogni ripetizione converge al primo tentativo — ed è statisticamente indistinguibile da M2 per UC1 ( $p = 0.849$ ), mentre su UC2 il classificatore richiede significativamente più iterazioni della sola ricerca: il guadagno è attribuibile alla **strategia di ricerca TOP-4**, non al classificatore. Un audit successivo delle etichette di addestramento (Sezione D.2) ne individua la causa meccanica: il classificatore era stato addestrato, di fatto, a riconoscere se il picco più alto dell’istogramma coincidesse con l’esito banale  $y = 0$  — ossia proprio il caso che la ricerca multi-candidato risolve per costruzione.

L’esito della verifica — l’ML applicato all’output, in quel punto e in quel modo, non serve — delimita con precisione dove va cercata la soluzione: se l’informazione distrutta dal rumore non è recuperabile a valle, l’errore va corretto *durante* il calcolo. La **seconda fase**, che costituisce il nucleo della tesi, è quindi dedicata alla Correzione degli Errori Quantistici (*Quantum Error Correction*) (QEC): la costruzione e la simulazione dei codici correttori — dal codice a ripetizione al codice di Steane  $[[7, 1, 3]]$ , fino al surface code con decodifica *Minimum Weight Perfect Matching* (MWPM) — e la misura sperimentale del **logical error rate**  $p_L$  in funzione dell’errore fisico  $p$  e della distanza di codice  $d$ . L’integrazione finale avviene a livelli: lo **Shor logico**, in cui ogni gate del circuito subisce l’errore logico residuo  $p_L$  misurato sperimentalmente, risponde alla domanda conclusiva del lavoro: *quale livello di correzione è necessario perché Shor mantenga una probabilità di successo accettabile?*



È in questa seconda fase che l'intelligenza artificiale viene ripresa, e nel punto in cui l'esito della prima indica che possa servire: non più sull'output, dove l'informazione sull'errore è già andata perduta, ma sulla **sindrome**, dove è ancora interamente presente. Un decoder appreso viene messo a confronto con il MWPM sugli stessi campioni, e il risultato precisa il criterio che regge l'intero lavoro. Sostituire il decoder analitico non conviene: a parità di modello di rumore la rete lo pareggia soltanto, e a costo di volumi di dati considerevoli. Affiancarglielo sì: un decoder **ibrido**, in cui la rete apprende unicamente *quando ribaltare* la decisione del matching, riduce l'errore logico fino al 21% quando il dispositivo presenta errori correlati che il decoder analitico non è in grado di rappresentare — e ricade esattamente su di esso quando il rumore è quello previsto, o quando il codice cresce al punto da lasciare al modello appreso troppo pochi esempi da cui imparare. L'apprendimento automatico, dunque, non ottimizza l'esecuzione di Shor ovunque lo si applichi: lo fa dove dispone di informazione che nessun metodo più semplice sa sfruttare, e questa tesi ne individua sperimentalmente il confine.

L'elaborato si sviluppa dalle fondamenta teoriche del calcolo quantistico, attraverso la verifica sperimentale su simulatori rumorosi, fino alla correzione d'errore quantistica e allo Shor logico. Gli obiettivi specifici e la struttura dettagliata del lavoro sono descritti nel Capitolo 2.

**Riproducibilità e materiale supplementare.** Tutto il lavoro condotto in questa tesi — i sorgenti  $\text{\LaTeX}$ , il codice sperimentale e le campagne di simulazione con i relativi risultati (seed e parametri inclusi) — è documentato ed è liberamente consultabile nel repository GITHUB pubblico dell'autore: <https://github.com/claudio-dragotta/shor-nisq-qec-thesis>. È inoltre disponibile una **demo interattiva** dell'algoritmo di Shor — circuito e sfere di Bloch passo per passo, con esecuzione statistica su molte iterazioni — consultabile dal vivo all'indirizzo <https://shor-demo-6knp.onrender.com> (codice sorgente: <https://github.com/claudio-dragotta/shor-demo>).

## 1.3 Struttura della Tesi

L’elaborato è organizzato in dodici capitoli, seguiti da cinque appendici (A–E) che raccolgono il contesto esteso, il materiale di dettaglio richiamato in forma sintetica nel corpo e un’esplorazione condotta oltre il perimetro del lavoro principale. Il Capitolo 2 svolge una funzione trasversale di raccordo tra teoria e pratica; i Capitoli 3–5 costituiscono la parte teorica; i Capitoli 6–10 la parte sperimentale; i Capitoli 11 e 12 chiudono il lavoro.

Il **Capitolo 2** (*Obiettivi e Piano Sperimentale*) motiva la vulnerabilità di RSA all’algoritmo di Shor e fissa il contratto sperimentale: obiettivi, ipotesi di ricerca, contributo, use case e metriche.

### Parte teorica (Capitoli 3–5).

Il **Capitolo 3** (*L’Algoritmo di Shor*) si apre con i richiami di calcolo quantistico necessari a seguirlo (Sezione 3.1: qubit, sovrapposizione, porte e circuiti, e l’entanglement come *risorsa fisica fragile* che anticipa la trattazione del rumore), quindi presenta la riduzione al *period finding*, la Quantum Phase Estimation e la complessità polinomiale  $O((\log N)^3)$ , con le implicazioni per RSA e la transizione post-quantum.

Il **Capitolo 4** (*Rumore Quantistico nei Sistemi NISQ*) analizza le quattro fonti fisiche di errore e i canali di rumore fondamentali, fino al crollo della probabilità di successo ( $\sim 3.4\%$ ) già per un modulo di soli 15 bit.

Il **Capitolo 5** (*Strategie per la Riduzione del Rumore Quantistico*) confronta le quattro macro-strategie anti-rumore nell’era NISQ e motiva l’approccio adottato.

### Parte sperimentale (Capitoli 6–10).

Il **Capitolo 6** (*Metodo e Implementazione*) risponde a tre domande in sequenza: con quali strumenti si lavora (Sezione 6.1: Qiskit, il simulatore Aer con GPU, il noise model parametrizzato e la transpilazione), con quale disegno sperimentale — la pipeline a tre stadi, le tecniche di mitigazione e i due metodi confrontati — e come il disegno è stato realizzato in codice, dall’ambiente WSL2 alla QFT inversa, dal circuito di Shor alla pipeline dei due metodi.

Il **Capitolo 7** (*Verifica Sperimentale dell’Ipotesi Iniziale: dal Classificatore ML alla Strategia TOP-K*) stabilisce la baseline e, tramite analisi di ablazione, dimostra che il guadagno è della strategia TOP-4 e non del classificatore ML — il risultato che motiva il pivot alla QEC.

Il **Capitolo 8** (*La Correzione d'Errore Quantistico: dal Codice a Ripetizione al Codice di Steane*) presenta il ciclo di correzione e lo verifica sul codice a ripetizione e sul codice di Steane [[7, 1, 3]].

Il **Capitolo 9** (*Il Surface Code e la Stima dell'Errore Logico*) estende la correzione al surface code e ne misura sperimentalmente l'errore logico e la soglia con Stim e PyMatching; le due sezioni conclusive mettono alla prova le assunzioni su cui quella stima poggia — il modello di rumore con cui il codice è simulato e quello con cui è decodificato — ed è nella seconda che il confronto fra decodifica appresa e MWPM individua il regime in cui l'apprendimento automatico produce un guadagno misurabile.

Il **Capitolo 10** (*Integrazione: lo Shor Logico e i Requisiti di Correzione*) esegue lo Shor logico con l'errore residuo misurato e traduce il livello di correzione necessario in requisiti di hardware.

Il **Capitolo 11** (*Sviluppi Futuri*) delinea le direzioni di ricerca oltre il perimetro sperimentale della tesi.

Il **Capitolo 12** (*Conclusioni*) verifica una per una le sei ipotesi e le sei domande di ricerca fissate nel Capitolo 2, dichiara i contributi e i limiti del lavoro e isola il criterio che unifica le due fasi sperimentali.

**Appendici.** Il corpo dell'elaborato è tenuto alla lunghezza di un argomento continuo; le cinque appendici raccolgono ciò che quel filo richiama ma non deve interrompere. Sono organizzate per tema, non per capitolo di provenienza, così che chi le consulti trovi in un solo luogo tutto il materiale di una stessa natura.

L'**Appendice A** (*Trattazione Teorica Estesa*) sviluppa per esteso la teoria sintetizzata nei Capitoli 3–4: i postulati della meccanica quantistica e l'insieme completo delle porte (Sez. A.1), l'anatomia fisica di una Unità di Elaborazione Quantistica (*Quantum Processing Unit*) (QPU) e il confronto fra le tecnologie di qubit (Sez. A.2), gli approfondimenti sull'algoritmo di Shor e sullo stato dell'arte della fattorizzazione quantistica (Sez. A.3) e le derivazioni complete dei canali di rumore in forma di Kraus (Sez. A.4).

L'**Appendice B** (*Strumenti, Ambiente e Codice*) motiva in dettaglio le scelte tecnologiche — confronto tra framework, metodi di simulazione di Aer, specifiche GPU e ambiente WSL (Sez. B.1) — e riporta il codice sorgente dei componenti implementati (Sez. B.2), dal circuito di Shor ai codici correttori.

L'**Appendice C** (*Contesto e Motivazione*) sviluppa i principi fisici del calcolo quantistico, la rivoluzione algoritmica degli anni Novanta, il protocollo RSA e la sua vulnerabilità, la crittografia post-quantistica e lo stato dell'arte dell'hardware

(Sez. C.1); raccoglie inoltre la motivazione crittografica estesa, i requisiti funzionali e la specifica completa di input e output del sistema sperimentale (Sez. C.2).

L'**Appendice D** (*Fase 1: la Campagna Classica nel Dettaglio*) riporta integralmente le sette sweep parametriche su  $M_{\text{TOP4}}$ , con il confronto previsione–esito per ciascun parametro, e il dettaglio metodologico del confronto con la Zero-Noise Extrapolation (Sez. D.1); documenta poi il classificatore valutato nella prima fase — le tre architetture confrontate, l'addestramento e le metriche — e l'audit delle etichette che ricostruisce quale domanda il modello abbia effettivamente appreso a rispondere (Sez. D.2).

L'**Appendice E** (*Fase 2: la Campagna QEC nel Dettaglio*) espone per intero la campagna sulla decodifica appresa — architettura del decoder, protocollo di addestramento, confronto con MWPM e con BP+OSD (Sez. E.1) — e mette alla prova il criterio conclusivo del lavoro su un caso esterno al perimetro principale, la scelta della mappatura del circuito sui qubit fisici condotta su dati di calibrazione reali (Sez. E.2).

# Capitolo 2

## Obiettivi e Piano Sperimentale

Il Capitolo 1 ha inquadrato il contesto storico e tecnologico del calcolo quantistico. Il presente capitolo costruisce su quel fondamento e svolge una funzione duplice: da un lato motiva e definisce gli obiettivi scientifici del lavoro; dall'altro stabilisce il contratto sperimentale completo — requisiti, parametri, use case e metriche — che guiderà tutta la parte implementativa. Il lettore che avrà letto questo capitolo avrà una visione completa di *perché* il lavoro esiste, *cosa* si propone di dimostrare e *come* intende farlo.

La motivazione crittografica in forma estesa — il confronto tra la complessità sub-esponenziale del *General Number Field Sieve* (GNFS) e quella polinomiale  $O((\log N)^3)$  di Shor, la conseguente compromissione irrecuperabile di Rivest-Shamir-Adleman (RSA) indipendentemente dalla lunghezza della chiave, e lo scenario *harvest now, decrypt later* — è sviluppata nella Sezione C.2 (Sez. C.2.1). In sintesi: la sicurezza di RSA cade con la disponibilità di un computer quantistico fault-tolerant, e l'unico ostacolo che oggi impedisce alla minaccia di materializzarsi è il **rumore** dei dispositivi *Noisy Intermediate-Scale Quantum* (NISQ) — la cui comprensione e mitigazione è la ragione d'essere di questo lavoro.

### 2.1 Obiettivi Generali

Partendo dal contesto delineato, il presente lavoro si propone di analizzare in profondità l'algoritmo di Shor per la fattorizzazione di interi e di affrontare il problema della sua esecuzione su hardware quantistico reale, afflitto da rumore e decoerenza.

Il filo conduttore del lavoro è duplice: da un lato la comprensione del **potenziale computazionale** offerto dall'algoritmo di Shor rispetto ai migliori approcci classici

noti; dall'altro lo studio delle **limitazioni pratiche** imposte dal rumore nei dispositivi NISQ attuali, e delle strategie per superarle.

Coerentemente con questo secondo asse, il lavoro sperimentale si articola in **due fasi**. La prima verifica se un'ottimizzazione basata su **modelli di intelligenza artificiale**, applicata a valle dell'esecuzione, riduca il costo dell'algoritmo; il suo esito — l'ML in quella posizione non è il meccanismo attivo — motiva la seconda fase, dedicata alla **Correzione degli Errori Quantistici** (QEC): la costruzione, la simulazione e la caratterizzazione dei codici correttori (ripetizione, Steane, surface code) e la loro integrazione con Shor tramite il modello a livelli dello **Shor logico**. Le due fasi condividono l'infrastruttura di simulazione e l'impianto statistico, e insieme coprono l'arco che va dalla fragilità del calcolo rumoroso alla sua correzione strutturale.

## 2.2 Obiettivi Specifici

1. **Fondamenti del calcolo quantistico.** Fornire una trattazione rigorosa dei principi matematici e fisici su cui si basano gli algoritmi quantistici: il modello del qubit, la sovrapposizione, l'entanglement, le porte logiche quantistiche e il meccanismo di interferenza. Questo obiettivo costituisce la base teorica indispensabile per la comprensione dell'algoritmo trattato nei capitoli successivi.
2. **Analisi teorica dell'algoritmo di Shor.** Descrivere in dettaglio il funzionamento dell'algoritmo di Shor per la fattorizzazione di interi in tempo polinomiale, con particolare attenzione alla riduzione al problema del period-finding, alla Quantum Fourier Transform (Trasformata di Fourier Quantistica (*Quantum Fourier Transform*)) (QFT)) e alla tecnica di phase estimation. Analizzare la complessità computazionale e valutare le implicazioni per la crittografia RSA e per la sicurezza informatica post-quantum.
3. **Implementazione su Qiskit e analisi sperimentale.** Implementare l'algoritmo di Shor utilizzando il framework open-source Qiskit, costruendo i circuiti per la QFT, la modular exponentiation e il circuito completo di fattorizzazione. Verificare il comportamento del circuito su simulatore ideale e analizzare le prestazioni su istanze concrete.
4. **Studio del rumore quantistico nell'algoritmo di Shor.** Analizzare le principali fonti di errore che affliggono l'esecuzione dell'algoritmo di Shor su

hardware reale – decoerenza, errori di gate, readout errors – con particolare attenzione alle componenti più sensibili al rumore: la QFT e la phase estimation. Studiare le strategie di QEC e di noise mitigation disponibili (*Zero-Noise Extrapolation* (ZNE), *Probabilistic Error Cancellation* (PEC), readout mitigation), valutandone l’efficacia sull’algoritmo di Shor.

5. **Ottimizzazione mediante modelli di intelligenza artificiale.** Determinare *in quale punto* della pipeline di esecuzione un modello appreso migliori effettivamente la resa dell’algoritmo di Shor in ambiente rumoroso. L’obiettivo non è assumere che l’apprendimento automatico giovi, ma stabilirlo sperimentalmente confrontandone due impieghi distinti, con lo stesso strumento e sotto lo stesso impianto statistico: **(i) a valle dell’esecuzione**, come classificatore che giudica l’istogramma di output, misurandone il contributo tramite analisi di ablazione contro la sola strategia di ricerca multi-candidato; **(ii) durante la correzione d’errore**, come decoder addestrato sulle sindromi del surface code, confrontato con il decoder analitico di riferimento a parità di informazione. Il criterio di valutazione è in entrambi i casi quantitativo — numero medio di iterazioni nel primo, *logical error rate* nel secondo — e l’esito atteso è una delimitazione, non una promozione: individuare il regime in cui l’intelligenza artificiale apporta un guadagno misurabile e quello in cui non lo apporta, con la spiegazione del perché.
6. **Correzione degli errori quantistici e integrazione con Shor.** Costruire e simulare i codici correttori d’errore in ordine di complessità crescente — il codice a ripetizione, il codice di Steane  $[[7, 1, 3]]$  e il surface code — caratterizzandone quantitativamente la capacità di protezione: la corrispondenza sindrome→errore, la soppressione dell’errore logico  $p_L$  in funzione dell’errore fisico  $p$  e della distanza di codice  $d$ , e il comportamento di soglia. Integrare infine la correzione con l’algoritmo di Shor tramite un modello a livelli (**Shor logico**), per stabilire quale livello di errore logico sia compatibile con un’esecuzione affidabile della fattorizzazione.

Questo secondo blocco di obiettivi si traduce in un insieme di **domande di ricerca** (DR) che la parte sperimentale sulla correzione d’errore affronta esplicitamente:

- DR1.** Come degrada la probabilità di successo di Shor al crescere dell’errore fisico sui gate, e quale fonte di rumore è la più dannosa?

- DR2.** In che modo un codice a ripetizione permette di introdurre il concetto di sindrome senza collassare lo stato logico?
- DR3.** Quali vantaggi e limiti offre il codice di Steane  $[[7, 1, 3]]$  come primo codice capace di correggere un errore arbitrario su un qubit?
- DR4.** Perché il surface code è più rilevante per scenari scalabili, e come si stima il suo logical error rate tramite decodifica? Esiste un comportamento di soglia osservabile?
- DR5.** Quale livello di errore logico  $p_L$  è necessario affinché una versione logica di Shor mantenga una probabilità di successo accettabile?
- DR6.** Esiste un regime in cui un decoder *appreso dai dati* supera il decoder analitico standard, e da che cosa dipende? In particolare: il vantaggio dipende dalla qualità della calibrazione del modello di rumore, oppure dalla sua rappresentabilità nella struttura del decoder?

Le prime cinque domande discendono dal piano di lavoro concordato sulla correzione d'errore; la sesta estende l'obiettivo specifico 5 alla seconda fase, chiudendo il confronto fra i due impieghi dell'apprendimento automatico su cui l'intero lavoro è costruito.

## 2.3 Ipotesi di Lavoro

Il contributo sperimentale della tesi è strutturato attorno a un'ipotesi principale e a due ipotesi secondarie, formulate prima dell'esecuzione degli esperimenti e verificate quantitativamente sui dati raccolti.

**Ipotesi principale.** L'integrazione di un classificatore ML nella pipeline di analisi riduce significativamente il numero medio di iterazioni necessarie per ottenere un risultato corretto dall'algoritmo di Shor su simulatore rumoroso. In termini formali, il fattore di riduzione

$$\rho = \frac{\bar{M}_1}{\bar{M}_2} \gg 1 \quad (2.1)$$

dove  $\bar{M}_1$  e  $\bar{M}_2$  sono rispettivamente il numero medio di iterazioni del Metodo 1 (baseline classico) e del Metodo 2 (classificatore ML). La verifica statistica avviene tramite il test di Mann-Whitney U (non parametrico, unilaterale) sull'ipotesi nulla  $H_0: \bar{M}_1 = \bar{M}_2$ , con soglia di significatività  $\alpha = 0.05$ .



**Ipotesi secondaria 1.** Il classificatore ML raggiunge prestazioni sufficienti a distinguere esecuzioni corrette da errate anche in presenza di rumore variabile:  $F1 > 0.85$  e  $AUC > 0.90$  sul test set.

**Ipotesi secondaria 2.** Il vantaggio del Metodo 2 si mantiene al crescere della dimensione dell'istanza ( $N = 15 \rightarrow 21 \rightarrow 35$ ) e al peggiorare del livello di rumore, confermando la generalizzabilità dell'approccio oltre il caso baseline.

La seconda fase del lavoro, sulla correzione d'errore, è retta da un'ulteriore terna di ipotesi, anch'esse formulate a priori e verificate quantitativamente.

**Ipotesi QEC 1 (soppressione).** La codifica rende il qubit logico più affidabile del qubit fisico al di sotto di una soglia di errore: per un codice di distanza  $d = 3$  (ripetizione, Steane) l'errore logico è soppresso quadraticamente,  $p_L \propto p^2$ , ed esiste un regime in cui  $p_L < p$ .

**Ipotesi QEC 2 (soglia).** Il surface code esibisce un comportamento di soglia: al di sotto di un errore fisico critico  $p_{th}$ , aumentare la distanza di codice  $d$  riduce l'errore logico  $p_L$ ; al di sopra, lo aumenta. Le curve  $p_L(p)$  a distanze crescenti si incrociano in prossimità di  $p_{th}$ .

**Ipotesi QEC 3 (integrazione).** Esiste un livello di errore logico  $p_L$  sufficientemente basso perché l'algoritmo di Shor, eseguito con quell'errore residuo su ogni gate logico, mantenga una probabilità di successo elevata; tale livello è raggiungibile dai codici studiati nel regime sotto-soglia.

## 2.4 Contributo Originale

Rispetto alla letteratura esistente sull'algoritmo di Shor e sulla mitigazione del rumore nei sistemi NISQ, questo lavoro apporta i seguenti contributi originali.

**Progettazione e validazione sperimentale della strategia TOP-K.** La maggioranza degli studi di mitigazione del rumore sull'algoritmo di Shor si concentra su tecniche strutturali (Zero-Noise Extrapolation, Probabilistic Error Cancellation, Dynamical Decoupling) applicate al circuito prima della misura. Il presente lavoro adotta invece un approccio *post-processing*: la strategia di ricerca multi-candidato TOP-K, applicata direttamente all'istogramma di output del simulatore rumoroso, riduce il numero di iterazioni necessarie sfruttando la struttura residua dei picchi QPE. L'analisi di ablazione dimostra che questo componente è il meccanismo attivo del miglioramento, applicabile senza modifiche al circuito né accesso al modello di rumore dell'hardware.

**Quantificazione empirica del fattore di riduzione  $\rho$ .** La letteratura fornisce stime teoriche del numero di iterazioni necessarie a ottenere un risultato corretto da Shor in presenza di rumore, ma raramente misure sperimentali sistematiche su più configurazioni. Il presente lavoro progetta quattro use case — due livelli di rumore per  $N = 15$  e due istanze di dimensione crescente ( $N = 21$ ,  $N = 35$ ) — e misura  $\bar{M}_1$  e  $\bar{M}$  (Metodo 1 e  $M_{\text{TOP4}}$ ) sui due in cui il confronto è possibile, producendo stime empiriche di  $\rho$  validate statisticamente con test di Mann-Whitney U. Sui due use case di dimensione maggiore nessuna strategia di estrazione risulta applicabile: la profondità del circuito traspilato azzerava la probabilità di successo (Capitolo 7, Tabella 7.1). Anche questo è un risultato del lavoro — la barriera di scalabilità è quantificata e attribuita alla decomposizione della moltiplicazione modulare — ma va dichiarato che la validazione quantitativa del confronto poggia su due configurazioni, non su quattro.

**Analisi di ablazione che separa il contributo TOP-K da quello del classificatore ML.** Il lavoro conduce un’analisi di ablazione esplicita che isola il contributo della strategia di ricerca rispetto a quello del classificatore ML. Il risultato — che  $M_{\text{TOP4}}$  (TOP-K senza classificatore) è statisticamente equivalente a M2 su UC1 e significativamente migliore su UC2 — chiarisce quale componente è responsabile del guadagno, e orienta gli sviluppi futuri verso l’ottimizzazione della strategia di ricerca piuttosto che del modello apprenditivo.

**Caratterizzazione sperimentale end-to-end della correzione d’errore su Shor.** La seconda fase costruisce e simula una progressione di codici correttori — ripetizione, Steane  $[[7, 1, 3]]$ , surface code con decodifica MWPM — misurandone il logical error rate con protocollo di validazione a flag, e li integra con l’algoritmo di Shor in un modello a livelli. Il risultato è una **figura conclusiva** che colloca sullo stesso grafico la probabilità di successo di Shor in funzione dell’errore per i tre regimi (fisico non corretto, Steane, surface), quantificando in un’unica misura il beneficio della correzione. Rispetto alla letteratura, che tratta separatamente la stima di soglia e l’esecuzione dell’algoritmo, il contributo è l’integrazione esplicita dei due livelli su un’istanza trattabile, con una discussione critica dei limiti del modello di rumore Clifford-Pauli adottato.

**Delimitazione sperimentale del regime di utilità dell’apprendimento automatico.** Il contributo che unifica le due fasi è la determinazione, sotto un unico impianto sperimentale e con il medesimo strumento modellistico, di *dove* un modello appreso migliori l’esecuzione di Shor in ambiente rumoroso. A valle dell’esecuzione l’ablazione mostra che non apporta nulla; sulla sindrome del surface

code il quadro cambia, ma non nella forma attesa: sostituire il decoder analitico non conviene, mentre affiancarlo — con una rete che apprende soltanto *quando ribaltarne* la decisione — riduce l’errore logico in presenza di rumore correlato. Ne discende un criterio di applicabilità formulato in termini strutturali anziché prestazionali: il guadagno non dipende dalla bontà della calibrazione del modello di rumore, ma dal fatto che la classe di errori presente nel dispositivo sia o non sia rappresentabile nella struttura del decoder analitico. Questa delimitazione — corredata della quantificazione del costo in dati necessario anche solo al pareggio — è, a conoscenza dell’autore, assente dalla letteratura, che tende a riportare i successi della decodifica appresa senza caratterizzarne le condizioni di fallimento.

I **requisiti funzionali** del sistema sperimentale e la specifica completa dei **parametri di input e output** sono formalizzati nella Sezione C.2 (Sez. C.2.2 e Sez. C.2.3): esecuzione configurabile del circuito di Shor, noise model parametrizzabile, raccolta riproducibile degli output e le pipeline dei due metodi. I quattro use case e le metriche di valutazione, che costituiscono il nucleo del contratto sperimentale, sono definiti qui di seguito.

## 2.5 I Quattro Use Case

I quattro use case sono scelti per garantire che i risultati non dipendano da una singola configurazione e che coprano un intervallo rappresentativo di condizioni operative. Il disegno sperimentale segue due assi di variazione indipendenti:

- **Asse rumore (Use Case 1 vs. 2):** stesso numero  $N = 15$ , stessa base  $a = 7$ , stesso circuito — livello di rumore diverso. Il confronto isola l’effetto del rumore sul numero di iterazioni necessarie, a parità di complessità circuitale. Il Use Case 2 utilizza parametri di errore circa cinque volte superiori a quelli del Use Case 1, per coprire sia un regime *NISQ-realistico* sia uno *NISQ-degradato*.
- **Asse scalabilità (Use Case 1, 3, 4):** numeri  $N$  di dimensione crescente ( $15 \rightarrow 21 \rightarrow 35$ ), stesso livello di rumore *NISQ-realistico*. Il confronto valuta come il numero medio di iterazioni e l’accuratezza del classificatore varino al crescere della profondità del circuito. Si vedrà più avanti (§2.5.2) che l’identificazione fra “ $N$  crescente” e “profondità crescente” non è automatica, e che per Use Case 4 non vale.

La scelta di quattro use case soddisfa il requisito metodologico minimo per la validazione accademica dei risultati in questo dominio [3].

### 2.5.1 Parametri dei Use Case

La Tabella 2.1 riporta la configurazione completa dei quattro use case. I parametri di rumore del livello *NISQ-realistico* sono derivati dalle specifiche di calibrazione di `ibm_marrakesh` riportate nel tutorial ufficiale IBM [4] e dalla metodologia di selezione dei noise model proposta in [5]. Il livello *NISQ-degradato* scala i tassi di errore di un fattore  $5\times$  e dimezza i tempi di coerenza, simulando condizioni di hardware più antico o in stato di calibrazione peggiore.

| Parametro                  | UC 1               | UC 2               | UC 3               | UC 4               |
|----------------------------|--------------------|--------------------|--------------------|--------------------|
| $N$                        | 15                 | 15                 | 21                 | 35                 |
| $a$                        | 7                  | 7                  | 2                  | 6                  |
| Periodo $r$ atteso         | 4                  | 4                  | 6                  | 2                  |
| $n_{\text{count}}$ (qubit) | 8                  | 8                  | 10                 | 12                 |
| $M_{\text{shots}}$         | 1024               | 1024               | 1024               | 1024               |
| <i>Livello rumore</i>      | NISQ-realistico    | NISQ-degradato     | NISQ-realistico    | NISQ-realistico    |
| $\epsilon_{1q}$            | $1 \times 10^{-3}$ | $5 \times 10^{-3}$ | $1 \times 10^{-3}$ | $1 \times 10^{-3}$ |
| $\epsilon_{2q}$            | $1 \times 10^{-2}$ | $5 \times 10^{-2}$ | $1 \times 10^{-2}$ | $1 \times 10^{-2}$ |
| $T_1$ (ns)                 | 100 000            | 50 000             | 100 000            | 100 000            |
| $T_2$ (ns)                 | 80 000             | 30 000             | 80 000             | 80 000             |
| $p_{\text{ro}}$            | $2 \times 10^{-2}$ | $5 \times 10^{-2}$ | $2 \times 10^{-2}$ | $2 \times 10^{-2}$ |

Tabella 2.1: Configurazione completa dei quattro use case. I parametri di rumore del livello NISQ-realistico sono derivati dalle specifiche di `ibm_marrakesh` [4, 5]. Il livello NISQ-degradato scala i tassi di errore di  $5\times$  e dimezza  $T_1$  e  $T_2$ .

### 2.5.2 Razionale per la Scelta delle Istanze

**Use Case 1** —  $N = 15$ , **NISQ-realistico**. È il caso di riferimento consolidato in letteratura: la prima dimostrazione sperimentale di Shor è avvenuta su  $N = 15$  con NMR a 7 qubit [6], e il tutorial ufficiale IBM riporta i dati di esecuzione per la stessa istanza su `ibm_marrakesh` [4]. La base  $a = 7$  produce un periodo  $r = 4$ , sufficiente per estrarre i fattori 3 e 5 tramite l’algoritmo delle frazioni continue. Questo use case funge da baseline quantitativa per entrambi i metodi.

**Use Case 2** —  $N = 15$ , **NISQ-degradato**. Configurazione identica al Use Case 1 eccetto per il livello di rumore, aumentato di  $5\times$  su tutti i parametri. Poiché il circuito è lo stesso, qualsiasi differenza nelle metriche  $\bar{M}_1$  e  $\bar{M}_2$  è attribuibile esclusivamente al rumore. Questo use case permette di valutare la **robustezza** del classificatore ML rispetto al degrado delle condizioni hardware, indipendentemente dalla complessità circuitale.

**Use Case 3 —  $N = 21$ , NISQ-realistico.**  $N = 21 = 3 \times 7$  è la fattorizzazione più grande dimostrata su hardware superconduttore a uso generale [7]. La base  $a = 2$  produce un periodo  $r = 6$ , che implica una profondità circuitale sensibilmente maggiore rispetto a  $N = 15$ . A parità di livello di rumore con il Use Case 1, questo use case isola l'effetto della scalabilità: ci si attende un aumento di  $\bar{M}_1$  per via del circuito più profondo, e si valuta se il classificatore ML mantiene un'accuratezza sufficiente nonostante la maggiore complessità.

**Use Case 4 —  $N = 35$ , NISQ-realistico.**  $N = 35 = 5 \times 7$  con base  $a = 6$  produce il periodo minimo  $r = 2$  (poiché  $6^2 = 36 \equiv 1 \pmod{35}$ ), il che consente di fattorizzare direttamente con  $\gcd(6 - 1, 35) = \gcd(5, 35) = 5$  e  $\gcd(6 + 1, 35) = \gcd(7, 35) = 7$ . La scelta di  $r = 2$  con  $N$  maggiore permette di separare l'effetto della dimensione del registro (più qubit) dall'effetto della profondità della modular exponentiation, fornendo un punto di confronto complementare rispetto al Use Case 3.

**Una precisazione sull'asse di scalabilità.** Le due letture appena date — Use Case 3 come punto sull'asse  $N$  crescente e Use Case 4 come sonda della sola larghezza del registro — non sono equivalenti, e la verifica sperimentale (Capitolo 7) mostrerà che la seconda è quella corretta. La profondità del circuito non è governata da  $N$  ma dal periodo  $r$ : ogni gate controllato  $U^{2^j}$  con  $2^j \equiv 0 \pmod{r}$  collassa nell'identità e viene eliminato in fase di traspilazione. Con  $r = 2$  sopravvive un solo gate su dodici, e il circuito di Use Case 4 risulta più corto di quello di Use Case 1 nonostante il modulo maggiore. Lungo la sequenza  $N = 15 \rightarrow 21 \rightarrow 35$  i periodi sono  $4 \rightarrow 6 \rightarrow 2$ : la difficoltà non cresce in modo monotono. L'**Ipotesi secondaria 2** va quindi intesa nella forma verificabile “il vantaggio si mantiene al crescere della profondità del circuito”, per la quale l'unica istanza informativa fra quelle previste è Use Case 3.

## 2.6 Metriche di Valutazione

### 2.6.1 Metriche del Metodo 1

- $\bar{M}_1$ : numero medio di esecuzioni necessarie per ottenere il primo risultato corretto, calcolato su  $K = 30$  ripetizioni indipendenti dello stesso esperimento.
- $\sigma_{M_1}$ : deviazione standard del numero di esecuzioni, a indicare la variabilità del metodo.

- $P_{\text{success},1}(M_{\text{max}})$ : probabilità di successo entro un budget fisso di  $M_{\text{max}}$  esecuzioni, dove  $M_{\text{max}}$  verrà fissato in base ai primi risultati sperimentali.

### 2.6.2 Metriche del Metodo 2

- $\bar{M}_2$ : numero medio di esecuzioni prima che il classificatore restituisca la prima etichetta 1 corretta, sulle stesse  $K$  ripetizioni usate per il Metodo 1.
- $\sigma_{M_2}$ : deviazione standard corrispondente.
- $\text{Acc}_{\text{clf}}$ : accuratezza del classificatore sul test set, definita come il rapporto tra predizioni corrette e numero totale di campioni di test.
- $\text{F1}_{\text{clf}}$ : F1-score, che bilancia la precisione e il recall nella classe positiva (output corretto). È la metrica preferita rispetto alla sola accuratezza in presenza di classi sbilanciate, un fenomeno frequente quando il tasso di successo dell'algoritmo è basso.
- $P_{\text{success},2}(M_{\text{max}})$ : probabilità di successo entro lo stesso budget  $M_{\text{max}}$  utilizzato per il Metodo 1.

### 2.6.3 Metrica di Confronto

La metrica principale per il confronto tra i due metodi è il **fattore di riduzione delle iterazioni**:

$$\rho = \frac{\bar{M}_1}{\bar{M}_2} \quad (2.2)$$

Un valore  $\rho > 1$  indica che il Metodo 2 converge più rapidamente del Metodo 1. L'ipotesi sperimentale, motivata nel Capitolo 5, è  $\rho \gg 1$ , con  $\bar{M}_2 \approx 3$ . La significatività statistica del risultato viene valutata tramite il test di Mann-Whitney U (non parametrico, unilaterale  $M_1 > M_2$ ) sulle distribuzioni di  $M_1$  e  $M_2$ . Poiché il Metodo 2 combina due componenti distinte (il classificatore ML e la ricerca multi-candidato TOP-K), il piano sperimentale prevede inoltre un'**analisi di ablazione**: la variante  $M_{\text{TOP}_4}$  (TOP-K senza classificatore) viene misurata nelle stesse condizioni, in modo da attribuire un eventuale guadagno all'una o all'altra componente e verificare se l'apprendimento automatico è effettivamente necessario.

## 2.6.4 Metriche della Parte QEC

La fase sulla correzione d'errore adotta un insieme di metriche proprio, centrato sul **logical error rate** anziché sul numero di iterazioni:

- $p_L$ : **logical error rate**, ossia la probabilità che il qubit logico subisca un errore non corretto dopo un ciclo di codifica, rumore, estrazione di sindrome e decodifica. È la metrica centrale della parte QEC, misurata in funzione dell'errore fisico  $p$  e della distanza di codice  $d$ .
- **Pendenza di soppressione**: l'esponente  $\gamma$  nella relazione  $p_L \propto p^\gamma$  a  $p$  piccolo; per un codice di distanza  $d = 3$  il valore atteso è  $\gamma \approx 2$  (correzione di un errore, fallimento a peso due).
- **Break-even**: il regime in cui  $p_L < p$ , in cui cioè il qubit logico è più affidabile del qubit fisico non protetto.
- **Soglia**  $p_{th}$ : per il surface code, il valore di errore fisico a cui le curve  $p_L(p)$  a distanze diverse si incrociano, separando il regime in cui aumentare  $d$  conviene da quello in cui è controproducente.
- $P_{\text{success}}(p_L)$  e  $P(k)$ : per lo Shor logico, la probabilità di successo per singola misura in funzione dell'errore logico per gate, e la probabilità cumulativa  $P(k) = 1 - (1 - P_s)^k$  dopo  $k$  esecuzioni indipendenti.

Ogni stima di  $p_L$  è accompagnata dal numero di campioni, dal seed e dall'intervallo di confidenza (deviazione standard binomiale), secondo le stesse regole di riproducibilità della prima fase.

## 2.6.5 Parametri di Error Mitigation Applicati

Il noise model incorpora il readout error come matrice di confusione simmetrica (parametro  $p_{ro}$ ) direttamente nel simulatore. Non viene applicata una correzione post-hoc tramite matrice di calibrazione: la robustezza dei metodi al readout error viene invece verificata sperimentalmente nella campagna parametrica (Sezione D.1.5 della Sezione D.1), che mostra invarianza di  $M_{\text{TOP4}}$  fino a  $p_{ro} = 20\%$ .

Il Metodo 1 identifica il candidato per la fattorizzazione selezionando la sola misura più frequente dell'istogramma, senza alcuna sogliatura preliminare: la funzione `extract_factors` è applicata direttamente alla moda della distribuzione. Le varianti

multi-candidato ( $M_{\text{TOP4}}$  e Metodo 2) estendono il tentativo ai  $K$  esiti più frequenti in ordine decrescente, ed è precisamente questa differenza che l'analisi di ablazione isola.

## 2.7 Approccio Metodologico

Il lavoro integra tre componenti — una parte teorica, una sperimentale e una di analisi comparativa tra strategie di ricerca — che si sviluppano in sequenza lungo l'elaborato. L'architettura dettagliata del sistema sperimentale, le scelte tecnologiche adottate e la struttura dei due metodi sviluppati sono descritte nel Capitolo 6.



## Capitolo 3

# L'Algoritmo di Shor

Questo capitolo introduce l'algoritmo che dà a questa tesi il proprio oggetto. Si apre con i richiami di calcolo quantistico indispensabili a seguirlo — il qubit, la sovrapposizione, le porte unitarie e il meccanismo di interferenza — di cui l'algoritmo costituisce l'applicazione più celebre.

L'**algoritmo di Shor**, proposto da Peter Shor nel 1994 [8], è un algoritmo quantistico che risolve il problema della **fattorizzazione intera** di un numero  $N$  in tempo **polinomiale** nel numero di bit di  $N$ :

$$T_{\text{Shor}}(N) = O((\log N)^3) \quad (3.1)$$

Questo risultato costituisce uno **speedup esponenziale** rispetto al miglior algoritmo classico noto — il GNFS — che richiede tempo sub-esponenziale (si veda l'equazione (3.3)), del tutto impraticabile per i numeri di grandi dimensioni usati in crittografia. È considerato il risultato algoritmico più dirompente dell'informatica quantistica, poiché la fattorizzazione è il fondamento matematico del sistema crittografico RSA, che protegge la quasi totalità delle comunicazioni digitali moderne.

L'algoritmo si articola in tre fasi: un *preprocessing* classico che riconduce il problema a trovare il periodo di una funzione modulare; un nucleo quantistico basato sulla QFT e sulla QPE, che trova quel periodo in modo esponenzialmente più efficiente di qualunque strategia classica; e una *post-elaborazione* classica che estrae i fattori di  $N$  tramite il calcolo del massimo comune divisore. Dopo i richiami si introduce il problema che l'algoritmo risolve e la sua rilevanza crittografica, per poi svilupparne nel dettaglio la struttura.

## 3.1 Richiami di Calcolo Quantistico

Questa sezione richiama in forma sintetica i concetti di meccanica quantistica e di calcolo quantistico necessari a seguire il resto della tesi. La trattazione completa — i quattro postulati, l'insieme esteso delle porte, le figure e il modello di complessità — è riportata nella Sezione A.1, a cui si rimanda per ogni dettaglio formale.

### 3.1.1 Qubit, Sovrapposizione e Sfera di Bloch

L'unità fondamentale del calcolo quantistico è il **qubit**, descritto da un vettore unitario nello spazio di Hilbert  $\mathcal{H} = \mathbb{C}^2$ . In notazione di Dirac, lo stato generico è la **sovrapposizione**

$$|\psi\rangle = \alpha |0\rangle + \beta |1\rangle, \quad \alpha, \beta \in \mathbb{C}, \quad |\alpha|^2 + |\beta|^2 = 1, \quad (3.2)$$

dove  $|\alpha|^2$  e  $|\beta|^2$  sono le probabilità di misurare rispettivamente 0 e 1 (**regola di Born**). Ogni stato puro si visualizza come un punto sulla **sfera di Bloch**, parametrizzato da  $\theta$  e  $\phi$  tramite  $|\psi\rangle = \cos(\theta/2) |0\rangle + e^{i\phi} \sin(\theta/2) |1\rangle$ : i poli sono  $|0\rangle$  e  $|1\rangle$ , l'equatore le sovrapposizioni equiprobabili (Sezione A.1, Fig. A.1).

### 3.1.2 Sistemi Multi-Qubit ed Entanglement

Un registro di  $n$  qubit vive nello spazio  $\mathbb{C}^{2^n}$ , ottenuto per **prodotto tensoriale**: è la dimensione esponenziale  $2^n$  la fonte del potere computazionale quantistico. Due qubit sono **entangled** quando il loro stato congiunto non è fattorizzabile nel prodotto degli stati individuali; l'esempio canonico è lo stato di Bell  $|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$ , in cui misurare il primo qubit determina istantaneamente l'esito del secondo.

#### L'Entanglement come Risorsa Fisica Fragile

L'entanglement non è solo una proprietà astratta: è la **risorsa** che gli algoritmi quantistici consumano per ottenere il loro vantaggio. Nell'algoritmo di Shor il registro di controllo e quello di lavoro devono restare entangled per tutta la phase estimation, affinché la Quantum Fourier Transform estragga il periodo corretto. Ma un qubit reale non è mai isolato: l'accoppiamento con l'ambiente trasferisce ad esso l'informazione di fase, riducendo lo stato puro a un **miscuglio statistico** in cui la fase relativa è persa — la **decoerenza** [9]. Il tempo caratteristico di questa perdita è  $T_2$  (*dephasing time*): sui processori superconduttori attuali  $T_2 \sim 50\text{--}200\ \mu\text{s}$ , mentre

una porta a due qubit dura  $\sim 300\text{--}500$  ns. Poiché la profondità di Shor cresce come  $O(n^3)$ , il limite imposto da  $T_2$  è superato già per  $n \gtrsim 10\text{--}15$  bit: è questo il collo di bottiglia che il Capitolo 4 tratta quantitativamente.

### 3.1.3 Porte, Misura e Interferenza

Le operazioni sui qubit sono **matrici unitarie** ( $U^\dagger U = I$ ), quindi reversibili. Le porte fondamentali sono le matrici di Pauli  $X$  (bit flip),  $Y$ ,  $Z$  (phase flip), la porta di **Hadamard**  $H$  — che genera la sovrapposizione uniforme  $H^{\otimes n} |0\rangle^{\otimes n} = 2^{-n/2} \sum_x |x\rangle$  — le porte di fase  $R_\phi$ , e la porta a due qubit **CNOT**, che con le porte a singolo qubit forma un insieme universale. La **misura** in base computazionale collassa lo stato  $|\psi\rangle = \sum_x \alpha_x |x\rangle$  sull'esito  $x$  con probabilità  $|\alpha_x|^2$ : è un'operazione non unitaria e irreversibile. Il meccanismo che rende utile tutto ciò è l'**interferenza**: un algoritmo efficiente è costruito perché le ampiezze degli esiti sbagliati si cancellino (interferenza distruttiva) e quelle degli esiti corretti si sommino (costruttiva). È esattamente ciò che la QFT realizza nell'algoritmo di Shor (Capitolo 3) per far emergere il periodo.

## 3.2 Il Problema della Fattorizzazione Intera

La **fattorizzazione intera** consiste nel trovare i fattori primi di un numero intero  $N$ . Per numeri piccoli il problema è banale, ma la sua difficoltà cresce in modo impressionante all'aumentare di  $N$ : i migliori algoritmi classici noti, come il GNFS, richiedono un tempo sub-esponenziale ma comunque super-polinomiale:<sup>1</sup>

$$T_{\text{classico}}(N) = O\left(\exp\left((c + o(1))(\log N)^{1/3}(\log \log N)^{2/3}\right)\right) \quad (3.3)$$

Nella sua formulazione decisionale il problema appartiene a NP, e più precisamente a  $\text{NP} \cap \text{co-NP}$ : sia l'esistenza sia l'assenza di un fattore in un dato intervallo ammettono un certificato verificabile in tempo polinomiale. È questa collocazione a rendere improbabile che la fattorizzazione sia NP-completa — lo fosse, ne seguirebbe  $\text{NP} = \text{co-NP}$ , contro l'opinione prevalente. Non è però noto se appartenga a P:

---

<sup>1</sup>Il GNFS detiene il record mondiale per la fattorizzazione classica: nel 2020, un consorzio internazionale ha fattorizzato RSA-250 (829 bit, 250 cifre decimali) [10], impiegando l'equivalente di circa 2700 anni-core. In precedenza, nel 2009, era stato fattorizzato RSA-768 (768 bit). I numeri RSA usati in produzione sono di 2048 o 4096 bit, rendendo la fattorizzazione classica del tutto impraticabile con qualunque tecnologia convenzionale prevedibile.

nessun algoritmo classico polinomiale è *conosciuto*, e si congettura che non esista, ma una dimostrazione di questa impossibilità manca.

### 3.2.1 Perché la Fattorizzazione Conta

La difficoltà di fattorizzare interi non è una curiosità matematica: è il fondamento su cui poggia RSA, e con esso buona parte della sicurezza delle comunicazioni odierne. Un algoritmo polinomiale per la fattorizzazione compromette RSA in modo irrecuperabile, e non per una debolezza implementativa ma perché ne viola l'assunzione di sicurezza. La trattazione estesa — il confronto fra la complessità sub-esponenziale del GNFS e quella polinomiale di Shor, la risposta della crittografia post-quantistica con gli standard *National Institute of Standards and Technology* (NIST) del 2024, e lo scenario *harvest now, decrypt later* — è nella Sezione C.2 dell'Appendice C. Qui basta il punto che motiva l'intero lavoro: l'unico ostacolo che oggi separa l'algoritmo dalla sua applicazione è il rumore dei dispositivi, ed è quello che questa tesi studia.

## 3.3 Riduzione alla Ricerca del Periodo

L'intuizione geniale di Shor consiste nel ricondurre la fattorizzazione a un problema di **period finding**, trattabile quantisticamente in modo efficiente.

**Osservazione chiave:** Dato  $N$  e un intero  $a$  con  $\gcd(a, N) = 1$  (coprimo con  $N$ ), la funzione

$$f(x) = a^x \bmod N \tag{3.4}$$

è **periodica** con periodo  $r$  (detto *ordine* di  $a$  modulo  $N$ ):  $f(x+r) = f(x)$  per ogni  $x$ .

Una volta trovato il periodo  $r$ , se  $r$  è pari si può calcolare:

$$\gcd(a^{r/2} - 1, N) \quad \text{e} \quad \gcd(a^{r/2} + 1, N) \tag{3.5}$$

Con alta probabilità, almeno uno di questi due valori è un fattore non banale di  $N$ . La prova utilizza proprietà della teoria dei numeri: in particolare, vale  $(a^{r/2} - 1)(a^{r/2} + 1) = a^r - 1 \equiv 0 \pmod{N}$ .




Figura 3.1: La funzione  $f(x) = 7^x \bmod 15$  è periodica con periodo  $r = 4$ . La periodicità è evidente dai valori che si ripetono:  $1, 7, 4, 13, 1, 7, 4, 13, \dots$ . Trovare  $r$  permette di calcolare  $\gcd(7^2 - 1, 15) = \gcd(48, 15) = 3$  e  $\gcd(7^2 + 1, 15) = \gcd(50, 15) = 5$ , ottenendo la fattorizzazione  $15 = 3 \times 5$ .

## 3.4 La Quantum Fourier Transform

Il componente quantistico fondamentale dell'algoritmo di Shor è la **Quantum Fourier Transform** (QFT), l'analogo quantistico della Trasformata Discreta di Fourier (Trasformata Discreta di Fourier (*Discrete Fourier Transform*) (DFT)).

### 3.4.1 Definizione

La QFT su  $\mathbb{Z}_{2^n}$  agisce su uno stato base come:

$$\text{QFT} |j\rangle = \frac{1}{\sqrt{2^n}} \sum_{k=0}^{2^n-1} e^{2\pi i j k / 2^n} |k\rangle \quad (3.6)$$

L'azione su uno stato generico  $|\psi\rangle = \sum_j \alpha_j |j\rangle$  produce:

$$\text{QFT} |\psi\rangle = \sum_k \hat{\alpha}_k |k\rangle \quad (3.7)$$

dove  $\hat{\alpha}_k = \frac{1}{\sqrt{2^n}} \sum_j \alpha_j e^{2\pi i j k / 2^n}$  sono i coefficienti della DFT.

### 3.4.2 Implementazione Efficiente

La DFT classica su  $N = 2^n$  elementi richiede  $O(N \log N)$  operazioni (con il Fast Fourier Transform), mentre la QFT si realizza con  $O(n^2) = O((\log N)^2)$  porte quantistiche: un conteggio esponenzialmente inferiore.

Questo confronto va però interpretato correttamente, perché la formulazione ingenua — “la QFT calcola la trasformata di Fourier esponenzialmente più in fretta” — è fuorviante. La QFT non restituisce i coefficienti  $\hat{\alpha}_k$ : li lascia *codificati nelle ampiezze* di uno stato quantistico, e la misura ne estrae un solo valore per esecuzione, con probabilità  $|\hat{\alpha}_k|^2$ . Non esiste quindi alcun modo di leggere lo spettro completo, e la QFT non sostituisce la FFT come strumento di calcolo generale. Il vantaggio è utilizzabile soltanto quando l’informazione cercata è una *proprietà globale* dello spettro che una singola misura è sufficiente a rivelare — ed è esattamente il caso della periodicità nell’algoritmo di Shor, dove i picchi della distribuzione trasformata cadono sui multipli di  $2^n/r$  e una manciata di misure basta a ricostruire  $r$ .

Il circuito della QFT è costruito ricorsivamente tramite porte di Hadamard e porte di fase controllate  $CR_k$  dove:

$$CR_k = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & e^{2\pi i/2^k} \end{pmatrix} \quad (3.8)$$




Figura 3.2: Circuito della QFT su  $n = 3$  qubit. Ogni qubit riceve una porta di Hadamard  $H$  seguita da porte di fase controllate  $R_k = \text{diag}(1, e^{2\pi i/2^k})$ : la rotazione applicata al qubit  $j$  dipende dai qubit successivi. Lo SWAP finale riordina i qubit nell’ordine corretto. La struttura si generalizza a  $n$  qubit richiedendo  $O(n^2)$  porte.

### 3.4.3 Phase Estimation

La QFT è impiegata, all’interno dell’algoritmo di Shor, attraverso la subroutine di **Phase Estimation** (QPE). Data una porta  $U$  con autovettore  $|u\rangle$  e autovalore  $e^{2\pi i\theta}$ ,

la QPE stima  $\theta$  con precisione arbitraria in tempo  $O(n^2)$ . Nell'algoritmo di Shor,  $U$  è l'operatore di moltiplicazione modulare  $U|x\rangle = |ax \bmod N\rangle$ , e il suo spettro di fase contiene l'informazione sul periodo  $r$ .




Figura 3.3: Circuito di Quantum Phase Estimation per  $N = 15$ ,  $a = 2$ , implementato con Qiskit. Il registro di controllo ( $C$ , 8 qubit) viene posto in sovrapposizione uniforme, entangolato tramite gli operatori  $M_2$  e  $M_4$  controllati, e trasformato con la  $QFT^{-1}$ . La misura del registro  $C$  produce una stima della fase  $\theta = k/r$ , da cui si ricava il periodo  $r$  tramite frazioni continue.




Figura 3.4: Gate di moltiplicazione modulare  $U_2 |x\rangle = |2x \bmod 15\rangle$  per  $N = 15$ ,  $a = 2$ . (a) Versione non controllata su 4 qubit: implementata come sequenza di SWAP. (b) Versione controllata  $CU_2$  su 5 qubit utilizzata nel circuito QPE. (c) Decomposizione in gate elementari dopo la traspilazione: le porte SWAP si espandono in triple di CNOT, rivelando il costo effettivo in gate a due qubit del blocco.




Figura 3.5: Gate di moltiplicazione modulare  $U_4 |x\rangle = |4x \bmod 15\rangle$  per  $N = 15$ ,  $a = 4 = 2^2$ . (a) Versione non controllata: il pattern di SWAP differisce da  $U_2$  poiché la permutazione modulare per  $a = 4$  è diversa. (b) Versione controllata  $CU_4$  su 5 qubit, secondo blocco del circuito QPE. (c) Decomposizione in gate elementari: il costo aggiuntivo rispetto a  $CU_2$  riflette la maggiore complessità della permutazione per  $a = 4$ .






Figura 3.6: Distribuzione di misura del registro di controllo per  $N = 15$ ,  $a = 7$ , su simulatore a basso rumore (1024 shot). I quattro stati più frequenti —  $\{0, 64, 128, 192\}$  — corrispondono ai multipli di  $2^8/r = 256/4 = 64$  attesi per il periodo  $r = 4$ . Ogni picco raccoglie circa 250–270 conteggi su 1024, confermando la struttura teorica della QPE.

### 3.5 L'Algoritmo di Shor: Schema Completo

L'algoritmo si articola in tre fasi: un preprocessing classico, l'esecuzione del circuito quantistico per il *period finding*, e una post-elaborazione classica per estrarre i fattori.

#### Fase 1 — Preprocessing classico

1. Scegliere  $a \in \{2, \dots, N - 1\}$  uniformemente a caso.
2. Calcolare  $g = \gcd(a, N)$ : se  $g > 1$ , restituire  $g$  (fattore trovato direttamente).

#### Fase 2 — Circuito quantistico (period finding)

3. Inizializzare  $n = 2\lceil \log_2 N \rceil$  qubit nel registro di controllo:  $|0\rangle^{\otimes n} |1\rangle$ .
4. Applicare  $H^{\otimes n}$  al registro di controllo, creando la sovrapposizione uniforme  $\frac{1}{\sqrt{2^n}} \sum_{x=0}^{2^n-1} |x\rangle$ .
5. Applicare la moltiplicazione modulare controllata:  $|x\rangle |1\rangle \mapsto |x\rangle |a^x \bmod N\rangle$ .

6. Misurare il registro di lavoro: il registro di controllo collassa in una sovrapposizione periodica di passo  $r$ . Il passo è *concettuale* — serve a rendere evidente l'origine della periodicità — e nell'implementazione viene omesso, come chiarito nella Sezione 3.5.1.
7. Applicare la  $\text{QFT}^{-1}$  al registro di controllo.
8. Misurare il registro di controllo: ottenere un intero proporzionale a  $s/r$ , con  $s \in \{0, \dots, r-1\}$ .

### Fase 3 — Post-elaborazione classica

9. Applicare l'algoritmo delle frazioni continue al risultato della misura per stimare il periodo  $r$ .
10. Se  $r$  è dispari o  $a^{r/2} \equiv -1 \pmod{N}$ : tornare al passo 1 con un nuovo valore di  $a$ .
11. Calcolare  $p = \gcd(a^{r/2} - 1, N)$  e  $q = \gcd(a^{r/2} + 1, N)$ .
12. Se  $p$  o  $q$  è un fattore non banale di  $N$ : restituirlo.  
Altrimenti: tornare al passo 1.




Figura 3.7: Schema a due registri dell'algoritmo di Shor. Il **Registro 1** (di controllo) viene posto in sovrapposizione uniforme con  $H^{\otimes n}$ , entangolato con il Registro 2 tramite la moltiplicazione modulare  $U_{a,N}$ , quindi trasformato con la  $\text{QFT}^{-1}$ . La misura produce un valore  $s/r$  elaborato classicamente: le frazioni continue stimano il periodo  $r$ , e il calcolo del MCD restituisce i fattori  $p$  e  $q$  di  $N$ .

### 3.5.1 Il Ruolo dell'Entanglement nel Period Finding

Il collasso descritto al passo 6 dello schema non è un effetto arbitrario: è la conseguenza diretta dell'**entanglement** creato al passo 5. Vale la pena rendere esplicito questo meccanismo, che è il cuore quantistico dell'intero algoritmo.

Dopo l'applicazione della moltiplicazione modulare controllata, i due registri si trovano nello stato entangled:

$$|\Psi\rangle = \frac{1}{\sqrt{2^n}} \sum_{x=0}^{2^n-1} |x\rangle \otimes |a^x \bmod N\rangle \quad (3.9)$$

Questo stato **non è separabile**: il valore del registro di lavoro è correlato in modo univoco al valore del registro di controllo. I due registri formano un unico sistema entangled, esattamente come accade in uno stato di Bell — dove misurare un qubit determina istantaneamente l'esito dell'altro.

Se a questo punto si misurasse il registro di lavoro e si ottenesse un valore  $v = a^{x_0} \bmod N$ , il registro di controllo collasserebbe *istantaneamente* nell'unica sovrapposizione compatibile con  $v$ : quella di tutti i valori  $x$  per cui  $a^x \equiv v \pmod{N}$ , ovvero

$$|x_0\rangle + |x_0 + r\rangle + |x_0 + 2r\rangle + \dots \quad (3.10)$$

La correlazione tra i due registri è **bidirezionale**: conoscere il valore del registro di lavoro vincola il registro di controllo a una sovrapposizione periodica di passo esattamente  $r$ . Questa è la “versione inversa” propria dell'entanglement: misurare uno dei due sottosistemi determina (o in questo caso, restringe) lo stato dell'altro.

In pratica il circuito di Shor non misura esplicitamente il registro di lavoro: la sola creazione dell'entanglement è sufficiente. Applicando la  $\text{QFT}^{-1}$  al registro di controllo prima della misura, si trasforma la periodicità nascosta dell'equazione (3.10) in picchi netti alle frequenze  $k/r$ , con  $k \in \{0, \dots, r-1\}$ . La misura finale del registro di controllo restituisce allora, con alta probabilità, un valore da cui le frazioni continue estraggono  $r$ .

In sintesi: l'entanglement tra i due registri è il meccanismo che *trasferisce* la periodicità della funzione  $f(x) = a^x \bmod N$  — che esiste nel registro di lavoro — verso il registro di controllo, dove la QFT la rende misurabile. Senza entanglement, questa trasmissione di informazione tra i due registri sarebbe impossibile, e l'intero speedup esponenziale di Shor verrebbe meno.

## 3.6 Analisi della Complessità

La complessità dell'algoritmo di Shor è **polinomiale** nel numero di bit di  $N$ :

- Il circuito quantistico richiede  $O(n^3)$  porte elementari con aritmetica modulare elementare, dove  $n = \log N$ ; ricorrendo alla moltiplicazione veloce il conteggio scende a  $O(n^2 \log n \log \log n)$ ;
- Il numero di qubit necessari è  $O(\log N)$ ; l'implementazione ottimizzata di Beauregard [11] lo riduce a  $2n + 3$  tramite addizione modulare in-place;
- Il numero atteso di iterazioni (con basi  $a$  diverse) prima del successo è  $O(1)$ .

Complessivamente, nella versione con aritmetica elementare,  $T_{\text{Shor}}(N) = O((\log N)^3)$ , a fronte della complessità sub-esponenziale dell'Equazione (3.3) del miglior algoritmo classico. Si tratta di uno **speedup esponenziale**.

## 3.7 Stato dell'Arte e Confronto con Altri Algoritmi

Le realizzazioni sperimentali di Shor su hardware reale, i miglioramenti algoritmici più recenti — fra cui la variante di Regev del 2023 — e la roadmap dei costruttori verso il calcolo fault-tolerant sono discussi nella Sezione A.3 dell'Appendice A, insieme al confronto con l'algoritmo di Grover. Due elementi di quel quadro vanno però anticipati qui, perché delimitano il perimetro della parte sperimentale.

Il primo è che **nessuna implementazione ha finora fattorizzato un numero non banale senza semplificazioni**: le dimostrazioni note sfruttano la conoscenza preventiva del risultato per ridurre il circuito, e questo colloca il presente lavoro — che esegue il circuito completo su simulatore rumoroso — in un regime diverso da quello delle dimostrazioni su hardware. Il secondo è che il divario fra Shor dimostrativo e Shor crittograficamente rilevante non è di scala ma di natura: le stime di risorse per moduli a 2048 bit derivano da analisi architetturali complete, non da estrapolazioni di istanze piccole, e il Capitolo 10 riprende esplicitamente questo punto.

# Capitolo 4

## Rumore Quantistico nei Sistemi NISQ

### 4.1 Introduzione al Rumore Quantistico

Il capitolo precedente ha presentato l'algoritmo di Shor nella sua forma ideale: un circuito che, eseguito su un calcolatore quantistico perfetto, fattorizza in tempo polinomiale. Quel calcolatore non esiste. Questo capitolo descrive la distanza fra il modello e la macchina — da dove nasce l'errore, come lo si rappresenta formalmente, e quanto costa all'algoritmo.

I computer quantistici reali operano in regime NISQ [12]: dispongono di decine o centinaia di qubit fisici, ma sono affetti da errori significativi che limitano la profondità dei circuiti eseguibili in modo affidabile.

Il rumore quantistico differisce fundamentalmente dal rumore nei sistemi classici: mentre un bit classico può essere protetto ridondando l'informazione, un qubit non può essere copiato (**teorema del no-cloning**) [13]. Inoltre, gli errori quantistici non sono binari — un qubit può subire rotazioni arbitrarie nello spazio di Hilbert — rendendo la loro caratterizzazione intrinsecamente più ricca e più difficile di quella classica.

Per analizzare il rumore in modo rigoroso è utile distinguere tre livelli di descrizione, che il presente capitolo tratta separatamente:

- **Anatomia della macchina** (Sezione 4.2): com'è fatta fisicamente una QPU e *dove*, nei suoi componenti, gli errori hanno origine;
- **Fonti fisiche** (Sezione 4.3): i quattro meccanismi concreti con cui l'hardware introduce errori;

- **Modelli matematici** (Sezione 4.5): i quattro canali quantistici con cui tali errori vengono formalizzati e simulati.

## 4.2 La Macchina Fisica: i Tre Fatti che Contano

Il rumore di un processore quantistico non è un disturbo generico ma la conseguenza diretta di come la macchina è costruita. La struttura di una QPU superconduttiva — l'architettura del chip criogenico, il ruolo dell'elettronica di controllo, il confronto fra le tecnologie di qubit disponibili e il meccanismo fisico della lettura — è descritta nella Sezione A.2 dell'Appendice A. Ai fini del seguito bastano tre fatti, che vale la pena isolare perché ricorrono in tutto il lavoro.

**Primo: le porte logiche non risiedono nel chip.** Aprendo una Unità di Elaborazione Centrale (*Central Processing Unit*) (CPU) classica si trovano registri e porte incise nel silicio; aprendo una QPU si trovano soltanto i qubit e le linee che li collegano. Le operazioni sono impulsi a microonde generati dall'elettronica esterna, e “applicare un gate” significa inviare un'onda sagomata che ruota lo stato dell'angolo voluto. Ne discende che la fedeltà di una porta è la fedeltà di un impulso analogico: non esiste una soglia di rigenerazione del segnale come nell'elettronica digitale, e ogni imprecisione si accumula.

**Secondo: il budget di operazioni è finito.** Lo stato di un qubit decade con tempi caratteristici  $T_1$  e  $T_2$ , mentre ogni gate richiede un tempo proprio. Il rapporto fra i due fissa quante operazioni si possono eseguire prima che l'informazione si perda, indipendentemente da quanto sia accurata la singola porta. È questo vincolo — non il numero di qubit — a determinare la profondità massima di un circuito utile, ed è la ragione per cui il Capitolo 7 misura la barriera di scalabilità in porte a due qubit anziché in qubit.

**Terzo: la topologia decide chi parla con chi.** Le QPU differiscono per geometria — catene lineari, griglie *heavy-hex*, connettività completa — e l'entanglement fra qubit non adiacenti richiede di attraversare quelli intermedi, con un costo che si paga in coerenza. La topologia determina quindi sia quali circuiti si mappano efficientemente, sia dove il crosstalk colpirà. È il fondamento architetturale del surface code (Capitolo 9), che richiede interazioni fra soli vicini proprio per questa ragione.

## 4.3 Le Quattro Fonti Fisiche di Rumore

Sui processori quantistici reali il rumore origina da quattro meccanismi distinti. Ognuno agisce su una scala temporale e spaziale diversa, e richiede strategie di mitigazione differenti.

### 4.3.1 Decoerenza ( $T_1$ e $T_2$ )

La **decoerenza** è il processo per cui un qubit perde le sue proprietà quantistiche a causa dell'interazione inevitabile con l'ambiente circostante (campi elettromagnetici parassiti, fononi, fluttuazioni termiche). Si manifesta attraverso due tempi caratteristici:

- $T_1$  – **Relaxation time**: il qubit decade spontaneamente dallo stato eccitato  $|1\rangle$  allo stato fondamentale  $|0\rangle$  per dissipazione energetica. Fisicamente corrisponde all'emissione di un fotone verso l'ambiente. Su hardware superconduttore tipicamente  $T_1 \sim 50\text{--}500\ \mu\text{s}$ .<sup>1</sup>
- $T_2$  – **Dephasing time**: la fase relativa tra  $|0\rangle$  e  $|1\rangle$  si randomizza senza necessariamente modificare le popolazioni, distruggendo la sovrapposizione.  $T_2$  comprende due contributi:

$$\frac{1}{T_2} = \frac{1}{2T_1} + \frac{1}{T_\phi} \quad (4.1)$$

dove  $T_\phi$  è il tempo di *pura* perdita di fase. Vale sempre  $T_2 \leq 2T_1$ ; tipicamente  $T_2 \sim 50\text{--}200\ \mu\text{s}$ .

La condizione necessaria per eseguire correttamente un circuito è:

$$\tau_{\text{circuito}} \ll \min(T_1, T_2) \quad (4.2)$$

Poiché l'algoritmo di Shor per un intero a  $n$  bit richiede una profondità  $O(n^3)$  gate, e ogni gate a due qubit su hardware IBM dura  $\sim 300\text{--}500\ \text{ns}$ , questa condizione è violata già per  $n \gtrsim 10\text{--}15$  bit sui processori NISQ attuali.

**Connessione con l'entanglement.**  $T_2$  ha un'interpretazione diretta in termini di entanglement: esso misura per quanto tempo i qubit del registro di controllo riescono a mantenere la coerenza di fase necessaria a sostenere lo stato entangled con il registro di lavoro. Nella phase estimation dell'algoritmo di Shor, ogni qubit di controllo  $q_j$  viene preparato in sovrapposizione  $\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$  e deve restare coerente per tutta la durata del blocco di modular exponentiation controllato da  $q_j$ . Se  $T_2$  è inferiore a questo intervallo, la fase relativa si randomizza: l'entanglement con il registro di lavoro decade, le ampiezze di interferenza nella QFT si riducono, e il

---

<sup>1</sup>La notazione  $T_1$  e  $T_2$  è mutuata dalla spettroscopia a Risonanza Magnetica Nucleare (*Nuclear Magnetic Resonance*) (NMR), dove Felix Bloch la introdusse nel 1946 per i tempi di rilassamento longitudinale e trasversale della magnetizzazione nucleare.



periodo  $r$  non è più estraibile in modo affidabile. Su `ibm_marrakesh`, con  $T_2 \approx 80 \mu\text{s}$  e un tempo di gate a due qubit di circa 400 ns, il numero massimo di gate a due qubit eseguibili entro  $T_2$  è dell'ordine di  $T_2/\tau_{\text{gate}} \approx 200$ : una soglia che il circuito di Shor per  $N = 15$  sfiora già in condizioni ideali di compilazione [4].

### 4.3.2 Errori di Gate

Le porte quantistiche fisiche non implementano perfettamente l'operazione unitaria ideale  $U$ , bensì un'operazione perturbata  $\tilde{U} = U + \delta E$ . L'**errore di gate** è quantificato dalla **gate infidelity**:

$$r(U, \tilde{U}) = 1 - F(U, \tilde{U}), \quad F(U, \tilde{U}) = \frac{1}{d^2} \left| \text{Tr}(U^\dagger \tilde{U}) \right|^2 \quad (4.3)$$

dove  $d$  è la dimensione dello spazio di Hilbert e  $F$  è la *process fidelity*, pari a 1 quando  $\tilde{U} = U$ . Le cause principali sono le imprecisioni nel controllo di ampiezza e frequenza dei pulse a microonde, l'accoppiamento residuo *always-on* tra qubit adiacenti, e il *leakage* verso stati non computazionali ( $|2\rangle, |3\rangle, \dots$ ) negli oscillatori di Josephson. Su hardware IBM (2024–2025) i valori tipici sono:  $r \approx 0.03\text{--}0.1\%$  per gate a singolo qubit ( $F \approx 99.9\text{--}99.97\%$ ) e  $r \approx 0.3\text{--}1\%$  per gate a due qubit come CNOT ed ECR ( $F \approx 99\text{--}99.7\%$ ).

### 4.3.3 Errori di Misura (Readout Errors)

La misura finale può restituire un risultato errato: il qubit si trova in  $|0\rangle$  ma viene letto come 1, o viceversa. Questo errore è modellato da una **matrice di confusione**  $A$ :

$$A_{ij} = P(\text{misura } i \mid \text{stato } j), \quad \sum_i A_{ij} = 1 \quad (4.4)$$

Per  $n$  qubit indipendenti,  $A = \bigotimes_{k=1}^n A_k$  con

$$A_k = \begin{pmatrix} 1 - e_0^{(k)} & e_1^{(k)} \\ e_0^{(k)} & 1 - e_1^{(k)} \end{pmatrix} \quad (4.5)$$

dove  $e_0^{(k)}$  è la probabilità di leggere 1 dato  $|0\rangle$  per il  $k$ -esimo qubit. Valori tipici:  $e_0, e_1 \approx 1\text{--}3\%$  su hardware IBM.

### 4.3.4 Crosstalk

Il **crosstalk** è l'interferenza indesiderata tra qubit adiacenti durante l'esecuzione di operazioni parallele. Origina dall'accoppiamento capacitivo residuo tra qubit vicini nel chip superconduttore: quando si applica un gate su un qubit, le perturbazioni del campo si propagano ai qubit circostanti causando rotazioni parassite non intenzionali. Il crosstalk è particolarmente dannoso nei circuiti profondi con molte operazioni parallele ed è difficile da modellare analiticamente [14], il che rende i modelli di apprendimento automatico particolarmente adatti a caratterizzarlo. Questa affermazione, qui anticipata, riceve verifica sperimentale nella Sezione 9.6: è precisamente in presenza di errori correlati fra qubit adiacenti — il crosstalk — che un decoder appreso supera quello analitico, perché tali errori non sono rappresentabili nella struttura su cui quest'ultimo si fonda.

| Fonte          | Causa fisica                 | Parametro                   | Valore tipico IBM |
|----------------|------------------------------|-----------------------------|-------------------|
| Decoerenza     | Interazione con l'ambiente   | $T_1, T_2$                  | 50–500 $\mu$ s    |
| Errori di gate | Imprecisione pulse / leakage | Gate infidelity             | 0.03–1%           |
| Readout errors | Risposta del rivelatore      | $e_0, e_1$                  | 1–3%              |
| Crosstalk      | Accoppiamento residuo        | Difficile da parametrizzare | $\sim 0.1$ –1%    |

Tabella 4.1: Riepilogo delle quattro fonti fisiche di rumore nei processori quantistici superconduttori.

## 4.4 Dal Fenomeno Fisico al Modello Matematico

I quattro fenomeni fisici descritti nella sezione precedente non sono isolati: ciascuno può essere ricondotto a uno o più canali matematici, che ne forniscono una descrizione quantitativa precisa e simulabile. La tabella seguente stabilisce il collegamento esplicito tra i due livelli di descrizione.

| Fonte fisica                     | Canale matematico            | Parametro chiave                   |
|----------------------------------|------------------------------|------------------------------------|
| Decadimento energetico ( $T_1$ ) | Amplitude Damping            | $\gamma = 1 - e^{-t/T_1}$          |
| Perdita di fase ( $T_2$ )        | Phase Flip                   | $p = \frac{1}{2}(1 - e^{-t/T_2})$  |
| Errori di gate (isotropici)      | Depolarizzante               | $p \approx \text{gate infidelity}$ |
| Errori di gate (asimmetrici)     | Bit Flip / Phase Flip        | $p$ dal profilo dell'errore        |
| Readout errors                   | Matrice di confusione $A$    | $e_0, e_1$ da calibrazione         |
| Crosstalk                        | Depolarizzante (multi-qubit) | Difficile da parametrizzare        |

Tabella 4.2: Corrispondenza tra fonti fisiche di rumore e canali quantistici.

In pratica, il simulatore Qiskit Aer combina amplitude damping e phase flip in un unico **canale di thermal relaxation**, parametrizzato direttamente da  $T_1$ ,  $T_2$  e dal tempo di gate  $\tau$ , per riprodurre fedelmente il comportamento dell'hardware IBM.

## 4.5 I Quattro Canali Matematici del Rumore

Per simulare e analizzare il rumore, le fonti fisiche vengono astratte in **canali quantistici**: mappe lineari *Completely Positive Trace-Preserving* (CPTP) che agiscono sulla matrice densità  $\rho$  del sistema [15]. Ogni canale CPTP ammette la **rappresentazione di Kraus**:

$$\mathcal{E}(\rho) = \sum_k K_k \rho K_k^\dagger, \quad \sum_k K_k^\dagger K_k = I \quad (4.6)$$

I quattro canali fondamentali, ciascuno dei quali cattura un diverso regime di errore, sono presentati di seguito.

### 4.5.1 Il Canale Depolarizzante

Fra i quattro, il canale **depolarizzante** merita la trattazione esplicita perché è quello su cui poggia l'intera campagna sperimentale: modella gli errori di gate, ed è il parametro  $\varepsilon_{2q}$  che la Sezione 7.6 farà variare su tre ordini di grandezza. Con probabilità  $p$  viene applicato un errore casuale fra  $\{X, Y, Z\}$ , ciascuno con probabilità  $p/3$ :

$$\mathcal{E}_{dep}(\rho) = (1 - p) \rho + \frac{p}{3} (X \rho X + Y \rho Y + Z \rho Z) \quad (4.7)$$

Usando l'identità  $X \rho X + Y \rho Y + Z \rho Z = 2I - \rho$ , valida per  $\text{Tr}(\rho) = 1$ , si ottiene la forma compatta

$$\mathcal{E}_{dep}(\rho) = \left(1 - \frac{4p}{3}\right) \rho + \frac{4p}{3} \frac{I}{2}, \quad (4.8)$$

che rende evidente il significato: il canale interpola fra lo stato  $\rho$  e quello massimamente misto  $I/2$ , contraendo *isotropicamente* il vettore di Bloch di un fattore  $(1 - 4p/3)$ . Per  $p = 3/4$  lo stato diventa completamente misto qualunque fosse quello iniziale.

L'isotropia è la ragione per cui questo canale è il modello standard degli errori di gate: non privilegia alcuna direzione, e descrive quindi un'imprecisione di controllo di cui non si conosce la natura. È anche la ragione per cui, come mostrerà il Capitolo 7, il conteggio delle porte a due qubit soggette a questo canale determina la stima analitica  $P_{\text{surv}} = (1 - \varepsilon_{2q})^k$ .

## 4.5.2 Gli Altri Tre Canali

Gli altri tre canali si enunciano compattamente; le derivazioni complete — operatori di Kraus espliciti, azione sulla matrice densità e trasformazione del vettore di Bloch — sono nella Sezione A.4 dell’Appendice A.

Il **bit flip** applica  $X$  con probabilità  $p$  e contrae le componenti  $r_y, r_z$  del fattore  $(1 - 2p)$ , lasciando  $r_x$  invariata. Il **phase flip** applica  $Z$  con probabilità  $p$ : lascia intatte le popolazioni e sopprime le coerenze  $\rho_{01}$  dello stesso fattore — è il canale che descrive il decadimento  $T_2$ , poiché ponendo  $p(t) = \frac{1}{2}(1 - e^{-t/T_2})$  si ottiene esattamente  $\rho_{01}(t) = \rho_{01}(0) e^{-t/T_2}$ . L’**amplitude damping**, infine, modella il rilassamento energetico  $T_1$ : il qubit decade da  $|1\rangle$  a  $|0\rangle$  con probabilità  $\gamma = 1 - e^{-t/T_1}$ , e a differenza degli altri è *non simmetrico* — contrae la sfera di Bloch verso il polo  $|0\rangle$  anziché verso il centro, sicché per  $t \rightarrow \infty$  ogni stato converge a  $|0\rangle\langle 0|$ .

Questi ultimi due sono i canali che la funzione `thermal_relaxation_error` di Qiskit Aer combina per riprodurre la decoerenza: il modello di rumore adottato in questa tesi (Sezione 6.9) li impiega entrambi, parametrizzati sui valori di  $T_1$  e  $T_2$  dell’hardware di riferimento.

Effetto dei quattro canali di rumore sulla sfera di Bloch  
(sezione nel piano  $xz$ , tratteggio = sfera ideale)




Figura 4.1: Effetto dei quattro canali di rumore sulla sfera di Bloch (sezione nel piano  $xz$ ). La curva tratteggiata grigia rappresenta la sfera ideale; la superficie colorata è la sfera dopo l'applicazione del canale con il parametro indicato. Il Bit Flip contrae la sfera lungo  $z$ ; il Phase Flip lungo  $x$  (distrugge le coerenze equatoriali); il canale Depolarizzante contrae isotropicamente verso il centro; l'Amplitude Damping sposta la sfera verso il polo nord  $|0\rangle$ .

| Canale            | Parametro | Effetto coerenze        | Effetto popolazioni | Modella                        |
|-------------------|-----------|-------------------------|---------------------|--------------------------------|
| Bit Flip          | $p$       | Contrae $r_y, r_z$      | Invariate           | Errori $X$ (inversione di bit) |
| Phase Flip        | $p$       | Sopprime $\rho_{01}$    | Invariate           | Dephasing ( $T_2$ )            |
| Depolarizzante    | $p$       | Contrae isotropicamente | Verso $I/2$         | Errori di gate generici        |
| Amplitude Damping | $\gamma$  | Sopprime $\rho_{01}$    | Verso $ 0\rangle$   | Decadimento $T_1$              |

Tabella 4.3: I quattro canali matematici fondamentali del rumore quantistico [15].

## 4.6 Impatto del Rumore sull'Algoritmo di Shor

L'algoritmo di Shor è particolarmente vulnerabile al rumore a causa della sua elevata profondità circuitale e della dipendenza critica dalla precisione delle fasi. La

Figura 4.2 localizza le quattro fonti fisiche sulle fasi dell’algoritmo: ciascuna colpisce prevalentemente uno stadio diverso della pipeline.




Figura 4.2: Localizzazione delle quattro fonti fisiche di rumore sulla pipeline dell’algoritmo di Shor. La decoerenza ① domina l’esponenziazione modulare (lo stadio più profondo,  $O(n^3)$  gate); gli errori di gate ② si accumulano su tutti i CX e sono particolarmente critici sulle rotazioni ad angolo piccolo della  $QFT^{-1}$ ; l’errore di lettura ③ colpisce la misura finale, tanto più quanto più il circuito arriva “lungo” al bordo di coerenza; il crosstalk ④ agisce trasversalmente ovunque vi siano operazioni parallele su qubit adiacenti, secondo la topologia del dispositivo (Sezione 4.2).

Le tre componenti più sensibili sono:

#### 4.6.1 Errori nella Quantum Fourier Transform

La QFT richiede porte di rotazione di fase  $R_k = \text{diag}(1, e^{2\pi i/2^k})$  con angoli esponenzialmente piccoli all’aumentare di  $k$ . Per  $k = 10$ , l’angolo è  $2\pi/1024 \approx 6 \times 10^{-3}$  rad. Un canale depolarizzante di intensità  $\epsilon$  su ciascuno degli  $n$  gate di rotazione accumula un errore di fase  $O(n\epsilon)$ , degradando la struttura di interferenza da cui dipende la corretta estrazione del periodo.

#### 4.6.2 Errori nella Phase Estimation

La phase estimation richiede che i qubit del registro di controllo mantengano la coerenza per tutta la durata del circuito di modular exponentiation, che ha profondità

$O(n^3)$ . La condizione necessaria è:

$$T_2 \gg \tau_{\text{gate}} \cdot O(n^3) \quad (4.9)$$

Sui processori NISQ attuali, questa condizione è violata già per  $n \gtrsim 10$ –15 bit.

### 4.6.3 Errori nella Modular Exponentiation

La modular exponentiation è la componente con la maggiore profondità. Modellando ogni gate con un canale depolarizzante di intensità  $\epsilon$ , la probabilità di successo è:

$$P_{\text{success}} \approx P_{\text{ideal}} \cdot (1 - \epsilon)^L, \quad L \sim O(n^3) \quad (4.10)$$

Per  $n = 15$  bit e  $\epsilon = 10^{-3}$ :  $(1 - 10^{-3})^{3375} \approx 0.034$  — la probabilità di risultato corretto crolla al 3.4% già per istanze molto piccole. La Figura 4.3 mostra come questo crollo si accentui drammaticamente all’aumentare di  $n$  e di  $\epsilon$ .




Figura 4.3: Probabilità di successo dell’algoritmo di Shor  $P_{\text{success}} \approx (1 - \epsilon)^{n^3}$  in funzione della dimensione dell’input  $n$  (in bit), per cinque valori di intensità di rumore depolarizzante  $\epsilon$ . Anche con  $\epsilon = 10^{-3}$  (fedeltà gate 99.9%), già per  $n = 15$  la probabilità di ottenere un risultato corretto scende al 3.4%. La linee tratteggiate orizzontali evidenziano le soglie del 50% e del 5%.



## 4.7 Sfide Pratiche su Hardware NISQ

- **Requisiti di qubit:** fattorizzare un intero a  $n$  bit richiede almeno  $2n$  qubit logici per la phase estimation, più ausiliari per la modular exponentiation.
- **Profondità:** anche per  $N = 15$ , il circuito compilato su `ibm_marrakesh` supera i 187 gate a due qubit [4].
- **Soluzioni parziali:** gli esperimenti su IBM hanno dimostrato la fattorizzazione di  $N = 15$  e  $N = 21$  solo con circuiti appositamente semplificati, non generalizzabili a  $N$  arbitrario [7].

Il problema non è di natura algoritmica ma fisica: l'algoritmo di Shor è teoricamente corretto, ma il substrato hardware introduce errori che ne compromettono l'output. Affrontare questo problema richiede strategie che operano a diversi livelli, dall'hardware al post-processing classico. Il capitolo seguente esamina queste strategie con particolare attenzione alla QEC e al suo inquadramento come sottocategoria del *Quantum Machine Learning* (QML), che costituisce l'approccio adottato in questa tesi.

## Capitolo 5

# Strategie per la Riduzione del Rumore Quantistico

Il capitolo precedente ha mostrato che il rumore quantistico non è un fastidio marginale: per l'algoritmo di Shor, già per istanze piccole come  $N = 15$ , la probabilità di ottenere un risultato corretto crolla al di sotto del 4% su hardware reale. Il problema è reale e quantificato, e richiede strategie concrete di mitigazione.

In letteratura si distinguono quattro macro-strategie. Questo capitolo le presenta in ordine crescente di complessità, spiega perché le prime tre non sono adatte al contesto di questa tesi, e approfondisce la quarta — il **Quantum Machine Learning** (QML) — che costituisce l'approccio adottato. Al suo interno, la **Correzione degli Errori Quantistici** (QEC) rappresenta la componente strutturale centrale, e il suo funzionamento viene spiegato nel dettaglio.

### 5.1 Le Quattro Strategie: Panoramica e Scelta

Le quattro macro-strategie per fronteggiare il rumore nei sistemi quantistici sono:

1. **Soppressione del rumore** (*Noise Suppression*): agisce *prima* che gli errori si manifestino, cercando di ridurre fisicamente l'accoppiamento tra il qubit e l'ambiente. Le tecniche principali sono il *Dynamical Decoupling* — sequenze di pulse che mediano a zero l'interazione con l'ambiente — l'ottimizzazione della durata dei gate, e l'isolamento fisico criogenico ed elettromagnetico dell'hardware. Riduce il rumore ma non lo elimina, ed è vincolata alle possibilità dell'hardware disponibile.

2. **Mitigazione degli errori** (*Error Mitigation*): opera *a posteriori*, senza correggere i qubit durante il calcolo. Si eseguono molte istanze del circuito con diversi livelli di rumore o con randomizzazioni, e si combinano i risultati classicamente per stimare l'output ideale. Le tecniche più diffuse sono la *Zero-Noise Extrapolation* (ZNE), il *Probabilistic Error Cancellation* (PEC) e il *Gate Twirling*. Il limite fondamentale è l'overhead esponenziale nel numero di campionamenti richiesti.
3. **Tolleranza ai guasti** (*Fault-Tolerant Quantum Computing*): è il paradigma architetturale a lungo termine. Codifica ogni qubit *logico* in molti qubit *fisici* e garantisce che, fintanto che il tasso di errore per gate rimane sotto una soglia critica (*threshold theorem* [16]), il tasso di errore logico può essere abbassato a valori arbitrariamente piccoli. Richiede però migliaia di qubit fisici per ogni qubit logico protetto — risorse ancora fuori dalla portata dell'hardware attuale.
4. **Quantum Machine Learning** (QML): sfrutta modelli di apprendimento automatico per apprendere il profilo di errore specifico dell'hardware e compensarlo senza richiedere un modello analitico del canale di rumore. È l'approccio più adattivo e flessibile, applicabile sia su hardware NISQ che su architetture future. Al suo interno, la QEC è la sottocategoria che gestisce la protezione strutturale dell'informazione quantistica.

| Strategia         | Quando agisce     | Overhead           | Era       | Adottata  |
|-------------------|-------------------|--------------------|-----------|-----------|
| Noise Suppression | Prima del calcolo | Basso (hardware)   | NISQ / FT | No        |
| Error Mitigation  | Dopo il calcolo   | Esponenziale       | NISQ      | No*       |
| Fault-Tolerant QC | Architetturale    | Molto alto (qubit) | Futuro    | No        |
| QML (incl. QEC)   | Ibrido (online)   | Medio (classico)   | NISQ / FT | <b>Sì</b> |

Tabella 5.1: Confronto delle quattro strategie anti-rumore per il contesto di questa tesi.

\*La ZNE non è adottata come strategia principale, ma viene confrontata *a posteriori* con  $M_{\text{TOP4}}$  nel Capitolo 7: ZNE-2 e ZNE-3 non riducono significativamente le iterazioni rispetto alla baseline, a fronte di un costo da due a tre volte superiore in shot.

**Motivazione per l'approccio QML.** Le prime tre strategie presentano limitazioni che le rendono inadatte al contesto di questa tesi. La soppressione del rumore è vincolata all'hardware disponibile e non è controllabile a livello software. La mitigazione degli errori richiede un numero esponenziale di esecuzioni, incompatibile con

l'obiettivo di ridurre il numero di iterazioni necessarie. La tolleranza ai guasti richiede risorse hardware ancora inesistenti. Il QML, al contrario, può essere applicato su qualunque simulatore o processore reale, si adatta al profilo di errore specifico del dispositivo senza un modello analitico, e — come si vedrà nella sezione 5.4 — riduce drasticamente il numero di esecuzioni necessarie per ottenere un risultato affidabile.

## 5.2 Quantum Machine Learning per la Robustezza al Rumore

Il QML, nel contesto della robustezza al rumore, non si riferisce all'uso di algoritmi quantistici per fare machine learning, bensì all'uso di modelli di *machine learning classici o ibridi* per compensare gli effetti del rumore su circuiti quantistici. L'idea fondamentale è semplice: invece di costruire un modello analitico del canale di rumore — operazione complessa e spesso impossibile per hardware reale con errori correlati e non stazionari — si lascia che un modello apprenditivo impari direttamente dalla distribuzione degli output rumorosi.

Le tre declinazioni principali del QML nel contesto di questa tesi sono:

- **Caratterizzazione del rumore:** un modello di regressione (Random Forest, rete neurale) apprende la relazione tra i parametri hardware ( $T_1$ ,  $T_2$ , profondità del circuito) e la fedeltà dell'output, permettendo di predire la qualità del risultato prima di eseguire il circuito.
- **Ottimizzazione variazionale:** i parametri del circuito (decomposizione della modular exponentiation, routing dei qubit) vengono ottimizzati tramite agenti di Reinforcement Learning che massimizzano la probabilità di successo sul simulatore rumoroso, adattando il circuito al profilo di errore specifico del dispositivo.
- **Correzione degli errori (QEC):** una rete neurale o un classificatore impara a decodificare le sindromi di errore e a determinare la correzione ottimale. Questa è la sottocategoria strutturalmente più profonda del QML e viene approfondita nella sezione seguente.

## 5.3 La Correzione degli Errori Quantistici come Sottocategoria del QML

### 5.3.1 Il Problema Fondamentale

Come si visto nel capitolo precedente, il teorema del no-cloning impedisce di proteggere un qubit semplicemente duplicandolo, come si farebbe con un bit classico. Eppure la correzione degli errori quantistici è possibile — e questa fu una delle scoperte più sorprendenti degli anni Novanta. Il principio è che si può *distribuire* l'informazione di un qubit logico su più qubit fisici in modo tale che, misurando opportune quantità collettive (le **sindromi**), sia possibile rilevare e correggere gli errori senza mai misurare — e quindi distruggere — lo stato logico.

### 5.3.2 Il Paradigma in Tre Fasi

Qualunque codice di correzione degli errori quantistici funziona secondo lo stesso schema:

1. **Codifica:** lo stato logico  $|\psi_L\rangle$  viene distribuito su  $n$  qubit fisici tramite un circuito di codifica. L'informazione è ridondante: nessun singolo qubit fisico contiene da solo l'informazione logica.
2. **Misura di sindrome:** si misurano operatori stabilizzatori — operatori che commutano con tutti i codeword ma anticommutano con gli operatori di errore. Questi operatori forniscono informazione sull'errore avvenuto senza rivelare il valore del qubit logico. Il risultato della misura è la **sindrome**, un vettore binario che identifica quale errore (o classe di errori) si è verificato.
3. **Decodifica e correzione:** dato il vettore di sindrome, un algoritmo di decodifica determina l'operazione di recupero da applicare per ripristinare lo stato logico corretto. Questa è la fase in cui entra il QML: i decoder tradizionali (minimum-weight perfect matching, look-up table) vengono sostituiti da reti neurali addestrate a inferire la correzione più probabile, con prestazioni superiori in regimi di rumore realistico e non-omogeneo.

### 5.3.3 I Principali Codici Quantistici

Nel corso degli anni sono stati sviluppati numerosi codici di correzione. I tre più rilevanti per questa tesi sono:

**Codice di Shor (1995).** Il primo codice di correzione degli errori quantistici [17], proposto dallo stesso Peter Shor dell’algoritmo di fattorizzazione, codifica 1 qubit logico in 9 qubit fisici ed è in grado di correggere qualsiasi errore singolo (bit flip, phase flip o entrambi). Lo stato logico è:

$$|0_L\rangle = \frac{1}{2\sqrt{2}}(|000\rangle + |111\rangle)^{\otimes 3}, \quad |1_L\rangle = \frac{1}{2\sqrt{2}}(|000\rangle - |111\rangle)^{\otimes 3} \quad (5.1)$$

La struttura è a due livelli: tre copie del qubit (ciascuna nella forma  $|000\rangle \pm |111\rangle$ ) proteggono da phase flip tramite interferenza; la ripetizione delle tre copie protegge da bit flip tramite ridondanza. Questo risultato dimostrò per la prima volta che il teorema del no-cloning non impedisce la correzione degli errori quantistici.

**Codice di Steane (1996).** Il codice di Steane [18] riduce l’overhead a 7 qubit fisici per 1 qubit logico, sfruttando la struttura del codice classico di Hamming [7, 4, 3]. Corregge qualsiasi errore singolo ed è il primo esempio di codice CSS (Calderbank–Shor–Steane) [19], una famiglia sistematica di costruzioni che collegano codici classici lineari a codici quantistici.

**Surface Code.** Il **surface code** [20] è oggi il codice più promettente per implementazioni su hardware reale, ed è quello su cui IBM e Google stanno costruendo le loro architetture fault-tolerant. Organizza i qubit fisici in una griglia 2D con interazioni solo tra qubit vicini — un requisito compatibile con le architetture superconduttrici. La sua proprietà chiave è il **threshold**: fintanto che il tasso di errore per gate rimane sotto circa 1%, aumentare la distanza  $d$  del codice abbassa il tasso di errore logico in modo esponenziale.<sup>1</sup> Per distanza  $d$ , il codice usa  $d^2$  qubit fisici per 1 qubit logico e corregge fino a  $\lfloor (d-1)/2 \rfloor$  errori.

### 5.3.4 Perché la QEC è una Sottocategoria del QML

Il legame tra QEC e QML emerge nella fase di decodifica. I decoder tradizionali assumono un modello di rumore semplice e stazionario, ma sull’hardware reale il

---

<sup>1</sup>Il threshold preciso dipende dal modello di rumore:  $\approx 1.1\%$  per rumore depolarizzante indipendente,  $\approx 0.5\text{--}0.7\%$  per modelli più realistici con correlazioni spaziali. I migliori processori IBM e Google si avvicinano oggi a queste soglie.

rumore è correlato, non uniforme e varia nel tempo. Un modello appreso non ha bisogno di quel modello analitico: ricava dai campioni di sindrome la correzione più probabile, adattandosi al profilo di errore specifico del dispositivo [21, 22]. In questo senso la QEC non è una strategia separata dal QML, ma il terreno su cui l'apprendimento automatico agisce nel punto strutturalmente più favorevole: sulla sindrome, dove l'informazione sull'errore è ancora presente, e non sull'output finale, dove è già stata distrutta.

Questa affermazione non resta, in questo lavoro, un richiamo alla letteratura: è verificata sperimentalmente nella Sezione 9.6, che confronta un decoder appreso con il decoder analitico standard sugli stessi campioni di sindrome. L'esito, anticipato qui perché delimita fin d'ora la portata della tesi appena enunciata, è duplice e va formulato con precisione: *sostituire* il decoder analitico con una rete non conviene — a parità di modello di rumore la rete lo pareggia soltanto, e a costo di volumi di dati considerevoli — mentre *affiancarglielo* produce un guadagno misurabile quando il rumore reale esce dal modello che il decoder analitico presuppone. È la stessa asimmetria che il Capitolo 7 incontrerà a valle dell'esecuzione, e la ragione per cui l'inquadramento della QEC come specializzazione del QML va inteso in senso stretto: non ogni impiego dell'apprendimento automatico nella correzione d'errore è utile, ma quello che opera sulla sindrome lo è.

## 5.4 Motivazione Pratica: il Contributo di questa Tesi

Chiarito il framework teorico, è importante spiegare concretamente cosa porta il QML rispetto all'alternativa più semplice.

**Senza ML — approccio statistico classico.** In assenza di un modello appreso, per determinare il risultato corretto dell'algoritmo di Shor in presenza di rumore è necessario eseguire il circuito molte volte, raccogliere la distribuzione degli output e analizzarne la forma. In condizioni ideali la distribuzione mostra picchi netti ai valori corretti (si veda il Capitolo 7); in presenza di rumore i picchi si allargano e si sovrappongono al fondo, rendendo necessaria un'analisi statistica per identificare il valore più probabile. Questo approccio richiede decine o centinaia di esecuzioni prima di raggiungere una confidenza sufficiente.

**Con ML — l'ipotesi che questa tesi mette alla prova.** L'ipotesi di partenza è addestrare un classificatore che, ricevuto in ingresso l'output di una singola esecuzione

dell'algoritmo di Shor su simulatore rumoroso, determini se quel risultato è corretto o meno: se il modello impara a distinguere i pattern di output corretto da quelli distorti dal rumore, dovrebbero bastare poche iterazioni (l'ipotesi quantitativa è  $\approx 3$ ) per ottenere una risposta affidabile, senza costruire una distribuzione statistica completa.

La prima fase sperimentale di questa tesi verifica rigorosamente questa ipotesi, e il suo esito è più interessante di una semplice conferma: la riduzione delle iterazioni si ottiene davvero (da  $\bar{M}_1 = 1.97$  a  $\bar{M} = 1.00$  per UC1), ma l'analisi di ablazione dimostra che il merito non è del classificatore, bensì della strategia di ricerca multi-candidato TOP-K che lo accompagna. Il risultato negativo sul filtro ML, documentato sperimentalmente, delimita il regime in cui il QML applicato all'output non apporta valore.

È questo esito a determinare la struttura del resto dell'elaborato. Il Capitolo 6 descrive gli strumenti, l'architettura e l'implementazione del sistema sperimentale, e il Capitolo 7 riporta la verifica con la relativa ablazione. Poiché tale verifica stabilisce che a valle dell'esecuzione non resta informazione da sfruttare, il **nucleo del lavoro** si sposta là dove l'errore può ancora essere intercettato — durante il calcolo — e occupa i tre capitoli successivi: la costruzione e la caratterizzazione dei codici correttori, dal codice a ripetizione al codice di Steane (Capitolo 8); il surface code, la stima sperimentale dell'errore logico e il confronto fra decodifica analitica e appresa (Capitolo 9); l'integrazione con l'algoritmo attraverso il modello dello Shor logico (Capitolo 10). È in questa seconda parte che le due strategie selezionate in questo capitolo — QML e QEC — si ricongiungono nella forma che la Sezione 5.3.4 ha anticipato.



# Capitolo 6

## Metodo e Implementazione

Il capitolo precedente ha concluso la parte teorica della tesi con un’ipotesi precisa da mettere alla prova: che il QML, nella sua declinazione di classificatore addestrato per la rilevazione degli errori, riduca in misura significativa il numero medio di esecuzioni necessarie ( $\rho = \bar{M}_1/\bar{M}_2 \gg 1$ ), portandolo a circa tre. Questo capitolo definisce il sistema sperimentale costruito per verificarla, e risponde in sequenza a tre domande: con quali strumenti si lavora, con quale disegno, e come quel disegno è stato realizzato in codice.

Si tratta dell’architettura della *prima fase* del lavoro: l’esito della verifica — che il guadagno osservato è reale ma attribuibile alla ricerca multi-candidato e non al classificatore (Capitolo 7) — motiva la seconda fase, che adotta un’architettura diversa perché diversa ne è la natura. Il protocollo sperimentale di ciascun codice correttore, essendo specifico del codice, è descritto nel capitolo che lo introduce (Capitoli 8–10); l’infrastruttura comune — organizzazione del codice, divisione degli strumenti fra Qiskit, Stim e PyMatching, e disciplina di riproducibilità — è nella Sezione 6.13.

### 6.1 Strumenti e Ambiente di Simulazione

Questa sezione riassume gli strumenti software e l’ambiente usati nella parte sperimentale. La motivazione estesa di ciascuna scelta — il confronto tra i framework, i metodi di simulazione di Aer, le specifiche GPU e la configurazione WSL — è riportata nella Sezione B.1.

**Framework: Qiskit + Qiskit Aer.** L’intera pipeline usa **Qiskit** [23], l’SDK di IBM Quantum, e il suo simulatore **Qiskit Aer**. La scelta è motivata dalla coerenza

con l’hardware superconduttore IBM su cui è calibrato il modello di rumore, dalla maturità del noise model di Aer rispetto alle alternative (Cirq, PennyLane), e dall’allineamento con la letteratura e con l’implementazione di riferimento dell’algoritmo di Shor [7, 24].

**Metodo di simulazione e limite di scala.** Tra i metodi di `AerSimulator` si adotta `statevector` (simulazione esatta del vettore di stato), per la precisione numerica richiesta dagli use case a 11–18 qubit. Il costo in memoria cresce come  $2^n$  (ampiezze `complex128`): con 12 GB di memoria il limite pratico è  $\approx 30$  qubit. È questo vincolo esponenziale a rendere impraticabile la simulazione diretta dello Shor logico con surface code e a imporre l’uso di Stim per i circuiti *stabilizer* della QEC (Capitoli 9 e 10).

**Strumenti della parte QEC.** La stima del *logical error rate* del surface code richiede milioni di esecuzioni di circuiti stabilizer, fuori portata per un simulatore statevector. Si adottano quindi due strumenti specializzati: **Stim** [25] (versione 1.16.0), che campiona *detection events* di circuiti Clifford sfruttando il teorema di Gottesman–Knill, e **PyMatching** [26] (versione 2.4.0), che implementa la decodifica MWPM a partire dal modello di errore del circuito. La divisione dei compiti — Qiskit Aer per i circuiti generali di piccola taglia, Stim e PyMatching per la QEC stabilizer — è discussa nel Capitolo 10.

**Modello di rumore.** Il modulo `qiskit_aer.noise` compone errore **depolarizzante**, **rilassamento termico**  $T_1/T_2$  e **readout error** (matrice di confusione), con parametri calibrati sull’hardware `ibm_marrakesh` [5]; la configurazione dettagliata è nel Capitolo 2. Prima dell’esecuzione i circuiti sono transpilati (`optimization_level=2`) per minimizzare profondità e accumulo di errori.

**Machine learning e ambiente.** Il classificatore del Metodo 2 è addestrato con **scikit-learn** [27], scelto per l’interfaccia unificata `fit/predict` che consente di confrontare più modelli sullo stesso dataset. Le simulazioni girano in **WSL2** (Ubuntu 22.04) su CPU: l’accelerazione Unità di Elaborazione Grafica (*Graphics Processing Unit*) (GPU) tramite `qiskit-aer-gpu` (NVIDIA RTX 4070) era prevista dal piano iniziale ma non è risultata utilizzabile in questo ambiente — il motivo tecnico e le conseguenze sui tempi di esecuzione sono documentati nella Sezione 6.7.2. Su questa base, il Capitolo 6 descrive l’architettura del pipeline sperimentale.

Stabiliti gli strumenti, la domanda successiva riguarda il disegno: quali componenti compongono il sistema, come si raccordano, e perché. Le sezioni che seguono descrivono l’architettura della pipeline e la struttura dei due metodi messi a confronto. Non si entra ancora nella descrizione del codice — quella è oggetto della Sezione 6.7

e seguenti — né dei risultati: qui si stabilisce il *perché* di ciascuna scelta progettuale e il *come* i componenti si raccordano tra loro.

## 6.2 Obiettivi della Parte Sperimentale

La parte sperimentale di questa tesi ha due obiettivi distinti ma complementari, che corrispondono ai due metodi sviluppati.

Il primo obiettivo è costruire una **baseline affidabile**: una misura quantitativa del numero di esecuzioni che l'approccio classico, privo di qualunque modello appreso, richiede per ricavare il risultato corretto dell'algoritmo di Shor in presenza di rumore. Questo primo metodo — chiamato nel seguito **Metodo 1** — opera su una singola esecuzione per volta: raccoglie l'istogramma degli output, ne prende la misura più frequente e tenta da quella l'estrazione dei fattori (strategia **TOP-1**); se il tentativo fallisce, l'iterazione viene ripetuta. Il Metodo 1 non introduce ipotesi sul profilo di errore del sistema: funziona su qualunque noise model e non richiede dati di addestramento. È il punto di partenza naturale e il termine di paragone contro cui misurare il miglioramento.

Il secondo obiettivo è dimostrare che un **classificatore addestrato** può sostituire l'accumulazione statistica con una decisione informata basata su una singola esecuzione. Questo secondo metodo — chiamato **Metodo 2** — apprende la firma degli output corretti e di quelli distorti dal rumore, e decide dopo ogni esecuzione se il risultato è affidabile o meno. L'ipotesi, motivata teoricamente nel Capitolo 5 e corroborata dalla letteratura recente sull'uso del ML per la mitigazione degli errori quantistici [28], è che bastino poche iterazioni — tipicamente dell'ordine di tre — per convergere.

Entrambi i metodi vengono valutati su **quattro use case** indipendenti, scelti per coprire diverse configurazioni di istanza e livello di rumore, secondo un requisito metodologico consolidato per la validazione accademica dei risultati sperimentali in questo dominio [3]. Come documentato nel Capitolo 7, il confronto quantitativo risulterà praticabile sui due use case per  $N = 15$ : per  $N = 21$  e  $N = 35$  la profondità del circuito traspirato azzerava la probabilità di successo di qualunque strategia, esito che il presente lavoro quantifica come barriera di scalabilità.

## 6.3 Architettura del Pipeline Sperimentale

Il sistema è strutturato come un pipeline a tre stadi sequenziali, illustrato in Figura 6.1.




Figura 6.1: Pipeline sperimentale. Il circuito ideale dell’algoritmo di Shor viene eseguito sul simulatore rumoroso **AerSimulator** di Qiskit. L’output è elaborato in parallelo dal Metodo 1 (estrazione dalla sola misura più frequente, TOP-1) e dal Metodo 2 (classificatore ML seguito da ricerca multi-candidato TOP-K). Entrambi producono i fattori di  $N$  e le metriche di confronto.

**Stadio 1 — Il circuito di Shor.** Il circuito dell’algoritmo di Shor è tratto dall’implementazione open-source di riferimento disponibile su GitHub [24]. Si tratta di un’implementazione ideale, costruita per un simulatore privo di rumore: in assenza di errori produce sempre la fattorizzazione corretta. Questo punto di partenza è una scelta deliberata. L’obiettivo della tesi non è modificare l’algoritmo, bensì studiare il suo comportamento su un simulatore realistico e sviluppare strumenti per recuperare l’informazione corretta nonostante la degradazione introdotta dal rumore.

**Stadio 2 — La simulazione rumorosa.** Il circuito ideale viene eseguito tramite il simulatore **AerSimulator** di Qiskit con un modello di rumore che replica le caratteristiche fisiche di un processore superconduttore NISQ. La scelta di un simulatore — anziché di un processore reale — consente di controllare con precisione i parametri di rumore, garantisce la riproducibilità degli esperimenti e permette di generare grandi dataset di addestramento per il classificatore del Metodo 2 senza i vincoli di accesso e costo tipici dell’hardware IBM Quantum. Il modello di rumore adottato è descritto in dettaglio nel Capitolo 2; la sua configurazione segue la metodologia proposta in [5] per la selezione e il calibrazione dei parametri di emulazione rispetto a backend reali.

**Stadio 3 — L’analisi.** L’output del simulatore viene elaborato indipendentemente dai due metodi. I risultati prodotti da entrambi vengono confrontati sulle stesse metriche e sugli stessi use case, garantendo la comparabilità del confronto.

## 6.4 Tecniche di Mitigazione del Rumore: Analisi e Scelte Implementative

Prima di descrivere i due metodi, è necessario motivare una scelta di fondo: *quali leve di mitigazione sono disponibili in questo contesto, e quali sono state adottate?* Il Capitolo 5 ha classificato le macro-strategie; qui si scende al livello operativo, analizzando le tecniche concrete applicabili sul simulatore Qiskit e spiegando perché alcune sono state adottate, altre scartate e altre ancora mantenute come termine di confronto.

Le tecniche disponibili si raggruppano in tre livelli di intervento: a livello di circuito (prima dell'esecuzione), a livello di misura (durante o subito dopo), e a livello di post-processing (sull'output classico).

### 6.4.1 Livello di Circuito: Transpilazione e Riduzione della Profondità

La sorgente di errore più diretta in un circuito quantistico rumoroso è la profondità del circuito stesso: ogni gate a due qubit (Controlled-X (porta CNOT) (CX)) introduce una probabilità di errore non trascurabile, e l'effetto si accumula in modo approssimativamente moltiplicativo. L'intervento più efficace — e con il minore overhead computazionale — è quindi ridurre il numero di gate CX prima dell'esecuzione.

Nel contesto dell'algoritmo di Shor, il collo di bottiglia è la **modular exponentiation**  $U_f : |x\rangle |0\rangle \mapsto |x\rangle |a^x \bmod N\rangle$ , la parte del circuito che implementa la funzione periodica il cui periodo  $r$  viene estratto dalla QPE. Realizzarla come operatore unitario denso, sintetizzato dal transpiler a partire dalla sua matrice, costa  $O(4^k)$  porte elementari su  $k$  qubit [29]: un andamento esponenziale che rende il circuito impraticabile non appena l'istanza cresce.

La **decomposizione di Beauregard** [11] evita la sintesi densa costruendo l'aritmetica modulare nel dominio della QFT con addizionatori di Draper, e ottiene un circuito di  $O(n^3)$  porte elementari su  $2n + 3$  qubit per un modulo di  $n$  bit. Il guadagno è di ordini di grandezza: per  $N = 21$  il modulo `beauregard.py` sviluppato in questa tesi produce circa 2 594 porte CX, contro le oltre 10 000 della sintesi densa.

Va però dichiarato con precisione lo stato di questa ottimizzazione nel presente lavoro: **gli esperimenti riportati nei capitoli seguenti non la utilizzano**. I circuiti effettivamente eseguiti impiegano la decomposizione densa, ed è questa la

ragione per cui i use case UC3 e UC4 risultano fuori portata (Capitolo 7, Tabella 7.1). Il modulo Beauregard è stato implementato e verificato sul conteggio delle porte, ma la sua validazione sperimentale completa eccede le risorse di calcolo disponibili ed è discussa fra gli sviluppi futuri (Capitolo 11). Per  $N = 15$ , l'istanza su cui il confronto è condotto, la decomposizione adottata resta comunque efficiente — 166 porte a due qubit in tutto — perché sfrutta matrici di permutazione già quasi ottimali.

Un ulteriore livello di riduzione è offerto dalla **transpilazione** di Qiskit: il transpiler decompone le porte nel gate set nativo del backend target, cancella sequenze identità e riordina i gate commutanti. Tutti gli esperimenti adottano `optimization_level=2`, per le ragioni discusse nella Sezione 6.4.4.

## 6.4.2 Livello di Misura: Mitigazione degli Errori di Readout

Gli errori di *readout* — la probabilità che un qubit nello stato  $|0\rangle$  venga letto come 1 e viceversa — sono una fonte di errore sistematica e in larga parte correggibile. La tecnica standard è la **calibrazione della matrice di assegnazione**: si preparano gli stati base  $|00\dots 0\rangle$ ,  $|10\dots 0\rangle$ , ... e si misurano le distribuzioni degli output; la matrice  $A_{ij} = P(\text{output} = i \mid \text{preparato} = j)$  viene poi invertita e applicata al vettore delle frequenze osservate.

Nel contesto di questa tesi la readout mitigation non è stata adottata come tecnica principale per due ragioni. Prima, il modello di rumore del simulatore **AerSimulator** include già errori di readout calibrati su hardware IBM reale: la probabilità di errore è dell'ordine di  $10^{-2}$  per qubit, un valore che il classificatore del Metodo 2 può compensare implicitamente senza richiedere la costruzione esplicita della matrice di calibrazione. Seconda, per i circuiti QPE con 9–20 qubit, la matrice di calibrazione ha dimensione  $2^n \times 2^n$ : la sua costruzione richiederebbe  $2^n$  preparazioni aggiuntive, un overhead incompatibile con l'obiettivo di minimizzare le esecuzioni. La readout mitigation è stata però inclusa nell'analisi a posteriori del Capitolo 7 come tecnica di confronto.

## 6.4.3 Livello di Post-processing: Zero-Noise Extrapolation

La **Zero-Noise Extrapolation** (ZNE) [30] è una tecnica di mitigazione che opera interamente in post-processing: si esegue il circuito a più livelli di rumore artificialmente amplificato (tipicamente  $\lambda = 1, 2, 3$  volte il rumore nominale, ottenuto per gate folding o pulse stretching), si misura il valor medio dell'osservabile di interesse

per ciascun livello, e si estrapolano i valori verso  $\lambda = 0$  tramite una regressione lineare o polinomiale.

Il pregio della ZNE è che non richiede conoscenza del modello di rumore e produce una stima dell'output ideale direttamente dall'output rumoroso. Il limite, nel contesto di questa tesi, è duplice. Da un lato, richiede almeno  $k \geq 2$  esecuzioni per ogni singola stima — il che contrasta direttamente con l'obiettivo del Metodo 2 di convergere in circa tre iterazioni totali. Dall'altro, l'amplificazione del rumore degrada ulteriormente la fedeltà dei gate già ai livelli  $\lambda = 2$  e  $\lambda = 3$ : per circuiti profondi come quello di Shor, il gate folding introduce errori aggiuntivi che non si distribuiscono linearmente e rendono l'estrapolazione inaffidabile.

Per questi motivi la ZNE non è stata adottata come tecnica principale. Essa compare però nel Capitolo 7 come termine di confronto sperimentale: i risultati mostrano che ZNE-2 e ZNE-3 non migliorano in modo significativo il numero di iterazioni rispetto alla baseline, a fronte di un costo in shot da due a tre volte superiore.

#### 6.4.4 Che Cosa Conta Davvero: l'Analisi di Sensibilità

Le tre tecniche appena discusse agiscono su parametri diversi, e sceglierne una richiede di sapere quale parametro incida realmente sull'esito. Prima di fissare l'architettura è stata quindi condotta una campagna a variazione singola sui sette parametri del modello di rumore e della strategia di ricerca, i cui risultati completi — con il confronto fra previsione ed esito per ciascun parametro — sono nella Sezione D.1 dell'Appendice D. Qui interessano le tre conseguenze che hanno orientato le scelte implementative.

**Nessun parametro del modello di rumore degrada la convergenza in modo apprezzabile.** Errori sui gate a singolo qubit, tempi di decoerenza e readout error risultano influenti su tutti gli intervalli testati —  $p_{ro}$  fino al 20% — e producono  $\bar{M} = 1.00$  con tasso di successo pieno. Il solo  $\varepsilon_{2q}$  lascia una traccia, facendo oscillare  $\bar{M}_1$  fra 1.3 e 2.0 senza andamento monotono, ma senza mai far scendere il successo sotto il 100%. Ne discende che **readout mitigation e ottimizzazioni di  $T_1/T_2$  sono inutili per  $N = 15$** : adottarle avrebbe aggiunto complessità senza impatto misurabile.

**La ZNE è inefficace su questo compito.** Il confronto sperimentale (Capitolo 7) mostra che né l'estrapolazione lineare né quella di Richardson riducono in modo statisticamente significativo il numero di iterazioni, pur richiedendo da due a tre

volte più shot. Il motivo è coerente con quanto sopra: non c'è un bias sistematico da rimuovere, perché la distribuzione rumorosa conserva già il segnale che serve.

**La leva dominante è la decomposizione del circuito, non il livello di ottimizzazione del transpiler.** Uno sweep su `optimization_level` da 0 a 3 mostra un guadagno complessivo del 17% sul numero di porte soggette a errore a due qubit, contro il fattore che separa una decomposizione densa da una efficiente. Si adotta il livello 2, che raggiunge il minimo senza il costo della ricerca esaustiva del livello 3.

**Come va contato  $P_{\text{surv}}$ .** Una precisazione necessaria, perché la stima ricorre in tutto il lavoro. Il modello di rumore applica l'errore depolarizzante a due qubit non alle sole porte `cx`, ma all'insieme `[cx, swap, cp]`: l'esponente di  $P_{\text{surv}}$  è dunque il numero *complessivo* di porte soggette a quell'errore. Per UC1 la composizione è  $114 \text{ cx} + 52 \text{ cp}$ , da cui  $k = 166$  e  $P_{\text{surv}} = (1 - \varepsilon_{2q})^{166}$ . Le `cp` provengono dalla QFT inversa, che il transpiler conserva nel gate set nativo: trascurarle sottostima l'errore accumulato di un terzo, e per le istanze maggiori — dove la decomposizione di Beauregard costruisce l'aritmetica interamente nel dominio della QFT — di decine di ordini di grandezza.

### 6.4.5 Scelta Adottata: Classificatore ML come Filtro Adattivo

L'analisi delle tecniche disponibili converge su una conclusione: le ottimizzazioni a livello di circuito (Beauregard, transpilazione) sono necessarie e già applicate; le tecniche di mitigazione tradizionali (readout, ZNE) presentano overhead o limitazioni che le rendono incompatibili con l'obiettivo di minimizzare le esecuzioni su hardware NISQ.

L'approccio adottato in questa tesi è diverso per natura: invece di modificare il circuito o correggere l'output stimando l'ideale, si **addestra un classificatore che apprende la firma degli output corretti** direttamente dalla distribuzione degli output rumorosi. Il classificatore non riduce il rumore, ma impara a distinguere i casi in cui il rumore non ha compromesso il risultato dai casi in cui l'ha reso inaffidabile. Questo lo rende:

- **Adattivo:** si calibra sul profilo di errore specifico del simulatore o del backend, senza assumere un modello di rumore analitico.
- **A basso overhead:** richiede una singola esecuzione per decisione, invece delle  $k \geq 2$  esecuzioni della ZNE.



- **Complementare alle ottimizzazioni circuitali:** può essere impilato sopra la transpilazione ottimizzata senza conflitti.

Questa scelta è la premessa dei due metodi descritti nelle sezioni seguenti.

## 6.5 Il Metodo 1: Approccio Statistico Classico

Il Metodo 1 è l'approccio di riferimento: non richiede alcun addestramento, non assume nulla sul profilo specifico del rumore e si basa esclusivamente sulla struttura probabilistica degli output dell'algoritmo di Shor.

In condizioni ideali, la distribuzione degli output del registro di controllo presenta picchi netti a multipli di  $2^{n_{\text{count}}}/r$ , dove  $r$  è il periodo della funzione modulare. Il rumore appiattisce questi picchi, allarga la loro base e introduce un fondo uniforme di misure errate. Il metodo recupera il risultato attraverso i seguenti passi:

1. Eseguire il circuito per  $M_{\text{shots}}$  shot, raccogliendo il conteggio di frequenza di ogni stringa di output del registro di controllo.
2. Selezionare la misura  $y$  **più frequente** dell'istogramma. Non si applica alcuna sogliatura né alcun filtro preliminare: l'estrazione opera direttamente sulle misure ordinate per frequenza decrescente (Capitolo 2, Sezione 2.6).
3. Stimare  $r$  tramite l'algoritmo delle frazioni continue applicato al rapporto  $y/2^{n_{\text{count}}}$ .
4. Calcolare  $p = \gcd(a^{r/2} - 1, N)$  e  $q = \gcd(a^{r/2} + 1, N)$  e verificare che siano fattori non banali di  $N$ .
5. Se il tentativo fallisce, ripetere l'iterazione con un nuovo seed, fino a un massimo di  $M_{\text{max}}$  iterazioni.

Il numero di iterazioni necessarie per ottenere il primo risultato corretto cresce al crescere del livello di rumore. Questa quantità —  $\bar{M}_1$ , misurata sperimentalmente per ciascun use case — costituisce la baseline del confronto.

## 6.6 Il Metodo 2: Classificatore ML

Il Metodo 2 adotta un approccio radicalmente diverso: invece di costruire una distribuzione statistica, addestra un modello che impara a distinguere gli output

corretti da quelli compromessi dal rumore, e lo usa per decidere dopo *ogni singola* esecuzione se il risultato è affidabile.

L’idea è coerente con la direzione più recente della letteratura sull’utilizzo del ML per la mitigazione del rumore quantistico. Lavori come [28] hanno mostrato che classificatori classici — in particolare Random Forest e reti neurali multistrato — possono apprendere la struttura degli errori su circuiti NISQ con prestazioni superiori agli approcci tradizionali, e con un overhead computazionale significativamente minore rispetto a tecniche come la Zero-Noise Extrapolation. Nel dominio della correzione degli errori quantistici, decoder basati su reti neurali — tra cui il recente AlphaQubit di Google DeepMind [22] — hanno dimostrato che i modelli appresi possono superare i decoder analitici classici in presenza di rumore realistico e non omogeneo.

Il classificatore sviluppato in questa tesi opera su un problema più semplice: non decodifica sindromi di un codice topologico, ma decide se l’output di una singola esecuzione dell’algoritmo di Shor è corretto. Questo lo rende addestrabile con risorse moderate, il che è compatibile con l’ambiente NISQ in cui si lavora.

**Input del classificatore.** Il vettore di feature è costruito a partire dalla misurazione del registro di controllo: i valori dei  $n_{\text{count}}$  qubit e caratteristiche derivate, come la distanza dai picchi teorici attesi e l’entropia della distribuzione locale osservata nelle ultime esecuzioni.

**Output del classificatore.** Un’etichetta binaria: 1 se il risultato è corretto (ovvero se i fattori estratti tramite frazioni continue e Massimo Comune Divisore (*Greatest Common Divisor*) (GCD) sono fattori non banali di  $N$ ), 0 altrimenti.

**Fase di addestramento.** Il dataset viene generato interamente dal simulatore rumoroso: si eseguono migliaia di istanze del circuito con parametri di rumore variabili nell’intorno dei valori dei use case, si calcolano le etichette di correttezza e si addestra il classificatore con una divisione standard training/validation/test. La libreria adottata per l’addestramento è scikit-learn [27], che offre un’interfaccia unificata per confrontare diversi classificatori — Random Forest, *Support Vector Machine* (SVM), Percettrone Multistrato (*Multi-Layer Perceptron*) (MLP) — sullo stesso dataset, facilitando la selezione del modello migliore.

**Utilizzo in inferenza.** A regime, il classificatore viene invocato dopo ogni esecuzione. Non appena restituisce l’etichetta 1, il risultato viene accettato e il processo si interrompe. Il numero di invocazioni prima del primo 1 corretto è la quantità misurata e confrontata con  $\bar{M}_1$ .

Le specifiche funzionali complete del sistema — i parametri di input e output, la

struttura dei quattro use case e le metriche di valutazione quantitativa — sono formalizzate nel Capitolo 2, che definisce il contratto sperimentale che l’implementazione deve rispettare.

Il Capitolo 2 ha formalizzato il contratto sperimentale — quattro use case, i parametri di rumore ipotizzati e le metriche di confronto — e le sezioni precedenti hanno definito l’architettura della pipeline a tre stadi. Resta la terza domanda: che cosa è stato concretamente costruito. Le sezioni che seguono descrivono il setup dell’ambiente di esecuzione, l’integrazione dell’algoritmo di Shor con il simulatore rumoroso, l’implementazione dei due metodi di analisi della prima fase e, nella Sezione 6.13, quella dei codici correttori che costituiscono il nucleo della seconda. Non vengono qui riportati i risultati degli esperimenti — quelli sono oggetto dei Capitoli 7 e 8–10 — ma le scelte implementative, il codice sviluppato e la struttura del sistema che li ha prodotti.

## 6.7 Setup dell’Ambiente di Esecuzione

L’ambiente di esecuzione è stato configurato su *Windows Subsystem for Linux* (WSL) (Ubuntu 22.04 LTS) su Windows 11. La scelta di WSL garantisce la compatibilità con l’ecosistema Linux di Qiskit e delle librerie scientifiche Python, mantenendo al contempo l’integrazione con l’ambiente di sviluppo Windows. Sebbene il sistema disponga di una GPU NVIDIA RTX 4070, questa non è risultata utilizzabile per la simulazione quantistica in ambiente WSL2 (cfr. Sezione 6.7.2); tutti gli esperimenti sono stati eseguiti su CPU.

### 6.7.1 Dipendenze e Virtual Environment

Tutte le dipendenze sono isolate in un virtual environment Python dedicato, per garantire la riproducibilità dell’ambiente (Listato B.1).

### 6.7.2 Accelerazione GPU: Tentativo e Limitazione WSL

Il piano originale prevedeva l’uso di `qiskit-aer-gpu` con la scheda NVIDIA RTX 4070 per ridurre i tempi di simulazione di 10–20×. Sebbene il driver CUDA per WSL rilevi correttamente la GPU (`AerSimulator.available_devices()` restituisce `['GPU']`), il backend C++ di Qiskit Aer lancia un `RuntimeError` a runtime quando si tenta di eseguire un circuito con `device='GPU'` (Listato B.2).

Questa limitazione è nota nell’ecosistema WSL: la modalità di accesso alla GPU tramite CUDA for WSL 2 non è ancora pienamente supportata dal backend `statevector` di Qiskit Aer nella versione installata. Tutti gli esperimenti sono stati eseguiti su CPU (modalità `statevector`). Il throughput misurato su macchina dedicata (22 core) è di  $\approx 0.5$  s per campione da 1 024 shot su 12 qubit, ossia circa mezzo millisecondo per traiettoria; il costo cresce però di oltre quattro ordini di grandezza per le istanze maggiori, ed è quantificato nel Capitolo 7 (Tabella 7.2).

## 6.8 L’Algoritmo di Shor: Implementazione di Riferimento

Il circuito dell’algoritmo di Shor è tratto dal repository open-source di riferimento [24]. L’implementazione costruisce il circuito per un generico numero  $N$  e base  $a$ , usando  $n_{\text{count}}$  qubit per il registro di controllo e  $\lceil \log_2 N \rceil$  qubit per il registro di lavoro.

### 6.8.1 La Quantum Fourier Transform

La QFT è la subroutine centrale del circuito. Il suo circuito è implementato ricorsivamente tramite porte di Hadamard e rotazioni di fase controllate  $R_k = \text{diag}(1, e^{2\pi i/2^k})$  (Listato B.3).

### 6.8.2 La Moltiplicazione Modulare Controllata

Il blocco di *modular exponentiation* implementa l’operazione  $U_f |x\rangle |y\rangle = |x\rangle |y \cdot a^x \bmod N\rangle$ . Per istanze concrete, questo blocco viene compilato come sequenza di porte SWAP che realizzano la permutazione degli stati della base computazionale indotta dall’operatore  $x \mapsto ax \bmod N$  (Listato B.4).

### 6.8.3 Circuito Completo e Post-Processing

Il circuito completo combina i componenti precedenti nell’architettura a due registri dell’algoritmo di Shor. Il post-processing classico stima il periodo  $r$  tramite frazioni continue e calcola i fattori tramite il GCD (Listato B.5).

## 6.9 Configurazione del Noise Model

Il noise model è costruito con il modulo `qiskit_aer.noise` e include le tre principali fonti di errore presenti nei processori superconduttori NISQ, in linea con i parametri di riferimento dell'hardware `ibm_marrakesh` riportati nel tutorial ufficiale IBM [4] (Listato B.6).

## 6.10 Implementazione del Metodo 1

Il Metodo 1 adotta la strategia *TOP-1*: ad ogni iterazione esegue il circuito, identifica la misura più frequente nell'istogramma degli output e tenta la fattorizzazione tramite il post-processing classico. Il loop si interrompe non appena viene trovata una coppia di fattori non banali.

Una scelta critica di implementazione riguarda la traspilazione del circuito. Affinché il noise model sia applicato correttamente a *tutti* i gate, il simulatore deve essere istanziato con il noise model nel costruttore prima della traspilazione, e il livello di ottimizzazione deve essere pari a 2 (Listato B.7).

Senza il noise model nel costruttore, Qiskit Aer non decompone le porte Toffoli (CCX) presenti nell'espansione di `.control()`: le 27 porte CCX del circuito per  $N = 15$  rimangono nella netlist finale come gate non rumorosi, rendendo la simulazione non fisicamente accurata. Con `optimization_level=2` e il noise model nel costruttore, il circuito traspilato contiene esclusivamente porte elementari: per  $N = 15$ ,  $a = 7$ ,  $n_{\text{count}} = 8$  si ottengono 114 porte `cx`, 52 `cp`, 0 `ccx` e 0 `swap`, per una profondità complessiva di 311. Le porte soggette all'errore a due qubit sono dunque  $k = 166$ , non 114: le `cp` della QFT inversa appartengono al gate set nativo e sopravvivono alla traspilazione.<sup>1</sup>

**Limite di scalabilità per UC3 e UC4.** Per  $N = 21$  e  $N = 35$ , il blocco di moltiplicazione modulare viene implementato tramite `UnitaryGate` (matrice di permutazione) anziché la decomposizione textbook valida solo per  $N = 15$ . La sintesi di `UnitaryGate` da parte di Qiskit produce tuttavia circuiti con  $> 8000$  porte `cx` dopo la traspilazione, rendendo la probabilità di sopravvivenza coerente  $(1 - \epsilon_{2q})^{8000} \approx 0$

---

<sup>1</sup>La ripartizione fra `cx` e `cp` dipende dalla versione del transpiler: le campagne riportate in questa tesi sono state eseguite con Qiskit 2.x, mentre versioni precedenti producevano 162 `cx` e 28 `cp` con profondità 309 (cfr. Tabella D.10). Il totale  $k$  è assai più stabile del solo conteggio `cx`: 166 contro 194.

già a  $\epsilon_{2q} = 10^{-2}$ . Entrambi i metodi risultano quindi inutilizzabili per UC3 e UC4 in regime NISQ: l'analisi scalabilità è discussa nel Capitolo 7.

## 6.11 Implementazione del Metodo 2

Il Metodo 2 si articola in due fasi: la generazione del dataset e l'addestramento del classificatore (fase offline), e l'uso del classificatore con ricerca *TOP-K* per identificare i fattori corretti (fase online).

### 6.11.1 Generazione del Dataset e Definizione dell'Etichetta

Il dataset viene generato eseguendo il circuito con parametri di rumore variabili nell'intorno dei valori nominali (fattore di variazione  $\pm 50\%$ ). La stessa traspilazione con `optimization_level=2` è usata per tutti i campioni, variando solo il noise model a run-time per efficienza.

L'etichetta di un campione vale 1 se *almeno uno* dei `TOP_K=16` misure più frequenti nell'istogramma corrisponde a fattori non banali. Questa definizione è coerente con la strategia di inferenza del Metodo 2: il classificatore impara a riconoscere gli istogrammi che “contengono segnale QPE utile”, indipendentemente da quale specifica misura sia la moda.

*Si veda il Listato B.8.*

### 6.11.2 Addestramento e Selezione del Modello

L'addestramento confronta tre architetture con scikit-learn [27]: **Random Forest** (200 alberi), **SVM** con kernel RBF e **MLP** con architettura (256, 128). Il modello con F1-score più elevato sul test set (suddivisione 80/20 stratificata) viene serializzato per l'inferenza tramite `joblib`.

La selezione del modello è stata eseguita su 2000 campioni per ciascun use case, con split stratificato 80/20 e criterio di scelta basato sull'F1-score: risulta selezionato il Random Forest per UC1 e l'SVM per UC2, entrambi con metriche di classificazione elevate (F1 fino a 0.98, Area Sotto la Curva ROC (*Area Under the Curve*) (AUC) fino a 0.99).

Le metriche complete dei tre modelli sui due use case, con le curve ROC e lauditi delle etichette di addestramento, sono nella Sezione D.2 dell'Appendice efapp:fase1.

Il **Random Forest** è il modello ottimale per UC1 (F1=0.949, AUC=0.964), dove la maggiore variabilità dell'istogramma — il dataset ha il 25.8% di esempi negativi

— favorisce un classificatore ensemble capace di catturare relazioni non lineari tra le feature. Per UC2, tutti e tre i modelli raggiungono prestazioni quasi identiche ( $F1 > 0.97$ ): la scelta ricade sull'**SVM** per il margine minimo di F1-score. In entrambi i casi, i valori di AUC-ROC  $> 0.96$  indicano una buona separabilità delle classi nello spazio delle feature istogramma.

### 6.11.3 Inferenza: Classificatore + Ricerca TOP-K

In fase di inferenza il Metodo 2 adotta un design a due livelli. Il classificatore agisce da **gate di qualità** (primo livello): decide se l'istogramma corrente “contiene segnale QPE” (label positiva per TOP\_K=16) oppure è dominato dal rumore. Se il classificatore accetta l'istogramma, la **ricerca TOP-4** (secondo livello) tenta i 4 candidati più frequenti in ordine decrescente, restituendo il primo che produce fattori non banali.

L'asimmetria tra TOP\_K=16 per le etichette di training e top\_k=4 per l'inferenza è intenzionale: il classificatore impara a rilevare la presenza di segnale QPE su una finestra ampia, mentre la ricerca usa una finestra stretta per limitare i tentativi per iterazione. Rispetto al Metodo 1, questa strategia trova la fase corretta anche quando il picco è stato spostato dal rumore: se la moda è 65 invece di 64, il Metodo 1 fallisce, ma il Metodo 2 trova 64 tra i top-4 candidati.

*Si veda il Listato B.9.*

## 6.12 Infrastruttura di Test e Raccolta Dati

Per garantire la riproducibilità e la comparabilità dei risultati, tutti i use case vengono eseguiti tramite uno script di orchestrazione (`run_experiments.py`). Per UC1 e UC2 vengono eseguite  $K = 30$  ripetizioni di entrambi i metodi; per UC3 e UC4, dove solo il Metodo 1 è applicabile a causa della profondità del circuito,  $K = 10$  ripetizioni con analisi esclusiva della scalabilità. I risultati vengono salvati in formato JSON con timestamp e parametri completi, per consentire l'analisi a posteriori (Listato B.10).

Il seed di ogni ripetizione viene calcolato come `seed = rep` e propagato al simulatore come `seed_simulator = rep * 10000 + iteration`, garantendo che ogni ripetizione e ogni iterazione interna abbiano realizzazioni di rumore indipendenti e riproducibili.

## 6.13 Implementazione della Correzione d'Errore

Quanto descritto finora realizza la prima fase sperimentale. La seconda — i codici correttori e la loro integrazione con Shor — richiede strumenti e strutture dati differenti, perché differente è la natura dei circuiti: non più un singolo circuito profondo di cui interessa l'istogramma finale, ma circuiti poco profondi eseguiti milioni di volte, di cui interessa la *sindrome*. Questa sezione descrive come tale seconda infrastruttura è stata costruita.

### 6.13.1 Organizzazione del codice e divisione degli strumenti

Il codice sperimentale è organizzato in una cartella per milestone, ciascuna contenente il proprio script, i risultati in formato JSON e un file di documentazione che ne dichiara i criteri di validazione. La divisione degli strumenti segue la natura dei circuiti, secondo il criterio già motivato nella Sezione 6.1.

| Cartella           | Oggetto              | Strumento           | Costo dominante         |
|--------------------|----------------------|---------------------|-------------------------|
| M5_repetition_code | codice a ripetizione | Qiskit Aer          | trascurabile            |
| M6_steane_code     | Steane $[[7, 1, 3]]$ | Qiskit Aer          | Monte Carlo Pauli       |
| M7_surface_code    | surface code         | Stim + PyMatching   | decodifica              |
| M8_shor_logico     | Shor logico          | Qiskit Aer          | simulazione statevector |
| M10_neural_decoder | decodifica appresa   | Stim + scikit-learn | addestramento           |

Tabella 6.1: Struttura del codice sperimentale della seconda fase. I circuiti dei codici correttori sono *stabilizer* e vengono trattati con Stim dove la scala lo richiede; quelli che contengono operazioni non-Clifford — lo Shor logico — restano su Qiskit Aer.

### 6.13.2 Il codice a ripetizione: sindrome senza collasso

L'implementazione del codice a ripetizione realizza in forma esplicita il ciclo descritto nel Capitolo 8. Il punto delicato non è la codifica, ma il fatto che la misura di sindrome non deve collassare lo stato logico: per questo gli stabilizzatori sono misurati *indirettamente*, copiandone la parità su due qubit ancillari che vengono poi letti al posto dei dati.

*Si veda il Listato B.11.*

Merita attenzione la scelta del **punto di iniezione del rumore**. Poiché il noise model di Aer associa gli errori alle *porte*, e non al tempo trascorso, per applicare un canale d'errore a probabilità nota sui soli qubit dati si inseriscono porte identità in corrispondenza dell'istante in cui il rumore deve agire: l'identità non altera lo stato



ideale ma costituisce l’aggancio a cui il modello di rumore associa il canale. È una tecnica standard e rende il parametro  $p$  delle curve del Capitolo 8 esattamente la probabilità di errore per qubit, anziché una quantità effettiva da calibrare.

### 6.13.3 Il codice di Steane

Per lo Steane la difficoltà implementativa si sposta sulla **preparazione dello stato logico**. Lo stato  $|0_L\rangle$  è la sovrapposizione uniforme degli otto *codeword*, e si ottiene senza scriverli esplicitamente: si individuano i tre qubit che compaiono in un solo stabilizzatore di tipo X — i “semi” — li si pone in sovrapposizione con una porta di Hadamard, e si propaga ciascun seme sul proprio supporto con una rete di CNOT. *Si veda il Listato B.12.*

La stima della curva  $p \rightarrow p_L$  non viene condotta simulando il circuito completo per ogni campione, ma nel **formalismo di Pauli**: si campiona un errore di Pauli per qubit con probabilità  $p$ , se ne calcola la sindrome come prodotto scalare binario con le matrici di parità, si applica la correzione a peso minimo dalla lookup table e si verifica se il residuo contiene un operatore logico non banale. Questa scelta rende trattabili i 200 000 campioni per punto e non introduce approssimazioni, perché per errori di Pauli e circuiti Clifford il risultato coincide con quello della simulazione esplicita. Ne discende però il limite dichiarato nel Capitolo 8: l’estrazione di sindrome così modellata è *ideale*, cioè le ancilla non sono soggette a errore, e il protocollo non è fault-tolerant.

### 6.13.4 Il surface code e l’iniezione del crosstalk

Per il surface code la generazione del circuito e la decodifica sono demandate a Stim e PyMatching secondo lo schema riportato nel Capitolo 9 (Listato B.14). L’unico intervento non standard riguarda l’esperimento sul rumore correlato della Sezione 9.6, che richiede di aggiungere al circuito generato un canale a due qubit fra dati adiacenti. Poiché Stim rappresenta i cicli intermedi con un blocco **REPEAT**, l’inserimento deve procedere ricorsivamente sulla struttura del circuito (Listato B.13).

Le coppie su cui il canale agisce sono determinate dalle coordinate della griglia: due qubit dati adiacenti distano 2 nel sistema di riferimento del layout ruotato, poiché fra di essi si trova un qubit di misura. L’identificazione dei qubit di misura richiede una cautela: nel *memory experiment* l’ultima operazione legge *anche* i qubit dati, sicché l’insieme dei qubit misurati nel circuito completo non è discriminante; si usa quindi il primo **MR**, che corrisponde al primo ciclo di estrazione della sindrome.

### 6.13.5 Lo Shor logico e il decoder appreso

Il modello a livelli del Capitolo 10 è realizzato applicando un canale depolarizzante di intensità  $p_L$  dopo ogni porta del circuito di Shor, con  $p_L$  trattato come parametro libero: il circuito è quello della Sezione 6.8, e cambia soltanto il modello di rumore associato. Il decoder appreso, infine, non richiede alcuna infrastruttura di generazione del dataset, perché i dati di addestramento coincidono con l'output del campionatore di Stim — la matrice dei *detection events* come variabile indipendente, l'esito dell'osservabile logico come etichetta. È il motivo per cui il confronto con il MWPM è leale per costruzione: i due decoder ricevono esattamente la stessa informazione, e differiscono solo per come la usano.

### 6.13.6 Riproducibilità

Ogni script accetta un seed che viene propagato a tutte le sorgenti di casualità — il campionatore di Stim, il generatore Monte Carlo e l'inizializzazione della rete — e lo registra nel JSON dei risultati insieme al numero di campioni e ai parametri del modello di rumore. Le figure dei Capitoli 8–10 sono prodotte da script dedicati che leggono quei JSON, cosicché nessun valore riportato in tesi è trascritto a mano. Questa disciplina ha una motivazione concreta: durante la revisione finale si è scoperto che il seed della campagna sul surface code, pur essendo accettato e registrato, non veniva propagato al campionatore; l'anomalia è stata corretta e la campagna rieseguita, con risultati coincidenti entro l'errore statistico.

## Capitolo 7

# Verifica Sperimentale dell’Ipotesi Iniziale: dal Classificatore ML alla Strategia TOP-K

Il Capitolo 6 ha descritto le scelte implementative dei due metodi: il Metodo 1 con strategia TOP-1 e il Metodo 2 con classificatore ML e ricerca TOP-K. Questo capitolo mette alla prova l’ipotesi da cui è partita la parte sperimentale — che un classificatore ML applicato all’output rumoroso riduca il numero di iterazioni — e ne documenta l’esito: *che cosa è stato testato, perché, e che cosa è stato appurato*. Il risultato, anticipato qui per chiarezza, è netto: la riduzione delle iterazioni si ottiene, ma il merito non è del classificatore, bensì della semplice ricerca multi-candidato TOP-4 che lo accompagna; l’ML applicato *in quel punto e in quel modo* non serve. È questo esito, verificato con un’analisi di ablazione, a motivare il cambio di prospettiva che costituisce il nucleo della tesi — la correzione degli errori *durante* l’esecuzione — presentato nei Capitoli 8–10.

### 7.1 Setup Sperimentale

Tutti gli esperimenti sono stati condotti nell’ambiente WSL descritto nel Capitolo 6, con il simulatore `AerSimulator` in modalità `statevector` (CPU): `optimization_level=2`,  $M_{\text{shots}} = 1024$  per iterazione,  $M_{\text{max}} = 50$  iterazioni,  $K = 30$  ripetizioni per UC1/UC2, seed deterministici.

**Indipendenza fra le iterazioni.** Un dettaglio dell’assegnazione dei seed merita di essere esplicitato, perché condiziona il significato stesso della metrica  $\bar{M}$ . Il simulatore deriva il seme di ciascuno shot dalla somma fra il seme dell’esecuzione e l’indice dello shot: due esecuzioni con semi consecutivi condividono quindi 1 023 campioni su 1 024 e costituiscono, in pratica, la medesima esecuzione. Poiché  $\bar{M}$  intende misurare quante esecuzioni *indipendenti* siano necessarie, le iterazioni devono essere separate di più del numero di shot; lo schema adottato è  $\text{seed} = \text{rep} \times 10^6 + \text{iter} \times 10^4$ . La verifica empirica conferma la necessità dell’accorgimento: la sovrapposizione fra gli istogrammi di due esecuzioni con semi consecutivi è del 99.9%, contro il 90.4% fra semi ben separati — valore, quest’ultimo, atteso fra campioni realmente indipendenti tratti da una distribuzione concentrata. I quattro use case seguono la struttura definita nel Capitolo 2 (Tabella 2.1): UC1 e UC2 usano lo stesso circuito per  $N = 15$  a due livelli di rumore diversi (asse rumore), mentre UC3 ( $N = 21$ ) e UC4 ( $N = 35$ ) testano la scalabilità a rumore NISQ-realistico costante.

Le tre configurazioni algoritmiche confrontate sono:

- **M1 (TOP-1):** a ogni iterazione si tenta l’estrazione dei fattori dalla sola misura più frequente dell’istogramma. È la baseline, priva di parametri da ottimizzare.
- **M2 (CLF+TOP-4):** un classificatore ML pre-addestrato decide se l’istogramma contiene segnale QPE recuperabile; in caso affermativo si tentano i 4 candidati più frequenti.
- **$M_{\text{TOP4}}$  (TOP-4 senza classificatore):** variante di ablazione che applica la sola ricerca multi-candidato, senza filtro ML. È il termine di confronto che isola il contributo del classificatore da quello della strategia di ricerca.

## 7.2 Analisi del Circuito e Barriera di Scalabilità

La profondità del circuito determina l’effetto cumulativo del rumore e definisce il perimetro entro cui il confronto è possibile.

Tabella 7.1: Caratteristiche del circuito traspilato e applicabilità dei metodi per ciascun use case. I valori si riferiscono all’implementazione adottata (`c_amod15` per  $N = 15$ , Beauregard per  $N = 21$  e  $N = 35$ ), con `optimization_level=2` e Qiskit 2.x.  $k = \text{cx} + \text{cp} + \text{swap}$  è il numero di porte soggette all’errore depolarizzante a due qubit, ed è l’esponente corretto di  $P_{\text{surv}}$  (Sezione 6.4.4).

| Use Case | N  | Qubit | Profondità | cx    | cp     | k      | $P_{\text{surv}} = (1 - \epsilon_{2q})^k$ |
|----------|----|-------|------------|-------|--------|--------|-------------------------------------------|
| UC1      | 15 | 12    | 311        | 114   | 52     | 166    | $1.9 \times 10^{-1}$                      |
| UC2      | 15 | 12    | 311        | 114   | 52     | 166    | $2.0 \times 10^{-4}$                      |
| UC3      | 21 | 22    | 9 883      | 3 406 | 11 436 | 14 842 | $1.7 \times 10^{-65}$                     |
| UC4      | 35 | 26    | 1 480      | 516   | 1 908  | 2 424  | $2.6 \times 10^{-11}$                     |

La tabella richiede una precisazione preliminare, perché contiene la correzione di un errore di conteggio in cui è facile incorrere. La probabilità di sopravvivenza coerente  $P_{\text{surv}}$  — la frazione di run in cui nessuna porta a due qubit introduce errore — ha per esponente il numero di porte a cui il modello di rumore applica effettivamente l’errore depolarizzante a due qubit, che è l’insieme `[cx, swap, cp]` e non le sole `cx`. Le porte `cp` sopravvivono alla traspilazione perché appartengono al gate set nativo, e per le istanze maggiori *dominano*: nella decomposizione di Beauregard, che costruisce l’aritmetica modulare interamente nel dominio della QFT, esse superano le `cx` di oltre tre volte. Contare le sole `cx` sottostima l’errore accumulato di un terzo su UC1 e di cinquanta ordini di grandezza su UC3. Per UC1 e UC2, dunque,  $k = 166$  e  $P_{\text{surv}}$  vale  $\approx 18.9\%$  e  $\approx 0.02\%$  rispettivamente.

Per UC3 e UC4 il motivo per cui nessun metodo risulta applicabile è diverso nei due casi, e in nessuno dei due coincide con quello che la prima versione di questa analisi suggeriva.

**UC3 è il caso genuinamente difficile.** Con  $a = 2$  e  $N = 21$  il periodo è  $r = 6$  e nessuno dei dieci gate controllati collassa nell’identità: il circuito è profondo per ragioni strutturali. La decomposizione di Beauregard [11], implementata nel modulo `beauregard.py`, porta il conteggio delle `cx` da 10 040 a 3 406, ma introduce 11 436 porte `cp`: il totale  $k = 14 842$  porta  $P_{\text{surv}}$  a  $1.7 \times 10^{-65}$ . È il prezzo strutturale dell’aritmetica nel dominio della QFT — si guadagna in numero di qubit e in scaling asintotico, non in porte rumorose — e mostra che la lettura per cui Beauregard avrebbe reso UC3 quasi raggiungibile era ottimistica di cinquanta ordini di grandezza.

**UC4 è un caso di natura diversa.** Con  $a = 6$  e  $N = 35$  il periodo è  $r = 2$ , ossia  $6^2 \equiv 1 \pmod{35}$ : tutti i gate controllati  $U^{2^j}$  con  $j \geq 1$  sono l’identità e vengono eliminati dal transpiler, lasciando *un solo* gate non banale su dodici. Il circuito risultante ha  $k = 2 424$ , un sesto di UC3 pur avendo un modulo maggiore, e

$P_{\text{surv}} \approx 2.6 \times 10^{-11}$ . Il valore resta tre ordini di grandezza sotto il minimo a cui la campagna parametrica ha verificato il funzionamento della strategia multi-candidato ( $2.5 \times 10^{-8}$ , si veda la Sezione 7.6): UC4 non è quindi dichiarabile né raggiungibile né preclusa sulla base della sola stima analitica, e la questione resta aperta perché il costo di simulazione dei suoi 26 qubit impedisce di risolverla per via sperimentale.

Questo esito è coerente con il razionale dichiarato nel Capitolo 2, dove  $r = 2$  era stato scelto *deliberatamente* per separare l'effetto della larghezza del registro da quello della profondità dell'esponenziazione modulare. La scelta è legittima e il risultato la conferma: UC4 misura la prima variabile a profondità minima. Ma proprio per questo UC4 **non appartiene all'asse di scalabilità** lungo cui l'Ipotesi secondaria 2 lo colloca. La difficoltà del circuito non cresce con  $N$ : cresce con il periodo  $r$ , che determina quanti dei gate controllati sopravvivono alla traspilazione. Lungo la sequenza  $N = 15 \rightarrow 21 \rightarrow 35$  i periodi sono  $4 \rightarrow 6 \rightarrow 2$ , e con essi la profondità va  $311 \rightarrow 9883 \rightarrow 1480$ : non è una progressione monotona, e trattarla come tale è un difetto di formulazione dell'ipotesi, non del disegno degli use case.

Ne discende una conseguenza che va dichiarata subito, perché riguarda il perimetro di validità di tutto il capitolo: l'**Ipotesi secondaria 2** formulata nel Capitolo 2 — che il vantaggio del Metodo 2 si mantenga al crescere dell'istanza ( $N = 15 \rightarrow 21 \rightarrow 35$ ) — **resta non verificata**, e va inoltre riformulata. Non è stata smentita: su UC3, l'unico dei tre che aumenti davvero la difficoltà, la verifica è impedita da una barriera doppia, fisica e computazionale; su UC4 dal solo costo di simulazione, e comunque su un'istanza che per costruzione non mette alla prova la profondità. Il piano sperimentale prevedeva quattro use case come requisito di validazione; ne restano misurabili due. Il Capitolo 11 riprende il punto indicando come andrebbe riformulata l'ipotesi perché l'asse di scalabilità sia quello effettivo.

**La barriera è doppia, e la decomposizione ne rimuove solo metà.** Poiché l'attribuzione della barriera alla sola decomposizione sarebbe incompleta, la si è verificata direttamente. Il modulo `beauregard.py` mantiene la promessa che la letteratura gli attribuisce — ridurre il numero di *qubit* e lo scaling asintotico — ma non quella che una lettura affrettata gli attribuirebbe: per  $N = 21$  le porte CX scendono da 10 040 a 3 406 su 22 qubit, mentre le `cp` salgono a 11 436, e il totale delle porte rumorose a due qubit *cresce* a 14 842. UC3 resta dunque irraggiungibile, per due ragioni indipendenti che è utile separare.

La prima è **fisica**: al livello di rumore previsto per UC3 ( $\varepsilon_{2q} = 10^{-2}$ ) la probabilità di sopravvivenza coerente vale  $P_{\text{surv}} = (1 - 10^{-2})^{14842} \approx 1.7 \times 10^{-65}$ . Anche disponendo

di una simulazione istantanea, l'output resterebbe presumibilmente indistinguibile dal rumore uniforme: la decomposizione efficiente non basta, occorre *anche* un errore di gate più basso. A  $\varepsilon_{2q} = 10^{-3}$  la stessa espressione dà  $P_{\text{surv}} \approx 3.6 \times 10^{-7}$ , e persino a  $10^{-4}$  soltanto 22%: perché UC3 rientri nel regime in cui la campagna parametrica ha verificato il funzionamento di TOP-4 serve un errore di gate due ordini di grandezza sotto quello dei dispositivi attuali.<sup>1</sup>

La seconda è **computazionale**, e si manifesta proprio nel regime in cui la prima si attenua. In presenza di un modello di rumore il simulatore non può evolvere lo stato una volta sola e campionarlo: ogni shot richiede una traiettoria indipendente, e il costo dell'intera iterazione scala linearmente con il numero di shot. La misura del costo richiede una cautela che vale la pena esplicitare, perché è una fonte di errore facile: Aer distribuisce le traiettorie sui core disponibili, sicché il costo *per shot* non è costante ma cala nettamente al crescere del numero di shot richiesti. Su UC1 si passa da 32.6 ms per shot misurando su quattro traiettorie a 2.9 ms misurando su 1 024 — un fattore undici. Stimare il costo di un'iterazione moltiplicando per 1 024 il costo di poche traiettorie lo sovrastima quindi di un ordine di grandezza. I valori seguenti sono ricavati dal regime già ammortizzato.

Tabella 7.2: Costo di simulazione misurato su macchina dedicata (22 core, 15 GB). Per UC1 il valore è la mediana di cinque iterazioni complete da 1 024 shot; per UC3 è estrapolato dal punto a 64 traiettorie, dove la curva di ammortamento è già piatta ( $18.3 \rightarrow 16.8$  s per shot fra 16 e 64); per UC4 dal punto a 16 traiettorie, ed è quindi un limite superiore.

|     | qubit | stato    | s / shot | 1 iterazione (1024 shot) |
|-----|-------|----------|----------|--------------------------|
| UC1 | 12    | 32 KB    | 0.0005   | 0.5 s                    |
| UC3 | 22    | 64 MB    | 16.8     | 4.8 h                    |
| UC4 | 26    | 1 024 MB | 71.1     | 20.2 h                   |

Il divario per shot fra UC1 e le istanze maggiori supera i quattro ordini di grandezza: una singola traiettoria di UC3 costa più di trenta iterazioni complete di UC1. Ma il dato più istruttivo è il confronto fra UC3 e UC4. **UC4 costa quattro volte più di**

<sup>1</sup>La cautela è d'obbligo in entrambe le direzioni. La campagna parametrica su UC1 (Sezione 7.6) ha mostrato che  $P_{\text{surv}}$  *sottostima* la recuperabilità del segnale — a  $P_{\text{surv}} = 2.5 \times 10^{-8}$  la strategia TOP-4 converge ancora al primo tentativo — ma quella verifica riguarda un circuito di 166 porte, non di quasi quindicimila, e nulla autorizza a estrapolarla di cinquantasette ordini di grandezza. La stima analitica indica un ordine di grandezza, non una soglia di impossibilità; solo la seconda barriera, quella computazionale, impedisce di stabilire quale delle due letture sia corretta.

**UC3 per iterazione pur avendo un circuito sei volte più corto**, e la ragione è nella terza colonna: il costo per traiettoria è dominato dalla dimensione dello spazio di Hilbert, non dalla profondità. Con un gigabyte per stato il simulatore può tenere in volo poche traiettorie per volta, e i core restano inutilizzati — si osserva infatti che UC4 ammortizza soltanto del 16% passando da 4 a 16 shot, contro il 50% di UC3, perché il vincolo non è il calcolo ma la memoria.

La conseguenza sul protocollo va enunciata con la cautela che i dati consentono. Nel caso peggiore — trenta ripetizioni che esauriscono ciascuna il budget di cinquanta iterazioni — UC3 richiederebbe circa 7 200 ore di calcolo, ossia dieci mesi. Se però UC3 convergesse come UC1, con  $\bar{M} \approx 2$ , basterebbero una sessantina di iterazioni complessive, cioè circa dodici giorni: impegnativo ma non impossibile. *Quale dei due scenari valga non è determinabile senza eseguire l'esperimento*, ed è esattamente ciò che il costo impedisce di fare. La barriera computazionale è dunque reale, ma la sua entità dipende dalla risposta che si vorrebbe ottenere — il che è a sua volta una ragione per spostare la verifica sull'hardware, dove il costo per shot è quello del dispositivo e non cresce con il numero di qubit.<sup>2</sup> Il metodo *matrix product state*, che su circuiti poco entangled sarebbe più efficiente, non offre scampo: l'algoritmo di Shor massimizza l'entanglement per costruzione, e la dimensione di legame cresce fino ad annullarne il vantaggio. È il metodo adottato per default dal runner della campagna, e su UC3 e UC4 non ha prodotto risultati entro il budget assegnato; un tentativo dedicato su UC4 con venti minuti di tempo di calcolo non ha completato neppure una traiettoria.

La formulazione corretta dell'esito è dunque la seguente: *delle due barriere, quella computazionale è di per sé decisiva*. Anche assumendo — come la campagna parametrica su UC1 autorizza a fare — che il segnale QPE resti recuperabile ben oltre quanto  $P_{\text{surv}}$  suggerisca, la verifica resterebbe fuori portata per il solo costo della simulazione. Non è un limite degli algoritmi di analisi né della decomposizione: è la conseguenza del fatto che simulare classicamente traiettorie rumorose su ventidue qubit costa più di eseguirle. La verifica dell'Ipotesi secondaria 2 appartiene propriamente all'hardware reale, dove il costo per shot è quello del dispositivo e non del simulatore — ed è per questo che il Capitolo 11 la colloca fra le direzioni immediate

---

<sup>2</sup>La misura è stata condotta su quattro traiettorie con la macchina occupata da altri processi; una stima precedente in condizioni di minor carico dava  $\approx 50$ s per shot, ossia quattordici ore per iterazione. L'ordine di grandezza — giorni per una singola iterazione, anni per il protocollo completo — non cambia.



anziché fra quelle a lungo termine.




Figura 7.1: Circuito di Quantum Phase Estimation per  $N = 21$ ,  $a = 2$  ( $n_{\text{count}} = 10$  qubit di controllo, 5 qubit target). La complessità della decomposizione **UnitaryGate** porta a 10040 porte CX dopo la traspilazione.




Figura 7.2: Distribuzione di misura del registro di controllo per  $N = 21$  con decomposizione **UnitaryGate** (1024 shot, noise model NISQ-realistico): l'output è indistinguibile da una distribuzione uniforme.

### 7.3 La Baseline: Metodo 1 (TOP-1)

La Figura 7.3 mostra i due volti dell'output di UC1: un'iterazione con segnale QPE strutturato (picchi intorno ai valori teorici  $\{64, 128, 192\}$ ) e una in cui il rumore

rende l'output quasi uniforme. Distinguere i due casi *prima* della post-elaborazione è esattamente il compito che l'ipotesi iniziale affidava al classificatore.




Figura 7.3: Confronto tra un istogramma QPE con segnale strutturato (sinistra) e uno dominato dal rumore (destra) per UC1 ( $N = 15$ , NISQ-realistico). I valori teorici attesi per  $r = 4$  sono  $\{64, 128, 192\}$  su  $2^8 = 256$  stati.

Tabella 7.3: Risultati del Metodo 1 sui quattro use case

| Use Case                     | $P_{\text{succ}}$ | $\bar{M}_1$ | $\sigma_{M_1}$ | Mediana |
|------------------------------|-------------------|-------------|----------------|---------|
| UC1 ( $N = 15$ , realistico) | 100% (30/30)      | 1.97        | 1.66           | 1.5     |
| UC2 ( $N = 15$ , degradato)  | 100% (30/30)      | 1.60        | 0.76           | 1.0     |
| UC3 ( $N = 21$ )             | 0%                | N/A         | —              | —       |
| UC4 ( $N = 35$ )             | 0%                | N/A         | —              | —       |

La distribuzione del numero di iterazioni è asimmetrica e approssimativamente geometrica: per UC1 ogni iterazione ha probabilità indipendente  $p_{\text{iter}} = 58.3\%$  di produrre la misura corretta tramite TOP-1 (misura diretta su 60 esecuzioni), da cui  $\bar{M}_1 \approx 2$ . Il dato saliente è che **la baseline non fallisce mai**: entro il budget di cinquanta iterazioni tutte e trenta le ripetizioni convergono, su entrambi gli use case. La differenza fra i metodi non riguarda dunque *se* il risultato venga trovato, ma *quante esecuzioni* servano per trovarlo — ed è precisamente ciò che la metrica  $\bar{M}$  misura.

Il confronto UC1 vs UC2 rivela un comportamento controintuitivo ( $\bar{M}_1$  *minore* sotto rumore maggiore), spiegato dalla banda di accettazione di `extract_factors` (`Fraction.limit_denominator`): il rumore allarga la distribuzione e aumenta la probabilità che la moda ricada nella banda.

La ragione per cui TOP-1 richiede più di un tentativo è strutturale, e vale la pena isolarla perché anticipa il risultato della sezione seguente. Su sessanta esecuzioni

indipendenti di UC1 la moda dell'istogramma cade su uno solo di quattro valori —  $\{0, 64, 128, 192\}$ , ossia esattamente i picchi  $j \cdot 2^8/r$  attesi dalla QPE per  $r = 4$  — e coincide con l'esito  $y = 0$  in 25 casi su 60 (41.7%), che ne fa l'esito *più frequente in assoluto*. Ma  $y = 0$  corrisponde a fase nulla e non porta alcuna informazione sul periodo: la funzione di estrazione lo scarta per costruzione. In altri termini, il candidato che TOP-1 seleziona è, in due casi su cinque, quello strutturalmente privo di contenuto informativo; la moda conduce ai fattori nel 58.3% delle esecuzioni, da cui  $\bar{M}_1 \approx 1/0.583 = 1.7$ , in accordo con il valore misurato 1.97. Quando invece si considerano i quattro candidati più frequenti, i picchi utili sono presenti in *tutte* e sessanta le esecuzioni: è questa la ragione per cui  $M_{\text{TOP4}}$  converge al primo tentativo con deviazione standard nulla.

I limiti della baseline sono dunque due, e motivano il passo successivo: (i) **spreco informativo** — TOP-1 usa una sola misura dell'istogramma e scarta tutto il resto, incluso il caso in cui la misura selezionata sia l'esito banale; (ii) **variabilità** —  $\sigma_{M_1} = 1.66$  contro  $\bar{M}_1 = 1.97$ : il costo di una sessione resta imprevedibile a priori e non si riduce aumentando gli shot, poiché dipende da quale picco risulti dominante in quella specifica realizzazione del rumore.

## 7.4 L'Ipotesi ML alla Prova

L'ipotesi formalizzata nel Capitolo 2 attribuiva la riduzione delle iterazioni a un classificatore ML, addestrato a riconoscere gli istogrammi privi di segnale QPE ( $\bar{M}_2 \approx 3$ ,  $\rho = \bar{M}_1/\bar{M}_2 > 1$ ). Sono state addestrate e confrontate tre architetture (Random Forest, SVM, MLP) su un dataset di 2000 istogrammi per use case: come *classificatori* i modelli funzionano molto bene (F1 fino a 0.98, AUC fino a 0.99). L'architettura, la procedura di addestramento e le metriche complete — con la tabella dei tre modelli e le curve ROC — sono riportate nella Sezione D.2 (Sez. D.2.1). Le metriche di classificazione, però, dicono soltanto che il modello sa distinguere le due classi di istogrammi; la domanda operativa è un'altra — *questo filtraggio riduce davvero le iterazioni rispetto alla sola ricerca multi-candidato TOP-4?* — ed è quella a cui risponde l'ablazione seguente.

## 7.5 Il Verdetto dell'Ablazione

Tabella 7.4: Riepilogo comparativo M1,  $M_{\text{TOP4}}$  e M2 — risultato principale con analisi di ablazione ( $K = 30$ ,  $M_{\text{max}} = 50$ )

| UC  | Variante                   | $P_{\text{succ}}$ | $\bar{M}$ | $\rho$ vs M1 | p-value (vs M1) |
|-----|----------------------------|-------------------|-----------|--------------|-----------------|
| UC1 | M1 (TOP-1)                 | 100%              | 1.97      | —            | —               |
|     | $M_{\text{TOP4}}$ (no clf) | 100%              | 1.00      | <b>1.967</b> | <0.001 (sign.)  |
|     | M2 (CLF+TOP-4)             | 100%              | 1.03      | 1.903        | <0.001 (sign.)  |
| UC2 | M1 (TOP-1)                 | 100%              | 1.60      | —            | —               |
|     | $M_{\text{TOP4}}$ (no clf) | 100%              | 1.00      | <b>1.600</b> | <0.001 (sign.)  |
|     | M2 (CLF+TOP-4)             | 100%              | 1.57      | 1.021        | 0.315 (n.s.)    |

Ablazione  $M_{\text{TOP4}}$  vs M2 (Mann-Whitney): UC1  $p = 0.849$  (n.s.); UC2  $p < 0.001$ , con M2 che richiede significativamente *più* iterazioni di  $M_{\text{TOP4}}$ .

**UC1: il classificatore è superfluo.** M2 raggiunge  $\bar{M}_2 = 1,03$  con  $\rho = 1,903$  significativo rispetto a M1: l'ipotesi numerica ( $\bar{M}_2 \approx 3$ ) è addirittura superata. Ma  $M_{\text{TOP4}}$  — TOP-4 *senza* classificatore — ottiene un risultato migliore ( $\bar{M} = 1,00$  esatto, con deviazione standard nulla: *ogni* ripetizione converge al primo tentativo), e il confronto  $M_{\text{TOP4}}$  vs M2 non è significativo ( $p = 0.849$ ). Il guadagno è interamente della ricerca multi-candidato: il picco QPE si trova sempre tra i quattro candidati più frequenti anche sotto rumore, perché il rumore allarga la distribuzione ma non ne distrugge la struttura — e, come osservato sopra, il candidato che TOP-1 scarta a favore dell'esito banale  $y = 0$  viene qui recuperato.

**UC2: il classificatore annulla il guadagno.** M2 produce  $\bar{M}_2 = 1,57$  contro  $\bar{M} = 1,00$  del solo  $M_{\text{TOP4}}$ : il classificatore riporta il costo quasi al livello della baseline ( $\rho = 1,021$ , non significativo rispetto a M1), vanificando il vantaggio che la ricerca multi-candidato aveva ottenuto. Il classificatore SVM, addestrato con rumore variato  $\pm 50\%$ , risulta eccessivamente conservativo al rumore nominale di UC2 e scarta iterazioni con segnale QPE parziale che la sola ricerca TOP-4 avrebbe risolto. Rispetto a UC1, dove il filtro è semplicemente inerte, qui esso è attivamente controproducente rispetto alla strategia che accompagna.




Figura 7.4: Analisi di ablazione su UC1 ( $K = 30$ ,  $M_{\text{max}} = 50$ ): confronto tra M1 (TOP-1),  $M_{\text{TOP4}}$  (TOP-4 senza classificatore) e M2 (CLF+TOP-4).  $M_{\text{TOP4}}$  è statisticamente indistinguibile da M2 ( $p = 0.849$ ): il guadagno è della strategia TOP-4, non del classificatore.

**La causa, verificata sui dati di addestramento.** La coesistenza di metriche di classificazione eccellenti e di un guadagno operativo nullo è troppo anomala per accontentarsi di una spiegazione narrativa, e i modelli addestrati sono stati archiviati assieme al proprio test set: le etichette si possono dunque *ricalcolare* dagli istogrammi e confrontare con quelle memorizzate. L’audit, riportato per esteso nella Sezione D.2 (Sez. D.2.2), dà un esito inequivocabile. La regola di etichettatura documentata considera positivo un istogramma se almeno una delle sedici misure più frequenti conduce ai fattori; le etichette effettivamente usate corrispondono invece alla sola moda, con una concordanza del 99.8% contro il 74.2% della regola dichiarata.

Poiché fra i quattro picchi della QPE l’unico che non conduce ai fattori è l’esito banale  $y = 0$ , ne segue che **il classificatore è stato addestrato a rispondere alla domanda “la moda dell’istogramma cade sulla cella 0?”** — e non alla domanda “questo istogramma ha perso il segnale?”. La verifica non ammette eccezioni: tutti e 103 i campioni negativi di UC1 e tutti e 67 quelli di UC2 hanno moda  $y = 0$ . Su UC1, per giunta, quegli istogrammi conservano il 75.8% della massa sui quattro picchi e un’entropia di 3.66 bit su 8: il segnale c’è tutto, è solo il picco più alto a essere quello inutile.

**Che cosa è stato appurato.** Il risultato qualitativo dell'ipotesi — che un approccio multi-candidato riduca  $\bar{M}$  — è confermato per entrambi gli use case tramite  $M_{\text{TOP4}}$ . La parte dell'ipotesi che attribuiva il guadagno al classificatore è **smentita**, e l'audit ne fornisce la ragione meccanica anziché una congettura: il filtro ML e la ricerca TOP-4 agiscono sullo stesso identico insieme di esecuzioni — quelle in cui la moda è  $y = 0$  — ma con esiti opposti. Il classificatore le scarta, imponendo un'iterazione aggiuntiva; TOP-4 le risolve al primo tentativo, perché i picchi utili occupano semplicemente le tre posizioni successive. Su UC1 i due effetti si compensano ( $p = 0.849$ ); su UC2, dove il filtro interviene più spesso, il costo prevale e  $\bar{M}$  risale a 1.57.

Le eccellenti metriche di classificazione non si traducono dunque in guadagno operativo per una ragione precisa: misurano la capacità di individuare l'argmax di un vettore di 256 numeri, non quella di diagnosticare la corruzione dell'informazione quantistica. E quando il dataset viene rigenerato con la regola dichiarata, la classe negativa scompare del tutto (2000 campioni positivi su 2000): al livello di rumore di UC1 non esiste alcun istogramma da scartare. Applicare l'ML lì — a valle dell'esecuzione, sul solo output — non ha senso non perché l'architettura sia inadeguata, ma perché non c'è nulla da apprendere che la struttura dell'output non offra già gratuitamente.

## 7.6 Robustezza della Strategia TOP-4

Identificato il componente attivo, una campagna parametrica sistematica a variazione singola ( $K_{\text{rep}} = 30$  per punto, test Mann-Whitney) ne ha caratterizzato i margini operativi su sette parametri. Il dettaglio completo, con il confronto previsione/esito per ciascun parametro, è riportato nella Sezione D.1; la Tabella 7.5 ne riassume gli esiti.

Tabella 7.5: Sintesi della campagna parametrica su  $M_{\text{TOP4}}$ : impatto atteso, osservato e raccomandazioni

| Parametro          | Categoria | Impatto atteso        | Impatto osservato                               | Raccomandazione                            |
|--------------------|-----------|-----------------------|-------------------------------------------------|--------------------------------------------|
| $K$                | Strategia | Alto ( $K = r = 4$ )  | Alto ma soglia a $K = 2$ , non $K = 4$          | $K = 2$ minimo; $K = 4$ per margine        |
| $\varepsilon_{2q}$ | Rumore    | Alto (dominante)      | Nulla su $M_{\text{TOP4}}$ ; soglia non trovata | TOP-K robusto su $[10^{-3}, 10^{-1}]$      |
| $M_{\text{shots}}$ | Strategia | Medio (soglia 1024)   | Nulla; 128 shot già sufficienti                 | Nessun requisito minimo pratico            |
| $T_1, T_2$         | Rumore    | Basso (per $N = 15$ ) | Nulla su $[20 \mu\text{s}, 500 \mu\text{s}]$    | Irrilevante per $N = 15$                   |
| $\varepsilon_{1q}$ | Rumore    | Basso                 | Nulla su $[10^{-4}, 2 \times 10^{-2}]$          | Trascurabile rispetto a $\varepsilon_{2q}$ |
| $p_{\text{ro}}$    | Rumore    | Basso                 | Nulla su $[0\%, 20\%]$                          | Irrilevante su tutto il range testato      |

Su sette parametri, uno solo —  $K$  — ha impatto, con soglia effettiva  $K = 2$  (più bassa del valore teorico  $K = r = 4$ ); tutti gli altri, incluso  $\varepsilon_{2q}$  su tre ordini di

grandezza, risultano irrilevanti.  $M_{\text{TOP4}}$  è quindi applicabile su hardware NISQ senza alcuna calibrazione: il meccanismo non si basa sulla preservazione del segnale QPE *in media* ma sulla sua recuperabilità *per realizzazione* — come mostra il caso estremo  $\varepsilon_{2q} = 10^{-1}$ , dove la probabilità che nessuna porta a due qubit sbagli è di sei parti su un milione e ciononostante ogni ripetizione converge al primo tentativo.

### 7.6.1 Perché $P_{\text{surv}}$ sbaglia: la frazione coerente efficace

L'insensibilità a  $\varepsilon_{2q}$  è tanto marcata da mettere in discussione la grandezza con cui la si è finora descritta. Vale la pena quantificare lo scarto anziché limitarsi a constatarlo, perché la stima  $P_{\text{surv}} = (1 - \varepsilon_{2q})^k$  viene usata in tutta la letteratura NISQ come indicatore di fattibilità, e questo lavoro la impiega per giudicare l'accessibilità di UC3 e UC4.

Sotto rumore depolarizzante l'istogramma osservato è descritto bene da una miscela fra la distribuzione ideale — massa equipartita sui quattro picchi  $\{0, 64, 128, 192\}$  — e la distribuzione uniforme sulle 256 celle:

$$P_{\text{oss}}(y) = f \cdot P_{\text{ideale}}(y) + (1 - f) / 256, \quad (7.1)$$

dove  $f$  è la **frazione coerente efficace**, stimabile dalla massa osservata sui quattro picchi. Confrontando  $f$  con  $P_{\text{surv}}$  si misura direttamente di quanto la stima analitica sbaglia.

Tabella 7.6: Frazione coerente efficace  $f$  stimata da (7.1) su 20 esecuzioni per punto, confrontata con la stima analitica  $P_{\text{surv}} = (1 - \varepsilon_{2q})^{166}$ . L'ultima colonna riporta l'esponente efficace  $k_{\text{eff}} = \ln f / \ln(1 - \varepsilon_{2q})$ , cioè il numero di porte che si comporterebbero come critiche se il modello moltiplicativo fosse esatto.

| $\varepsilon_{2q}$       | $P_{\text{surv}}$     | $f$   | $f/P_{\text{surv}}$  | $k_{\text{eff}}$ |
|--------------------------|-----------------------|-------|----------------------|------------------|
| $10^{-3}$                | $8.5 \times 10^{-1}$  | 0.862 | 1.0                  | 148              |
| $5 \times 10^{-3}$       | $4.3 \times 10^{-1}$  | 0.804 | 1.9                  | 44               |
| $10^{-2}$ (UC1)          | $1.9 \times 10^{-1}$  | 0.739 | 3.9                  | 30               |
| $2 \times 10^{-2}$       | $3.5 \times 10^{-2}$  | 0.622 | 17.8                 | 24               |
| $5 \times 10^{-2}$ (UC2) | $2.0 \times 10^{-4}$  | 0.372 | $1.9 \times 10^3$    | 19               |
| $10^{-1}$                | $2.5 \times 10^{-8}$  | 0.158 | $6.2 \times 10^6$    | 18               |
| $2 \times 10^{-1}$       | $8.2 \times 10^{-17}$ | 0.032 | $3.9 \times 10^{14}$ | 15               |
| $3 \times 10^{-1}$       | $1.9 \times 10^{-26}$ | 0.008 | $4.0 \times 10^{23}$ | 14               |




Figura 7.5: Frazione di segnale QPE sopravvissuto, in funzione dell'errore sui gate a due qubit. La stima analitica  $P_{\text{surv}}$  (rossa, tratteggiata) e la frazione coerente efficace misurata  $f$  (blu) coincidono nel regime di rumore molto basso — come devono, ed è il controllo che dà credibilità al resto — ma divergono senza limite al crescere di  $\varepsilon_{2q}$ . Ai livelli nominali dei due use case lo scarto è già di un fattore quattro (UC1) e di tre ordini di grandezza (UC2). Scala doppio-logaritmica; figura rigenerabile da `figure_src/gen_audit_classificatore.py`.

Il quadro che ne esce è netto, e la Figura 7.5 lo rende immediato. Nel regime di rumore molto basso le due grandezze coincidono, come devono: a  $\varepsilon_{2q} = 10^{-3}$  il rapporto vale 1.0 e l'esponente efficace 148, prossimo alle 166 porte reali. Ma già al valore nominale di UC1 la stima analitica sbaglia di un fattore quattro, e da lì in poi diverge senza limite: a  $\varepsilon_{2q} = 10^{-1}$  il rumore residuo conserva ancora il 16% di segnale coerente là dove  $P_{\text{surv}}$  prevedeva una parte su quaranta milioni.

La lettura più informativa è quella dell'ultima colonna. L'esponente efficace *non* è il numero di porte a due qubit del circuito: si stabilizza fra 14 e 20 per  $\varepsilon_{2q} \geq 2 \times 10^{-2}$ , ossia attorno a **un nono delle 166 porte presenti**. In altre parole, la stragrande maggioranza degli errori a due qubit non distrugge l'informazione di fase. Il motivo è che  $(1 - \varepsilon)^k$  conta gli *errori*, non i *danni*: il canale depolarizzante applica una fra quindici Pauli non banali, molte delle quali agiscono sul registro di lavoro senza alterare il kickback di fase già accumulato sul registro di controllo, altre si compensano a vicenda, e la periodicità della moltiplicazione modulare — da cui i



picchi discendono — sopravvive a gran parte di esse.<sup>3</sup>

Questo risultato ha una conseguenza che va oltre la strategia TOP-K, e che il seguito della tesi deve tenere presente: **le stime di fattibilità basate su  $P_{\text{surv}}$  sono pessimistiche di ordini di grandezza**, e tanto più quanto più il circuito è profondo. Là dove il presente capitolo la usa per dichiarare UC3 e UC4 fuori portata, essa va intesa come indicatore di un regime, non come dimostrazione di impossibilità: la conclusione su quei due use case regge sulla barriera computazionale, che è misurata, e non su quella analitica.

## 7.6.2 Confronto con la Zero-Noise Extrapolation

Il confronto con la ZNE sullo stesso task (Tabella 7.7; dettaglio in Sezione D.1) completa il quadro. Nessuna delle due varianti di estrapolazione degrada il risultato — tutte le strategie raggiungono il 100% di successo — ma nessuna lo migliora in modo significativo:  $\bar{M}$  resta statisticamente indistinguibile da quello della baseline, mentre il costo in shot raddoppia o triplica per il campionamento ai livelli di rumore amplificato. La ZNE è dunque *inefficace*, non controproducente: paga un prezzo certo per un beneficio che su questo compito non si manifesta. La strategia che accetta il rumore e amplia la ricerca, al contrario, dimezza le iterazioni al costo di un solo campionamento.

Tabella 7.7: Confronto M1, ZNE-2, ZNE-3 e  $M_{\text{TOP4}}$  su UC1 ( $K_{\text{rep}} = 30$ ,  $M_{\text{shots}} = 1024$  per livello)

| Strategia                     | $P_{\text{succ}}$ | $\bar{M}$ | Shot/iter | Shot totali | $\rho$ vs M1 | p-value        |
|-------------------------------|-------------------|-----------|-----------|-------------|--------------|----------------|
| M1 (baseline)                 | 100%              | 1.97      | 1024      | 2014        | —            | —              |
| ZNE-2 (lineare)               | 100%              | 2.03      | 2048      | 4164        | 0.967        | 0.728 (n.s.)   |
| ZNE-3 (Richardson)            | 100%              | 1.57      | 3072      | 4813        | 1.255        | 0.250 (n.s.)   |
| $M_{\text{TOP4}}$ ( $K = 4$ ) | 100%              | 1.00      | 1024      | 1024        | 1.967        | <0.001 (sign.) |

<sup>3</sup>La stima di  $f$  dipende dal modello di miscela (7.1), che assume equipartizione sui quattro picchi e uniformità del fondo: è un'approssimazione, e i valori vanno letti come ordini di grandezza. La conclusione qualitativa — divergenza crescente fra  $f$  e  $P_{\text{surv}}$ , con esponente efficace di un ordine di grandezza inferiore al conteggio delle porte — non dipende però dai dettagli del modello, essendo già implicata dal solo fatto che il tasso di successo resti al 100% dove  $P_{\text{surv}} \approx 10^{-8}$ .

## 7.7 Bilancio della Verifica e Ponte verso il Nucleo della Tesi

Questa prima fase sperimentale ha appurato tre fatti, tutti con significatività statistica e piena riproducibilità (seed, noise model, circuito e split espliciti e fissati; codice nella repository della tesi):

1. la ricerca multi-candidato TOP-4 riduce  $\bar{M}$  da 1.97 a 1.00 (UC1), portando ogni ripetizione a convergere al primo tentativo, ed è robusta su tutto il range di rumore NISQ testato, senza addestramento e senza calibrazione;
2. il classificatore ML a valle dell'esecuzione non aggiunge nulla (UC1) o peggiora (UC2): l'ipotesi iniziale, nella parte che attribuiva il guadagno all'apprendimento automatico, era sbagliata — e l'ablazione lo dimostra;
3. le tecniche di correzione dell'output (ZNE) sono inefficaci su questo task: non degradano il risultato, ma non lo migliorano in modo significativo e costano da due a tre volte più shot.

Il punto 2 merita di essere letto in positivo, perché delimita con precisione *dove* si ferma ogni strategia a valle: sul solo output, l'informazione utile è già interamente catturata da una ricerca multi-candidato a costo zero — e ciò che il rumore ha distrutto durante l'esecuzione non è più recuperabile da nessun post-processing, per quanto sofisticato. La conseguenza è strutturale: per andare oltre, l'errore va intercettato e corretto *mentre* il calcolo è in corso, agendo sullo stato quantistico prima che l'informazione sia persa. È esattamente il programma dei prossimi capitoli, che costituiscono il nucleo di questa tesi: la correzione d'errore quantistica — dal codice a ripetizione al codice di Steane (Capitolo 8), al surface code con la stima sperimentale dell'errore logico (Capitolo 9) — fino allo Shor logico, che quantifica il livello di correzione necessario all'algoritmo (Capitolo 10).

## Capitolo 8

# La Correzione d'Errore Quantistico: dal Codice a Ripetizione al Codice di Steane

Il Capitolo 7 ha chiuso la verifica dell'ipotesi iniziale con un esito netto e una lezione precisa: filtrare l'output rumoroso — con o senza apprendimento automatico — non aggiunge nulla che una ricerca multi-candidato non ottenga già a costo zero, perché a quel punto l'informazione distrutta dal rumore è irrecuperabile. Se l'errore non può essere recuperato *dopo*, deve essere corretto *durante*: è la prospettiva della QEC, introdotta nel quadro teorico del Capitolo 5 e resa operativa qui. Questo capitolo costruisce gli strumenti concettuali e sperimentali della correzione d'errore — stabilizzatori, sindrome, decodifica — e li applica in due laboratori a complessità crescente: il codice a ripetizione a 3 qubit, che introduce il meccanismo della sindrome nel caso più semplice, e il codice di Steane  $[[7, 1, 3]]$ , il primo codice pienamente quantistico della tesi, capace di correggere un errore arbitrario su un singolo qubit. Il capitolo successivo estende il percorso al surface code e alla stima quantitativa dell'errore logico.

### 8.1 Dalla Ridondanza Ingenua alla Codifica

L'idea di proteggere l'informazione replicandola è classica: si trasmettono tre copie di un bit e si decide a maggioranza. Sul piano quantistico questa strada è sbarrata due volte. Il teorema di no-cloning [13] (Sezione 3.1) impedisce di copiare uno stato ignoto; e la misura diretta di un qubit, necessaria per un ipotetico “voto di

maggioranza”, distrugge la sovrapposizione che si voleva proteggere. Per questo la pratica NISQ più diffusa si limita a una ridondanza *a livello di esecuzione* — eseguire istanze gemelle dello stesso circuito su regioni diverse del dispositivo e usare l’esito della copia sopravvissuta — che paga un raddoppio di qubit fisici senza agire sulla causa degli errori.

La QEC risolve il problema in modo strutturalmente diverso [17, 18, 31]: l’informazione di un **qubit logico** (*logical qubit*) viene *codificata* — non copiata — nelle correlazioni di entanglement di più **qubit fisici** (*physical qubits*), e gli errori vengono diagnosticati misurando operatori ausiliari che rivelano *che cosa è andato storto* senza rivelare — e quindi senza distruggere — *che cosa è codificato*. È questa distinzione, non la semplice ridondanza, a rendere possibile la correzione durante il calcolo.

## 8.2 Il Ciclo della Correzione: Stabilizzatori, Sindrome, Decoder

Il funzionamento di ogni codice correttore quantistico segue lo stesso ciclo concettuale:

1. **Codifica**: lo stato logico  $|\psi_L\rangle$  viene preparato su  $n$  qubit fisici;
2. **Rumore**: i canali fisici del Capitolo 4 agiscono sui qubit fisici;
3. **Estrazione della sindrome**: qubit ausiliari (*ancilla*) misurano gli stabilizzatori del codice; l’esito — una stringa di bit classica detta **sindrome** (*syndrome*) — identifica la classe di errore senza toccare l’informazione logica;
4. **Decodifica**: un algoritmo classico, il **decoder**, interpreta la sindrome e propone la correzione più probabile;
5. **Correzione**: la correzione viene applicata fisicamente, oppure registrata in un registro classico — il **Pauli frame** — che tiene memoria delle correzioni da interpretare sulle misure successive, riducendo le operazioni fisiche e la propagazione di errori.

**Stabilizzatori.** Uno **stabilizzatore** (*stabilizer*) [32] è un operatore  $S$  che lascia invariati tutti gli stati validi del codice:  $S|\psi_L\rangle = |\psi_L\rangle$ . Finché lo stato resta nello spazio del codice, ogni misura di  $S$  restituisce  $+1$ ; un esito  $-1$  segnala che un errore

ha portato lo stato fuori dal sottospazio consentito. La collezione degli esiti di tutti i generatori del gruppo stabilizzatore costituisce la sindrome. Il punto cruciale è che gli stabilizzatori commutano con l'informazione logica: la loro misura proietta lo stato in un autospazio dell'errore, ma non distingue — e quindi non collassa — i coefficienti della sovrapposizione logica.

**Distanza del codice.** Un codice si denota  $[[n, k, d]]$ :  $n$  qubit fisici,  $k$  qubit logici, distanza  $d$ . La distanza è il peso minimo di un errore capace di trasformare uno stato logico valido in un altro senza essere rilevato; un codice di distanza  $d$  corregge fino a

$$t = \left\lfloor \frac{d-1}{2} \right\rfloor \quad (8.1)$$

errori arbitrari. Lo Steane code ( $d = 3$ ) corregge un errore; un surface code di distanza 5 ne corregge due, di distanza 7 tre. La soglia oltre la quale aggiungere distanza *conviene* — il regime sotto-soglia in cui l'errore logico decresce all'aumentare di  $d$  — è l'oggetto quantitativo del Capitolo 9, e la sua esistenza è garantita in linea di principio dal teorema della soglia per il calcolo fault-tolerant [16].

## 8.3 Il Panorama dei Codici e la Scelta Metodologica

| Codice                  | Parametri            | Corregge                    | Pro / Contro                                            | Uso in questa tesi             |
|-------------------------|----------------------|-----------------------------|---------------------------------------------------------|--------------------------------|
| Repetition (bit-flip)   | $[[3, 1, 1]]$ su X   | solo bit-flip               | semplice / non corregge phase-flip                      | primo laboratorio (sindrome)   |
| Repetition (phase-flip) | 3 qubit, base H      | solo phase-flip             | mostra dualità X/Z / parziale                           | secondo laboratorio            |
| Shor code               | $[[9, 1, 3]]$        | errore arbitrario singolo   | storico, intuitivo / più pesante dello Steane           | approfondimento didattico [17] |
| Steane code             | $[[7, 1, 3]]$        | errore arbitrario singolo   | Calderbank-Shor-Steane (CSS), compatto / distanza bassa | <b>codice centrale</b> [18]    |
| Five-qubit              | $[[5, 1, 3]]$        | errore arbitrario singolo   | minimo possibile / non CSS                              | confronto teorico              |
| Surface code            | $[[\sim d^2, 1, d]]$ | errori locali su griglia 2D | scalabile, standard industriale / molti qubit           | Capitolo 9 [20]                |

Tabella 8.1: Confronto tra i principali codici correttori e loro ruolo nella tesi. La progressione metodologica — repetition per introdurre la sindrome, Steane per la correzione di errori arbitrari, surface code per la prospettiva scalabile — segue il documento di indirizzo del lavoro.

La scelta metodologica è dunque una progressione a tre stadi: il *repetition code* introduce l'estrazione di sindrome nel caso più leggibile; lo *Steane code* è il codice centrale, primo capace di correggere un errore arbitrario; il *surface code* porta il discorso sul terreno scalabile e permette la stima del **logical error rate**  $p_L$  con un decoder reale.

## 8.4 Laboratorio I: il Codice a Ripetizione

### 8.4.1 Il codice bit-flip a 3 qubit

Il codice a ripetizione contro errori X codifica  $|0_L\rangle = |000\rangle$  e  $|1_L\rangle = |111\rangle$ : uno stato arbitrario  $\alpha|0\rangle + \beta|1\rangle$  diventa  $\alpha|000\rangle + \beta|111\rangle$  — uno stato entangled, non tre copie. Gli stabilizzatori sono  $Z_1Z_2$  e  $Z_2Z_3$ : misurano la *parità* tra coppie di qubit senza

misurare i singoli qubit. Un bit-flip su un qubit altera una o entrambe le parità, e la sindrome a 2 bit identifica univocamente quale dei tre qubit ha subito l'errore — che viene corretto riapplicando  $X$ . La misura di parità avviene tramite ancilla: due CNOT copiano la parità sull'ancilla, che viene misurata al posto dei qubit dati.

Il limite è strutturale: il codice non rileva gli errori  $Z$  (phase-flip), che commutano con tutti gli stabilizzatori. Il duale — codificare nella base di Hadamard,  $|\pm_L\rangle = |\pm\pm\pm\rangle$ , con stabilizzatori  $X_1X_2$  e  $X_2X_3$  — protegge dai phase-flip ma non dai bit-flip. La dualità  $X/Z$  è la ragione per cui la correzione quantistica è più difficile di quella classica, e la concatenazione delle due protezioni è esattamente la costruzione del codice di Shor a 9 qubit [17].

## 8.4.2 Risultati del laboratorio repetition

Il laboratorio è stato implementato in Qiskit con estrazione di sindrome tramite due qubit ancilla, secondo il ciclo della Sezione 8.2. Il primo test verifica che la sindrome identifichi correttamente il qubit colpito: si inietta un errore deterministico su ciascuno dei tre qubit dati (un  $X$  per il codice bit-flip, un  $Z$  per il duale phase-flip) e si legge la sindrome. La Tabella 8.2 riporta l'esito: in tutti i casi la sindrome osservata coincide con la previsione della lookup table, e la posizione dell'errore è ricostruita senza ambiguità.

| Errore iniettato | Sindrome $(a_0, a_1)$ | Qubit dedotto | Esito |
|------------------|-----------------------|---------------|-------|
| nessuno          | $(0, 0)$              | —             | ✓     |
| su $q_0$         | $(1, 0)$              | $q_0$         | ✓     |
| su $q_1$         | $(1, 1)$              | $q_1$         | ✓     |
| su $q_2$         | $(0, 1)$              | $q_2$         | ✓     |

Tabella 8.2: Verifica della sindrome: iniezione deterministica di un errore su ciascun qubit e sindrome osservata (senza rumore). Vale identicamente per il codice bit-flip (errore  $X$ , stabilizzatori  $Z_0Z_1$ ,  $Z_1Z_2$ ) e per il duale phase-flip (errore  $Z$ , stabilizzatori  $X_0X_1$ ,  $X_1X_2$ ): il duale si ottiene dal primo per coniugazione di Hadamard, e a parità di seed le due simulazioni producono esiti identici cifra per cifra. La coincidenza non è quindi una conferma indipendente della dualità — che è un fatto algebrico — ma la verifica che l'implementazione la rispetti. L'ancilla  $a_0$  misura la parità dei qubit  $\{0, 1\}$ , l'ancilla  $a_1$  quella di  $\{1, 2\}$ .

Il secondo test misura il beneficio della correzione. Si prepara lo stato logico, si applica a ciascun qubit dato un errore indipendente con probabilità  $p$  (canale  $X$  per il bit-flip,  $Z$  per il phase-flip), si estrae la sindrome, si applica la correzione e

si decodifica: la frazione di esiti logici errati su 20 000 ripetizioni (seed = 42) stima l'errore logico  $p_L$ . La Figura 8.1 confronta i punti Monte Carlo con la previsione analitica del voto di maggioranza: il codice sbaglia quando almeno due dei tre qubit subiscono un errore, cioè

$$p_L = 3p^2(1 - p) + p^3 = 3p^2 - 2p^3. \quad (8.2)$$




Figura 8.1: Errore logico  $p_L$  in funzione dell'errore fisico  $p$  per il codice a ripetizione a 3 qubit. I punti Monte Carlo del codice bit-flip e del duale phase-flip (20 000 ripetizioni per punto) coincidono con la previsione analitica  $3p^2 - 2p^3$  (Eq. 8.2) entro l'errore statistico. Nella regione  $p < 0.5$  la curva giace sotto la bisettrice  $p_L = p$ : la codifica rende il qubit logico più affidabile del qubit fisico non protetto. Il punto di *break-even* è a  $p = 0.5$ , dove correzione e assenza di correzione si equivalgono; oltre, la ridondanza amplifica gli errori anziché sopprimerli.

L'accordo con l'Eq. 8.2 è quantitativo su tutto l'intervallo: ad esempio, per  $p = 0.10$  si osserva  $p_L = 0.0288 \pm 0.0012$  contro il valore teorico 0.0280, e per  $p = 0.20$  si ha  $p_L = 0.1026 \pm 0.0021$  contro 0.1040. Il messaggio operativo è quello che l'intera parte QEC svilupperà su codici più potenti: sotto una soglia di errore fisico, la codifica *sopprime* l'errore — qui da  $p$  a  $\mathcal{O}(p^2)$  — mentre sopra la soglia lo *amplifica*. Il codice a ripetizione paga però un limite strutturale già discusso: protegge da un solo tipo di errore per volta. Un errore  $Z$  sul codice bit-flip commuta con entrambi gli stabilizzatori, non produce sindrome e resta invisibile — ragione per cui il passo



successivo richiede un codice, come quello di Steane, capace di correggere *qualunque* errore su un qubit.

## 8.5 Laboratorio II: il Codice di Steane $[[7, 1, 3]]$

### 8.5.1 Struttura del codice

Lo Steane code [18] codifica un qubit logico in sette qubit fisici, ha distanza 3 e corregge un errore arbitrario (X, Z o Y) su un singolo qubit. È un codice CSS, costruito a partire dal codice classico di Hamming  $[7, 4, 3]$ : la stessa matrice di parità classica genera sia gli stabilizzatori di tipo X sia quelli di tipo Z, il che permette di trattare separatamente le due famiglie di errori.

| Parametro | Valore | Significato                             |
|-----------|--------|-----------------------------------------|
| $n$       | 7      | qubit fisici                            |
| $k$       | 1      | qubit logici                            |
| $d$       | 3      | distanza del codice                     |
| $t$       | 1      | errori arbitrari correggibili (Eq. 8.1) |
| Tipo      | CSS    | sindromi X e Z separate                 |

Tabella 8.3: Parametri del codice di Steane  $[[7, 1, 3]]$ .

I generatori degli stabilizzatori, nella convenzione adottata, sono:

$$\begin{aligned}
 \text{tipo X: } & IIIXXXX, \quad IXXIIXX, \quad XIXIXIX \\
 \text{tipo Z: } & IIIZZZZ, \quad IZZIIZZ, \quad ZIZIZIZ
 \end{aligned} \tag{8.3}$$

Gli stabilizzatori di tipo Z rilevano gli errori X; quelli di tipo X rilevano gli errori Z; un errore Y, essendo proporzionale a  $XZ$ , produce entrambe le sindromi. La struttura di Hamming rende la decodifica trasparente: i tre bit di sindrome di ciascuna famiglia, letti come numero binario, indicano direttamente la *posizione* del qubit colpito (sindrome 011  $\rightarrow$  qubit 3, sindrome 110  $\rightarrow$  qubit 6, e così via), e una lookup table  $\text{sindrome} \rightarrow \text{correzione}$  completa il decoder.

### 8.5.2 Protocollo di laboratorio

Il laboratorio segue il protocollo del documento di indirizzo: (i) preparazione di uno stato logico  $|0_L\rangle$  o  $|+_L\rangle$  secondo una costruzione documentata; (ii) iniezione manuale

di un errore  $X$  su ciascuno dei sette qubit e misura della sindrome; (iii) ripetizione con errori  $Z$  e  $Y$ ; (iv) costruzione della lookup table; (v) valutazione della probabilità di correzione riuscita al crescere dell'errore fisico  $p$ ; (vi) distinzione tra errori sui qubit dati ed errori sulle ancilla durante l'estrazione della sindrome.

Su quest'ultimo punto va dichiarata fin d'ora un'assunzione metodologica: lo Steane code corregge un errore arbitrario *solo se* il modello assume al più un errore rilevante nel blocco, o se il protocollo fault-tolerant impedisce che un singolo guasto si propaghi in più errori non correggibili. La versione implementata in questa tesi usa un'estrazione di sindrome non fault-tolerant, e i risultati vanno letti entro questa assunzione — distinguere ciò che il codice garantisce da ciò che l'implementazione didattica mostra è parte del rigore richiesto al lavoro.

### 8.5.3 Risultati del laboratorio Steane

Il laboratorio è stato implementato in Qiskit. Lo stato logico  $|0_L\rangle$  si prepara come sovrapposizione uniforme degli otto *codeword* del codice: partendo da tre qubit “seme” (quelli che compaiono in un solo stabilizzatore di tipo  $X$ ) posti in sovrapposizione con una porta di Hadamard, una rete di Controlled-NOT (CNOT) propaga la struttura degli stabilizzatori sugli altri quattro qubit. La correttezza della codifica è il primo controllo: misurando i sei stabilizzatori sullo stato preparato si ottiene sindrome nulla 000000 su tutti i 2000 campioni — lo stato è effettivamente nel *code space*.

**La syndrome table è biiettiva.** Il secondo controllo è il cuore del codice: iniettando un errore su ciascuno dei sette qubit e leggendo la sindrome, la posizione del qubit colpito dev'essere ricostruita senza ambiguità. La Tabella 8.4 riporta l'esito per gli errori  $X$  (letti dagli stabilizzatori  $Z$ ): le sette sindromi sono tutte distinte e non nulle, e coincidono con la rappresentazione binaria della posizione, esattamente come prescrive la struttura di Hamming. Per dualità CSS, gli errori  $Z$  producono la stessa tabella sugli stabilizzatori  $X$  (sindrome  $Z$  nulla), e un errore  $Y$  accende *entrambe* le famiglie con la medesima sindrome — confermando che il codice gestisce l'errore arbitrario, non solo bit-flip o phase-flip. La biiettività è verificata per tutti e 21 i casi ( $X$ ,  $Z$ ,  $Y$  su 7 qubit).

| Qubit | Sindrome | Valore | Correzione                    |
|-------|----------|--------|-------------------------------|
| $q_0$ | 001      | 1      | applica $X$ (o $Z$ ) su $q_0$ |
| $q_1$ | 010      | 2      | ... su $q_1$                  |
| $q_2$ | 011      | 3      | ... su $q_2$                  |
| $q_3$ | 100      | 4      | ... su $q_3$                  |
| $q_4$ | 101      | 5      | ... su $q_4$                  |
| $q_5$ | 110      | 6      | ... su $q_5$                  |
| $q_6$ | 111      | 7      | ... su $q_6$                  |

Tabella 8.4: Tabella sindrome→qubit→correzione, verificata sperimentalmente. La sindrome (tre bit) letta come numero binario indica direttamente la posizione del qubit colpito. Vale per gli errori  $X$  (via stabilizzatori  $Z$ ) e, per dualità, per gli errori  $Z$  (via stabilizzatori  $X$ ); un errore  $Y$  accende entrambe le famiglie con la stessa sindrome.

**Il qubit logico batte il fisico: soppressione quadratica.** Il terzo controllo misura il beneficio della correzione. Sotto un canale depolarizzante di intensità  $p$  per qubit, si stima la probabilità di errore logico  $p_L$  con una simulazione Monte Carlo nel formalismo di Pauli (200 000 campioni per punto, seed = 42): per ogni campione si estrae la sindrome, si applica la correzione a peso minimo dalla Tabella 8.4 e si verifica se il residuo contiene un operatore logico non banale. La Figura 8.2 mostra il risultato in scala doppio-logaritmica: i punti seguono un andamento  $p_L \propto p^2$ , con pendenza log-log misurata 1.94 — la firma di un codice di distanza  $d = 3$ , che corregge ogni errore singolo e fallisce solo a partire da due errori. Poiché  $\binom{2}{2}$  configurazioni di peso due sono l'evento dominante di fallimento, l'errore logico è soppresso da  $\mathcal{O}(p)$  a  $\mathcal{O}(p^2)$ .




Figura 8.2: Errore logico  $p_L$  in funzione dell'errore fisico  $p$  (canale depolarizzante), scala doppio-logaritmica. I punti Monte Carlo seguono il riferimento  $\propto p^2$  (pendenza  $d = 3$ ); la bisettrice  $p_L = p$  rappresenta il qubit fisico non protetto. L'intersezione individua la **pseudo-soglia**  $p \approx 0.08$ : sotto di essa il qubit logico è più affidabile del fisico, sopra la ridondanza amplifica l'errore. Curva rigenerabile da `figure_src/gen_qec_steane.py`.

Il regime di convenienza è netto: per  $p = 0.01$  si ha  $p_L = 1.67 \times 10^{-3}$  (già un ordine di grandezza sotto  $p$ ), per  $p = 0.05$  si ha  $p_L = 3.4 \times 10^{-2} < p$ , mentre a  $p = 0.10$  si ha  $p_L = 0.116 > p$ . La pseudo-soglia — l'intersezione tra la curva e la bisettrice  $p_L = p$  — cade attorno a  $p \approx 0.08$ : al di sotto, codificare conviene.

**Confronto con il repetition e assunzioni.** Rispetto al repetition code (Sezione 8.4), che pure esibisce una soppressione  $\propto p^2$ , lo Steane paga sette qubit fisici invece di tre ma ottiene un vantaggio qualitativo decisivo: protegge simultaneamente da errori  $X$ ,  $Z$  e  $Y$ , mentre il repetition è cieco a un intero tipo di errore. Va infine ribadita l'assunzione dichiarata nella Sezione 8.5: l'estrazione di sindrome qui implementata *non è fault-tolerant*. Il modello Monte Carlo inietta errori solo sui qubit dati e assume una lettura di sindrome ideale; un errore sulle ancilla durante l'estrazione può corrompere la sindrome e indurre una correzione errata. La quantificazione di questo effetto — e le tecniche fault-tolerant che lo mitigano — appartiene al terreno del surface code, oggetto del Capitolo 9, dove il decoder opera su cicli ripetuti di misura proprio per distinguere gli errori di dato da quelli di misura.

## Capitolo 9

# Il Surface Code e la Stima dell'Errore Logico

Il Capitolo 8 ha mostrato che un codice di distanza 3 può correggere un errore arbitrario su un singolo qubit — ma anche che questa protezione, da sola, non basta: con sette qubit fisici per qubit logico e distanza fissa, lo Steane code non offre alcuna via per *ridurre a piacere* l'errore residuo. La proprietà che manca è la scalabilità della protezione: un parametro che, aumentato, faccia diminuire l'errore logico. È esattamente ciò che offre il **surface code** [33, 20], oggi lo standard di riferimento industriale per il calcolo fault-tolerant: un codice definito su una griglia bidimensionale di qubit con sole interazioni locali, la cui distanza  $d$  cresce con la taglia della griglia. Questo capitolo ne descrive il funzionamento operativo, introduce il problema della decodifica e la sua soluzione standard — il *matching* di peso minimo — e presenta l'esperimento centrale della parte QEC della tesi: la stima del **logical error rate**  $p_L$  in funzione dell'errore fisico  $p$  e della distanza  $d$ , condotta con gli strumenti specializzati Stim e PyMatching. Le due sezioni conclusive mettono poi alla prova le assunzioni su cui quella stima poggia: prima il modello di rumore con cui il codice viene *simulato* (Sezione 9.5), poi quello con cui viene *decodificato* (Sezione 9.6) — ed è in quest'ultima che l'apprendimento automatico, giudicato superfluo nel Capitolo 7 quando applicato all'output, trova il punto della pipeline in cui produce un guadagno misurabile.

## 9.1 Il Codice su Griglia: Concetto Operativo

Il surface code dispone su una griglia bidimensionale due popolazioni di qubit: i **qubit dati** (*data qubits*), che portano l'informazione logica, e i **qubit di misura** (*measure qubits*), che estraggono ciclicamente stabilizzatori *locali* — ciascuno coinvolge solo i pochi qubit dati adiacenti sulla griglia. Questa località è il vantaggio architetturale decisivo: ogni operazione richiesta dal codice è un'interazione tra vicini fisici, compatibile con le topologie reali delle QPU superconduttive descritte nel Capitolo 4.

I parametri del codice sono  $[[\sim d^2, 1, d]]$ : una distanza maggiore richiede una griglia più grande — il costo in qubit fisici cresce quadraticamente — ma corregge più errori (Eq. 8.1). L'estrazione degli stabilizzatori viene ripetuta per più cicli (*rounds*) consecutivi, perché anche le misure di sindrome sono rumorose: la diagnosi non può basarsi su un singolo ciclo. Una *variazione* dell'esito di uno stabilizzatore tra due cicli successivi costituisce un **detection event**: è il segnale grezzo da cui il decoder deve ricostruire cosa è accaduto.

## 9.2 La Decodifica: Minimum Weight Perfect Matching

Gli errori fisici sul surface code producono detection events *in coppie* (un errore su un qubit dati viola i due stabilizzatori adiacenti), e catene di errori producono eventi solo agli estremi della catena. Il problema del decoder è quindi: dati gli eventi osservati nello spazio-tempo dei cicli di misura, inferire la configurazione di errori *più probabile* che li ha generati. La formulazione standard è un problema di accoppiamento su grafo: il MWPM associa gli eventi a coppie minimizzando un peso legato alla probabilità degli errori, e la libreria PyMatching [26] lo implementa in modo efficiente a partire dal modello di errore del circuito.

Se la catena di correzione proposta dal decoder e la catena di errori reale differiscono per un ciclo che attraversa la griglia da parte a parte, la correzione fallisce *silenziosamente*: l'informazione logica è stata alterata senza che alcuna sindrome lo riveli. La frequenza di questi fallimenti è il logical error rate  $p_L$  — la metrica centrale di tutta la parte QEC.

**Perché servono strumenti dedicati.** La stima di  $p_L$  richiede milioni di esecuzioni di circuiti con centinaia di qubit: fuori portata per un simulatore statevector, il cui

costo cresce come  $2^n$  (Sezione 6.1). I circuiti del surface code, però, sono interamente *stabilizer* (composti di sole operazioni Clifford e misure), e per questa classe il teorema di Gottesman-Knill garantisce la simulabilità classica efficiente. Stim [25] sfrutta esattamente questa proprietà: campiona detection events di circuiti stabilizer a velocità di milioni di shot al secondo. Il rovescio della medaglia — il fatto che Shor *non* sia un circuito stabilizer — è il punto di partenza del Capitolo 10.

La struttura del codice che realizza questa stima — generazione parametrica del circuito, campionamento dei detection events, costruzione del *Detector Error Model* (DEM) e decodifica — è riportata nel Listato B.14 (Sezione B.2).

## 9.3 Disegno Sperimentale

L'esperimento segue il protocollo del documento di indirizzo:

| Variabile    | Valori                           | Osservazione attesa                                 |
|--------------|----------------------------------|-----------------------------------------------------|
| distanza $d$ | 3, 5, 7, 9                       | $p_L$ diminuisce con $d$ se $p$ è sotto soglia      |
| rounds       | $d$ e $2d$                       | cicli di memoria quantistica                        |
| $p$ fisico   | $10^{-4} \dots 2 \times 10^{-2}$ | curva $p$ vs $p_L$                                  |
| shots        | $\geq 10^4$ per punto            | stima stabile di $p_L$ con intervalli di confidenza |
| base         | memory X e memory Z              | confronto protezione errori X/Z                     |

Tabella 9.1: Griglia sperimentale prescritta per la stima del logical error rate. La campagna effettivamente eseguita ne copre un sottoinsieme: tutte e quattro le distanze ed entrambe le basi, con rounds =  $d$  e  $p \in [2 \times 10^{-3}, 10^{-2}]$  — l'intervallo in cui cade l'incrocio delle curve, cioè la grandezza che l'esperimento deve misurare. Lo scaling a rounds =  $2d$  non è stato eseguito (Sezione 9.4).

Il risultato scientifico atteso è una famiglia di curve  $p$  vs  $p_L$ , una per distanza. Se, in una regione di  $p$  sufficientemente bassa, le curve si ordinano in modo che  $d$  maggiore dia  $p_L$  minore — mentre sopra una certa soglia l'ordine si inverte — l'esperimento avrà osservato il comportamento *threshold-like* che il teorema della soglia [16] prevede: sotto soglia, aggiungere ridondanza conviene; sopra soglia, il codice amplifica i propri stessi errori. Il valore di  $p$  a cui le curve si incrociano, confrontato con i tassi d'errore fisici realistici del Capitolo 4, dice quanto margine separa l'hardware attuale dal regime in cui la correzione scalabile funziona.

## 9.4 Risultati

L'esperimento è stato realizzato con **Stim** per il campionamento dei circuiti stabilizzatori e **PyMatching** per la decodifica MWPM, secondo lo schema della Sezione 9.3: memory experiment a rounds =  $d$ , modello di rumore *circuit-level* (depolarizzazione dopo ogni Clifford, flip di reset e di misura tutti pari a  $p$ ), campionamento dimensionato punto per punto in modo da raccogliere circa duecento eventi logici — da  $2 \times 10^5$  a  $4 \times 10^7$  campioni secondo la distanza e il livello di rumore, poiché a  $d = 9$  e  $p = 2 \times 10^{-3}$  il tasso logico è dell'ordine di  $10^{-5}$  e una numerosità fissa produrrebbe una manciata di eventi. La Figura 9.1 riporta le curve  $p$  vs  $p_L$  per  $d = 3, 5, 7, 9$  in base  $Z$ .




Figura 9.1: Errore logico  $p_L$  in funzione dell'errore fisico  $p$  (*circuit-level*) per il surface code ruotato a distanza  $d = 3, 5, 7, 9$ , decoder MWPM, scala doppio-logaritmica. A  $p$  basso le curve *divergono* — distanza maggiore dà errore logico molto minore — e si *incrociano* attorno alla soglia  $p_{th} \approx 0.9\%$ . È la firma del comportamento *threshold-like*: sotto soglia la ridondanza sopprime l'errore, sopra soglia lo amplifica. Barre d'errore statistiche (spesso più piccole del marcatore); curva rigenerabile da `figure_src/gen_qec_surface.py`.

**La soglia è osservata.** Il risultato centrale è la presenza di un incrocio netto. Nel regime sotto-soglia la soppressione è marcata e cresce con la distanza: a  $p = 2 \times 10^{-3}$  si passa da  $p_L = 1.94 \times 10^{-3}$  ( $d = 3$ ) a  $5.10 \times 10^{-4}$  ( $d = 5$ ), a  $1.02 \times 10^{-4}$  ( $d = 7$ ), a  $2.01 \times 10^{-5}$  ( $d = 9$ ) — con fattori di soppressione 3.8, 5.0 e 5.1 per incremento di



distanza. Il fatto che gli ultimi due coincidano entro l'errore è significativo: indica che il regime asintotico è stato raggiunto e che la soppressione è *geometrica* in  $d$ , non un effetto di piccola taglia. L'ordine si mantiene fino a circa  $p = 6 \times 10^{-3}$ ; oltre, le curve si accavallano e a  $p = 10^{-2}$  è *invertito* ( $p_L = 3.9\%$  per  $d = 3$  contro  $5.6\%$  per  $d = 9$ ): sopra soglia aumentare la distanza peggiora l'errore. La soglia osservata,  $p_{th} \approx 0.9\%$  in base Z e  $\approx 0.7\%$  in base X (la lieve asimmetria è attesa per il layout ruotato), è coerente con i valori di letteratura per il surface code con decoder MWPM sotto rumore circuit-level. La coincidenza qualitativa tra le due basi conferma la robustezza del risultato.

**Dalla constatazione alla legge di scala.** Con quattro distanze anziché tre la soglia non va più soltanto letta dall'incrocio: può essere *stimata*. La teoria prevede che, sotto soglia, l'errore logico segua

$$p_L(d, p) = A \left( \frac{p}{p_{th}} \right)^{\lfloor (d+1)/2 \rfloor}, \quad (9.1)$$

dove l'esponente è il numero di errori fisici necessari a produrre un errore logico non rilevabile. Adattando (9.1) ai punti con  $p \leq 6 \times 10^{-3}$  per tutte e quattro le distanze si ottiene  $A = 3.5 \times 10^{-2}$  e  $p_{th} = 0.86\%$  in base Z ( $A = 3.4 \times 10^{-2}$ ,  $p_{th} = 0.81\%$  in base X), con residuo quadratico medio di 0.08 in  $\ln p_L$  — ossia un accordo entro l'8% su cinque ordini di grandezza di errore logico. La stima della soglia ricavata dal fit e quella letta dall'incrocio concordano, il che è un controllo non banale: la prima usa il comportamento sotto soglia, la seconda quello al confine.

Il valore di questa formulazione è che rende il risultato *predittivo* anziché descrittivo. Invertendo la (9.1) si ottiene la distanza minima necessaria a raggiungere un dato errore logico, e con essa il costo in qubit fisici, che per il surface code ruotato è  $2d^2 - 1$  per qubit logico.

Tabella 9.2: Distanza minima e costo in qubit fisici per qubit logico, ricavati invertendo la (9.1) con i parametri stimati in base Z. Il confronto fra le due colonne quantifica quanto la fedeltà dei gate valga in risorse: dimezzare l'errore fisico da  $2 \times 10^{-3}$  a  $10^{-3}$  riduce di oltre tre volte il numero di qubit necessari a raggiungere  $p_L = 10^{-6}$ .

| $p_L$ richiesto | $p = 2 \times 10^{-3}$ |              | $p = 10^{-3}$ |              |
|-----------------|------------------------|--------------|---------------|--------------|
|                 | $d$                    | qubit fisici | $d$           | qubit fisici |
| $10^{-4}$       | 9                      | 161          | 5             | 49           |
| $10^{-6}$       | 15                     | 449          | 9             | 161          |
| $10^{-9}$       | 23                     | 1 057        | 17            | 577          |
| $10^{-12}$      | 33                     | 2 177        | 23            | 1 057        |

**Distanza dall'hardware attuale.** Il confronto con i parametri NISQ del Capitolo 4 è istruttivo: il tasso d'errore a due qubit assunto per il regime realistico ( $\varepsilon_{2q} \approx 10^{-2}$ ) cade *sopra* la soglia osservata. In altre parole, con la fedeltà dei dispositivi odierni il surface code non sopprimerebbe ancora l'errore — servono gate a due qubit al di sotto di  $\sim 10^{-3}$  perché aggiungere distanza produca il guadagno esponenziale atteso. È esattamente il margine che separa l'era NISQ dal calcolo fault-tolerant. Il valore di  $p_L$  ottenibile nel regime sotto-soglia (ad esempio  $p_L \approx 1.0 \times 10^{-4}$  a  $p = 2 \times 10^{-3}$ ,  $d = 7$ ) è il dato che alimenta il modello di Shor logico del Capitolo 10: è il tasso di errore per gate logico che una versione codificata di Shor erediterebbe.

La legge di scala permette però di andare oltre il singolo punto e di rispondere in modo diretto alla domanda di risorse. L'istanza  $N = 15$  richiede dodici qubit logici (otto di controllo e quattro di lavoro); combinando questo dato con la Tabella 9.2 si ottiene che una versione codificata al livello  $p_L = 10^{-4}$  — quello che il Capitolo 10 individua come sufficiente — costerebbe **circa 1 900 qubit fisici** a  $p = 2 \times 10^{-3}$ , e ne basterebbero **poco meno di 600** se la fedeltà dei gate migliorasse di un fattore due. È il modo più concreto di enunciare il costo della correzione: non un fattore moltiplicativo astratto, ma due ordini di grandezza di qubit per eseguire in modo protetto la fattorizzazione di un numero a quattro bit.

**Riproducibilità.** Ogni punto è stimato con seed del campionatore fissato in modo deterministico per ciascuna coppia (errore fisico, distanza), e gli intervalli mostrati sono le corrispondenti deviazioni standard binomiali: la curva è rigenerabile bit per bit dallo script versionato. La numerosità è scelta in due passate — una prima stima a  $2 \times 10^5$  campioni fissa l'ordine di grandezza di  $p_L$ , la seconda dimensiona il campione per raccogliere circa duecento eventi logici — ed è riportata nel JSON dei risultati punto per punto. Il criterio è necessario alle distanze grandi: a  $d = 9$

e  $p = 2 \times 10^{-3}$  una numerosità fissa di  $2 \times 10^5$  campioni produce due soli eventi, con incertezza relativa del 70%, mentre il campionamento adattivo porta lo stesso punto al 3.5%. È questa precisione a rendere possibile l'adattamento della legge di scala (9.1): con la statistica precedente i fattori di soppressione a  $d = 7$  e  $d = 9$  non sarebbero stati distinguibili. Una ripetizione indipendente della campagna, condotta con seed diverso, ha riprodotto ogni punto entro l'errore statistico e ha restituito gli stessi valori di soglia. Lo scaling rounds =  $2d$  e distanze ancora maggiori sono estensioni naturali; l'implementazione con Stim rende il campionamento a queste distanze poco oneroso, e il vincolo pratico è la memoria richiesta dal campionamento a blocchi più che il tempo di calcolo.

## 9.5 Oltre il Modello di Pauli: Errori Coerenti e Leakage

La stima del logical error rate appena presentata poggia su un'assunzione che va resa esplicita, perché ne delimita la validità: Stim è un simulatore a **stabilizzatori**, efficiente proprio perché i gate sono Clifford e gli errori sono Pauli casuali ( $X$ ,  $Y$ ,  $Z$ ) con probabilità assegnate. È il modello standard delle grandi campagne di soglia, ma l'hardware reale non commette necessariamente errori di Pauli. Un lavoro recente [34] argomenta in modo sistematico che questa semplificazione può rendere le stime *ottimistiche*, e che una parte della fisica rilevante — errori coerenti, leakage, correlazioni temporali — va conservata nella simulazione per non certificare un'astrazione al posto del dispositivo.

Due sono le sorgenti di errore non-Pauli più importanti. La prima è l'**errore coerente**: un'imperfezione di calibrazione produce una piccola sovrarotazione sistematica  $U = e^{-i\varepsilon H}$ , uguale a ogni ripetizione del gate. A differenza di un errore stocastico, le sovrarotazioni si sommano *in ampiezza*, non in probabilità. La seconda è il **leakage**: un transmon non è un sistema a due livelli e può popolare lo stato  $|2\rangle$ , un grado di libertà che un modello Pauli su due livelli non può nemmeno rappresentare.

**Una verifica diretta su scala trattabile.** Il meccanismo alla base del divario si dimostra con un esperimento elementare, alla portata della simulazione *full-state* (Figura 9.2): un singolo qubit soggetto a  $N$  operazioni rumorose ripetute, con la stessa probabilità di errore per operazione  $p = 10^{-2}$ , modellata in due modi — come errore di Pauli ( $X$  con probabilità  $p$ ) e come errore coerente (sovrarotazione  $RX(\theta)$ )

con  $\sin^2(\theta/2) = p$ ). L'errore di Pauli si accumula *linearmente* in  $N$ ; quello coerente *quadraticamente*, perché gli angoli si sommano ( $\sin^2(N\theta/2)$ ). La simulazione (Qiskit Aer) coincide con la previsione analitica e mostra un divario netto: già a  $N = 8$  operazioni l'errore coerente è circa 7 volte quello di Pauli. Un modello che trattasse le sovrarotazioni come errori Pauli equivalenti sottostimerebbe l'errore reale esattamente di questo fattore.




Figura 9.2: Accumulo dell'errore su un singolo qubit al crescere del numero  $N$  di operazioni rumorose, a parità di probabilità di errore per operazione ( $p = 10^{-2}$ ). L'errore coerente (sovrarotazione, in rosso) cresce quadraticamente e raggiunge il regime di errore quasi certo intorno a  $N = 16$ ; l'errore di Pauli (in blu) cresce linearmente. La simulazione *full-state* (marcatori) coincide con la teoria (linee). A  $N = 8$  il divario è di circa un fattore 7: il modello di Pauli è *ottimistico*. Rigenerabile da `figure_src/gen_coherent.py`.

**Implicazioni per la stima di soglia.** Su un codice completo il divario si amplifica. Lo studio citato riporta, su esperimenti didattici controllati, che il modello Clifford-Pauli stima un errore logico dell'1.7% contro il 23.5% della simulazione completa in presenza di leakage, e del 18.1% contro il 38.7% in presenza di errori coerenti; su un modello di gate CZ fra transmon con surface code a distanza 9, l'errore logico reale può risultare da 25 a 56 volte superiore alla stima Clifford-Pauli, con la soglia sovrastimata di circa il 20% [34]. La direzione metodologica che ne emerge è l'approccio *channel-first*: descrivere il rumore fisico una sola volta come canale quantistico completo (operatori di Kraus, equazione di Lindblad) e scegliere di volta

in volta la rappresentazione di simulazione più adatta, conservando gli effetti non-Pauli dove contano. La soglia cessa così di essere un singolo numero e diventa una *superficie* nello spazio dei parametri fisici del dispositivo ( $T_1$ ,  $T_2$ , durata di gate, leakage, crosstalk), che indica quale imperfezione limiti davvero la macchina.

**Quanto pesa davvero, dentro un ciclo di correzione.** I numeri citati sopra si riferiscono a regimi e distanze diversi da quelli qui studiati, e vale la pena misurare l'entità del divario sul proprio sistema anziché ereditarla. La verifica è stata condotta su un codice di distanza 3 simulato in *full-state* — Stim, essendo un simulatore a stabilizzatori, non può rappresentare una sovrarotazione coerente — iniettando alternativamente errori di Pauli e sovrarotazioni  $R_X$  di *pari probabilità marginale* ( $\sin^2(\theta/2) = p$ ), su quattro cicli di estrazione della sindrome.

Il risultato è più contenuto di quanto la dimostrazione a singolo qubit lasci temere. A  $p = 3 \times 10^{-2}$ , il rumore coerente produce *meno* flip logici grezzi del corrispondente rumore di Pauli (0.237 contro 0.262, ossia il 9% in meno), ma dopo la decodifica MWPM l'errore logico risulta *maggiore* (0.0789 contro 0.0767): il decoder riceve una situazione di partenza migliore e ne restituisce una peggiore. La penalità complessiva imputabile al modello sbagliato è dunque di circa il 12% in termini relativi — significativa, ma di gran lunga inferiore agli ordini di grandezza che il confronto a singolo qubit suggerirebbe.

La spiegazione è nel protocollo stesso. L'estrazione della sindrome entangla ripetutamente i qubit dati con le ancille e ne proietta lo stato a ogni ciclo: questa misura agisce come un **twirling parziale**, convertendo l'accumulo di ampiezza in statistica di Pauli prima che possa crescere quadraticamente. Il ciclo di correzione, in altre parole, si protegge in parte da solo dalla coerenza, e l'assunzione di Pauli del decoder è meno sbagliata *dentro* un codice attivo di quanto non lo sia su un qubit lasciato evolvere liberamente.

**Una previsione che il twirling porta con sé, e la sua verifica.** Se il ciclo di correzione converte l'accumulo di ampiezza in statistica di Pauli prima che possa crescere, allora un modello appreso sulla sindrome non deve trovare, sotto rumore coerente, alcuna struttura in più di quella che trova sotto rumore di Pauli — perché la sindrome che riceve è, in entrambi i casi, di natura statistica. È una previsione, e il medesimo esperimento la verifica: il decoder ibrido della Sezione 9.6 è stato eseguito su entrambi i tipi di rumore, e il guadagno che produce rispetto al MWPM è 1.019,

1.036 e 1.041 sotto errori di Pauli contro 1.029, 1.048 e 1.052 sotto errori coerenti, ai tre livelli  $p = 1, 2, 3 \times 10^{-2}$ .

Lo scarto è di circa un punto percentuale, dell'ordine di una deviazione standard sulla stima di  $p_L$  ( $\sigma \approx 9.6 \times 10^{-4}$  su  $7.5 \times 10^4$  campioni di test): **non significativo**. Va però registrato che il segno è lo stesso in tutti e tre i punti, il che è compatibile con un effetto reale ma di entità pari a circa un decimo di quello che l'intuizione “il rumore coerente è più lontano dal modello di Pauli, quindi la rete deve renderci di più” lascerebbe attendere. La cecità del matching che l'apprendimento sfrutta non è dunque genericamente il “non essere Pauli”: una sovrarotazione  $R_X$  su un singolo qubit dato, quando produce un flip, accende gli stessi stabilizzatori di un errore  $X$  ed è rappresentabile come arco del grafo esattamente come quello. Ciò che il matching non può rappresentare, e che l'apprendimento recupera, è la *non decomponibilità* — un meccanismo che accende più di due detector, come il crosstalk fra qubit dati adiacenti della Sezione 9.6. È una precisazione del criterio, non un'eccezione ad esso.

Per questa tesi la conseguenza è triplice e va dichiarata: i valori di soglia e di  $p_L$  qui riportati vanno intesi come **baseline ottimistica** valida entro il modello Pauli — ottimistica di circa il 12% alla distanza esaminata, non di ordini di grandezza; il loro raffinamento verso un modello di rumore fisico più ricco, con distanze maggiori e cicli meno frequenti, è la naturale continuazione del lavoro; e il vantaggio della decodifica appresa **non** si estende agli errori coerenti, contrariamente a quanto la loro maggiore distanza dal modello di Pauli suggerirebbe.

## 9.6 La Decodifica Appresa: Sintesi della Campagna

La sezione precedente ha mostrato che il modello di rumore usato per *simulare* il codice è un'idealizzazione. Esiste però una seconda idealizzazione, indipendente dalla prima e altrettanto conseguente, che riguarda il modello usato per *decodificare*. Il MWPM non è un algoritmo generico: presuppone che ogni meccanismo d'errore accenda al più due detection events e sia quindi rappresentabile come un arco del grafo. Un errore correlato che colpisca due qubit dati adiacenti ne accende fino a quattro e non ammette alcun arco che lo rappresenti — non viola l'ipotesi di Pauli, che resta soddisfatta, ma quella di **decomponibilità**.

Da qui la domanda che chiude il cerchio metodologico della tesi: *esiste un regime in cui un decoder appreso dai dati, che non assume alcun modello ma lo ricava dai campioni, fa meglio di quello analitico?* Il Capitolo 7 ha stabilito che l'apprendimento applicato *a valle* dell'esecuzione non aggiunge nulla; qui il medesimo strumento —

un percettrone multistrato di `scikit-learn` — viene applicato alla **sindrome**, dove l'informazione strutturale non è ancora stata distrutta. Cambia il punto di applicazione, non la tecnologia: è ciò che permette di attribuire l'esito al *dove* e non al *come*.

La campagna consta di sette esperimenti, riportati per esteso nella Sezione E.1 dell'Appendice E. Se ne riassumono qui gli esiti e il criterio che ne discende.

|     | domanda                                          | esito                                                                                       |
|-----|--------------------------------------------------|---------------------------------------------------------------------------------------------|
| E1  | sostituire il matching con una rete?             | <b>No</b> : nessuna vittoria su 14 configurazioni; pareggio a $d = 3$ , sconfitta a $d = 5$ |
| E1b | quanti dati servirebbero?                        | $10^5$ – $10^6$ campioni solo per pareggiare a $d = 3$                                      |
| E2  | e se il rumore esce dal modello del decoder?     | la rete vince a $d = 3$ ( $1.14$ – $1.19\times$ )                                           |
| E3  | sa prevedere <i>quando</i> il matching sbaglia?  | sì, $AUC = 0.941$                                                                           |
| E4  | affiancarlo invece di sostituirlo?               | $-18/ -21\%$ a $d = 3$ , $-1/ -3\%$ a $d = 5$ , <b>nullo</b> a $d = 7$                      |
| E5  | è trasferibile fra profili di rumore?            | sì, 12 trasferimenti su 12 battono il matching                                              |
| E6  | un modello <i>mal calibrato</i> apre un margine? | <b>No</b> : 0 su 12; il matching perde solo l'1–3%                                          |
| E7  | un decoder analitico migliore lo cattura già?    | a $d = 5$ sì, e meglio della rete                                                           |

Tabella 9.3: Sintesi dei sette esperimenti sulla decodifica appresa. Il dettaglio, con tabelle, figure e test di significatività, è nella Sezione E.1.

**Che cosa se ne ricava.** Il risultato centrale è che **sostituire** il decoder analitico non conviene, mentre **affiancarlo** sì. Il decoder ibrido, in cui la rete apprende unicamente *quando ribaltare* la decisione del matching, riduce l'errore logico fino al 21% in presenza di errori correlati e ricade esattamente sul matching quando il rumore è quello previsto: degrada con grazia, riconoscendo di non avere nulla da aggiungere.

Due controlli successivi ne delimitano però la portata, e vanno enunciati senza attenuazioni. Il primo (E6) esclude che il vantaggio nasca dal fornire al matching un modello esatto che l'hardware non offre: perturbando il modello fino a un ordine di grandezza l'errore logico varia dell'1–3%, e la rete non vince mai. Il secondo (E7) confronta con BP+OSD, decoder analitico strettamente più espressivo: a  $d = 5$  esso guadagna il 17–27% dove l'ibrido si ferma all'1–3%.

Il quadro che ne esce non è però una sconfitta dell'apprendimento, bensì una precisazione su *quale* informazione esso sfrutti. Il guadagno di BP+OSD **decresce** al crescere del rumore correlato, quello dell'ibrido **cresce**: i due metodi agiscono su assi ortogonali, perché il primo sfrutta meglio il modello che riceve e il secondo cattura ciò che al modello sfugge.

Sarebbe naturale inferirne che i due guadagni si *sommino*, e che costruire il residuo appreso sopra BP+OSD anziché sopra il matching li cumuli. Due ulteriori esperimenti mostrano che l’inferenza è sbagliata, e insieme spiegano perché. Il primo (E8) realizza la costruzione: il decoder combinato eguaglia sempre il migliore dei due singoli e mai il loro prodotto, e sopra BP+OSD il residuo migliora in modo significativo in una sola configurazione su dieci. Il secondo (E10) ne dà la ragione, misurando sei decoder sui medesimi campioni: in presenza di rumore correlato il matching col residuo, BP+OSD col residuo e la rete usata *da sola*, senza alcun decoder analitico sotto, atterrano tutti entro l’1–2% sullo stesso errore logico, mentre i decoder analitici da cui provengono restano il 16–18% sopra; in assenza di rumore correlato quel pavimento comune non esiste e i metodi si ordinano per qualità intrinseca. Un terzo controllo (E11) esclude che si tratti del tetto dell’architettura scelta: una rete con quaranta volte i parametri atterra sullo stesso valore entro lo 0.8%, e un decoder che memorizzi le sindromi anziché stimarne un modello fa peggio. **Il limite non appartiene dunque a nessuno dei due metodi**, e impilarli non porta al di sotto di esso.

**Il criterio, nella sua forma definitiva.** Ne discende l’enunciato che regge l’intero lavoro, ora verificato su due impieghi opposti dello stesso strumento: *un modello appreso produce valore quando la classe di errore non è rappresentabile nella struttura del metodo analitico — non quando è rappresentata con parametri imprecisi*. La cecità che conta è strutturale, non di calibrazione. E poiché il vantaggio si annulla a  $d = 7$ , dove la discriminazione della rete densa sui 336 detector resta troppo bassa perché ribaltare la predizione del matching risulti in attivo — e ciò accade anche quando gli esempi di addestramento abbondano — la nicchia in cui l’apprendimento è la scelta giusta risulta reale ma stretta: il primo controllo da eseguire, prima di introdurre un modello appreso, è verificare di avere già adottato il miglior metodo analitico disponibile.



## Capitolo 10

# Integrazione: lo Shor Logico e i Requisiti di Correzione

I Capitoli 8 e 9 hanno costruito e misurato la correzione d'errore su circuiti dedicati; il Capitolo 7 aveva misurato quanto il rumore fisico degrada Shor. Questo capitolo chiude il cerchio unendo i due fili: che cosa succederebbe all'algoritmo di Shor se i suoi qubit fossero *logici*, protetti da un codice correttore? La tentazione naturale — codificare ogni qubit di Shor con Steane o surface code e simulare tutto esplicitamente — non è percorribile, e la ragione è strutturale, non solo pratica. La soluzione metodologicamente corretta, prescritta dal documento di indirizzo del lavoro, è un'**integrazione a livelli**: caratterizzare separatamente Shor rumoroso e correzione d'errore, e connetterli attraverso un'unica grandezza di scambio — il logical error rate  $p_L$ . Il prodotto finale è la risposta a una domanda scientifica precisa: *quale livello di errore logico è necessario affinché Shor mantenga una probabilità di successo accettabile?*

### 10.1 L'Architettura a Quattro Livelli

Il percorso sperimentale complessivo della tesi si organizza in quattro livelli di simulazione, ciascuno con il proprio strumento e la propria domanda:

| Livello | Oggetto       | Strumento                                                | Dove nella tesi  |
|---------|---------------|----------------------------------------------------------|------------------|
| 1       | Shor ideale   | Qiskit Aer (statevector)                                 | Capp. 6–7        |
| 2       | Shor rumoroso | Qiskit Aer + noise model                                 | Cap. 7, App. D.1 |
| 3       | QEC isolata   | Qiskit (repetition, Steane); Stim + PyMatching (surface) | Capp. 8–9        |
| 4       | Shor logico   | Qiskit Aer + errore logico $p_L$                         | questo capitolo  |

Tabella 10.1: L’integrazione a livelli: ogni livello isola una domanda. Il livello 4 connette i precedenti: l’errore logico  $p_L$ , misurato al livello 3, sostituisce il rumore fisico del livello 2 nel circuito del livello 1.

**Perché la simulazione completa non è percorribile.** Due barriere si sommano. La prima è dimensionale: codificare i 12 qubit di Shor per  $N = 15$  con un surface code di distanza 3 richiederebbe centinaia di qubit fisici simulati, ben oltre il limite statevector già discusso nella Sezione 6.1. La seconda è strutturale: Stim, che ai livelli di qubit richiesti sarebbe l’unico strumento efficiente, simula solo circuiti *stabilizer* — e Shor non lo è. L’esponenziazione modulare e le rotazioni della QFT sono operazioni non-Clifford, che nessun simulatore stabilizer può trattare senza perdere l’efficienza garantita dal teorema di Gottesman-Knill. Presentare Stim come simulatore di uno Shor completo sarebbe un errore metodologico; la divisione dei compiti tra Qiskit Aer (circuiti generali piccoli) e Stim/PyMatching (QEC stabilizer) è l’unica configurazione corretta, ed è quella adottata.

## 10.2 Il Modello di Shor Logico

L’idea del livello 4 è sostituire il rumore fisico con il suo residuo dopo la correzione. In un’esecuzione fault-tolerant reale, ogni operazione logica — gate su qubit codificati, cicli di sindrome, misura logica — lascia una probabilità residua  $p_L$  di errore logico non corretto. Il modello di Shor logico rappresenta questo residuo direttamente: il circuito di Shor del Capitolo 6 viene eseguito con un canale d’errore di probabilità  $p_L$  applicato dopo ogni gate logico (o, in una variante a granularità maggiore, dopo ogni blocco computazionale), con  $p_L$  trattato come parametro libero nell’intervallo stimato sperimentalmente al Capitolo 9.

Il modello è dichiaratamente un’approssimazione: assume errori logici indipendenti e uniformi tra i gate, trascura le correlazioni residue del decoder e l’overhead dei gate logici non trasversali. La sua funzione non è riprodurre fedelmente una macchina fault-tolerant, ma porre in modo quantitativo la domanda di ricerca conclusiva:

*quale valore di  $p_L$  è necessario affinché la probabilità di successo di Shor superi una soglia prefissata — ad esempio l'80%?*

La risposta, combinata con le curve  $p \rightarrow p_L$  del surface code, si traduce in un requisito sull'hardware fisico: dato il tasso d'errore fisico  $p$  di una QPU, quale distanza di codice — e quindi quanti qubit fisici — servono perché quella QPU esegua Shor in modo affidabile. Il confronto con il livello 2 (lo stesso circuito sotto rumore fisico diretto, dove per  $N = 15$  una singola iterazione produce il risultato corretto con probabilità  $\approx 17\%$  usando la sola misura più frequente, Capitolo 7) quantifica il beneficio della correzione, e il **break-even** — il regime in cui il qubit logico diventa più affidabile del qubit fisico equivalente — fornisce il criterio sintetico di valutazione.

## 10.3 Il Contesto: le Stime di Risorse per Shor Fault-Tolerant

Per collocare i risultati didattici nella giusta scala, il capitolo si chiude sul confronto con le stime di risorse della letteratura. Gidney ed Ekerå hanno stimato nel 2021 che fattorizzare un modulo RSA a 2048 bit richiederebbe circa 20 milioni di qubit fisici rumorosi per 8 ore di calcolo, sotto assunzioni fisiche esplicite — con il costo dominato non dall'algoritmo ma dall'overhead di correzione: cicli di sindrome, routing e distillazione di stati magici [35]. È doverosa un'avvertenza metodologica: **questi numeri non si ottengono estrapolando i risultati con  $N = 15$** . Lo Shor a 12 qubit di questa tesi è un esperimento dimostrativo, mentre le stime di risorse sono analisi architetturali complete — che includono compilazione fault-tolerant, layout dei qubit, distillazione e schedulazione — non commensurabili con una singola istanza simulata. Il valore del confronto è qualitativo: chiarisce perché Shor dimostrativo e Shor crittograficamente rilevante siano problemi radicalmente diversi, e quale grandezza li connetta concettualmente — il costo, in qubit e cicli, di portare  $p_L$  al livello richiesto.

In prospettiva futura, va segnalato che queste stime sono in rapida evoluzione: un lavoro più recente di Gidney [36] riduce il fabbisogno sotto il milione di qubit fisici grazie a nuove tecniche di aritmetica modulare, di codifica e di preparazione degli stati magici. La direzione della ricerca — meno qubit a parità di affidabilità — conferma che il collo di bottiglia non è l'algoritmo di Shor in sé, ma l'efficienza

dell'infrastruttura di correzione d'errore che lo sostiene: esattamente il tema di questa parte della tesi.

## 10.4 Risultati del Confronto

**Come l'errore logico è trasferito al circuito.** Il trasferimento del *logical error rate* stimato ai Capitoli 8 e 9 avviene tramite un **unico canale di rumore logico**: dopo ogni gate del circuito di Shor si applica un canale depolarizzante indipendente di intensità  $p_L$ , dove  $p_L$  è il tasso di errore logico residuo che il codice scelto (Steane, oppure surface a una data distanza) lascia sul singolo qubit logico. Va dichiarato con precisione il perimetro di questa scelta: si tratta di un **modello efficace**, non di una simulazione fault-tolerant completa dell'algoritmo. Non si codificano esplicitamente i qubit di Shor né si simulano i cicli di estrazione della sindrome sul circuito logico; si assume invece che l'effetto netto della correzione sia riassumibile in un tasso di errore per operazione logica, indipendente e uniforme tra i gate. È l'approssimazione “a livelli” del documento di indirizzo (§11.3): permette di porre la domanda quantitativa senza il costo, intrattabile, della simulazione fault-tolerant esplicita, al prezzo di trascurare correlazioni e non-idealità che la Sezione 10.4.1 discute.

Concretamente, il modello è stato realizzato iniettando il canale depolarizzante di intensità  $p_L$  dopo ogni gate del circuito di Shor per  $N = 15$  ( $a = 7$ , periodo  $r = 4$ ) e misurando la probabilità di successo come frazione di misure che ricostruiscono i fattori corretti (16 384 campioni per punto, seed fissato). La Figura 10.1 è la figura conclusiva della tesi: mostra  $P_{\text{success}}$  in funzione dell'errore logico per gate  $p_L$ , con sovrapposti i tre regimi di correzione.




Figura 10.1: Probabilità di successo di Shor ( $N = 15$ ) in funzione dell'errore logico per gate  $p_L$ . La curva scende in modo monotono dalla probabilità di successo per singola misura ( $\approx 0.75$  a  $p_L \rightarrow 0$ , base  $a = 7$ ) fino al livello di successo casuale ( $\approx 0.25$ ). I tre marcatori collocano sull'asse tre regimi operativi, ciascuno con il proprio errore fisico e il proprio modello di rumore: *Shor fisico nudo* ( $p_L \approx 10^{-2}$ , nessuna correzione: è il tasso d'errore a due qubit  $\varepsilon_{2q}$  del regime NISQ-realistico), *codice di Steane* ( $p_L \approx 1.7 \times 10^{-3}$ , misurato a errore fisico  $p = 10^{-2}$  sotto canale depolarizzante per qubit con estrazione di sindrome ideale, Cap. 8) e *surface code*  $d = 7$  ( $p_L \approx 9 \times 10^{-5}$ , misurato a errore fisico  $p = 2 \times 10^{-3}$  sotto rumore *circuit-level* con sindrome rumorosa, Cap. 9). I marcatori indicano dunque *dove ciascun codice opera*, non un confronto fra codici a parità di condizioni: la Sezione 10.4.1 discute il punto. Il valore di  $P_{\text{success}}$  al marcatore del surface code è interpolato, poiché  $p_L = 10^{-4}$  è inferiore al più piccolo errore logico simulato ( $2 \times 10^{-3}$ ). Muovendosi verso sinistra — cioè riducendo l'errore logico residuo —  $P_{\text{success}}$  risale verso il limite dell'istanza. Curva rigenerabile da `figure_src/gen_shor_logico.py`.

La curva è monotona e ha due asintoti: a  $p_L \rightarrow 0$  (correzione ideale)  $P_{\text{success}} \approx 0.75$ , a  $p_L$  elevato satura a  $\approx 0.25$ , il livello di successo puramente casuale su un istogramma ormai piatto. Tra i due estremi la correzione compie il suo lavoro: passando dal regime fisico non corretto ( $p_L \approx 10^{-2}$ ,  $P_{\text{success}} \approx 0.64$ ) al codice di Steane ( $p_L \approx 1.7 \times 10^{-3}$ ,  $P_{\text{success}} \approx 0.72$ ) e al surface code sotto soglia ( $p_L \approx 9 \times 10^{-5}$ ,  $P_{\text{success}} \approx 0.74$  per interpolazione), la probabilità di successo risale progressivamente. Questo è, in un solo grafico, il messaggio dell'intera parte sperimentale: ridurre l'errore logico residuo trasforma un calcolo dominato dal rumore in un calcolo affidabile, e la grandezza che governa il guadagno è una sola,  $p_L$ .

**Che cosa la figura non afferma.** Va detto con precisione, perché è il punto in cui la lettura affrettata porterebbe fuori strada: i tre marcatori **non** costituiscono una graduatoria fra i codici a parità di condizioni. Ciascuno è misurato al proprio errore fisico e sotto il proprio modello di rumore, e i due modelli non sono commensurabili — lo Steane è caratterizzato con canale depolarizzante per qubit e sindrome ideale, il surface code con rumore *circuit-level* e cicli di sindrome anch’essi rumorosi, condizione molto più severa. Confrontandoli invece *allo stesso* errore fisico  $p = 10^{-2}$ , i dati dei Capitoli 8 e 9 danno  $p_L = 1.7 \times 10^{-3}$  per lo Steane contro  $p_L = 5.3 \times 10^{-2}$  per il surface code a  $d = 7$ : quest’ultimo è peggiore di oltre un ordine di grandezza, e la ragione è nota e attesa —  $p = 10^{-2}$  cade *sopra* la soglia  $p_{th} \approx 0.9\%$  misurata nel Capitolo 9, dove aumentare la distanza amplifica l’errore anziché sopprimerlo. Ciò che la figura afferma è dunque una relazione fra  $p_L$  e  $P_{\text{success}}$ , valida qualunque sia il codice che produce quel  $p_L$ ; e che i codici studiati raggiungono valori di  $p_L$  progressivamente più bassi *nei rispettivi regimi di validità*. Il surface code non è “meglio” dello Steane su questa istanza: è il solo dei due che, disponendo di hardware sotto soglia, può ridurre  $p_L$  a piacere aumentando  $d$  — ed è per questo, e non per il valore assoluto misurato qui, che è la via allo Shor fault-tolerant.

**Che cosa misura, e che cosa non misura, il valore 0.75.** Il valore  $P_{\text{success}} \approx 0.75$  a correzione ideale va interpretato con cautela: *non* è un limite intrinseco e invalicabile dell’algoritmo, ma la probabilità di successo di una **singola misura** con la specifica scelta della base  $a = 7$ . Occorre distinguere grandezze diverse che il termine “successo” confonde: la probabilità di ricostruire *esattamente* il periodo  $r$  dalla fase misurata; la probabilità di ottenere *un fattore* (che è maggiore, perché il post-processing con gcd recupera i fattori anche da alcune stime parziali del periodo); la dipendenza dalla base  $a$  scelta; e, soprattutto, la differenza tra la probabilità di *una singola misura* e la probabilità *cumulativa* dopo più esecuzioni. L’algoritmo di Shor è per sua natura probabilistico e si esegue ripetutamente: per esecuzioni indipendenti la probabilità di successo cumulativa dopo  $k$  tentativi è

$$P(k) = 1 - (1 - P_s)^k, \quad (10.1)$$

dove  $P_s$  è la probabilità per singolo run. La Figura 10.2 mostra che una  $P_s$  inferiore all’80% non impedisce affatto di superare tale soglia con poche ripetizioni: con  $P_s \approx 0.75$  bastano  $k = 2$  esecuzioni per raggiungere il 94%, e anche partendo da un regime rumoroso ( $P_s = 0.40$ ) sono sufficienti quattro tentativi. La soglia dell’80% va

dunque letta come obiettivo *cumulativo*, non come requisito sul singolo run.




Figura 10.2: Probabilità di successo cumulativa  $P(k) = 1 - (1 - P_s)^k$  (Eq. 10.1) in funzione del numero di esecuzioni indipendenti  $k$ , per diversi valori della probabilità per singolo run  $P_s$ . Il cerchio evidenzia il primo  $k$  che supera la soglia dell'80%: con  $P_s \approx 0.75$  (correzione ideale su  $N = 15$ ) sono sufficienti  $k = 2$  tentativi; anche a  $P_s = 0.40$  ne bastano quattro. Una probabilità per singolo run inferiore all'80% non impedisce di superare quella soglia in modo cumulativo.

**La barriera di scalabilità.** Il modello logico è stato applicato a  $N = 15$  perché l'estensione a istanze maggiori incontra un limite pratico netto, esplorato seguendo l'indicazione di procedere per  $N$  crescenti finché la simulazione resta stabile. Già per  $N = 21$  il circuito, dopo la transpilazione della moltiplicazione modulare (decomposizione di Beauregard), raggiunge una profondità di circa 9 500 porte su 22 qubit: la simulazione classica, anche in assenza di rumore, non completa una singola esecuzione in tempi ragionevoli. È la stessa barriera di scalabilità documentata nel Capitolo 7 per gli use case UC3/UC4, e coincide con l'avvertenza del documento di indirizzo (istanze piccole,  $N = 21$  e 35 solo “se gestibili”). La finestra di  $N$  simulabili si esaurisce dunque a  $N = 15$ : è precisamente questo limite a motivare, sul piano metodologico, il ricorso alle stime di risorse della Sezione 10.3 anziché alla simulazione diretta per proiettare il costo su scala crittografica.

**Che cosa guadagna Shor da un decoder migliore.** Il modello a livelli consente di rispondere a una domanda che, formulata direttamente, resterebbe senza risposta: *quanto vale, per l'algoritmo, migliorare la decodifica?* La Sezione 9.6 misura la

riduzione di errore logico ottenuta dal decoder ibrido rispetto al MWPM in presenza di rumore correlato; la curva della Figura 10.1 traduce un errore logico in una probabilità di successo. Componendo le due si ottiene il guadagno end-to-end, riportato nella Tabella 10.2.

| $d$ | $p_{ct}$           | errore logico $p_L$ |        | $P_{\text{success}}$ di Shor |              |
|-----|--------------------|---------------------|--------|------------------------------|--------------|
|     |                    | MWPM                | ibrido | MWPM                         | ibrido       |
| 3   | $5 \times 10^{-3}$ | 0.0309              | 0.0261 | 0.490                        | <b>0.519</b> |
|     | $1 \times 10^{-2}$ | 0.0583              | 0.0485 | 0.384                        | <b>0.416</b> |
|     | $2 \times 10^{-2}$ | 0.1114              | 0.0918 | 0.283                        | <b>0.305</b> |
|     | $4 \times 10^{-2}$ | 0.2075              | 0.1746 | 0.249                        | <b>0.256</b> |
| 5   | $5 \times 10^{-3}$ | 0.0356              | 0.0352 | 0.467                        | 0.469        |
|     | $1 \times 10^{-2}$ | 0.0870              | 0.0843 | 0.314                        | <b>0.320</b> |

Tabella 10.2: Guadagno end-to-end della decodifica appresa. Le colonne  $p_L$  riportano l'errore logico misurato nella Sezione 9.6; quelle  $P_{\text{success}}$  il corrispondente valore letto sulla curva della Figura 10.1. Il guadagno massimo è di 3.2 punti percentuali, da 0.384 a 0.416. **I valori di  $P_{\text{success}}$  sono ottenuti per interpolazione della curva già misurata, non da nuove simulazioni:** la composizione eredita quindi tutte le approssimazioni del modello a livelli.

Il guadagno è reale ma modesto, e va letto per quello che è. Si manifesta a distanza 3, dove il decoder appreso è competitivo, e si assottiglia a distanza 5, dove — come documentato nella Sezione E.1.5 — l'ibrido recupera poco rispetto al matching. Soprattutto, l'intero intervallo esplorato cade in un regime di errore logico elevato, in cui  $P_{\text{success}}$  è comunque lontana dal limite dell'istanza: è il regime in cui il rumore correlato mette in difficoltà il decoder analitico, non un regime operativo desiderabile. L'affermazione corretta non è dunque che la decodifica appresa renda Shor affidabile, ma che *recupera una frazione misurabile di ciò che il rumore correlato sottrae al decoder analitico*, e che tale frazione si traduce in un guadagno quantificabile sulla probabilità di fattorizzare.

Il valore metodologico di questo passaggio è tuttavia maggiore del suo valore numerico: è il punto in cui la catena che attraversa l'intera tesi — *modello appreso*  $\rightarrow$  *decodifica migliore*  $\rightarrow$  *errore logico minore*  $\rightarrow$  *algoritmo più affidabile* — viene percorsa per intero con grandezze misurate, anziché essere argomentata a parole.



### 10.4.1 Discussione

La domanda di ricerca conclusiva — quale  $p_L$  è necessario affinché Shor mantenga una probabilità di successo elevata — riceve una risposta articolata. Nel regime sotto-soglia il surface code porta l'errore logico a  $p_L \approx 10^{-4}$ , sufficiente a riportare  $P_{\text{success}}$  (per singola misura) al valore massimo dell'istanza; è il codice di Steane, con  $p_L \approx 10^{-3}$ , a rappresentare il gradino intermedio. Quanto alla soglia dell'80% presa a riferimento dal documento di indirizzo, va letta correttamente come obiettivo *cumulativo*: per  $N = 15$  e base  $a = 7$  la probabilità per singolo run a correzione ideale è  $\approx 0.75$ , ma — come mostrato dall'Eq. 10.1 e dalla Figura 10.2 — due sole esecuzioni portano la probabilità cumulativa al 94%. Il valore 0.75 non è quindi un tetto invalicabile, ma il riflesso della natura probabilistica di Shor e della particolare scelta di  $a$ ; una base diversa, o semplicemente qualche ripetizione, spostano l'asticella. Il criterio che sintetizza il capitolo è dunque il **break-even** relativo: ogni riduzione dell'errore logico residuo avvicina  $P_{\text{success}}$  al massimo dell'istanza, in modo monotono e riproducibile. Come precisato sopra, questa non è una graduatoria fra codici — che richiederebbe di misurarli sotto lo stesso modello di rumore e allo stesso errore fisico — ma la quantificazione di quanto *ciascun livello di correzione raggiungibile* valga in termini di probabilità di successo dell'algoritmo.

**Il bilancio dell'intero percorso.** Questo risultato chiude un arco coerente. La prima campagna sperimentale (Capitolo 7) aveva stabilito, tramite ablazione, che l'apprendimento automatico applicato *a valle* dell'esecuzione non aggiunge nulla: il guadagno era interamente della ricerca multi-candidato TOP-K. Quel risultato negativo, lungi dall'essere un vicolo cieco, indicava dove il problema andava affrontato — non nel post-processing dell'output, ma nella *struttura* del calcolo. La seconda parte ha percorso questa strada: la correzione d'errore quantistica codifica l'informazione in modo che l'errore possa essere rilevato e corretto prima che si propaghi, dal codice a ripetizione (che introduce la sindrome) al codice di Steane (che corregge un errore arbitrario) al surface code (che scala verso il regime fault-tolerant). La figura conclusiva riunisce le due parti: mostra quanto della fragilità di Shor sul rumore fisico venga recuperato passando ai qubit logici, e quantifica il prezzo — in distanza di codice, e quindi in qubit fisici — di quel recupero.

Va però osservato che questo bilancio, così formulato, sarebbe incompleto: descrive un arco che va dall'apprendimento automatico *alla* correzione d'errore, come se il primo fosse stato semplicemente abbandonato lungo la strada. Non è ciò che è

accaduto. L'apprendimento automatico rientra nella seconda parte, e vi rientra nel punto che il risultato negativo della prima aveva indicato: non sull'output, ma sulla **sindrome**. La Sezione 9.6 lo documenta, e la Tabella 10.2 ne misura l'effetto fin quaggiù, sulla probabilità di successo dell'algoritmo. L'arco corretto non è dunque “dal machine learning alla QEC”, ma *dal machine learning applicato dove non serve a quello applicato dove serve* — ed è la correzione d'errore ad aver fornito il luogo in cui applicarlo utilmente. Le due strategie che il Capitolo 5 aveva selezionato come promettenti non sono alternative che si escludono: la seconda è la condizione perché la prima abbia qualcosa da fare.

**Limiti e perimetro.** I risultati vanno letti entro il perimetro dichiarato. Il modello logico è un'approssimazione: assume errori logici indipendenti e uniformi tra i gate, trascura le correlazioni residue del decoder, l'overhead dei gate logici non trasversali e la distillazione degli stati magici necessari alle rotazioni non-Clifford. Le stime di errore logico di Steane e surface provengono da modelli di rumore non identici (depolarizzazione per qubit nel primo, *circuit-level* nel secondo) e vanno intese come ordini di grandezza, non come misure direttamente commensurabili. Infine, l'estrazione di sindrome implementata non è fault-tolerant, e l'istanza  $N = 15$  è didattica. Ciò che i risultati dimostrano non è la fattibilità di Shor su scala crittografica — che le stime di risorse [35] collocano a milioni di qubit fisici — ma la *relazione* quantitativa tra capacità di correzione ed affidabilità del calcolo, verificata end-to-end su un'istanza trattabile: è questa relazione, e non il singolo numero fattorizzato, il contributo del lavoro.

# Capitolo 11

## Sviluppi Futuri

Ogni lavoro sperimentale su una tecnologia emergente porta con sé, oltre ai risultati ottenuti, una mappa di direzioni non esplorate: vincoli di tempo, risorse e maturità tecnologica che delimitano il perimetro di ciò che è stato fatto. I Capitoli 8–10 hanno portato la tesi dalla verifica del rumore alla correzione d’errore quantistica e allo Shor logico. Questo capitolo raccoglie le direzioni che stanno *oltre* quel perimetro: le estensioni più naturali del lavoro svolto, le domande che i risultati aprono senza rispondere e le opportunità che lo stato dell’arte attuale rende oggi accessibili.

Le direzioni presentate sono ordinate per urgenza e vicinanza ai risultati ottenuti: si parte dall’estensione più immediata e realizzabile — la scalabilità a istanze maggiori tramite decomposizioni efficienti — per passare alla validazione su hardware reale, alla generalizzazione ad altri algoritmi e al proseguimento della decodifica appresa, concludendo con l’evoluzione del classificatore a valle, il cui contributo è risultato secondario rispetto alla strategia di ricerca TOP-K.

I risultati sperimentali della tesi evidenziano tre aperture concrete: (i) la barriera di scalabilità per  $N \geq 21$  è doppia — la decomposizione **UnitaryGate** ( $> 10\,000$  porte CX) ne è solo la metà rimovibile, mentre la metà residua è fisica e resiste anche a Beauregard (Capitolo 7); (ii) il simulation gap tra il simulatore statevector e l’hardware reale rimane da quantificare sperimentalmente; (iii) l’analisi di ablazione ha dimostrato che il classificatore ML applicato all’output è irrilevante — il vantaggio  $\rho = 1.90$  su UC1 è interamente attribuibile alla strategia TOP-K — apertura che ha trovato la sua risposta strutturale nel nucleo QEC della tesi (Capitoli 8–10) e, per quanto riguarda specificamente il ruolo dell’apprendimento automatico, nella decodifica appresa della Sezione 9.6.

## 11.1 Scalabilità a Istanze di Maggiore Dimensione

I quattro use case di questa tesi utilizzano numeri  $N$  di piccola dimensione. Questa scelta è dettata dai limiti computazionali del simulatore: la simulazione statevector di un circuito di Shor richiede una memoria proporzionale a  $2^{n_{\text{tot}}}$ , dove  $n_{\text{tot}} = n_{\text{count}} + \lceil \log_2 N \rceil$  è il numero totale di qubit. Per  $N = 15$  con  $n_{\text{count}} = 8$ , si hanno 12 qubit e  $2^{12} = 4096$  ampiezze complesse — perfettamente gestibile. Per  $N = 2048$  bit (rilevante crittograficamente), servirebbero  $\sim 4000$  qubit logici, del tutto fuori dalla portata sia dei simulatori che dell’hardware attuale.

Il principale collo di bottiglia identificato dagli esperimenti non è il numero di qubit ma la **profondità del circuito**, e la sua origine è duplice. La decomposizione di Beauregard [11] — che costruisce l’aritmetica modulare nel dominio della QFT con addizionatori di Draper, implementata nel modulo `beauregard.py` sviluppato durante questa tesi — riduce per  $N = 21$  le porte CX da 10 040 a 3 406 su 22 qubit. Ma il conteggio delle sole CX è ingannevole: l’aritmetica nel dominio della QFT paga in porte `cp`, che nel modello di rumore adottato sono soggette allo stesso errore a due qubit, e che qui sono 11 436. Il totale delle porte rumorose *cresce* a 14 842, con  $P_{\text{surv}} \approx 1.7 \times 10^{-65}$ . A questo si somma un costo di simulazione di 16.8 s per traiettoria — oltre trentamila volte quello di UC1 — da cui quasi cinque ore per una sola iterazione da 1 024 shot (Capitolo 7, Tabella 7.2).

Ne segue una direzione di lavoro concreta che questa tesi non ha percorso: **ottimizzare la decomposizione rispetto al numero di porte rumorose anziché al numero di CX**. Le due metriche divergono, e Beauregard le ottimizza in direzioni opposte. Approcci ibridi che sostituiscano le catene di rotazioni controllate con addizionatori a ripple-carry, o che tronchino le rotazioni `cp` di angolo trascurabile — una potatura nota in letteratura come *approximate QFT*, il cui effetto sulla fedeltà è controllabile analiticamente — potrebbero ridurre  $k$  di un fattore rilevante a parità di qubit. Resta comunque vero che l’estensione del confronto M1 vs  $M_{\text{TOP4}}$  a UC3 richiede anche un livello di errore fisico inferiore di ordini di grandezza — ovvero, ancora una volta, la correzione d’errore.

**Come andrebbe riformulata l’ipotesi di scalabilità.** L’analisi di UC4 (Capitolo 7) ha messo in luce un difetto di formulazione dell’Ipotesi secondaria 2 che è indipendente dalle risorse di calcolo, e che una prosecuzione del lavoro dovrebbe correggere per prima cosa. L’ipotesi assume che la difficoltà cresca con il modulo, lungo la sequenza  $N = 15 \rightarrow 21 \rightarrow 35$ . Non è così: la profondità del circuito è gover-

nata dal *periodo*  $r$  dell'elemento  $a$  scelto, perché ogni gate controllato  $U^{2^j}$  con  $2^j \equiv 0 \pmod{r}$  collassa nell'identità e viene eliminato dal transpiler. Lungo la sequenza dei tre use case i periodi valgono  $4 \rightarrow 6 \rightarrow 2$  e le profondità  $311 \rightarrow 9\,883 \rightarrow 1\,480$ : la progressione non è monotona, e UC4 — la cui scelta  $r = 2$  era peraltro deliberata, per isolare l'effetto della larghezza del registro — risulta più *semplice* di UC1 pur avendo un modulo più che doppio.

La riformulazione corretta assume come variabile indipendente il periodo. La verifica diretta degli ordini moltiplicativi mostra che due istanze su tre già la rispettano: per  $N = 15$  l'ordine massimo in  $\mathbb{Z}_N^*$  è 4, raggiunto da  $a \in \{2, 7, 8, 13\}$  fra cui la base  $a = 7$  adottata; per  $N = 21$  è 6, raggiunto da  $a \in \{2, 5, 10, 11, 17, 19\}$  fra cui  $a = 2$ . Per  $N = 35$  l'ordine massimo è 12, raggiunto da  $a \in \{2, 3, 12, 17, 18, 23, 32, 33\}$ , mentre la base  $a = 6$  ha ordine 2 — il minimo non banale. Affiancare a UC4 una quinta istanza  $(N, a) = (35, 2)$  ripristinerebbe la monotonia dell'asse di scalabilità a costo nullo in fase di disegno, con l'avvertenza che il circuito tornerebbe profondo e ricadrebbe nello stesso regime di UC3: la verifica appartiene comunque all'hardware reale, non alla simulazione.

La direzione di sviluppo immediata è quindi la validazione sperimentale di UC3 e di un UC4 ridisegnato, attraverso una delle seguenti modalità: (i) **IBM Quantum** — hardware reale con  $\geq 20$  qubit, accessibile gratuitamente per accademici, che esegue 1024 shot in  $\sim 60$  secondi ed è immune alla barriera computazionale, essendo il dispositivo stesso a eseguire le traiettorie; (ii) **cluster HPC universitario** — lo stesso codice `run_top4_baseline.py` può essere inviato come job batch senza modifiche; (iii) **analisi teorica estesa** — se le risorse non sono disponibili, il contributo di Beauregard può essere quantificato analiticamente tramite  $P_{\text{surv}}$  e confrontato con la letteratura, tenendo però presente che tale stima sottovaluta sistematicamente la recuperabilità del segnale QPE. In tutti i casi, l'obiettivo è verificare se il vantaggio  $\rho \approx 1.9$  osservato per  $N = 15$  si mantiene a profondità circuitale maggiore.

## 11.2 Test e Validazione su Hardware Quantistico Reale

Il sistema sperimentale sviluppato in questa tesi opera interamente su simulatore. Questa scelta garantisce riproducibilità, controllo preciso dei parametri di rumore e accesso illimitato — tutti requisiti indispensabili per la generazione del dataset

di addestramento e per l'esecuzione sistematica dei quattro use case. Tuttavia, la simulazione è per definizione un'approssimazione: il noise model adottato replica il comportamento macroscopico del processore IBM `ibm_marrakesh` attraverso canali di rumore indipendenti e stazionari, mentre il rumore su hardware reale è correlato spazialmente tra qubit vicini, non stazionario nel tempo e affetto da derive lente dei parametri fisici non catturate da un modello statico. Su hardware reale diventano quindi rilevanti le tecniche di compilazione consapevoli del rumore — il mapping adattivo, che assegna il circuito ai qubit e agli accoppiamenti a più alta fedeltà [37], e le politiche che tengono conto della variabilità qubit-per-qubit [38] — che selezionano layout e routing in base ai parametri di errore locali del dispositivo.




Figura 11.1: Confronto degli istogrammi QPE per  $N = 15$  con base  $a = 2$  su simulatore (sinistra) e su hardware IBM Quantum reale (destra). **Entrambi gli istogrammi provengono dall'esecuzione del notebook del tutorial ufficiale IBM [4] sul processore `ibm_marrakesh`, e non dalla pipeline sperimentale di questa tesi, che opera su simulatore e adotta la base  $a = 7$  (Capitolo 7): sono riportati qui come termine di paragone qualitativo, non come misura propria.** Sul simulatore i quattro picchi corretti  $\{0, 64, 128, 192\}$  raccolgono  $\approx 250$  conteggi ciascuno su 1024 shot; sull'hardware reale gli stessi picchi risultano significativamente più deboli ( $\approx 40$ – $58$  conteggi), con la maggior parte dei conteggi dispersi uniformemente. Il divario dà la misura qualitativa della distanza fra un modello di rumore statico e il rumore reale, correlato e non stazionario, di un processore fisico.

Il passo più immediato è quindi l'esecuzione di UC1 e UC2 su hardware reale attraverso IBM Quantum, verificando in che misura le metriche ottenute su simulatore — in particolare il fattore di riduzione  $\rho = \bar{M}_1 / \bar{M}_{\text{TOP4}}$  — si trasferiscono all'hardware fisico. Poiché l'analisi di ablazione ha dimostrato che  $M_{\text{TOP4}}$  non richiede addestramento, questa validazione è immediata: basta eseguire la strategia TOP-K

sui risultati reali senza alcuna fase di fine-tuning. Ci si attende che  $M_{\text{TOP4}}$  mostri la stessa robustezza osservata su simulatore, dato che la sua efficacia non dipende dal profilo specifico del rumore ma dalla struttura dei picchi QPE. Questa differenza è di per sé un risultato scientifico interessante: quantifica il *simulation gap*, ossia la distanza tra il comportamento del simulatore e quello dell’hardware reale.

## 11.3 Generalizzazione ad Altri Algoritmi Quantistici NISQ

La strategia multi-candidato TOP-K sviluppata in questa tesi è stata validata sugli output dell’algoritmo di Shor e non richiede alcun addestramento. Proprio per questo la struttura del problema è più generale: dato un algoritmo quantistico che produce, in assenza di rumore, una distribuzione di output con picchi netti, il rumore degrada quei picchi allargandoli e aggiungendo un fondo uniforme. La strategia TOP-K — che sfrutta la struttura residua dei picchi senza modificare il circuito né il profilo di errore — può in principio essere applicata a qualunque algoritmo con quella struttura.

I candidati più naturali per una generalizzazione sono:

**Algoritmo di Grover.** Come descritto nel Capitolo 3, Grover concentra l’ampiezza sullo stato soluzione tramite *amplitude amplification*. In presenza di rumore, l’ampiezza sullo stato obiettivo si riduce e la distribuzione si appiattisce progressivamente con il numero di iterazioni. La struttura del problema è analoga a quella di Shor: la distribuzione ideale ha un picco dominante, il rumore lo degrada. Una strategia TOP-K applicata a Grover potrebbe tentare i  $K$  candidati più frequenti invece del solo massimo, riducendo il numero di iterazioni necessarie.

**Variational Quantum Eigensolver (VQE).** Il VQE [39] è uno degli algoritmi più rilevanti per l’era NISQ: stima il valore atteso di un Hamiltoniano usando circuiti parametrizzati e ottimizzazione classica. Il rumore introduce un bias sistematico nella stima dell’energia. Un modello di regressione addestrato a correggere questo bias — estensione diretta dell’approccio di [28] — potrebbe ridurre significativamente il numero di misurazioni necessarie per convergere all’energia dello stato fondamentale.

**Quantum Approximate Optimization Algorithm (QAOA).** Il QAOA [40] è progettato per problemi di ottimizzazione combinatoria (Max-Cut, TSP). La funzione obiettivo è anch’essa un valore atteso misurato su un circuito quantistico, e il rumore la degrada in modo analogo al VQE. La tecnica TOP-K sviluppata per Shor potrebbe essere adattata per selezionare, dopo ogni valutazione della funzione obiettivo, i  $K$

candidati più promettenti invece del solo massimo, riducendo il numero di valutazioni necessarie.

## 11.4 Integrazione con la Quantum Error Correction Strutturale

La strategia  $M_{\text{TOP4}}$  sviluppata in questa tesi opera al livello degli *output*: sfrutta la struttura statistica dell'istogramma rumoroso per identificare il risultato corretto. La QEC strutturale — basata su codici come il surface code — opera invece al livello dei *qubit fisici*: rileva e corregge gli errori *durante* l'esecuzione, prima che si propaghino.

Questi due approcci sono complementari, non alternativi, e il modello di Shor logico del Capitolo 10 fornisce il banco di prova naturale per la loro combinazione: nello Shor logico, TOP-K non dovrebbe più compensare il rumore fisico dei gate — quello è compito del codice correttore — ma l'incertezza residua  $p_L$  derivante da errori oltre la soglia del codice o da imprecisioni nella decodifica della sindrome.

La verifica è stata condotta, ed è opportuno riportarne l'esito perché delimita la proposta anziché confermarla: **su  $N = 15$  la strategia TOP-K non è in grado di discriminare a livello logico**. Facendo variare l'errore logico per gate su tre ordini di grandezza, fino a valori ai quali la probabilità di successo per singola misura è già scesa al livello del caso, la frazione di iterazioni risolte da TOP-4 resta pari al 100%: la curva è esattamente piatta. Ne è responsabile la stessa degenerazione discussa nel Capitolo 10 — con periodo  $r = 4$  una frazione elevata degli esiti conduce comunque ai fattori attraverso le frazioni continue — che rende il criterio insensibile al parametro che si vorrebbe misurare.

L'estensione resta dunque interessante, ma non è a basso costo come potrebbe sembrare: richiede un'istanza con periodo meno degenerare, e ricade perciò nella barriera di scalabilità documentata nel Capitolo 7. Le due limitazioni — degenerazione dell'istanza piccola e intrattabilità di quelle grandi — non sono indipendenti: sono lo stesso ostacolo che si presenta due volte, e superarlo richiede hardware, non una scelta algoritmica diversa.

Una seconda direzione riguarda la decodifica appresa, che in questa tesi non è più una prospettiva ma un risultato: la Sezione 9.6 mostra che una rete addestrata sulle sindromi riduce l'errore logico del surface code in presenza di rumore correlato, e che il suo impiego efficace non è sostituire il decoder analitico ma correggerlo. Ciò che resta aperto sono quattro estensioni naturali di quel risultato, di cui la



prima è emersa dai controlli condotti contro il risultato stesso. **Andare sotto il pavimento.** La direzione che sembrava più promettente è già stata percorsa, e si è chiusa. Poiché BP+OSD e il decoder appreso agiscono su assi ortogonali rispetto al rumore correlato, era naturale attendersi che i loro guadagni si sommassero; gli esperimenti della Sezione E.1.8 mostrano invece che il decoder combinato eguaglia il migliore dei due e mai il loro prodotto, perché entrambe le strade conducono al medesimo pavimento — lo stesso su cui atterra la rete usata da sola, senza alcun decoder analitico. Quel pavimento è una proprietà dell'informazione contenuta nella sindrome, e la domanda che resta aperta non è più come sommare due decodifiche ma *come procurarsi informazione che la sindrome non contiene*. Due vie sono concrete: estendere l'ingresso del decoder ai dati analogici della misura — i *soft outcomes*, l'ampiezza del segnale di dispersione anziché il bit già discretizzato, che quantificano la confidenza di ciascuna misura e che l'hardware produce ma il formalismo scarta; e sfruttare la *storia temporale* fra cicli successivi, che il decoder qui impiegato tratta come un unico vettore piatto. In entrambi i casi non si tratta di decodificare meglio la stessa sindrome, ma di riceverne una più ricca. La seconda estensione è **architetturale**, ed è quella che il risultato a distanza 7 rende necessaria — e che la diagnosi condotta sui dati rende anche l'unica sensata. La spiegazione immediata del fallimento sarebbe la scarsità di esempi, poiché l'evento da apprendere è il fallimento del matching e la sua frequenza è  $p_L$ , che decresce esponenzialmente con la distanza. Un esperimento dedicato la esclude. Variando il numero di cicli di estrazione della sindrome si può cambiare il numero di detector *a distanza fissa*, e l'incrocio  $2 \times 2$  che ne risulta (Tabella E.5) separa le due variabili che altrimenti si muovono insieme: a distanza 5 con 336 detector e  $1.9 \times 10^5$  esempi positivi il residuo si astiene, mentre a distanza 7 con 144 detector e tre volte meno esempi interviene. Il comportamento segue la larghezza dell'ingresso, non la distanza del codice. Un ulteriore controllo ne chiarisce il meccanismo e rende verificabile il rimedio: a 336 detector la rete non è cieca — ordina i fallimenti del matching con AUC fra 0.57 e 0.77 — ma poiché ribaltare una predizione corretta costa quanto correggerne una sbagliata, l'operazione è in attivo solo se fra gli shot ribaltati la precisione supera il cinquanta per cento, e a quella larghezza nessuna soglia vi arriva. Il criterio di successo per un'architettura alternativa è dunque netto e verificabile in anticipo: innalzare la discriminazione quanto basta a superare quella soglia. La via consiste nello sfruttare la simmetria del problema anziché ignorarla: architetture **convoluzionali o a grafo**, che condividono i pesi fra regioni equivalenti del reticolo, riducono drasticamente il numero di parametri da stimare e possono apprendere da un numero di esempi molto

inferiore. È la direzione dei decoder allo stato dell'arte — AlphaQubit [22] e i decoder transformer [41], nella linea aperta da [21] — che sfruttano appunto la località della griglia e la struttura temporale dei cicli di sindrome, e da cui ci si attende che il vantaggio sopravviva alle distanze in cui la rete densa non regge. La terza riguarda il **tipo di rumore**, e va formulata tenendo conto che la sua versione più ovvia è già stata provata e smentita. Sarebbe ragionevole attendersi che il vantaggio del decoder appreso cresca sugli errori coerenti, che dal modello di Pauli del matching sono più lontani del crosstalk; la verifica riportata nella Sezione 9.5 mostra invece che il guadagno resta lo stesso entro una deviazione standard, perché l'estrazione ciclica della sindrome converte la coerenza in statistica di Pauli prima che si accumuli, e perché una sovrarotazione su un singolo qubit resta comunque decomponibile in archi del grafo. Ciò che resta da esplorare è dunque il **leakage**, che è l'unica delle sorgenti non-Pauli discusse a violare la decomponibilità e non solo l'ipotesi di Pauli: la fuga verso  $|2\rangle$  non è rappresentabile nello spazio degli errori del decoder, persiste per più cicli e corrompe più stabilizzatori, cioè presenta esattamente la firma strutturale su cui l'apprendimento ha mostrato di rendere. Simularlo richiede però un modello a tre livelli e un simulatore full-state, il che confina l'esperimento a distanze molto piccole. La quarta è la **diagnosi**: un modello che non si limiti a segnalare il fallimento ma indichi quale tipologia di errore lo ha causato trasformerebbe il decoder in uno strumento di caratterizzazione del dispositivo. Con l'avanzare dell'hardware verso processori capaci di surface code su istanze non banali (la roadmap IBM prevede questa capacità entro il 2026–2029 [42]), tutte queste direzioni diventano sperimentabili anche su dispositivi reali, dove il rumore correlato non va iniettato perché è già presente.

## 11.5 Evoluzione del Classificatore ML

L'analisi di ablazione ha dimostrato che il classificatore ML applicato all'output non contribuisce al miglioramento delle prestazioni: la variante  $M_{\text{TOP4}}$  senza classificatore è statisticamente equivalente a M2 per UC1 ( $p = 0.849$ ) e significativamente migliore per UC2 ( $p < 0.001$ ). La risposta strutturale a questo risultato negativo — correggere gli errori durante l'esecuzione anziché filtrarne gli effetti a valle — è il nucleo QEC della tesi (Capitoli 8–10), e il ruolo costruttivo dell'apprendimento automatico in quel contesto (la decodifica appresa) è discusso nella Sezione 11.4. Su questa direzione, però, l'audit delle etichette (Sezione D.2) impone una precisazione che ne ridimensiona la portata, e che è più onesto anticipare qui. Il problema di classificazione a valle

non è semplicemente *difficile*: nella formulazione documentata non ammette istanze negative, perché 63 dei 256 esiti possibili conducono ai fattori e la probabilità che nessuno dei sedici candidati più frequenti sia utile vale 0.9% anche su un istogramma privo di informazione. Rigenerando il dataset con quella regola si ottengono duemila campioni positivi su duemila, per entrambi gli use case, e la ricerca della soglia di rumore a cui la classe negativa comincia a popolarsi non ne trova alcuna: la frazione satura allo 0.5% già a venti volte l'errore di gate dei dispositivi attuali, e non cresce oltre.

Le direzioni elencate di seguito vanno lette entro questo perimetro. Esse conservano interesse in scenari *strutturalmente diversi* da quello studiato — istanze con periodo grande, in cui i picchi QPE siano numerosi e la banda di accettazione delle frazioni continue proporzionalmente più stretta, oppure regimi in cui il costo per iterazione sia tanto elevato da rendere conveniente anche un filtraggio imperfetto — ma non come miglioramenti incrementali del classificatore qui valutato, la cui inefficacia non dipende dall'architettura scelta.

**Classificatore adattivo al regime di rumore.** Il risultato di UC2 ha evidenziato che, quando la probabilità di successo per iterazione della baseline è già alta, il filtraggio del classificatore annulla il vantaggio della ricerca multi-candidato:  $\bar{M}_2 = 1.57$  contro  $\bar{M} = 1.00$  del solo TOP-4. Una soluzione naturale è un classificatore che stima direttamente  $p_{\text{iter}}$  dall'istogramma e decide dinamicamente la strategia ottimale: ricerca TOP-1 (equivalente al Metodo 1) quando  $p_{\text{iter}}$  stimata è alta, ricerca TOP-K quando  $p_{\text{iter}}$  stimata è bassa. Questo adattamento al regime richiederebbe un modello di regressione o un sistema a due stadi con una soglia di commutazione calibrata sul noise model corrente.

**Calibrazione probabilistica dell'output.** Anziché un'etichetta binaria secca, un classificatore calibrato produce una probabilità  $p(\text{corretto} \mid \text{output})$ . Questo consente di impostare una soglia adattiva: il loop si interrompe quando la probabilità stimata supera un livello di confidenza configurabile, bilanciando il rischio di falsi positivi con il costo delle iterazioni aggiuntive.

**Transfer learning tra noise model diversi.** Un classificatore addestrato su un noise model specifico (es. `ibm_marrakesh`) potrebbe essere adattato a un hardware diverso (es. `ibm_kyoto`) attraverso una fase di fine-tuning su un piccolo dataset del nuovo dispositivo, senza riaddestrare da zero. Questa tecnica, ispirata al transfer learning del deep learning classico, ridurrebbe significativamente il costo di portare il sistema su nuovi hardware.

# Capitolo 12

## Conclusioni

Il Capitolo 11 ha delineato ciò che resta oltre il perimetro di questo lavoro. Questo capitolo chiude il lavoro stesso: riprende la domanda da cui è partito, verifica una per una le ipotesi e le domande di ricerca formulate nel Capitolo 2, dichiara ciò che è stato stabilito e ciò che non lo è stato, e isola il criterio che unifica le due fasi sperimentali.

### 12.1 Il Problema e il Percorso

L'algoritmo di Shor fattorizza interi in tempo polinomiale, ma il divario fra questo risultato teorico e la sua esecuzione su hardware reale non è tecnologico: è fisico. Il rumore quantistico degrada l'informazione mentre il calcolo procede, e la sua azione cresce con la profondità del circuito — cioè proprio con la dimensione dei numeri che renderebbero l'algoritmo interessante. La domanda operativa da cui questo lavoro è partito è se un modello appreso possa ridurre il costo di quella degradazione, e la risposta che il lavoro restituisce non è un sì né un no, ma una *delimitazione*: l'intelligenza artificiale migliora l'esecuzione di Shor in ambiente rumoroso soltanto dove dispone di informazione che nessun metodo più semplice è in grado di sfruttare, e questo lavoro individua sperimentalmente dove quel confine cada.

Il percorso ha attraversato due fasi. La prima ha messo alla prova l'ipotesi di partenza — un classificatore che, a valle dell'esecuzione, riconosca gli output recuperabili — e l'ha smentita nella sua attribuzione causale. La seconda ha spostato l'intervento dove l'informazione sull'errore è ancora presente: la correzione d'errore quantistica, con la sua progressione di codici, e infine la decodifica appresa applicata alla sindrome.

## 12.2 Le Domande di Ricerca

Le sei domande formulate nella Sezione 2.3 ricevono le risposte seguenti.

**DR1 — Come degrada la probabilità di successo al crescere dell’errore fisico, e quale fonte di rumore è la più dannosa?** La degradazione è governata dal numero di porte a due qubit, non dai tempi di coerenza né dalla lettura. Per l’istanza  $N = 15$  il circuito traspilato conta 166 porte soggette all’errore a due qubit (114 cx più 52 cp), da cui una probabilità di sopravvivenza coerente  $P_{\text{surv}} = (1 - \varepsilon_{2q})^{166}$  pari al 18.9% nel regime NISQ-realistico e allo 0.02% in quello degradato. La campagna parametrica (Sezione D.1) conferma la gerarchia in modo netto: su sette parametri fatti variare singolarmente,  $\varepsilon_{1q}$ ,  $T_1$ ,  $T_2$  e  $p_{\text{ro}}$  risultano ininfluenti sull’esito entro tutti gli intervalli testati —  $p_{\text{ro}}$  fino al 20% — mentre l’unico parametro con effetto sulla strategia di estrazione è il numero di candidati  $K$ .

Va però aggiunta una qualificazione che la campagna rende inevitabile, ed è essa stessa parte della risposta. Il numero di porte a due qubit governa la probabilità di sopravvivenza *analitica*, non l’esito osservato: facendo variare  $\varepsilon_{2q}$  su tre ordini di grandezza,  $P_{\text{surv}}$  crolla dall’85% a  $2.5 \times 10^{-8}$ , ma il tasso di successo resta del 100% e  $\bar{M}_1$  oscilla fra 1.3 e 2.0 senza andamento monotono. La ragione è che il segnale della QPE non è concentrato in un unico esito che il rumore possa distruggere: la misura della distribuzione delle mode su UC1 mostra che esse cadono sempre su uno dei quattro picchi attesi  $\{0, 64, 128, 192\}$ , e che il fallimento di TOP-1 è dovuto in due casi su cinque all’esito banale  $y = 0$ , non alla perdita del segnale.  $P_{\text{surv}}$  è dunque un limite superiore molto pessimistico della difficoltà effettiva — una lezione che vale per l’intero lavoro, e che ridimensiona l’uso di questa stima come predittore di fattibilità. La fonte dominante di degradazione resta l’errore sui gate a due qubit, con meccanismo moltiplicativo nella profondità: è questa la ragione per cui la barriera si manifesta come barriera di *scalabilità* e non di rumore.

**DR2 — In che modo il codice a ripetizione introduce la sindrome senza collassare lo stato logico?** Misurando osservabili di *parità* anziché i singoli qubit. Gli stabilizzatori  $Z_1 Z_2$  e  $Z_2 Z_3$  commutano con lo stato logico codificato e la loro misura, effettuata tramite qubit ancillari, rivela quale qubit sia stato colpito senza rivelare nulla sull’informazione codificata. La verifica sperimentale (Sezione 8.4.2) mostra corrispondenza esatta fra errore iniettato e sindrome osservata in tutti i casi, e la curva Monte Carlo coincide con la previsione analitica  $p_L = 3p^2 - 2p^3$  entro

l'errore statistico. Il codice resta però protetto contro un solo tipo di errore per volta: un errore di fase sul codice bit-flip commuta con entrambi gli stabilizzatori e non produce alcuna sindrome.

**DR3 — Quali vantaggi e limiti offre il codice di Steane  $[[7, 1, 3]]$ ?** Il vantaggio è la correzione di un errore *arbitrario* su un singolo qubit con soli sette qubit fisici: la struttura CSS derivata dal codice di Hamming rende la corrispondenza sindrome–errore biettiva, verificata su tutti e ventuno i casi ( $X, Z, Y$  su sette qubit), e la soppressione misurata è quadratica con pendenza log-log 1.94, la firma attesa per un codice di distanza 3. Il limite è strutturale: la distanza è fissa, quindi l'errore residuo non può essere ridotto a piacere — la pseudo-soglia misurata,  $p \approx 0.08$ , separa il regime in cui la codifica conviene da quello in cui amplifica gli errori, ma nulla permette di spostarla. A ciò si aggiunge, nell'implementazione adottata, un'estrazione di sindrome non fault-tolerant, dichiarata nella Sezione 8.5.

**DR4 — Perché il surface code è più rilevante per scenari scalabili, ed esiste una soglia osservabile?** Perché la sua distanza cresce con la taglia della griglia mantenendo interazioni esclusivamente locali, condizione compatibile con le topologie reali delle QPU superconduttive. La soglia è stata osservata direttamente: le curve  $p_L(p)$  per  $d = 3, 5, 7, 9$  si incrociano a  $p_{th} \approx 0.9\%$  in base  $Z$  e  $\approx 0.7\%$  in base  $X$ , con soppressione di circa un fattore 4–5 per incremento di distanza al di sotto della soglia e inversione dell'ordine al di sopra. Il confronto con l'hardware è il dato che orienta: il tasso d'errore a due qubit assunto per il regime NISQ-realistico,  $\varepsilon_{2q} \approx 10^{-2}$ , cade *sopra* la soglia misurata. È la distanza che separa l'era attuale dal regime in cui aggiungere ridondanza produce il guadagno esponenziale atteso.

**DR5 — Quale errore logico serve perché Shor mantenga una probabilità di successo accettabile?** Un errore logico per gate dell'ordine di  $10^{-4}$  — il valore che il surface code a distanza 7 raggiunge a errore fisico  $2 \times 10^{-3}$ , cioè sotto soglia — riporta la probabilità di successo per singola misura al massimo consentito dall'istanza. Su questo punto la risposta richiede una precisazione che il Capitolo 10 sviluppa: per  $N = 15$  con base  $a = 7$  quel massimo vale  $\approx 0.75$ , un limite dovuto alla degenerazione del periodo e non al rumore, sicché la soglia dell'80% assunta come riferimento non è raggiungibile per singola esecuzione. Va letta in senso cumulativo: essendo Shor un algoritmo probabilistico che si ripete, con  $P_s \approx 0.75$  bastano due esecuzioni indipendenti per superare il 94%.

**DR6 — Esiste un regime in cui un decoder appreso supera quello analitico, e da che cosa dipende?** Sì, e non dipende dalla qualità della calibrazione bensì dalla *rappresentabilità strutturale* degli errori. A parità di modello di rumore — il regime per cui il MWPM è costruito — la rete non lo supera in nessuna delle quattordici configurazioni testate: lo pareggia a distanza 3, al prezzo di  $10^5$ – $10^6$  campioni di addestramento, e perde a distanza 5. Introducendo errori correlati fra qubit dati adiacenti, che il grafo di matching non può rappresentare con alcun arco, il quadro cambia: il decoder ibrido descritto dall’Equazione (E.1) riduce l’errore logico del 18–21% a distanza 3 e dell’1–3% a distanza 5, con significatività fino a  $10^{-312}$  al test di McNemar. A sostegno della risposta concorrono due evidenze indipendenti. La prima è indiretta ma sorprendente: a distanza 3, fornire al matching il modello di rumore *esatto* lo rende peggiore che fornirgli quello nominale sbagliato. La seconda è diretta, e verifica la stessa affermazione per la via opposta: perturbando deliberatamente il modello di rumore del decoder — sbagliando l’errore di misura fino a un ordine di grandezza — l’errore logico varia tipicamente dell’1–3%, e la rete non supera il matching mis-calibrato in nessuna delle dodici configurazioni provate. Un modello con i parametri imprecisi continua a rappresentare le stesse classi di errore, e il matching che ne discende resta quasi ottimale; è la classe di errore *assente* dalla struttura, non il parametro sbagliato, ad aprire spazio all’apprendimento.

Il risultato va però delimitato, e il limite è netto: il guadagno del decoder ibrido vale 18–21% a distanza 3, si riduce all’1–3% a distanza 5 e si annulla del tutto a distanza 7, dove la rete non ribalta alcuno shot in nessuna configurazione. La causa è stata isolata separando le due spiegazioni possibili: non la scarsità di esempi — a distanza 7 la rete si astiene anche disponendo di oltre duecentomila fallimenti da cui imparare, mentre a distanza 5 interviene con appena diciassettemila — ma la larghezza della sindrome: al crescere dei detector la capacità della rete densa di riconoscere i fallimenti del matching si degrada, e sotto una soglia netta — quella che rende il ribaltamento conveniente — il guadagno non si riduce gradualmente, si annulla. Poiché la crescita della distanza è la strategia della correzione scalabile, il metodo così com’è non accompagna il codice nel regime che conta; il rimedio che la diagnosi indica è architetturale, non statistico.

## 12.3 Verifica delle Ipotesi

Le ipotesi formulate a priori nella Sezione 2.3 sono verificate come segue.

| Ipotesi                                                                     | Esito                                   | Evidenza                                                                                                                                                                                              |
|-----------------------------------------------------------------------------|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Principale</b> — il classificatore ML riduce le iterazioni, $\rho \gg 1$ | <b>smentita</b> nell'attribuzione       | $\rho = 1.90$ è misurato su UC1, ma l'ablazione lo attribuisce interamente al TOP-4: $M_{\text{TOP4}}$ equivale a M2 su UC1 ( $p = 0.849$ ) e lo supera su UC2 ( $p < 0.001$ )                        |
| <b>Secondaria 1</b> — $F1 > 0.85$ e $AUC > 0.90$                            | <b>confermata</b> , ma non pertinente   | F1 fino a 0.979, AUC fino a 0.987; l'audit delle etichette mostra però che il compito appreso era “la moda è $y = 0$ ?”, non “manca il segnale?”                                                      |
| <b>Secondaria 2</b> — il vantaggio si mantiene al crescere di $N$           | <b>non verificabile</b> e mal formulata | la difficoltà cresce con il periodo $r$ , non con $N$ (periodi $4 \rightarrow 6 \rightarrow 2$ ); l'unica istanza informativa, $N = 21$ , è preclusa da una barriera doppia — fisica e computazionale |
| <b>QEC 1</b> — soppressione $p_L \propto p^2$ e regime di break-even        | <b>confermata</b>                       | ripetizione: coincidenza con $3p^2 - 2p^3$ ; Steane: pendenza 1.94, pseudo-soglia $\approx 0.08$                                                                                                      |
| <b>QEC 2</b> — comportamento di soglia del surface code                     | <b>confermata</b>                       | incrocio delle curve $d = 3, 5, 7, 9$ a $p_{th} \approx 0.9\%$ (Z) e $0.7\%$ (X); la legge di scala adattata sulle quattro distanze dà $p_{th} = 0.86\%$ , in accordo                                 |
| <b>QEC 3</b> — esiste un $p_L$ raggiungibile compatibile con Shor           | <b>confermata</b> con riserva           | $p_L \approx 10^{-4}$ è raggiungibile sotto soglia e riporta $P_{\text{success}}$ al massimo dell'istanza; la soglia dell'80% va però intesa in senso cumulativo                                      |

Tabella 12.1: Verifica delle sei ipotesi formulate prima dell'esecuzione degli esperimenti. Due esiti meritano attenzione: l'ipotesi principale è smentita non nella previsione numerica ma nella causa, e l'ipotesi secondaria 1 è confermata senza che ciò comporti alcun beneficio operativo.

Il caso dell'ipotesi secondaria 1 è quello metodologicamente più istruttivo dell'intero lavoro. Il classificatore soddisfa ampiamente i criteri di prestazione fissati a priori — è, in senso stretto, un ottimo classificatore — e nondimeno non riduce il numero di iterazioni. L'audit delle etichette di addestramento (Sezione D.2, Sez. D.2.2) ne ha individuato la ragione meccanica, che è più specifica e più severa di quanto la sola ablazione lasciasse intendere: ricalcolando le etichette dagli istogrammi archiviati si scopre che esse corrispondono alla regola “la moda conduce ai fattori?” e non a quella dichiarata “uno dei sedici candidati più frequenti vi conduce?”. Poiché fra i quattro picchi della QPE l'unico sterile è l'esito banale  $y = 0$ , il modello è stato



addestrato di fatto a riconoscere se l'argmax dell'istogramma cada sulla cella 0 — e tutti i campioni negativi di entrambi gli use case, senza eccezione, sono esattamente quelli. Il compito è quasi banale, il che spiega  $F1 = 0.98$ ; ed è lo stesso caso che la ricerca TOP-4 risolve per costruzione, il che spiega il guadagno nullo.

Due misure ulteriori chiudono la questione, e vale la pena riportarle qui perché sono la forma più netta del risultato. La prima riguarda **quanto sia fragile la distinzione appresa**: nel dataset di UC1, in 14 dei 103 campioni negativi i due picchi più alti raccolgono *esattamente lo stesso numero di conteggi*, e l'etichetta è stata decisa dal criterio di spareggio della funzione che ne calcola il massimo; in 29 casi differiscono di al più un conteggio. In oltre un quarto della classe negativa, dunque, ciò che separa un campione “positivo” da uno “negativo” è uno o due shot di differenza — rumore di campionamento, non il rumore quantistico che il modello avrebbe dovuto diagnosticare.

La seconda misura mostra che il problema **non ha soluzione nemmeno riformulandolo correttamente**. Poiché le frazioni continue con `limit_denominator` mappano sul periodo  $r = 4$  un'intera banda di fasi, ben 63 dei 256 esiti possibili conducono ai fattori: per un istogramma privo di ogni informazione, la probabilità che nessuno dei sedici valori più frequenti sia utile vale  $\binom{193}{16} / \binom{256}{16} = 0.9\%$ . La regola dichiarata etichetta quindi come positivo il 99% degli istogrammi per puro effetto combinatorio, e in effetti rigenerando il dataset con essa la classe negativa scompare del tutto: 2000 campioni positivi su 2000, per entrambi gli use case. Non esiste, a valle dell'esecuzione, un problema di classificazione sensato da porre — né nella formulazione applicata, che chiedeva qualcosa di banale, né in quella documentata, che non ammette istanze negative.

Se ne ricavano due avvertimenti di portata generale, entrambi guadagnati a spese di questo lavoro. Il primo: le metriche di classificazione misurano la separabilità delle classi, non l'utilità della decisione, e le due cose possono divergere completamente. Il secondo, meno ovvio e più insidioso: prima di interpretare una metrica conviene verificare *quale* domanda le etichette codifichino davvero, perché un dataset può rispondere a una domanda diversa da quella che il codice dichiara, e in tal caso un'ottima metrica è la conferma di un equivoco anziché di un risultato.

## 12.4 I Contributi del Lavoro

Il lavoro apporta quattro contributi, i primi due relativi alla prima fase e gli altri due alla seconda.

**L’ablazione che separa la strategia di ricerca dal modello appreso.** La riduzione delle iterazioni da  $\bar{M}_1 = 1.97$  a  $\bar{M} = 1.00$  è reale e statisticamente significativa, ma l’analisi a tre bracci ne attribuisce il merito alla ricerca multi-candidato TOP-4 e non al classificatore. La strategia risultante non richiede addestramento né calibrazione, è invariante rispetto a sei dei sette parametri di rumore esplorati, e domina la Zero-Noise Extrapolation sullo stesso compito.

**La quantificazione della barriera di scalabilità.** L’impossibilità di estendere il confronto a  $N = 21$  e  $N = 35$  è stata caratterizzata anziché aggirata, e la caratterizzazione ha corretto due letture ingenue. La prima attribuiva la barriera alla sola decomposizione della moltiplicazione modulare: l’implementazione di Beauregard riduce sì le porte `cx` per  $N = 21$  da 10 040 a 3 406, ma ne introduce 11 436 di tipo `cp`, e il totale delle porte rumorose a due qubit *cresce* a 14 842, con  $P_{\text{surv}}$  di ordine  $10^{-65}$ . Il guadagno di Beauregard è nel numero di qubit e nello scaling asintotico, non nell’errore accumulato: la barriera resta doppia, fisica e computazionale, e la decomposizione non ne rimuove nessuna delle due. La seconda assumeva che la difficoltà crescesse con il modulo: essa cresce invece con il periodo  $r$ , poiché i gate controllati  $U^{2^j}$  con  $2^j \equiv 0 \pmod{r}$  collassano nell’identità. Lungo la sequenza  $N = 15 \rightarrow 21 \rightarrow 35$  i periodi valgono  $4 \rightarrow 6 \rightarrow 2$  e le profondità  $311 \rightarrow 9\,883 \rightarrow 1\,480$ : l’istanza più grande è anche la più corta, e l’asse di scalabilità va ridefinito sul periodo perché l’ipotesi sia verificabile.

**La caratterizzazione end-to-end della correzione d’errore su Shor.** La progressione ripetizione  $\rightarrow$  Steane  $\rightarrow$  surface code è stata costruita, simulata e validata con criteri quantitativi dichiarati a priori, e connessa all’algoritmo attraverso il modello a livelli dello Shor logico. Il risultato è la relazione fra errore logico residuo e probabilità di successo, misurata su un’istanza trattabile e corredata della discussione dei limiti del modello di rumore adottato.

**La delimitazione del regime di utilità dell’apprendimento automatico.** È il contributo che unifica le due fasi. Lo stesso strumento modellistico, applicato in due punti diversi della pipeline sotto il medesimo impianto statistico, produce esiti opposti; e la seconda applicazione fornisce, oltre al risultato positivo, il criterio strutturale che lo spiega e un decoder ibrido che degrada con grazia — riducendo l’errore logico dove il modello analitico è inadeguato e ricadendo esattamente su di esso dove non lo è.

## 12.5 Limiti

I risultati vanno letti entro un perimetro che è opportuno enunciare per intero.

L'intero lavoro è condotto **su simulatore**: il rumore modellato è indipendente e stazionario, mentre quello dell'hardware reale è correlato spazialmente, non stazionario e soggetto a derive di calibrazione. L'istanza  $N = 15$  è **didattica** e non estrapolabile: le stime di risorse per moduli crittograficamente rilevanti derivano da analisi architetturali complete e non da estensioni dei risultati qui riportati. Il confronto quantitativo della prima fase poggia su **due use case** anziché sui quattro progettati. Nella parte QEC, l'estrazione di sindrome dello Steane **non è fault-tolerant**, il modello dello Shor logico è un **modello efficace** che assume errori logici indipendenti e uniformi fra i gate, e le stime di errore logico dei diversi codici provengono da modelli di rumore non commensurabili fra loro — ragione per cui la figura conclusiva del Capitolo 10 non costituisce una graduatoria fra codici. Infine, la decodifica appresa impiega un'architettura densa di capacità modesta, e il rumore correlato modellato resta di tipo Pauli: i risultati della Sezione 9.6 vanno intesi come verifica di un principio, non come stima del potenziale della decodifica neurale allo stato dell'arte. Su questo punto il lavoro dichiara anche il proprio limite più severo, emerso da due controlli condotti *contro* il risultato: il vantaggio del decoder ibrido si annulla a distanza 7, e a distanza 5 un decoder analitico più espressivo del matching — BP+OSD — ne recupera assai più di quanto faccia il modello appreso. La nicchia in cui l'apprendimento è la scelta giusta è dunque reale ma stretta, e il primo controllo da eseguire prima di introdurre un modello appreso è verificare di avere già adottato il miglior metodo analitico disponibile.

## 12.6 Il Criterio che Unifica il Lavoro

Resta un fatto che attraversa entrambe le fasi e che costituisce, più di ogni singolo numero, ciò che questo lavoro ha appreso.

In entrambi i casi il **complemento a basso costo ha battuto la sostituzione ambiziosa**. Nella prima fase, una ricerca multi-candidato che si limita a provare quattro esiti anziché uno ha battuto un classificatore addestrato su duemila istogrammi. Nella seconda, una rete che si limita a segnalare quando il decoder analitico sbaglia ha battuto la rete che pretendeva di sostituirlo — e lo ha fatto proprio nel regime, la distanza 5, in cui la sostituzione falliva. Non è una coincidenza né una massima di prudenza ingegneristica: discende dal fatto che ciascun metodo esistente

già sfrutta l'informazione che è in grado di rappresentare, sicché un modello appreso produce valore solo per la parte di informazione che a quel metodo sfugge — ed è quella parte, non l'intero problema, che conviene affidargli.

Va aggiunto che il complemento a basso costo eredita anche il limite del suo componente appreso. A distanza 7 la rete non dispone più di esempi sufficienti, e l'ibrido — correttamente — si astiene: coincide con il matching cifra per cifra. È una proprietà desiderabile del disegno, perché l'architettura residuale include fra i propri candidati la scelta “non intervenire mai” e la seleziona quando è quella giusta; ma significa anche che il vantaggio misurato non si estende al regime in cui la correzione d'errore diventa utile. Il superamento di questo limite — architetture che sfruttino la simmetria traslazionale del reticolo anziché trattare i detector come dimensioni indipendenti — è la direzione più concreta che questo lavoro lascia aperta.

Il criterio ammette però una precisazione, che un'esplorazione condotta oltre il perimetro del lavoro principale ha reso necessaria. L'Sezione E.2 lo mette alla prova su un terzo caso — la scelta della mappatura del circuito sui qubit fisici, dove il criterio di ottimizzazione generico ignora l'asimmetria fra registro di conteggio e registro di lavoro — e trova che l'informazione mancante c'è ed è predittiva, ma che il vantaggio non si materializza: sfruttarla richiede di vincolare il collocamento dei qubit, e ogni vincolo si paga in porte di instradamento aggiuntive. Alla condizione va dunque aggiunto un termine: l'informazione deve essere non soltanto assente dal metodo esistente e predittiva dell'esito, ma anche **sfruttabile senza costi compensativi**. I due casi favorevoli di questa tesi la soddisfano per una ragione comune — entrambi intervengono *a valle* di ciò che migliorano, senza alterarne le condizioni — mentre il terzo, che agisce a monte e modifica l'oggetto stesso su cui si misura il guadagno, non la soddisfa.

Applicato all'algoritmo di Shor in ambiente rumoroso, il criterio individua un confine preciso. A valle dell'esecuzione non c'è nulla da apprendere, perché ciò che il rumore ha distrutto non è più nell'output: nessun post-processing, per quanto sofisticato, può recuperarlo. Sulla sindrome, invece, l'informazione sull'errore è ancora interamente presente, e la questione diventa se il decoder analitico sia in grado di rappresentarla tutta. Finché il rumore appartiene alla classe che il matching sa descrivere, la risposta è sì e l'apprendimento non serve. Quando il dispositivo esce da quella classe — ed è ciò che i dispositivi reali fanno, con crosstalk, errori coerenti e leakage — l'apprendimento diventa il modo per recuperare la differenza.

È questa, in ultima analisi, la risposta che il lavoro dà alla domanda da cui era partito: l'intelligenza artificiale non rende l'algoritmo di Shor eseguibile su hardware

rumoroso, e nessuna tecnica di post-elaborazione può farlo. A renderlo eseguibile sarà la correzione d'errore quantistica, con il costo in qubit fisici che le stime di risorse quantificano. L'apprendimento automatico ha però un ruolo preciso e misurabile in quella costruzione: colmare lo scarto fra il modello di rumore che il decoder assume e il dispositivo che si ha davanti.

# Appendice A

## Trattazione Teorica Estesa

### A.1 Fondamenti del Calcolo Quantistico

#### A.1.1 Dalla Meccanica Classica alla Meccanica Quantistica

La meccanica quantistica descrive il comportamento della materia e dell'energia alle scale atomiche e subatomiche, dove i principi della fisica classica cessano di essere validi. I suoi postulati, formulati nella prima metà del Novecento da Heisenberg, Schrödinger, Dirac e Bohr, introducono concetti radicalmente diversi da quelli classici: lo stato di un sistema fisico non è determinato in modo assoluto, ma è descritto da una **funzione d'onda** la cui evoluzione è governata dall'equazione di Schrödinger.

Il calcolo quantistico traduce questi principi fisici in risorse computazionali. La **sovrapposizione** consente a un bit quantistico di trovarsi in una combinazione lineare di 0 e 1 simultaneamente; l'**entanglement** crea correlazioni non classiche tra qubit distinti; l'**interferenza** permette di amplificare le soluzioni corrette e cancellare quelle errate.

### A.1.2 I Postulati della Meccanica Quantistica

Il formalismo matematico della meccanica quantistica poggia su quattro postulati fondamentali, che costituiscono l'assiomatica della teoria e il punto di partenza rigoroso per la descrizione di qualsiasi sistema quantistico [15].

1. **Postulato dello spazio degli stati.** Ad ogni sistema fisico isolato è associato uno **spazio di Hilbert**  $\mathcal{H}$ , detto *spazio degli stati* del sistema. Lo stato del sistema è completamente descritto da un vettore unitario  $|\psi\rangle \in \mathcal{H}$ , detto *vettore di stato* o *ket*. Per un sistema a due livelli (qubit),  $\mathcal{H} = \mathbb{C}^2$  e lo stato generale è  $|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$  con  $|\alpha|^2 + |\beta|^2 = 1$ .
2. **Postulato dell'evoluzione.** L'evoluzione di un sistema quantistico chiuso è descritta da una **trasformazione unitaria**: se lo stato del sistema all'istante  $t_1$  è  $|\psi(t_1)\rangle$ , allora all'istante  $t_2$  esso si trova nello stato

$$|\psi(t_2)\rangle = U(t_1, t_2) |\psi(t_1)\rangle \quad (\text{A.1})$$

dove  $U(t_1, t_2)$  è un operatore unitario ( $U^\dagger U = I$ ) che dipende dagli istanti  $t_1$  e  $t_2$ . In forma differenziale, l'evoluzione è governata dall'**equazione di Schrödinger**:

$$i\hbar \frac{d}{dt} |\psi(t)\rangle = \hat{H} |\psi(t)\rangle \quad (\text{A.2})$$

dove  $\hat{H}$  è l'**Hamiltoniano** del sistema — un operatore hermitiano ( $\hat{H} = \hat{H}^\dagger$ ) che rappresenta l'energia totale — e  $\hbar = h/(2\pi)$  è la costante di Planck ridotta.<sup>1</sup>

3. **Postulato della misura.** Le misure quantistiche sono descritte da un insieme  $\{M_m\}$  di **operatori di misura**, indicizzati dagli esiti  $m$ , soggetti alla relazione di completezza:

$$\sum_m M_m^\dagger M_m = I \quad (\text{A.3})$$

Se il sistema si trova nello stato  $|\psi\rangle$  prima della misura, la probabilità di ottenere l'esito  $m$  è:

$$p(m) = \langle \psi | M_m^\dagger M_m | \psi \rangle \quad (\text{A.4})$$

---

<sup>1</sup>Nel calcolo quantistico a porte, ogni porta è la realizzazione discreta di questo postulato: la matrice unitaria  $U$  descrive l'evoluzione del registro di qubit in un passo computazionale. L'Hamiltoniano fisico che implementa una porta specifica dipende dall'architettura hardware (impulsi a microonde per qubit superconduttori, impulsi laser per ioni intrappolati, ecc.).

e lo stato immediatamente dopo la misura con esito  $m$  è il vettore normalizzato:

$$|\psi'\rangle = \frac{M_m |\psi\rangle}{\sqrt{p(m)}} \quad (\text{A.5})$$

Nel caso della **misura proiettiva in base computazionale** — il caso standard nel calcolo quantistico — gli operatori sono i proiettori  $M_m = |m\rangle \langle m|$ , e la probabilità di ottenere  $m$  si riduce alla **regola di Born**:  $p(m) = |\langle m|\psi\rangle|^2$ . La misura è un'operazione *non unitaria* e *irreversibile*: il collasso dello stato distrugge irrecuperabilmente le ampiezze che non corrispondono all'esito osservato.

4. **Postulato dei sistemi composti.** Lo spazio degli stati di un sistema fisico composto da  $n$  sottosistemi con spazi  $\mathcal{H}_1, \dots, \mathcal{H}_n$  è il **prodotto tensoriale**:

$$\mathcal{H} = \mathcal{H}_1 \otimes \mathcal{H}_2 \otimes \dots \otimes \mathcal{H}_n \quad (\text{A.6})$$

Se ciascun sottosistema  $i$  si trova nello stato  $|\psi_i\rangle$ , lo stato del sistema composto è  $|\psi_1\rangle \otimes |\psi_2\rangle \otimes \dots \otimes |\psi_n\rangle$ . Esistono tuttavia stati del sistema composto — gli stati **entangled** — che non possono essere scritti in questa forma fattorizzata per nessuna scelta degli stati individuali: la misura di un sottosistema modifica istantaneamente le probabilità degli esiti di misura sull'altro, indipendentemente dalla distanza fisica tra i due.

Questi quattro postulati forniscono il quadro assiomatico completo entro cui si collocano tutti i concetti che seguono: il qubit (Postulato 1), le porte quantistiche come trasformazioni unitarie (Postulato 2), la misura e il collasso dello stato (Postulato 3), i registri multi-qubit e l'entanglement (Postulato 4).



### A.1.3 Il Qubit

#### Definizione Matematica

L'unità fondamentale del calcolo quantistico è il **qubit** (*quantum bit*). Mentre un bit classico assume uno dei due valori  $\{0, 1\}$ , un qubit è descritto da un vettore unitario nello spazio di Hilbert bidimensionale  $\mathcal{H} = \mathbb{C}^2$ .<sup>2</sup>

Introducendo la **notazione di Dirac**<sup>3</sup>, i due stati base computazionali sono:

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad (\text{A.7})$$

Lo stato generico di un qubit è la **sovrapposizione**:

$$|\psi\rangle = \alpha |0\rangle + \beta |1\rangle, \quad \alpha, \beta \in \mathbb{C}, \quad |\alpha|^2 + |\beta|^2 = 1 \quad (\text{A.8})$$

dove  $|\alpha|^2$  e  $|\beta|^2$  rappresentano le probabilità di ottenere rispettivamente 0 e 1 al momento della misura. Il vincolo di normalizzazione  $|\alpha|^2 + |\beta|^2 = 1$  garantisce che le probabilità sommino a 1.

#### La Sfera di Bloch

Ogni stato puro di un qubit può essere visualizzato come un punto sulla superficie della **sfera di Bloch**, una sfera unitaria in  $\mathbb{R}^3$ .<sup>4</sup> Parametrizzando le ampiezze complesse tramite angoli reali  $\theta \in [0, \pi]$  e  $\phi \in [0, 2\pi]$ :

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right) |0\rangle + e^{i\phi} \sin\left(\frac{\theta}{2}\right) |1\rangle \quad (\text{A.9})$$

I poli nord e sud corrispondono agli stati  $|0\rangle$  e  $|1\rangle$ , mentre i punti sull'equatore rappresentano sovrapposizioni equiprobabili con fasi diverse.

---

<sup>2</sup>Lo **spazio di Hilbert** prende il nome dal matematico tedesco David Hilbert (1862–1943), uno dei più influenti matematici del XX secolo. In meccanica quantistica indica uno spazio vettoriale complesso dotato di prodotto interno, che fornisce il formalismo matematico per descrivere gli stati di un sistema fisico.

<sup>3</sup>La **notazione bra-ket** fu introdotta dal fisico britannico Paul Adrien Maurice Dirac (1902–1984), Premio Nobel per la Fisica nel 1933. Il simbolo  $|\psi\rangle$  è detto *ket*, mentre  $\langle\psi|$  è detto *bra*; il prodotto interno  $\langle\phi|\psi\rangle$  forma il *bracket*, da cui il nome.

<sup>4</sup>La **sfera di Bloch** deve il suo nome al fisico svizzero-americano Felix Bloch (1905–1983), Premio Nobel per la Fisica nel 1952 (insieme a Edward Purcell) per lo sviluppo della spettroscopia a risonanza magnetica nucleare (NMR). La stessa notazione  $T_1$  e  $T_2$  per i tempi di decoerenza proviene dal formalismo NMR di Bloch.




Figura A.1: La sfera di Bloch: ogni stato puro di un qubit corrisponde a un punto sulla superficie della sfera unitaria, parametrizzato dagli angoli  $\theta \in [0, \pi]$  e  $\varphi \in [0, 2\pi)$ . I poli nord e sud rappresentano gli stati base  $|0\rangle$  e  $|1\rangle$ ; i punti sull'equatore corrispondono a sovrapposizioni equiprobabili.

#### A.1.4 Sistemi Multi-Qubit e Prodotto Tensoriale

Un sistema di  $n$  qubit è descritto da un vettore nello spazio di Hilbert  $\mathcal{H}^{\otimes n} = \mathbb{C}^{2^n}$ , ottenuto come prodotto tensoriale degli spazi individuali. Uno stato generico di  $n$  qubit è:

$$|\psi\rangle = \sum_{x \in \{0,1\}^n} \alpha_x |x\rangle, \quad \sum_x |\alpha_x|^2 = 1 \quad (\text{A.10})$$

La dimensione esponenziale  $2^n$  dello spazio di Hilbert è la fonte del potere computazionale dei sistemi quantistici: con  $n = 300$  qubit, lo spazio degli stati ha dimensione  $2^{300}$ , superiore al numero di atomi nell'universo osservabile.

#### Entanglement

Due qubit sono detti **entangled** quando il loro stato congiunto non può essere scritto come prodotto tensoriale degli stati individuali. Gli stati di Bell costituiscono la base

canonica degli stati entangled a due qubit:

$$|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle) \quad (\text{A.11})$$

$$|\Phi^-\rangle = \frac{1}{\sqrt{2}}(|00\rangle - |11\rangle) \quad (\text{A.12})$$

$$|\Psi^+\rangle = \frac{1}{\sqrt{2}}(|01\rangle + |10\rangle) \quad (\text{A.13})$$

$$|\Psi^-\rangle = \frac{1}{\sqrt{2}}(|01\rangle - |10\rangle) \quad (\text{A.14})$$

Lo stato  $|\Phi^+\rangle$  non può essere fattorizzato come  $|\psi_A\rangle \otimes |\psi_B\rangle$  per nessuna scelta di  $|\psi_A\rangle$  e  $|\psi_B\rangle$ : misurare il primo qubit come 0 garantisce che il secondo sia 0, indipendentemente dalla distanza fisica tra i due sistemi.




Figura A.2: Circuito quantistico per la preparazione dello stato di Bell  $|\Phi^+\rangle$ . Una porta di Hadamard  $H$  posta sul qubit di controllo crea la sovrapposizione  $\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$ ; la successiva porta CNOT introduce le correlazioni di entanglement, producendo lo stato  $\frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$ .

## L'Entanglement come Risorsa Fisica Fragile

L'entanglement non è soltanto una proprietà astratta degli stati quantistici: è la **risorsa fisica** che gli algoritmi quantistici consumano per ottenere il loro vantaggio computazionale. Nell'algoritmo di Shor, il registro di controllo e il registro di lavoro devono restare entangled per tutta la durata della phase estimation affinché la Quantum Fourier Transform possa estrarre il periodo corretto. La perdita anche parziale di questa correlazione è sufficiente a degradare il risultato.

La fragilità dell'entanglement ha un'origine fisica precisa. Un sistema quantistico reale non è mai perfettamente isolato dall'ambiente che lo circonda: campi elettromagnetici residui, vibrazioni termiche del reticolo cristallino e fluttuazioni di carica si accoppiano continuamente ai qubit. Quando questo accoppiamento

avviene, il sistema entra in uno stato entangled *con l'ambiente*, trasferendo ad esso parte dell'informazione di fase. Dal punto di vista del solo sistema, le ampiezze di interferenza si riducono: il qubit non è più in una sovrapposizione pura  $\alpha|0\rangle + \beta|1\rangle$ , ma in un **miscuglio statistico** in cui la fase relativa tra  $|0\rangle$  e  $|1\rangle$  è persa. Questo processo prende il nome di **decoerenza** [9].

Il tempo caratteristico entro cui questa perdita di fase diventa apprezzabile è  $T_2$ , il **tempo di coerenza di fase** (*dephasing time*). Esso misura per quanto tempo un qubit riesce a mantenere la propria sovrapposizione coerente prima che l'interazione con l'ambiente la distrugga. Sui processori superconduttori attuali,  $T_2$  è tipicamente nell'intervallo 50–200  $\mu\text{s}$ ; ogni singola porta a due qubit dura circa 300–500 ns. Un calcolo diretto rivela che l'algoritmo di Shor, la cui profondità cresce come  $O(n^3)$  nel numero di bit dell'intero da fattorizzare, supera il limite imposto da  $T_2$  già per  $n \gtrsim 10$ –15 bit. La trattazione quantitativa di questi tempi caratteristici e del loro impatto sull'algoritmo è oggetto del Capitolo 4.

### A.1.5 Porte Quantistiche

Le operazioni su qubit sono rappresentate da **matrici unitarie**:  $U^\dagger U = I$ . La condizione di unitarietà garantisce la reversibilità del calcolo e la conservazione della norma (delle probabilità).

#### Porte a Singolo Qubit

Le principali porte a singolo qubit sono:

Le tre **matrici di Pauli**  $X$ ,  $Y$ ,  $Z$  costituiscono, insieme all'identità  $I$ , una base per lo spazio delle matrici  $2 \times 2$  hermitiane a traccia nulla, e giocano un ruolo centrale sia nella descrizione degli stati del qubit sia nella caratterizzazione dei canali di rumore.

**Porta di Pauli-X (NOT quantistico / Bit Flip):**

$$X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad X|0\rangle = |1\rangle, \quad X|1\rangle = |0\rangle \quad (\text{A.15})$$

È l'analogo quantistico del NOT classico: inverte i valori di  $|0\rangle$  e  $|1\rangle$ .

**Porta di Pauli-Y:**

$$Y = \begin{pmatrix} 0 & -i \\ i & 0 \end{pmatrix}, \quad Y|0\rangle = i|1\rangle, \quad Y|1\rangle = -i|0\rangle \quad (\text{A.16})$$

Combina un bit flip e un phase flip: è equivalente (a meno di una fase globale) alla composizione  $iXZ$ . Compare naturalmente nella decomposizione di rotazioni generali su qubit e nella descrizione del canale di *depolarizzazione*.

**Porta di Pauli-Z (Phase Flip):**

$$Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}, \quad Z|0\rangle = |0\rangle, \quad Z|1\rangle = -|1\rangle \quad (\text{A.17})$$

Lascia invariato  $|0\rangle$  e aggiunge una fase  $-1$  a  $|1\rangle$ : è un *phase flip*.

Le tre matrici di Pauli soddisfano le seguenti relazioni algebriche fondamentali:

$$X^2 = Y^2 = Z^2 = I \quad (\text{A.18})$$

$$XY = iZ, \quad YZ = iX, \quad ZX = iY \quad (\text{A.19})$$

$$\{X, Y\} = \{Y, Z\} = \{X, Z\} = 0 \quad (\text{A.20})$$

dove  $\{A, B\} = AB + BA$  è l'**anticommutatore**. Le prime due relazioni mostrano che le matrici di Pauli formano l'algebra di Lie  $\mathfrak{su}(2)$ ; la terza — l'anticommutazione — è alla base della struttura dei codici di correzione degli errori quantistici, dove  $X$  e  $Z$  rappresentano rispettivamente errori di bit flip e phase flip indipendenti.

**Porta di Hadamard:**

$$H = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$$

$$H|0\rangle = \frac{|0\rangle + |1\rangle}{\sqrt{2}} \equiv |+\rangle, \quad H|1\rangle = \frac{|0\rangle - |1\rangle}{\sqrt{2}} \equiv |-\rangle \quad (\text{A.21})$$

La porta di Hadamard è fondamentale: applicata a  $n$  qubit inizializzati in  $|0\rangle^{\otimes n}$ , genera la **sovrapposizione uniforme** di tutti i  $2^n$  stati base:

$$H^{\otimes n} |0\rangle^{\otimes n} = \frac{1}{\sqrt{2^n}} \sum_{x=0}^{2^n-1} |x\rangle \quad (\text{A.22})$$

**Porta di fase  $R_\phi$ :**

$$R_\phi = \begin{pmatrix} 1 & 0 \\ 0 & e^{i\phi} \end{pmatrix} \quad (\text{A.23})$$

Casi particolari:  $T = R_{\pi/4}$  (T-gate) e  $S = R_{\pi/2}$  (S-gate o Phase gate).

## Porte a Due Qubit

### Porta CNOT:

$$\text{CNOT} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad (\text{A.24})$$

Applica una NOT sul qubit *target* se e solo se il qubit *control* è  $|1\rangle$ . È la porta a due qubit più comune e, insieme alle porte a singolo qubit, forma un insieme universale.

**Porta Toffoli (Controlled-Controlled NOT (porta di Toffoli) (CCNOT)):**  
Generalizzazione a tre qubit; applica NOT sul terzo qubit solo se entrambi i qubit di controllo sono  $|1\rangle$ .




Figura A.3: Simboli circuitali delle principali porte quantistiche a singolo qubit ( $X$ ,  $Y$ ,  $Z$ ,  $H$ ,  $R_\phi$ ) e della porta CNOT a due qubit. Nella porta CNOT, il punto pieno indica il qubit di controllo  $q_c$  e il cerchio con croce indica il qubit target  $q_t$ .

### A.1.6 Circuiti Quantistici

Un **circuito quantistico** è una sequenza ordinata di porte quantistiche applicata a un registro di qubit. I circuiti si leggono da sinistra a destra, con ogni filo orizzontale che rappresenta l'evoluzione temporale di un qubit. La composizione di porte corrisponde al prodotto matriciale degli operatori unitari associati.

L'equivalente quantistico del teorema di universalità classico afferma che qualunque trasformazione unitaria su  $n$  qubit può essere **approssimata con precisione arbitraria** da una sequenza finita di porte prese da un insieme universale, tipicamente  $\{H, T, \text{CNOT}\}$ . La distinzione fra approssimazione e decomposizione esatta non è pedanteria: le sequenze finite su un insieme di porte fissato sono numerabili, mentre le trasformazioni unitarie non lo sono, sicché una decomposizione esatta è impossibile in generale. Il teorema di Solovay–Kitaev garantisce che l'approssimazione a precisione  $\varepsilon$  richiede  $O(\log^c(1/\varepsilon))$  porte, con  $c$  costante piccola: il costo dell'approssimazione cresce dunque solo polilogaritmicamente, ed è questa la ragione per cui l'universalità resta praticamente utile.

### A.1.7 Misura Quantistica

La **misura** in base computazionale di uno stato  $|\psi\rangle = \sum_x \alpha_x |x\rangle$  produce il risultato  $x$  con probabilità  $|\alpha_x|^2$ , e collassa irrevocabilmente lo stato in  $|x\rangle$ . La misura è una operazione *non unitaria* e *non reversibile*: una volta effettuata, l'informazione sulle ampiezze è irreversibilmente persa.

Questa caratteristica impone che gli algoritmi quantistici siano progettati per amplificare selettivamente l'ampiezza della risposta corretta prima della misura, in modo da ottenere il risultato voluto con alta probabilità.

### A.1.8 Interferenza Quantistica

L'**interferenza** è il meccanismo fondamentale attraverso cui gli algoritmi quantistici realizzano il loro vantaggio computazionale. Le ampiezze quantistiche sono numeri complessi e possono combinarsi costruttivamente (quando hanno lo stesso segno/fase) o distruttivamente (quando hanno fase opposta).

Un algoritmo quantistico efficiente è costruito in modo che:

- Le ampiezze degli stati **sbagliati** si cancellino per **interferenza distruttiva**;
- Le ampiezze degli stati **corretti** si sommino per **interferenza costruttiva**.

Questo meccanismo è alla base sia dell'algoritmo di Grover sia dell'algoritmo di Shor (Capitolo 3), dove la Quantum Fourier Transform realizza l'interferenza necessaria al ritrovamento del periodo.

### A.1.9 Modello di Complessità Quantistica

La complessità di un algoritmo quantistico è misurata in termini di numero di porte (equivalente delle operazioni elementari classiche) e di profondità del circuito (numero di livelli di porte parallele). Si definiscono le classi di complessità quantistiche più rilevanti:

- *Bounded-error Quantum Polynomial time* (BQP): classe dei problemi risolvibili in tempo polinomiale con probabilità di errore al più  $1/3$  da un computer quantistico. È la classe centrale del calcolo quantistico.
- *Quantum Merlin-Arthur* (QMA): analogo quantistico di NP; problemi la cui soluzione può essere verificata efficientemente da un computer quantistico.

Le inclusioni  $\mathbf{P} \subseteq \mathbf{BPP} \subseteq \mathbf{BQP} \subseteq \mathbf{PSPACE}$  sono *dimostrate*; ciò che resta aperto è se siano **strette**. Non è noto se BQP contenga propriamente P o BPP — cioè se esista davvero un problema che un computer quantistico risolva efficientemente e uno classico no — né se sia propriamente contenuto in PSPACE. Una dimostrazione di separazione stretta fra BQP e BPP implicherebbe  $\mathbf{P} \neq \mathbf{PSPACE}$ , un risultato che la teoria della complessità non ha ancora raggiunto: è questa la ragione per cui il vantaggio quantistico, per Shor come per gli altri algoritmi, resta una congettura ampiamente creduta e non un teorema.



Gerarchia delle classi di complessità nel calcolo quantistico




Figura A.4: Gerarchia delle classi di complessità nel calcolo quantistico. La classe BQP cattura i problemi efficientemente risolvibili da un computer quantistico; le inclusioni mostrate ( $P \subseteq BPP \subseteq BQP \subseteq PSPACE$ ) sono dimostrate, mentre è congetturata — e non dimostrata — la loro *strettezza*. Gli algoritmi di Shor e Grover risiedono in BQP; che la fattorizzazione non appartenga a P è ritenuto probabile ma non provato.

## A.2 L'Anatomia Fisica di una QPU

### A.2.1 L'Anatomia Fisica di una QPU

Per capire dove nascono gli errori bisogna prima capire com'è fatta la macchina. Una QPU superconduttiva è un chip criogenico che contiene *esclusivamente* i qubit e le linee fisiche che li collegano: contrariamente all'intuizione, **le porte logiche non risiedono nel chip**. Aprendo una CPU classica si trovano registri e porte logiche incise nel silicio; aprendo una QPU si trovano solo i qubit. Le operazioni sono realizzate dall'**elettronica di controllo esterna**, che invia impulsi a microonde convogliati ai qubit tramite guide d'onda: “far passare un qubit in un gate” significa in realtà inviargli un'onda sagomata che ne ruota lo spin dell'angolo desiderato ( $90^\circ$ ,  $30^\circ$ ,  $10^\circ$ , ...). La Figura A.5 schematizza questa architettura per una QPU a 5 qubit con topologia a catena lineare.




Figura A.5: Anatomia di una QPU superconduttiva a 5 qubit con topologia a catena lineare. Nel chip criogenico risiedono solo i qubit e gli accoppiatori fisici; le porte logiche sono impulsi a microonde generati dall’elettronica esterna e convogliati tramite guide d’onda, usate sia per il controllo sia per la lettura. L’entanglement diretto è possibile solo tra qubit adiacenti ( $Q_1$ – $Q_2$  sì,  $Q_0$ – $Q_2$  solo tramite operazioni intermedie, che amplificano il disturbo). Il qubit di test  $T_0$ , privo di collegamenti, serve a misurare il tempo di coerenza “puro”: un qubit collegato a una guida d’onda perde sempre un po’ di energia attraverso di essa.

La Figura A.6 mostra come questa architettura si presenta nella realtà: all’esterno il sistema integrato (criostato, elettronica e schermature racchiusi nella teca), all’interno della sala macchine i cilindri criogenici sospesi con il fascio di tubi e cavi coassiali che convogliano le microonde di controllo e lettura — le “guide d’onda” dello schema precedente.



(a) IBM Quantum System One (Ehningen, Germania)



(b) Criostati IBM Q con il cablaggio di controllo

Figura A.6: La QPU reale. (a) Il sistema integrato IBM Quantum System One: il cilindro nero al centro è il criostato che contiene il chip, circondato dall'elettronica di controllo. (b) Criostati IBM Q in sala macchine: dall'alto arrivano i tubi per la refrigerazione e i cavi coassiali che convogliano le microonde di controllo e lettura verso il chip, sospeso sul fondo del cilindro a  $\sim 15$  mK. *Crediti: (a) IBM Research, licenza CC BY 2.0; (b) Connie Zhou per IBM, pubblico dominio; entrambe via Wikimedia Commons.*




Figura A.7: Resa tridimensionale di un chip quantistico superconduttivo con 6 qubit transmon e 12 giunzioni di test. Si riconoscono gli elementi dello schema di Figura A.5: i qubit con i loro risonatori, le linee di accoppiamento, le piazzole dorate per il collegamento alle guide d'onda e — ai quattro angoli — le strutture di test isolate, l'analogo reale del qubit  $T_0$ . *Credito: Onri Jay Benally, licenza CC BY 4.0, via Wikimedia Commons.*

Questa architettura ha tre conseguenze dirette per gli errori.

**La lettura distrugge lo stato — fisicamente.** Anche la misura avviene tramite microonde: per leggere un qubit lo si “bombarda” con un’onda di sonda e si osserva come essa torna indietro — un modo di risposta corrisponde a  $|0\rangle$ , un altro a  $|1\rangle$ . L’atto stesso di sondare blocca la dinamica del qubit: è per questo che la misura di uno stato quantistico lo distrugge *realmente*, non per convenzione matematica. Ed è per questo che nei circuiti le letture stanno tutte alla fine, in parallelo: misurare un solo qubit lasciando gli altri in sovrapposizione significa inviare un’onda che, per quanto focalizzata, perturba anche i vicini e può farli precipitare.

**Il budget di operazioni: coerenza vs velocità dei gate.** Le prestazioni di una QPU dipendono dal rapporto tra due tempi: quanto a lungo il qubit resta coerente e quanto dura una singola operazione. Con una finestra di coerenza di  $100\ \mu\text{s}$  e gate da  $\sim 25\ \text{ns}$ , si eseguono  $\sim 4\,000$  operazioni; una macchina con coerenza superiore ma gate

più lenti può eseguirne *meno*. È il rapporto che conta, non il singolo parametro — ed è questo rapporto a decidere se il circuito di Shor per una data istanza è fisicamente eseguibile. La Tabella A.1 confronta gli ordini di grandezza delle due principali tecnologie.

|                         | Superconduttori (IBM, IQM, ...)     | Ioni intrappolati (IonQ, Quantinuum, ...) |
|-------------------------|-------------------------------------|-------------------------------------------|
| Tempo di coerenza       | 50–300 $\mu$ s                      | da secondi a minuti                       |
| Durata gate (1 qubit)   | $\sim 15$ –40 ns                    | $\sim 1$ –100 $\mu$ s                     |
| Durata gate (2 qubit)   | $\sim 60$ –500 ns                   | $\sim 0.1$ –1 ms                          |
| Operazioni per finestra | $\sim 10^3$ – $10^4$                | $\sim 10^3$                               |
| Lettura                 | più esposta a errori e interferenze | più stabile e affidabile                  |
| Crosstalk               | presente (accoppiamento capacitivo) | ridotto                                   |
| Velocità di esecuzione  | molto alta                          | bassa (gate lenti)                        |

Tabella A.1: Ordini di grandezza indicativi delle due principali tecnologie di QPU. La coerenza lunghissima degli ioni intrappolati non si traduce in più operazioni utili, perché i gate sono da  $10^3$  a  $10^4$  volte più lenti: il budget di operazioni per finestra di coerenza è simile, ma i superconduttori lo spendono molto più in fretta. Gli ioni sono invece più robusti su lettura e crosstalk.

**Il bordo di coerenza.** Gli errori non sono distribuiti uniformemente nel tempo: finché il calcolo occupa una piccola frazione della finestra di coerenza, la probabilità di decadimento è bassa; quando il circuito si spinge *verso la fine* della finestra — il “bordo di coerenza” — la probabilità che il qubit sia già decaduto al momento della misura cresce rapidamente. La Figura A.8 illustra il concetto: è la ragione per cui circuiti profondi come quello di Shor, che consumano gran parte del budget, producono letture inaffidabili anche quando “tecnicamente” rientrano nella finestra.




Figura A.8: Il “budget” di operazioni di un qubit: la finestra di coerenza  $\min(T_1, T_2)$  divisa per la durata del singolo gate dà il numero massimo di operazioni eseguibili  $N_{\max}$ . Un circuito che consuma solo la prima parte della finestra opera in zona affidabile; un circuito profondo come quello di Shor spinge la misura verso il *bordo di coerenza*, dove la probabilità che il qubit sia già decaduto — e che la lettura restituisca un valore errato — è massima.

**La topologia decide chi parla con chi.** Le QPU differiscono anche per geometria: catene lineari, griglie (heavy-hex di IBM), connettività completa. Su una catena, l’entanglement tra qubit non adiacenti richiede un “cross-entanglement” attraverso i qubit intermedi: ogni passaggio disperde energia e accorcia la vita dello stato condiviso — più cross si fanno, prima lo stato decade. La topologia determina quindi sia *quali* circuiti si possono mappare in modo efficiente, sia *dove* il crosstalk colpirà. Questo aspetto — insieme al fatto che i parametri di coerenza variano da qubit a qubit dello stesso chip — è ripreso nel Capitolo 9, dove la località delle interazioni sulla griglia è il fondamento architetturale del surface code.

### A.3 L’Algoritmo di Shor — Approfondimenti e Stato dell’Arte

Questa sezione raccoglie il materiale di contesto e di approfondimento dell’algoritmo di Shor: lo stato delle realizzazioni sperimentali, i miglioramenti algoritmici recenti, la roadmap verso il calcolo fault-tolerant e il confronto con l’algoritmo di Grover. Il Capitolo 3 ne riporta la sintesi.

### A.3.1 Sviluppi Recenti e Stato dell'Arte

#### Implementazioni su Hardware Reale

Nonostante la solidità teorica, l'esecuzione di Shor su hardware reale rimane limitata a istanze molto piccole a causa dei requisiti di profondità circuitale. I principali risultati sperimentali sono:

- **2001 – NMR (Vandersypen et al.):** prima dimostrazione sperimentale di Shor su un sistema a 7 spin nucleari; fattorizzazione di  $N = 15$  in  $3 \times 5$  [6].
- **2016 – Ioni intrappolati (Monz et al.):** implementazione scalabile su 5 qubit ionici; fattorizzazione di  $N = 15$  con un'architettura modulare [43].
- **2021 – Qubit superconduttori International Business Machines (IBM):** dimostrazione della fattorizzazione di  $N = 21$  su processori IBM Quantum utilizzando solo 5 qubit [7], attualmente il risultato più avanzato su hardware superconduttore di uso generale;
- **Fotonica:** esperimenti su piattaforme fotoniche hanno raggiunto la fattorizzazione di  $N = 35$ , sfruttando la maggiore coerenza dei qubit ottici, sebbene con circuiti fortemente semplificati rispetto all'algoritmo generale.

Il record di  $N = 21$  evidenzia quanto la distanza tra le istanze dimostrabili e quelle crittograficamente rilevanti (RSA-2048, con  $N$  a 2048 bit) sia ancora enorme: fattorizzare un numero a  $L$  bit richiede circa  $5L + 1$  qubit logici e  $72L^3$  gate [44], valori del tutto inaccessibili ai processori NISQ attuali. Una analisi aggiornata delle sfide pratiche nell'esecuzione di Shor su piattaforme esistenti è discussa in [44].

#### Miglioramenti Algoritmici: Regev 2023

Un risultato teorico rilevante è stato pubblicato nel 2023 da Oded Regev [45], che ha proposto una variante migliorata dell'algoritmo di Shor richiedente solo  $O(n^{3/2})$  gate (rispetto agli  $O(n^2)$  della versione originale), al costo di un overhead classico maggiore. Sebbene non ancora implementata su hardware reale, questa riduzione della profondità circuitale è promettente per le architetture NISQ, dove la profondità è il principale collo di bottiglia.

## Roadmap IBM verso il Quantum Fault-Tolerant

IBM ha delineato una roadmap concreta verso il calcolo quantistico fault-tolerant [42]:

- **2025**: processori Loon e Nighthawk (120 qubit con 218 coupler sintonizzabili), con dimostrazione dei componenti chiave per la fault-tolerance tramite codici qLDPC;
- **2026**: target di vantaggio quantistico su problemi pratici;
- **2029**: sistema Quantum Starling con 200 qubit logici e oltre  $10^8$  operazioni quantistiche.

Questi traguardi definiscono l'orizzonte temporale entro cui l'algoritmo di Shor potrà diventare una minaccia concreta per la crittografia RSA, motivando ulteriormente la transizione urgente verso gli standard PQC discussi nella sezione precedente.

Le sfide hardware principali per l'esecuzione di Shor su istanze crittograficamente rilevanti sono analizzate in dettaglio nel Capitolo 4, mentre l'implementazione pratica con Qiskit e le tecniche di ottimizzazione basate su intelligenza artificiale sono presentate nel Capitolo 6.



### A.3.2 Contesto: Confronto con l'Algoritmo di Grover

Per collocare correttamente l'algoritmo di Shor nel panorama dell'informatica quantistica, è utile confrontarlo con l'altro grande risultato algoritmico degli anni Novanta: l'algoritmo di Grover per la ricerca non strutturata [46].

#### Il Problema di Grover

Dato un insieme di  $N$  elementi e una funzione oracolo  $f : \{0, \dots, N-1\} \rightarrow \{0, 1\}$ , l'obiettivo è trovare  $x^*$  tale che  $f(x^*) = 1$ . Classicamente, nel caso peggiore, sono necessarie  $O(N)$  interrogazioni. Grover (1996) dimostrò che un algoritmo quantistico, sfruttando il meccanismo di *amplitude amplification*, può trovare la soluzione in sole  $O(\sqrt{N})$  interrogazioni – uno **speedup quadratico** che è stato dimostrato ottimale: nessun algoritmo quantistico può fare meglio [47, 48].

#### Differenze Fondamentali

I due algoritmi rappresentano due regimi distinti di vantaggio quantistico:

| Caratteristica           | Shor                                      | Grover                                 |
|--------------------------|-------------------------------------------|----------------------------------------|
| Problema target          | Fattorizzazione intera / period finding   | Ricerca non strutturata                |
| Speedup                  | Esponenziale rispetto al miglior classico | Quadratico: $O(\sqrt{N})$ vs $O(N)$    |
| Tecnica quantistica core | QFT + Phase Estimation                    | Amplitude Amplification                |
| Ottimalità               | Non dimostrata in assoluto                | Dimostrata ottimale [47]               |
| Impatto crittografico    | Rompe RSA, DH, ECDSA (chiave pubblica)    | Dimezza sicurezza AES/SHA (simmetrica) |
| Requisiti hardware       | $O(\log N)$ qubit, alta profondità        | $O(\log N)$ qubit, bassa profondità    |

Tabella A.2: Confronto tra l'algoritmo di Shor e l'algoritmo di Grover

L'impatto sulla crittografia simmetrica di Grover è significativo ma gestibile: raddoppiare la lunghezza delle chiavi (da AES-128 a AES-256) è sufficiente a ripristinare il livello di sicurezza. Al contrario, non esiste un analogo rimedio per RSA: l'unica risposta è la migrazione verso gli standard post-quantum discussi nella sezione precedente. È per questa ragione che l'algoritmo di Shor rappresenta la minaccia quantistica più urgente e motivante per la ricerca sul calcolo quantistico applicato.

Tutta l'analisi svolta in questo capitolo ha però assunto un modello di calcolo *ideale*: porte unitarie perfette, coerenza illimitata, nessuna interazione con l'ambiente.

Su hardware reale questi presupposti non reggono, e la distanza tra il modello teorico e l'esecuzione fisica è precisamente il nodo critico che rende ancora irraggiungibile la fattorizzazione di numeri crittograficamente rilevanti. Comprendere le origini e gli effetti del rumore quantistico è quindi il passo necessario per valutare le reali prospettive dell'algoritmo di Shor.

## A.4 I Canali di Rumore: Derivazioni Complete

I quattro canali quantistici che modellano il rumore sono mappe *Completely Positive Trace-Preserving* (CPTP) in rappresentazione di Kraus, secondo l'Eq. 4.6. Il Capitolo 4 ne riporta il canale depolarizzante per esteso, essendo quello su cui poggia la campagna sperimentale, e l'enunciato compatto degli altri tre; qui se ne danno le derivazioni complete.

### Canale Bit Flip

Il canale **bit flip** modella un errore di tipo  $X$  discreto: con probabilità  $p$  il qubit viene invertito ( $|0\rangle \leftrightarrow |1\rangle$ ), con probabilità  $1 - p$  rimane invariato. Gli operatori di Kraus sono  $K_0 = \sqrt{1-p} I$  e  $K_1 = \sqrt{p} X$ , e il canale agisce come:

$$\mathcal{E}_{BF}(\rho) = (1-p)\rho + p X\rho X \quad (\text{A.25})$$

Sulla sfera di Bloch, le componenti  $r_y$  e  $r_z$  vengono contratte di un fattore  $(1-2p)$  mentre la componente  $r_x$  rimane invariata. Per  $p = 1/2$  lo stato è completamente distrutto sul piano  $yz$ .

### Canale Phase Flip

Il canale **phase flip** modella la perdita di informazione di fase senza cambiamento di popolazione: la sovrapposizione decade senza che l'energia venga dissipata. Con operatori di Kraus  $K_0 = \sqrt{1-p} I$  e  $K_1 = \sqrt{p} Z$ , il canale è:

$$\mathcal{E}_{PF}(\rho) = (1-p)\rho + p Z\rho Z \quad (\text{A.26})$$

L'effetto sulla matrice densità è immediato:

$$\mathcal{E}_{PF} \begin{pmatrix} \rho_{00} & \rho_{01} \\ \rho_{10} & \rho_{11} \end{pmatrix} = \begin{pmatrix} \rho_{00} & (1-2p)\rho_{01} \\ (1-2p)\rho_{10} & \rho_{11} \end{pmatrix} \quad (\text{A.27})$$

Le popolazioni  $\rho_{00}$  e  $\rho_{11}$  rimangono invariate, mentre le **coerenze**  $\rho_{01}$ ,  $\rho_{10}$  vengono sopprese di un fattore  $(1 - 2p)$ . Questo è il canale che descrive il decadimento  $T_2$ : parametrizzando  $p(t) = \frac{1}{2}(1 - e^{-t/T_2})$ , si ottiene  $\rho_{01}(t) = \rho_{01}(0) e^{-t/T_2}$ .

### Canale di Amplitude Damping

Il canale di **amplitude damping** modella il rilassamento energetico  $T_1$ : il qubit decade spontaneamente dallo stato eccitato  $|1\rangle$  allo stato fondamentale  $|0\rangle$  con probabilità  $\gamma = 1 - e^{-t/T_1}$ . Gli operatori di Kraus sono:

$$K_0 = \begin{pmatrix} 1 & 0 \\ 0 & \sqrt{1-\gamma} \end{pmatrix}, \quad K_1 = \begin{pmatrix} 0 & \sqrt{\gamma} \\ 0 & 0 \end{pmatrix} \quad (\text{A.28})$$

Il canale agisce sulla matrice densità come:

$$\mathcal{E}_{AD}(\rho) = \begin{pmatrix} \rho_{00} + \gamma \rho_{11} & \sqrt{1-\gamma} \rho_{01} \\ \sqrt{1-\gamma} \rho_{10} & (1-\gamma) \rho_{11} \end{pmatrix} \quad (\text{A.29})$$

La popolazione  $\rho_{11}$  decade verso  $\rho_{00}$  con tasso  $\gamma$ , mentre le coerenze vengono sopprese di  $\sqrt{1-\gamma}$ . A differenza dei canali precedenti, questo canale è **non simmetrico**: sulla sfera di Bloch contrae la sfera verso il polo nord  $|0\rangle$ , non verso il centro:

$$r_x \rightarrow \sqrt{1-\gamma} r_x, \quad r_y \rightarrow \sqrt{1-\gamma} r_y, \quad r_z \rightarrow (1-\gamma) r_z + \gamma \quad (\text{A.30})$$

Per  $t \rightarrow \infty$  ( $\gamma \rightarrow 1$ ), qualsiasi stato converge a  $|0\rangle \langle 0|$ , indipendentemente dallo stato iniziale.

# Appendice B

## Strumenti, Ambiente e Codice

### B.1 Strumenti e Ambiente di Simulazione — Trattamento Esteso

La scelta degli strumenti di simulazione non è neutrale. In informatica quantistica, il framework adottato determina quali modelli di rumore sono disponibili, verso quale hardware è possibile traslare i circuiti e con quali risultati della letteratura è possibile confrontarsi direttamente. Questo capitolo descrive gli strumenti utilizzati nella parte sperimentale di questa tesi, motivando ciascuna scelta e collocandola rispetto alle alternative disponibili.

#### B.1.1 Qiskit: il Framework Quantistico di Riferimento

**Qiskit** (*Quantum Information Science Kit*) è un *Software Development Kit* (SDK) open-source sviluppato da IBM Quantum per la programmazione, la simulazione e l'esecuzione di algoritmi su processori quantistici superconduttori [23]. Rilasciato pubblicamente nel 2017, è oggi il framework di riferimento per la ricerca e la sperimentazione su hardware IBM ed è il più adottato nella letteratura scientifica sugli algoritmi quantistici a corto termine [7, 3].

#### Architettura del Framework

Qiskit è organizzato in tre componenti principali, ciascuno con un ruolo distinto nel ciclo di vita di un esperimento quantistico:

- **Qiskit (core)** — il nucleo del framework, già noto come Qiskit Terra. Fornisce le primitive fondamentali per la costruzione di circuiti quantistici (`QuantumCircuit`),

la compilazione e la trasposizione verso un backend target (**transpile**), e le interfacce di esecuzione (**Sampler**, **Estimator**). Gestisce l'intera pipeline dalla descrizione astratta del circuito fino all'invio al simulatore o all'hardware reale.

- **Qiskit Aer** — il modulo di simulazione classica ad alte prestazioni. Implementa diversi metodi di simulazione esatta e approssimata, con supporto nativo per modelli di rumore realistici. È il componente centrale di questa tesi e viene descritto in dettaglio nella Sezione B.1.2.
- **Qiskit IBM Runtime** — l'interfaccia per l'esecuzione su processori IBM Quantum reali tramite cloud (**qiskit-ibm-runtime**). Fornisce le primitive **Sampler** e **Estimator** ottimizzate per l'hardware reale, con supporto per tecniche di soppressione del rumore come il *Dynamical Decoupling* e il *Gate Twirling* [4].

## Perché Qiskit e non un'alternativa

La scelta di Qiskit è stata formalizzata nell'incontro con il relatore del 18 marzo 2026, in seguito all'analisi del tutorial ufficiale IBM per l'algoritmo di Shor [4]. La decisione è motivata da quattro ragioni convergenti.

**Prima ragione: coerenza con la piattaforma hardware.** Il lavoro di tesi utilizza un modello di rumore calibrato su processori superconduttori IBM. Qiskit è sviluppato da IBM Quantum e i suoi modelli di rumore, le sue primitive di esecuzione e le sue tecniche di mitigazione sono progettati e validati su quella stessa architettura fisica. Questa coerenza garantisce che i parametri di simulazione siano direttamente confrontabili con dati sperimentali reali [5].

**Seconda ragione: maturità del simulatore Aer.** Qiskit Aer è il simulatore con il modello di rumore più maturo e documentato tra i framework open-source disponibili. I principali competitor — Cirq (Google) [49], PennyLane (Xanadu) [50] — offrono simulazione con rumore, ma con un supporto meno esteso per i modelli fisici dei processori superconduttori (errori di depolarizzazione, rilassamento termico  $T_1/T_2$ , errori di misura).

**Terza ragione: disponibilità dell'implementazione di riferimento.** Il circuito dell'algoritmo di Shor utilizzato in questa tesi è tratto da un'implementazione open-source in Qiskit [24]. Questo punto di partenza, validato dalla letteratura [7], ha reso naturale mantenere Qiskit come framework unico lungo l'intero pipeline sperimentale.

**Quarta ragione: allineamento con la letteratura.** La grande maggioranza dei lavori recenti sull’implementazione dell’algoritmo di Shor e sulla mitigazione del rumore su sistemi NISQ utilizza Qiskit [7, 3, 28]. L’adozione dello stesso framework garantisce la comparabilità diretta dei risultati senza necessità di ricalibrare modelli o convertire rappresentazioni.

Tabella B.1: Confronto tra i principali framework per la simulazione quantistica con rumore.

| Framework       | Sviluppatore      | Simulatore con rumore                 | Target hardware primario |
|-----------------|-------------------|---------------------------------------|--------------------------|
| Qiskit + Aer    | IBM Quantum       | Completo (T1, T2, depolarz., readout) | IBM superconduttori      |
| Cirq            | Google Quantum AI | Parziale                              | Google superconduttori   |
| PennyLane       | Xanadu            | Limitato                              | Vari (plug-in)           |
| Forest / PyQuil | Rigetti           | Parziale                              | Rigetti superconduttori  |

### B.1.2 Qiskit Aer: il Simulatore

Qiskit Aer è il modulo di simulazione classica di Qiskit. Il suo componente principale è `AerSimulator`, un simulatore ad alte prestazioni che supporta più metodi di simulazione selezionabili a seconda della dimensione del circuito e del tipo di analisi richiesta.

#### Metodi di Simulazione

`AerSimulator` espone i seguenti metodi principali tramite il parametro `method`:

- `statevector` — simulazione esatta del vettore di stato completo. Richiede  $2^n$  ampiezze complesse in memoria, il che limita la scalabilità a circa 30 qubit su hardware consumer con GPU. È il metodo adottato in questa tesi per la precisione numerica che garantisce.
- `density_matrix` — evolve la matrice densità  $\rho$  anziché il vettore di stato, permettendo di modellare canali di rumore non unitari in modo esatto. Richiede  $4^n$  elementi e riduce il limite pratico a circa 25 qubit.

- **stabilizer** — simulazione efficiente di circuiti Clifford puri (senza porte non-Clifford come  $T$  o  $R_z$  arbitrarie). Scala a migliaia di qubit ma non è applicabile all'algoritmo di Shor, che utilizza rotazioni di fase arbitrarie.
- **matrix\_product\_state** — approssima lo stato come prodotto di tensori, adatto a circuiti con bassa entanglement. Non adeguato per le istanze di Shor usate in questa tesi, dove l'entanglement è significativo.

La scelta del metodo **statevector** è motivata dal numero di qubit delle istanze trattate (da 11 a 18 qubit nei quattro use case) e dalla necessità di un risultato esatto, non approssimato.

## Modelli di Rumore

Il modulo `qiskit_aer.noise` fornisce le primitive per costruire modelli di rumore compositi. Ogni errore è rappresentato come un canale quantistico che viene applicato ai gate specificati, con la possibilità di assegnare errori diversi a qubit diversi (rumore eterogeneo) o un errore uniforme a tutti i qubit (*all-qubit error*). I tipi di errore disponibili includono:

- **depolarizing\_error** — errore depolarizzante su gate a 1 o 2 qubit, parametrizzato dal tasso  $\epsilon$ .
- **thermal\_relaxation\_error** — modella il rilassamento verso lo stato fondamentale ( $T_1$ ) e la perdita di coerenza di fase ( $T_2$ ), con un tempo di gate configurabile.
- **ReadoutError** — matrice di confusione che descrive la probabilità di misurare  $|0\rangle$  come  $|1\rangle$  e viceversa.
- Errori coerenti — applicazione di una rotazione indesiderata su ogni gate, modellabile tramite operatori unitari arbitrari.

Il modello di rumore usato in questa tesi combina errori depolarizzanti, rilassamento termico e readout error, con parametri calibrati sull'hardware **ibm\_marrakesh** secondo la metodologia descritta in [5]. La configurazione dettagliata è riportata nel Capitolo 2.

## Transpilazione

Prima dell'esecuzione, il circuito deve essere *transpilato*: la funzione `transpile` riscrive il circuito nel gate set nativo del backend target (per `AerSimulator`: `cx`, `h`, `rz`, `x`, `swap`) e applica ottimizzazioni strutturali selezionabili tramite il parametro `optimization_level` (da 0 a 3). Un livello di ottimizzazione elevato riduce il numero di gate e, di conseguenza, l'accumulo di errori, a scapito di un maggior tempo di compilazione. In questa tesi si usa `optimization_level=3` per minimizzare la profondità del circuito eseguito.

### B.1.3 Accelerazione GPU con Qiskit Aer

La libreria `qiskit-aer-gpu` estende `AerSimulator` con il supporto per l'accelerazione tramite GPU NVIDIA attraverso CUDA. Il backend `statevector` è interamente eseguito sulla GPU: il vettore di stato viene allocato nella memoria VRAM e le operazioni di gate sono eseguite come moltiplicazioni matrice-vettore parallelizzate su migliaia di core CUDA.

**Motivazione pratica.** La parte sperimentale di questa tesi richiede la generazione di un dataset di addestramento per il classificatore del Metodo 2: migliaia di esecuzioni del circuito di Shor con parametri di rumore variabili. Su CPU, ogni esecuzione richiede diversi secondi per circuiti a 15–18 qubit con  $10^3$  shot; su GPU, il tempo si riduce di un fattore tra 10 e 20 per circuiti ad alto numero di shot, rendendo praticabile la generazione dell'intero dataset in una singola sessione di lavoro.

**Specifiche hardware.** La GPU prevista è una NVIDIA GeForce RTX 4070 con 12 GB di memoria VRAM e 5888 core CUDA (architettura Ada Lovelace). La capacità di memoria consentirebbe di simulare circuiti fino a circa 30 qubit in modalità `statevector`, sufficiente per tutti gli use case di questa tesi.<sup>1</sup>

**Esito: l'accelerazione non è stata utilizzabile.** Quanto sopra descrive il piano iniziale. In sede di implementazione il backend GPU si è rivelato inutilizzabile nell'ambiente WSL adottato — il driver CUDA riconosce la scheda, ma il backend C++ di Aer solleva un errore a runtime sull'esecuzione dei circuiti — e **tutti gli esperimenti riportati in questa tesi sono stati eseguiti su CPU**. La diagnosi completa e le conseguenze sui tempi di esecuzione sono nella Sezione 6.7.2. Il vincolo

---

<sup>1</sup>Il limite teorico di VRAM per la simulazione `statevector` è  $2^n \times 16$  byte per  $n$  qubit (ampiezza `complex128`). Con 12 GB:  $\lfloor \log_2(12 \times 10^9 / 16) \rfloor = 29.8$  qubit.



di memoria resta quello indicato, riferito però alla memoria di sistema anziché alla VRAM.

#### B.1.4 scikit-learn: la Libreria per il Classificatore

Il Metodo 2 richiede l'addestramento di un classificatore binario. La libreria scelta è scikit-learn [27], una delle librerie di machine learning più consolidate nell'ecosistema Python scientifico.

La motivazione principale è pragmatica: scikit-learn espone un'interfaccia unificata (`fit` / `predict`) per un ampio catalogo di classificatori — Random Forest, SVM, MLP, e altri — permettendo di confrontarli sullo stesso dataset con minime modifiche al codice. Questo facilita la selezione sperimentale del modello migliore senza dover introdurre dipendenze da framework più pesanti (TensorFlow, PyTorch) per un classificatore che, per il problema in esame, si prevede non richieda architetture profonde.

#### B.1.5 Ambiente di Esecuzione: WSL con Ubuntu

Le simulazioni vengono eseguite in ambiente Linux tramite WSL (versione 2) su Windows 11. La scelta è motivata dalla necessità di mantenere la compatibilità con l'ecosistema Linux di Qiskit e delle librerie scientifiche Python, garantendo al contempo l'integrazione con i driver CUDA per WSL forniti da NVIDIA.

WSL 2 esegue un kernel Linux completo in una macchina virtuale leggera. L'ambiente Python è isolato in un virtual environment dedicato, garantendo la riproducibilità delle dipendenze e la compatibilità delle versioni tra le librerie usate; le versioni esatte sono versionate nel file `requirements.txt` della repository. È in questo stesso ambiente che l'accesso alla GPU si è rivelato non praticabile (Sezione 6.7.2).

Con l'ambiente così definito, il Capitolo 6 descrive come Qiskit, Aer e scikit-learn si integrano nell'architettura del pipeline sperimentale: dalla costruzione del circuito di Shor alla generazione del dataset di addestramento, fino all'inferenza del classificatore.

## B.2 Codice Sorgente dei Componenti Implementati

Questa sezione raccoglie il codice sorgente dei componenti descritti nel Capitolo 6. Il capitolo motiva le scelte implementative; qui se ne riporta la realizzazione, perché

sia verificabile e riproducibile. Ogni listato è richiamato puntualmente dal punto del corpo che lo discute.

```
# Creazione del virtual environment
python3 -m venv ~/quantum-env
source ~/quantum-env/bin/activate

# Framework quantistico e simulatore
pip install qiskit qiskit-aer qiskit-ibm-runtime

# Simulatore con accelerazione GPU (CUDA)
pip install qiskit-aer-gpu

# Librerie scientifiche e ML
pip install numpy scipy matplotlib
pip install scikit-learn

# Verifica
python -c "import qiskit; print(qiskit.__version__)"
python -c "from qiskit_aer import AerSimulator; print('Aer OK
    ')"
```

Listing B.1: Installazione dell'ambiente Python e delle librerie necessarie

```
RuntimeError: Simulation device "GPU" is not supported on this
system
```

Listing B.2: Errore GPU su WSL durante i test

```
from qiskit import QuantumCircuit
import numpy as np

def qft_circuit(n_qubits):
    """Quantum Fourier Transform su n_qubits qubit."""
    qc = QuantumCircuit(n_qubits, name='QFT')
    for j in range(n_qubits):
        qc.h(j)
        for k in range(j + 1, n_qubits):
            angle = np.pi / (2 ** (k - j))
            qc.cp(angle, k, j)
    for i in range(n_qubits // 2):
```

```

        qc.swap(i, n_qubits - i - 1)
    return qc

def inverse_qft(n_qubits):
    """QFT inversa: coniugato trasposto della QFT."""
    return qft_circuit(n_qubits).inverse()

```

Listing B.3: Implementazione della Quantum Fourier Transform

```

def mod_exp_15_7(power):
    """
    Implementa  $U^{\text{power}}$  dove  $U|y\rangle = |7y \bmod 15\rangle$ .
    Valida per power in {1, 2, 4, 8, ...}.
    """
    U = QuantumCircuit(4, name=f' $U^{\text{power}}$ ')
    if power % 4 == 1:
        U.swap(0, 1); U.swap(1, 2); U.swap(2, 3)
        U.x(0); U.x(2)
    elif power % 4 == 2:
        U.swap(1, 3); U.swap(0, 2)
    #  $U^4 = I \pmod{15}$  con  $a=7$ : nessuna operazione
    return U

```

Listing B.4: Modular exponentiation per  $N=15$ ,  $a=7$

```

from qiskit import QuantumCircuit, transpile
from qiskit_aer import AerSimulator
from math import gcd
from fractions import Fraction

def shor_circuit(N, a, n_count):
    """Algoritmo di Shor per N con base a e n_count qubit di
    controllo."""
    n_work = N.bit_length()
    qc = QuantumCircuit(n_count + n_work, n_count)
    for q in range(n_count):
        qc.h(q)
    qc.x(n_count) # registro di lavoro
                  # inizializzato a  $|1\rangle$ 
    for j in range(n_count):

```

```

        power = 2 ** j
        ctrl_U = mod_exp_15_7(power).control(1)
        qc.append(ctrl_U, [j] + list(range(n_count, n_count +
            n_work)))
    qc.barrier()
    qc.append(inverse_qft(n_count), range(n_count))
    qc.measure(range(n_count), range(n_count))
    return qc

def extract_factors(measured_value, n_count, N, a):
    """Stima il periodo r e calcola i fattori di N."""
    if measured_value == 0:
        return None, None
    phase = measured_value / (2 ** n_count)
    frac = Fraction(phase).limit_denominator(N)
    r = frac.denominator
    if r % 2 != 0:
        return None, None
    p = gcd(a ** (r // 2) - 1, N)
    q = gcd(a ** (r // 2) + 1, N)
    if 1 < p < N:
        return p, N // p
    if 1 < q < N:
        return q, N // q
    return None, None

```

Listing B.5: Circuito completo di Shor e post-processing

```

from qiskit_aer.noise import (NoiseModel, depolarizing_error,
                              thermal_relaxation_error,
                              ReadoutError)

import numpy as np

def build_noise_model(eps_1q, eps_2q, t1_ns, t2_ns,
                    gate_time_ns=50, p_ro=0.02):
    """
    Costruisce un noise model con parametri configurabili.
    eps_1q: tasso errore depolarizzante gate 1 qubit
    eps_2q: tasso errore depolarizzante gate 2 qubit
    """

```

```

t1_ns:  tempo di rilassamento in ns
t2_ns:  tempo di dephasing in ns
p_ro:   probabilita' di readout error
"""

nm = NoiseModel()

# Errore depolarizzante su gate a 1 qubit
e1 = depolarizing_error(eps_1q, 1)
nm.add_all_qubit_quantum_error(e1, ['h', 'x', 'rz', 'cp'])

# Errore depolarizzante su gate a 2 qubit
e2 = depolarizing_error(eps_2q, 2)
nm.add_all_qubit_quantum_error(e2, ['cx', 'swap'])

# Rilassamento termico (T1, T2)
e_relax = thermal_relaxation_error(t1_ns, t2_ns,
    gate_time_ns)
nm.add_all_qubit_quantum_error(e_relax, ['h', 'x'])

# Readout error (matrice di confusione simmetrica)
ro_matrix = [[1 - p_ro, p_ro], [p_ro, 1 - p_ro]]
ro_error = ReadoutError(ro_matrix)
nm.add_all_qubit_readout_error(ro_error)

return nm

```

Listing B.6: Costruzione del noise model parametrizzato

```

def run_method1(N, a, n_count, noise_model, shots=1024,
    max_iter=50, seed=42):
    base_qc = shor_circuit(N, a, n_count)
    # CRITICO: NM nel costruttore + opt=2 decompone CCX -> CX
    # garantendo che il noise model si applichi a tutti i gate
    sim = AerSimulator(noise_model=noise_model, method='
        statevector')
    transpiled = transpile(base_qc, sim, optimization_level=2)

    for iteration in range(1, max_iter + 1):
        counts = sim.run(transpiled, shots=shots,

```

```

        seed_simulator=seed * 10000 +
            iteration
        ).result().get_counts()
# TOP-1: misura piu' frequente nell'istogramma
meas = int(max(counts, key=counts.get), 2)
p, q = extract_factors(meas, n_count, N, a)
if p is not None:
    return {'factors': (p, q), 'iterations': iteration
        ,
            'success': True, 'counts': counts}

return {'factors': (None, None), 'iterations': max_iter,
        'success': False, 'counts': {}}
```

Listing B.7: Pipeline del Metodo 1 (TOP-1, ottimizzazione corretta)

```

def generate_dataset(N, a, n_count, noise_base, noise_factor
=0.5,
                    n_samples=2000, shots=1024, seed=0):
    rng = np.random.default_rng(seed)
    X, y = [], []
    TOP_K = 16

    # Traspilosizione unica con noise model di riferimento
    nm_ref = build_noise_model(**noise_base)
    sim_tp = AerSimulator(noise_model=nm_ref, method='
        statevector')
    tqc = transpile(shor_circuit(N, a, n_count), sim_tp,
                    optimization_level=2)

    # Simulatore senza NM fisso: noise model varia a run-time
    sim = AerSimulator(method='statevector')

    for i in range(n_samples):
        # Variazione casuale dei parametri di rumore
        f = 1.0 + rng.uniform(-noise_factor, noise_factor)
        eps_2q = np.clip(noise_base['eps_2q'] * f, 1e-3, 0.3)
        # ...altri parametri analogamente...
        nm = build_noise_model(eps_1q, eps_2q, t1_ns, t2_ns,
```

```

        p_ro=noise_base['p_ro'])
counts = sim.run(tqc, noise_model=nm, shots=shots,
                 seed_simulator=seed + i).result().
                 get_counts()

# Etichetta TOP-K: 1 se almeno una delle top-16 misure
# piu' frequenti produce fattori validi
sorted_meas = sorted(counts.items(),
                     key=lambda x: x[1], reverse=True)

found = any(
    extract_factors(int(ms, 2), n_count, N, a)[0] is
    not None
    for ms, _ in sorted_meas[:TOP_K]
)
label = 1 if found else 0

feature = np.zeros(2 ** n_count)
for k, v in counts.items():
    feature[int(k, 2)] = v / shots
X.append(feature); y.append(label)

return np.array(X), np.array(y)

```

Listing B.8: Generazione del dataset con etichetta TOP-K

```

def run_method2(N, a, n_count, noise_model, classifier,
               shots=1024, max_iter=50, seed=42, top_k=4):
    base_qc = shor_circuit(N, a, n_count)
    sim = AerSimulator(noise_model=noise_model, method='
    statevector')
    transpiled = transpile(base_qc, sim, optimization_level=2)

    for iteration in range(1, max_iter + 1):
        counts = sim.run(transpiled, shots=shots,
                        seed_simulator=seed * 10000 +
                        iteration
                        ).result().get_counts()

```

```

# Feature: istogramma normalizzato a  $2^{n\_count}$ 
# dimensioni
feature = np.zeros(2 ** n_count)
for k, v in counts.items():
    feature[int(k, 2)] = v / shots

# Porta del classificatore: salta se l'istogramma e'
# troppo rumoroso
if classifier.predict([feature])[0] == 0:
    continue

# Ricerca TOP-K: prova i candidati piu' frequenti in
# ordine
sorted_meas = sorted(counts.items(),
                      key=lambda x: x[1], reverse=True)
for meas_str, _ in sorted_meas[:top_k]:
    p, q = extract_factors(int(meas_str, 2), n_count,
                           N, a)
    if p is not None:
        return {'factors': (p, q), 'iterations':
                iteration,
                'success': True}

return {'factors': (None, None), 'iterations': max_iter,
        'success': False}

```

Listing B.9: Loop di inferenza del Metodo 2 (classificatore + TOP-K)

```

USE_CASES = [
    {'name': 'UC1', 'N': 15, 'a': 7, 'n_count': 8,
     'noise': NOISE_REALISTIC, 'has_m2': True},
    {'name': 'UC2', 'N': 15, 'a': 7, 'n_count': 8,
     'noise': NOISE_DEGRADED, 'has_m2': True},
    {'name': 'UC3', 'N': 21, 'a': 2, 'n_count': 10,
     'noise': NOISE_REALISTIC, 'has_m2': False}, #
    'scalabilita' solo
    {'name': 'UC4', 'N': 35, 'a': 6, 'n_count': 12,
     'noise': NOISE_REALISTIC, 'has_m2': False}, #
    'scalabilita' solo

```



```

]
K_REPETITIONS = 30    # UC1/UC2: stima statistica di  $M_{\text{bar}}$ 
K_SCALABILITY = 10    # UC3/UC4: analisi profondita' circuito

```

Listing B.10: Schema di orchestrazione degli esperimenti

```

# --- Codifica:  $|0_L\rangle = |000\rangle$ ,  $|1_L\rangle = |111\rangle$  (stato entangled,
#         non 3 copie)
if logical_value == 1:
    qc.x(0)
qc.cx(0, 1)
qc.cx(0, 2)
if basis == 'X':
    qc.h(DATA)          #  $|+_L\rangle = H^3 |0_L\rangle \rightarrow$  duale phase-
                        flip

# --- Punto di iniezione del rumore: identita' "rumorose" sui
#         data
for q in DATA:
    qc.id(q)

# --- Estrazione della sindrome tramite ancilla (i data NON
#         vengono misurati)
if basis == 'Z':
    qc.cx(0, 3); qc.cx(1, 3)      # stabilizzatore Z0Z1 ->
    ancilla 3
    qc.cx(1, 4); qc.cx(2, 4)      # stabilizzatore Z1Z2 ->
    ancilla 4
else:
    qc.h(3); qc.cx(3, 0); qc.cx(3, 1); qc.h(3)    # X0X1
    qc.h(4); qc.cx(4, 1); qc.cx(4, 2); qc.h(4)    # X1X2
qc.measure(ANC[0], 0)
qc.measure(ANC[1], 1)

```

Listing B.11: Codifica ed estrazione di sindrome del codice a ripetizione. Il registro classico separa i due bit di sindrome dai tre di lettura dei dati. Il codice duale phase-flip si ottiene coniugando con Hadamard: la stessa struttura protegge dagli errori  $Z$  anziché  $X$ .

```

def encode_zero_L(qc):

```

```

"""|0_L> = sovrapposizione uniforme degli 8 codeword."""
for s in SEED:                                # H sui 3 qubit "seme"
    qc.h(s)
for s, support in SEED.items():               # propaga il seme sul
    suo supporto
    for d in support:
        if d != s:
            qc.cx(s, d)

def measure_syndrome(qc):
    for k, support in enumerate(GZ):           # tipo Z: rilevano
        errori X
        for d in support:
            qc.cx(d, ANC_Z[k])
    for k, support in enumerate(GX):           # tipo X: rilevano
        errori Z
        qc.h(ANC_X[k])
        for d in support:
            qc.cx(ANC_X[k], d)
        qc.h(ANC_X[k])

```

Listing B.12: Preparazione di  $|0_L\rangle$  e misura dei sei stabilizzatori del codice di Steane. Le due famiglie richiedono schemi diversi: gli stabilizzatori di tipo Z si misurano portando la parità sui dati verso l'ancilla, quelli di tipo X operando nella base coniugata.

```

def _inject(block, pairs, p_ct):
    out = stim.Circuit()
    first = True
    for inst in block:
        if isinstance(inst, stim.CircuitRepeatBlock):
            out += _inject(inst.body_copy(), pairs, p_ct) *
                inst.repeat_count
            continue
        out.append(inst)
        if inst.name == 'DEPOLARIZE1':
            if first:
                out.append('DEPOLARIZE2', pairs, p_ct) #
                    coppie di dati adiacenti

```

```

        first = not first
    return out

```

Listing B.13: Iniezione del crosstalk nel circuito del surface code. L’inizio di ogni ciclo di sindrome è individuato dal primo DEPolarize1 che segue le porte di Hadamard sulle ancilla; la ricorsione tratta il blocco REPEAT con cui Stim rappresenta i cicli intermedi.

```

import stim
import pymatching

circuit = stim.Circuit.generated(
    'surface_code:rotated_memory_x',
    distance=d,
    rounds=rounds,
    after_clifford_depolarization=p,
    after_reset_flip_probability=p,
    before_measure_flip_probability=p,
)

sampler = circuit.compile_detector_sampler()
events, observables = sampler.sample(shots,
    separate_observables=True)

model = circuit.detector_error_model(decompose_errors=True)
matching = pymatching.Matching.from_detector_error_model(model
    )

predictions = matching.decode_batch(events)
p_L = (predictions != observables).any(axis=1).mean()

```

Listing B.14: Struttura concettuale della stima di  $p_L$  con Stim e PyMatching (dal documento di indirizzo). Il circuito di memoria del surface code viene generato parametricamente, campionato, e decodificato con MWPM;  $p_L$  è la frazione di shot in cui la predizione del decoder non coincide con l’osservabile logico.

# Appendice C

## Contesto e Motivazione

### C.1 Contesto Esteso dell'Introduzione

Questa appendice raccoglie in forma estesa il contesto richiamato sinteticamente nel Capitolo 1: i principi fisici del calcolo quantistico e la loro implementazione hardware, la rivoluzione algoritmica degli anni Novanta, il protocollo RSA e la sua vulnerabilità all'algoritmo di Shor, la crittografia post-quantistica e lo stato dell'arte dell'hardware quantistico.

#### C.1.1 Dal Bit al Qubit: i Principi Fisici del Calcolo Quantistico

Per comprendere appieno le potenzialità e i limiti del calcolo quantistico, è necessario esaminare le differenze fisiche fondamentali tra l'unità di informazione classica e quella quantistica.

#### Il Qubit e la Sovrapposizione

Un computer classico elabora l'informazione attraverso **bit** – unità fisiche che possono trovarsi in uno di due stati discreti, convenzionalmente 0 e 1, realizzati come livelli di tensione in circuiti elettronici. L'unità fondamentale del calcolo quantistico è invece il **qubit** (*quantum bit*): un sistema fisico a due livelli che obbedisce alle leggi della meccanica quantistica.

Matematicamente, lo stato di un qubit è descritto da un vettore nello spazio di Hilbert  $\mathcal{H} \cong \mathbb{C}^2$ :

$$|\psi\rangle = \alpha |0\rangle + \beta |1\rangle, \quad \alpha, \beta \in \mathbb{C}, \quad |\alpha|^2 + |\beta|^2 = 1 \quad (\text{C.1})$$

dove  $|0\rangle$  e  $|1\rangle$  sono i due stati della base computazionale, analoghi ai valori 0 e 1 del bit classico. La differenza fondamentale è che  $\alpha$  e  $\beta$  possono essere simultaneamente diversi da zero: il qubit si trova in una **sovrapposizione** dei due stati base, con probabilità  $|\alpha|^2$  di essere misurato in  $|0\rangle$  e probabilità  $|\beta|^2$  di essere misurato in  $|1\rangle$ .

È cruciale sottolineare che la sovrapposizione non equivale a ignoranza sullo stato del sistema: il qubit non è “segretamente” in uno stato definito che non conosciamo. Si tratta di una proprietà fisica genuina, verificata sperimentalmente con precisione straordinaria, che non ha analogo nella fisica classica.

### La Sfera di Bloch

Poiché la norma è unitaria e la fase globale è fisicamente irrilevante, lo stato di un qubit puro può essere parametrizzato da soli due angoli reali:

$$|\psi\rangle = \cos\frac{\theta}{2} |0\rangle + e^{i\phi} \sin\frac{\theta}{2} |1\rangle, \quad \theta \in [0, \pi], \quad \phi \in [0, 2\pi) \quad (\text{C.2})$$

Questo definisce un punto sulla superficie di una sfera unitaria – la **sfera di Bloch** – dove il polo nord corrisponde a  $|0\rangle$ , il polo sud a  $|1\rangle$ , e i punti equatoriali a sovrapposizioni equiprobabili con fasi diverse. Questa rappresentazione geometrica è di grande utilità pratica: le operazioni su un singolo qubit corrispondono a **rotazioni rigide** della sfera di Bloch, e il rumore – come si vedrà nel Capitolo 4 – corrisponde alla contrazione progressiva del vettore di Bloch verso il centro, fino a ridurlo a zero (stato completamente misto, massima incertezza).

### L'Entanglement

Quando due o più qubit interagiscono tramite porte quantistiche opportune, possono formare stati **entangled**: stati del sistema composto che non possono essere scritti come prodotto tensoriale di stati individuali. Il prototipo è lo stato di Bell:

$$|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle) \quad (\text{C.3})$$

In questo stato, misurare il primo qubit in  $|0\rangle$  collassa istantaneamente il secondo in  $|0\rangle$ , e viceversa per  $|1\rangle$ , indipendentemente dalla distanza fisica tra i due qubit. L'entanglement crea correlazioni impossibili da replicare con qualunque modello classico a variabili nascoste locali, come dimostrato teoricamente da Bell nel 1964 [51] e verificato sperimentalmente con crescente precisione negli anni successivi [52]. Nel contesto del calcolo quantistico, l'entanglement è la risorsa che permette agli algoritmi di elaborare esponenzialmente più informazione rispetto ai circuiti classici: un registro di  $n$  qubit entangled descrive uno stato nello spazio  $\mathbb{C}^{2^n}$ , inaccessibile a qualunque rappresentazione classica di dimensione polinomiale in  $n$ .

## L'Interferenza Quantistica

Il terzo pilastro del calcolo quantistico è l'**interferenza**: la capacità di far sommare costruttivamente o annullare distruttivamente le ampiezze di probabilità di percorsi computazionali diversi. Le ampiezze  $\alpha$  e  $\beta$  in (C.1) sono numeri complessi, e possono quindi avere segni opposti o sfasamenti arbitrari: quando si sommano, possono amplificarsi o cancellarsi esattamente come onde fisiche.

Un algoritmo quantistico ben progettato sfrutta sistematicamente questo meccanismo: attraverso una sequenza opportuna di porte quantistiche, si costruisce un'interferenza *costruttiva* sui percorsi che portano alla risposta corretta e *distruttiva* su quelli errati, concentrando la probabilità di misura sull'output desiderato. È esattamente questo il meccanismo alla base della ricerca quadraticamente accelerata di Grover e della fattorizzazione polinomiale di Shor.

## Implementazione Fisica: i Qubit Superconduttori di IBM

Un qubit può essere realizzato con qualunque sistema fisico a due livelli: la polarizzazione di un fotone, lo spin di un elettrone, i livelli energetici di un atomo intrappolato. I **qubit superconduttori** utilizzati da IBM – la piattaforma adottata nel presente lavoro – sono circuiti elettrici macroscopici che operano nel regime quantistico grazie al raffreddamento a temperature criogeniche estreme.

Il componente chiave è la **giunzione di Josephson** [53]: una sottile barriera isolante (spessa  $\sim 1\text{--}2\text{ nm}$ ) interposta tra due materiali superconduttori. Questo elemento introduce una non-linearità nell'energia del circuito che rompe la degenerazione dei livelli energetici, isolando i due stati computazionali  $|0\rangle$  e  $|1\rangle$  da tutti gli altri. Il risultato è il **transmon** [54] – il tipo di qubit superconduttore adottato da

IBM – un oscillatore anelastico con frequenza tipica 4–6 GHz, controllato da impulsi a microonde.

Per operare nel regime quantistico, questi circuiti devono essere raffreddati a temperature dell'ordine di 15 mK ( $-273.13\text{ C}$ ), più fredde dello spazio cosmico a 2.7 K, tramite refrigeratori a diluizione. A queste temperature la resistenza elettrica scompare per effetto della superconduttività, eliminando la dissipazione termica che causerebbe la distruzione dello stato quantistico.

I parametri operativi tipici dei processori IBM (serie Eagle, Heron) sono:

- **Temperatura operativa:**  $\sim 15$  mK
- **Tempi di coerenza:**  $T_1, T_2 \sim 50\text{--}500\ \mu\text{s}$
- **Durata gate a singolo qubit:**  $\sim 50$  ns
- **Durata gate a due qubit (ECR/CNOT):**  $\sim 300\text{--}500$  ns
- **Fedeltà gate a singolo qubit:**  $\sim 99.9\text{--}99.97\%$
- **Fedeltà gate a due qubit:**  $\sim 99\text{--}99.7\%$

Il rapporto tra il tempo di coerenza e la durata di un gate determina quante operazioni possono essere eseguite prima che il qubit perda il proprio stato quantistico – ed è proprio questo rapporto il principale collo di bottiglia per l'esecuzione di algoritmi profondi come Shor sui processori attuali.

### C.1.2 La Rivoluzione Algoritmica degli Anni Novanta

Negli anni successivi alla proposta di Deutsch, la comunità scientifica si interrogò sulla effettiva esistenza di problemi che un computer quantistico potesse risolvere in modo *probabilmente* più efficiente di qualunque macchina classica. La risposta arrivò in forma dirompente nel corso di pochi anni.

Nel 1992, Daniel Simon<sup>1</sup> identificò un problema artificiale per il quale un algoritmo quantistico era esponenzialmente più veloce di qualunque algoritmo classico. Questo risultato rimase per alcuni anni una curiosità teorica, fino a quando, nel **1994**, Peter Shor pubblicò un risultato che scosse le fondamenta della sicurezza informatica mondiale: un algoritmo quantistico in grado di fattorizzare un intero di  $n$  bit in tempo *polinomiale*  $O(n^3)$  [8], a fronte della complessità sub-esponenziale ma super-polinomiale dei migliori algoritmi classici noti. Le implicazioni furono immediate e devastanti: l'intero edificio della crittografia a chiave pubblica – RSA, Diffie-Hellman, le firme digitali *Elliptic Curve Digital Signature Algorithm* (ECDSA) – si fondava proprio sull'assunzione che la fattorizzazione fosse computazionalmente intrattabile.

---

<sup>1</sup>L'**algoritmo di Simon** (1994, pubblicato nel 1997) fu il primo a dimostrare uno speedup *esponenziale* rispetto a qualunque algoritmo classico probabilistico, stabilendo la prova di principio che i computer quantistici potessero essere genuinamente più potenti. Shor riconobbe che la sua tecnica si ispirava direttamente alle idee di Simon.



Un computer quantistico sufficientemente grande avrebbe reso obsoleta, in un solo colpo, l'intera infrastruttura crittografica su cui poggia Internet.

Due anni dopo, nel **1996**, Lov Grover presentò un algoritmo di tutt'altra natura, ma di eguale importanza [46]. Mentre Shor aveva risolto un problema specifico della teoria dei numeri, Grover affrontò una sfida universale: la **ricerca non strutturata**. Dato un insieme di  $N$  elementi senza alcuna struttura o ordinamento, trovare quello che soddisfa una certa proprietà richiede, nel caso classico, un numero di interrogazioni proporzionale a  $N$ . Grover dimostrò che un algoritmo quantistico può fare lo stesso lavoro in sole  $O(\sqrt{N})$  interrogazioni – uno *speedup quadratico* – e che questo risultato è *ottimale*: nessun algoritmo quantistico può fare di meglio [48]. Sebbene meno spettacolare dello speedup esponenziale di Shor, il vantaggio di Grover è universale, applicabile a qualunque problema di ricerca, e porta con sé implicazioni profonde per la crittografia simmetrica, l'ottimizzazione combinatoria e la ricerca in grandi basi di dati.

Questi due algoritmi – Shor e Grover – rappresentano ancora oggi i pilastri dell'informatica algoritmica quantistica: il primo come dimostrazione del potere *esponenziale* del calcolo quantistico su problemi strutturati, il secondo come strumento *universale* di accelerazione quadratica applicabile al problema computazionale più fondamentale.

### C.1.3 RSA e le Implicazioni Crittografiche dell'Algoritmo di Shor

Per comprendere appieno la portata rivoluzionaria dell'algoritmo di Shor è necessario esaminare la struttura matematica del sistema crittografico che esso minaccia. Il sistema **RSA**, proposto nel 1977 da Rivest, Shamir e Adleman [55], è la pietra angolare della crittografia a chiave pubblica e il fondamento di praticamente ogni protocollo sicuro su Internet.

#### Struttura del Protocollo RSA

La sicurezza di RSA si basa sulla **asimmetria computazionale** tra due operazioni inverse: moltiplicare due numeri primi grandi  $p$  e  $q$  per ottenere  $N = p \cdot q$  è un'operazione elementare (complessità  $O(n^2)$  per numeri a  $n$  bit), mentre fattorizzare  $N$  per recuperare  $p$  e  $q$  è computazionalmente intrattabile con gli algoritmi classici noti. La generazione delle chiavi segue i passi seguenti:

1. Scegliere due primi grandi  $p$  e  $q$  (tipicamente a 1024–2048 bit ciascuno) e calcolare  $N = p \cdot q$ ;
2. Calcolare la funzione di Eulero  $\phi(N) = (p-1)(q-1)$ ;
3. Scegliere  $e$  coprimo con  $\phi(N)$  (convenzionalmente  $e = 65537 = 2^{16} + 1$ , primo di Fermat);
4. Calcolare  $d \equiv e^{-1} \pmod{\phi(N)}$  tramite l'algoritmo di Euclide esteso.

La **chiave pubblica** è la coppia  $(N, e)$ ; la **chiave privata** è  $d$ . Cifrare un messaggio  $m < N$  produce il crittogramma  $c = m^e \bmod N$ ; decifrarlo richiede  $m = c^d \bmod N$ . La correttezza si fonda sul **teorema di Eulero** — la generalizzazione del piccolo teorema di Fermat a moduli composti, secondo cui  $m^{\phi(N)} \equiv 1 \pmod{N}$  per  $m$  coprimo con  $N$ : essendo  $ed \equiv 1 \pmod{\phi(N)}$ , si ha  $ed = 1 + k\phi(N)$  e quindi  $(m^e)^d = m^{1+k\phi(N)} \equiv m \pmod{N}$ . Tutta la sicurezza risiede nell'impossibilità di calcolare  $d$  da  $(N, e)$  senza conoscere la fattorizzazione di  $N$ .

## Perché l'Algoritmo di Shor Rompe RSA

Il miglior algoritmo classico per la fattorizzazione di un intero a  $n$  bit è il *General Number Field Sieve* (GNFS) [56], con complessità sub-esponenziale:

$$T_{\text{GNFS}}(N) = O(\exp[c \cdot (\log N)^{1/3} (\log \log N)^{2/3}]) \quad (\text{C.4})$$

Per  $N$  a 2048 bit, questa espressione implica circa  $2^{112}$  operazioni classiche — un numero astronomico, ben oltre la capacità di qualunque infrastruttura computazionale esistente o prevedibile in ambito classico. I migliori risultati pratici al 2020 hanno raggiunto la fattorizzazione di RSA-250 (829 bit) [10], impiegando circa 2700 anni-CPU di calcolo distribuito.

L'algoritmo di Shor riduce questa complessità a  $O(n^3)$  — un salto da sub-esponenziale a **polinomiale** — rendendo la fattorizzazione di chiavi RSA-2048 un problema risolvibile in ore su un computer quantistico fault-tolerant con qualche migliaio di qubit logici. La struttura dell'algoritmo, descritta in dettaglio nel Capitolo 3, sfrutta la Quantum Fourier Transform per trovare il periodo di una funzione modulare, problema che si riduce efficientemente alla fattorizzazione.

## Implicazioni Pratiche per la Sicurezza Informatica

Le conseguenze sono sistemiche. RSA-2048 e le sue varianti sono il fondamento di:

- **HTTPS e TLS:** proteggono oltre il 95% del traffico web mondiale, incluse operazioni bancarie, sanitarie e governative;
- **Certificati X.509:** l'infrastruttura a chiave pubblica (PKI) su cui si basa l'autenticità di ogni sito web;
- **SSH:** il protocollo standard per l'accesso remoto sicuro ai server;
- **Firme digitali:** documenti legali, transazioni finanziarie, aggiornamenti software firmati.

Un computer quantistico scalabile renderebbe retroattivamente vulnerabili anche le comunicazioni *storicamente registrate*, attraverso il cosiddetto attacco “*harvest now, decrypt later*” (HNDL): avversari statali raccolgono oggi grandi volumi di traffico cifrato con RSA, conservandoli in attesa di poterli decifrare quando l'hardware quantistico raggiungerà la scala necessaria. Questo scenario non è teorico: rapporti di intelligence statunitensi e cinesi documentano campagne di raccolta massiva di traffico cifrato attive da almeno un decennio. Stime dell'NSA e del NIST indicano che chiavi RSA-2048 potrebbero diventare vulnerabili entro il 2030–2035 con il proseguire dell'avanzamento tecnologico quantistico [57].

### C.1.4 Crittografia Post-Quantistica: la Risposta dell’Industria

La consapevolezza della minaccia quantistica ha spinto il NIST a lanciare nel 2016 un processo di standardizzazione internazionale per la **crittografia post-quantistica** (*Post-Quantum Cryptography* (PQC)) – algoritmi crittografici resistenti agli attacchi di computer quantistici, progettati per essere eseguiti su hardware classico convenzionale e quindi immediatamente distribuibili.

#### Gli Standard NIST 2024

Dopo otto anni di valutazione pubblica, crittoanalisi internazionale e tre successivi turni di selezione tra 69 candidati iniziali, nell’agosto 2024 il NIST ha pubblicato i primi tre standard definitivi [58]:

- **ML-KEM** (FIPS 203, ex CRYSTALS-Kyber): meccanismo di incapsulamento di chiavi basato sul problema *Module Learning With Errors* (MLWE) su reticoli. È il sostituto designato per lo scambio di chiavi RSA e Diffie-Hellman nei protocolli TLS;
- **ML-DSA** (FIPS 204, ex CRYSTALS-Dilithium): schema di firma digitale basato sullo stesso fondamento matematico di ML-KEM. Sostituisce RSA e ECDSA per le firme digitali;
- **SLH-DSA** (FIPS 205, ex SPHINCS+): schema di firma basato esclusivamente su funzioni hash, senza assunzioni algebriche. Più conservativo per sicurezza, adottato come backup contro potenziali attacchi futuri ai reticoli.

La sicurezza di questi schemi si fonda su problemi matematici – trovare vettori corti in reticoli ad alta dimensione, o invertire funzioni hash – per i quali non sono noti algoritmi quantistici con speedup esponenziale. In particolare, l’algoritmo di Grover fornisce al più uno speedup quadratico sui problemi basati su hash, motivando l’aumento dei parametri di sicurezza (es. passaggio da 128 a 256 bit di sicurezza classica equivalente).

#### La Sfida della Migrazione

La transizione verso la crittografia post-quantistica è un’operazione di ingegneria su scala globale, paragonabile per complessità alla migrazione da IPv4 a IPv6, ma con urgenza maggiore. Le principali sfide includono:

- **Eterogeneità dei sistemi:** miliardi di dispositivi embedded, sensori industriali e infrastrutture legacy con cicli di vita decennali che non riceveranno aggiornamenti software;
- **Overhead di banda:** il materiale crittografico post-quantistico è sensibilmente più voluminoso. Al livello di sicurezza più basso (ML-KEM-512), la chiave di incapsulamento occupa 800 byte e il crittogramma 768 byte, contro i circa 256 byte di una chiave pubblica RSA-2048: un fattore di crescita che pesa sui protocolli a bassa latenza e sui dispositivi con banda limitata;
- **Migrazione a doppio binario:** nella fase transitoria, molte implementazioni adottano schemi *ibridi* (classico + post-quantistico in parallelo) per mantenere compatibilità con sistemi non aggiornati.

Aziende come Google (Chrome 131), Apple (iMessage PQ3) [59] e Cloudflare hanno già avviato implementazioni ibride nei loro protocolli di produzione. La coesistenza di questa transizione con la ricerca attiva su algoritmi quantistici come Shor definisce il contesto strategico in cui si inserisce il presente lavoro: comprendere i limiti reali di Shor su hardware NISQ è rilevante non solo teoricamente, ma anche per calibrare con maggiore precisione le tempistiche e le priorità della transizione crittografica globale.

### C.1.5 Lo Stato dell'Arte: dall'Era NISQ ai Computer Fault-Tolerant

Nonostante la solidità teorica di questi risultati, la realizzazione pratica di computer quantistici di scala sufficiente ad eseguirli su istanze realmente significative incontra ostacoli formidabili. I sistemi quantistici fisici sono intrinsecamente fragili: qualunque interazione non controllata con l'ambiente esterno – vibrazioni termiche, campi elettromagnetici, imperfezioni nei materiali – provoca fenomeni di **decoerenza** – ossia la perdita progressiva della coerenza quantistica causata dall'entanglement indesiderato tra il qubit e i gradi di libertà ambientali, che sopprime le interferenze quantistiche riducendo il sistema a una miscela statistica classica – degradando lo stato quantistico in modo irreversibile prima che il calcolo possa completarsi. A differenza di un bit classico, che può essere protetto dalla ridondanza, un qubit non può essere copiato (teorema del no-cloning [13]) né letto senza distruggerlo: questo rende la correzione degli errori quantistici un problema radicalmente diverso e molto più complesso di quella classica.

Il panorama tecnologico attuale è dominato da un insieme variegato di piattaforme hardware in competizione, ciascuna con vantaggi e svantaggi distinti:

- **Qubit superconduttori** (IBM, Google, Rigetti): alta velocità dei gate ( $\sim 50\text{--}500\text{ ns}$ ), scalabilità su chip in silicio, ma tempi di coerenza limitati a  $\sim 100\text{--}500\text{ }\mu\text{s}$  e necessità di raffreddamento a  $15\text{ mK}$ ;
- **Ioni intrappolati** (IonQ, Quantinuum): tempi di coerenza eccellenti ( $> 1\text{ s}$ ), fedeltà dei gate superiore al 99.9% anche su due qubit, ma gate lenti ( $\sim 10\text{--}100\text{ }\mu\text{s}$ ) e scalabilità più complessa;
- **Fotoni** (PsiQuantum, Xanadu): operano a temperatura ambiente, naturalmente adatti alla comunicazione quantistica, ma la generazione deterministica di fotoni entangled rimane una sfida aperta;
- **Spin in silicio** (Intel, UNSW): compatibili con i processi di fabbricazione CMOS esistenti, potenzialmente scalabili a milioni di qubit, ma con tecnologia di controllo ancora in fase di sviluppo.

Un momento simbolico di questa corsa fu raggiunto nel **2019**, quando il team di Google rivendicò il raggiungimento della cosiddetta *quantum supremacy*<sup>2</sup> con il processore Sycamore a 53 qubit [60]: un calcolo specifico fu completato in 200 secondi, mentre le stime attribuivano al più potente supercomputer classico un tempo di circa 10.000 anni per lo stesso compito. Nel 2023, IBM ha presentato il processore *Condor* a 1.121 qubit e ha delineato una roadmap [42] verso sistemi con architettura fault-tolerant entro la fine del decennio, con il target *Quantum Starling* previsto per il 2029.

Tuttavia, la distanza tra i dispositivi attuali e un computer quantistico *fault-tolerant* – in grado di eseguire Shor su istanze RSA reali – è ancora enorme. I processori odierni operano nel regime cosiddetto NISQ, un termine coniato da John Preskill nel 2018 [12] per descrivere macchine con decine o centinaia di qubit fisici, affette da errori significativi che limitano la profondità dei circuiti eseguibili. In questo scenario, la ricerca si concentra su due direzioni parallele e complementari:

- **QEC:** tecniche per codificare qubit logici in qubit fisici ridondanti, in modo da rilevare e correggere gli errori durante il calcolo, a costo di un overhead fisico significativo (centinaia o migliaia di qubit fisici per qubit logico);
- **Noise mitigation:** tecniche che, senza richiedere overhead hardware, riducono l'effetto del rumore a livello di post-processing classico, estendendo la portata dei circuiti eseguibili su hardware NISQ.

## C.2 Dettaglio degli Obiettivi e del Piano Sperimentale

Questa appendice raccoglie il materiale di dettaglio del Capitolo 2: la motivazione crittografica estesa, i requisiti funzionali del sistema sperimentale e la specifica completa dei parametri di input e di output.

---

<sup>2</sup>Il termine *quantum supremacy*, coniato da John Preskill nel 2012, indica il punto in cui un computer quantistico esegue un calcolo specifico in un tempo che nessun supercomputer classico potrebbe eguagliare in modo pratico. La rivendicazione di Google con il processore Sycamore è rimasta controversa: IBM sostenne che il calcolo avrebbe potuto essere eseguito classicamente in 2.5 giorni anziché 10.000 anni, con un algoritmo migliorato. Questo dibattito evidenzia la difficoltà di definire e misurare il vantaggio quantistico.

### C.2.1 Motivazione: la Vulnerabilità della Crittografia Attuale

La quasi totalità delle comunicazioni digitali sicure — dalle transazioni bancarie alle connessioni *HyperText Transfer Protocol Secure* (HTTPS), dai protocolli *Secure Shell* (SSH) ai certificati digitali — è protetta da sistemi crittografici la cui sicurezza si fonda su un presupposto computazionale: la difficoltà di fattorizzare il prodotto di due grandi numeri primi. Il sistema RSA, ad esempio, costruisce la propria chiave pubblica come  $N = p \cdot q$ , dove  $p$  e  $q$  sono primi di centinaia o migliaia di bit. Finché non esiste un algoritmo classico efficiente per recuperare  $p$  e  $q$  a partire da  $N$ , la chiave privata rimane al sicuro.

Per comprendere perché i sistemi crittografici attuali siano strutturalmente vulnerabili all'algoritmo di Shor, è necessario mettere a confronto le complessità computazionali in gioco. Il miglior algoritmo classico per la fattorizzazione, il GNFS, richiede un tempo:

$$T_{\text{classico}}(N) = O\left(\exp\left((c + o(1))(\log N)^{1/3}(\log \log N)^{2/3}\right)\right) \quad (\text{C.5})$$

che, pur crescendo più lentamente di un esponenziale puro, rimane del tutto impraticabile per i valori di  $N$  usati in crittografia. A titolo di esempio, fattorizzare un numero RSA a 2048 bit con algoritmi classici richiederebbe un tempo stimato superiore all'età dell'universo, anche impiegando l'intera potenza di calcolo disponibile sul pianeta.

Nel 1994, Peter Shor dimostrò che un computer quantistico è in grado di eseguire la stessa operazione in tempo **polinomiale** [8]:

$$T_{\text{Shor}}(N) = O((\log N)^3) \quad (\text{C.6})$$

Lo scarto tra le due espressioni non è una differenza di grado, ma una differenza di *natura*: il tempo classico cresce in modo super-polinomiale con la lunghezza della chiave, mentre il tempo quantistico cresce polinomialmente. Ciò significa che **aumentare la lunghezza della chiave RSA non è una contromisura efficace** contro Shor: raddoppiare  $n$  (i bit di  $N$ ) porta il tempo classico da impraticabile a ancora più impraticabile, ma porta il tempo quantistico da  $O(n^3)$  a  $O((2n)^3) = 8O(n^3)$  — un fattore costante, del tutto gestibile. La sicurezza di RSA è quindi **irrecuperabilmente compromessa** dalla disponibilità di un computer quantistico fault-tolerant, indipendentemente dalla lunghezza della chiave scelta. La stessa rottura si estende a tutti i sistemi basati sul logaritmo discreto (Diffie-Hellman,



ECDSA), per i quali Shor fornisce un algoritmo analogamente efficiente.

La minaccia non è futura in senso astratto. Il fenomeno del *harvest now, decrypt later* — già documentato in ambito di intelligence — consiste nel raccogliere oggi grandi quantità di dati cifrati con RSA, conservarli, e decifrarli non appena sarà disponibile un computer quantistico fault-tolerant. I dati cifrati oggi con chiavi RSA-2048 potrebbero quindi diventare leggibili in un orizzonte di dieci-quindici anni, secondo le roadmap pubblicate da IBM e da altri produttori di hardware quantistico [42].

Il problema pratico che impedisce questa minaccia di materializzarsi oggi è il **rumore**. I processori quantistici attuali operano in regime NISQ: dispongono di decine o centinaia di qubit fisici, ma sono affetti da decoerenza, errori di gate e readout error che degradano l’output dell’algoritmo di Shor fino a renderlo inaffidabile senza un numero elevato di ripetizioni. Comprendere questo limite e stabilire quali strategie lo superino — e in quale punto della pipeline di esecuzione i modelli di machine learning contribuiscano davvero — è la ragione d’essere del presente lavoro.

## C.2.2 Requisiti Funzionali

Definiti gli obiettivi e il contributo originale, è possibile formalizzare cosa il sistema sperimentale deve concretamente fare. I requisiti seguenti traducono le ipotesi di ricerca in vincoli tecnici verificabili, e costituiscono il riferimento rispetto al quale l’implementazione descritta nel Capitolo 6 verrà valutata.

Il sistema sperimentale deve soddisfare i seguenti requisiti funzionali:

1. **Esecuzione configurabile del circuito di Shor.** Dato un intero  $N$  da fattorizzare e una base  $a$  con  $\gcd(a, N) = 1$ , il sistema costruisce il circuito dell’algoritmo di Shor a partire dall’implementazione di riferimento [24], lo configura con il numero di qubit  $n_{\text{count}}$  specificato e lo esegue tramite **AerSimulator** con il noise model attivo per un numero di shot  $M_{\text{shots}}$  configurabile.
2. **Modello di rumore parametrizzabile.** Il sistema permette di configurare in modo indipendente tutti i parametri del noise model — tassi di errore depolarizzante per gate a singolo e doppio qubit, tempi di rilassamento  $T_1$  e  $T_2$ , probabilità di readout error — in modo da poter riprodurre diverse condizioni operative e generare dataset con distribuzione di rumore variabile. Questo requisito è fondamentale per la creazione di un dataset di addestramento

sufficientemente ricco per il Metodo 2, come indicato dalla metodologia di selezione dei noise model proposta in letteratura [5].

3. **Raccolta e archiviazione degli output.** Il sistema registra la distribuzione di misura del registro di controllo per ogni esecuzione e la archivia in formato strutturato, garantendo la riproducibilità degli esperimenti tramite seed fisso per il generatore di numeri casuali di Qiskit Aer.
4. **Analisi statistica del Metodo 1.** Il sistema implementa la pipeline del Metodo 1: selezione della misura più frequente dell'istogramma (strategia TOP-1, senza sogliatura preliminare), stima del periodo  $r$  tramite frazioni continue, verifica della correttezza dei fattori estratti. Misura e registra il numero di iterazioni necessarie per raggiungere il primo risultato corretto.
5. **Training, validazione e inferenza del Metodo 2.** Il sistema genera il dataset dal simulatore rumoroso, addestra il classificatore con divisione training/validation/test, ne valuta le metriche di accuratezza e lo utilizza in modalità inferenza: dopo ogni esecuzione del circuito, il classificatore decide se l'istogramma contiene segnale QPE recuperabile e, in caso affermativo, la ricerca multi-candidato TOP-K tenta l'estrazione dei fattori dai  $K$  esiti più frequenti.
6. **Confronto sistematico sui use case previsti.** Entrambi i metodi vengono eseguiti sugli stessi use case, nelle medesime condizioni di rumore, producendo metriche confrontabili secondo i criteri definiti nella Sezione 2.6. Come documentato nel Capitolo 7, il confronto risulterà praticabile sui due use case per  $N = 15$ : per  $N = 21$  e  $N = 35$  la profondità del circuito traspilato azzerà la probabilità di successo di qualunque strategia di estrazione.
7. **Riproducibilità.** Tutti gli esperimenti sono riproducibili: seed fisso, parametri esplicitati, codice disponibile nel repository del progetto. Questo requisito è condizione necessaria per la validazione accademica dei risultati [3].

### C.2.3 Parametri di Input e Output

#### Parametri di Input

La Tabella C.1 elenca i parametri di configurazione del sistema. I loro valori vengono fissati per ciascun use case prima dell'esecuzione e rimangono costanti per tutta la durata dell'esperimento corrispondente.

| Parametro          | Unità         | Descrizione                                              |
|--------------------|---------------|----------------------------------------------------------|
| $N$                | intero        | Numero da fattorizzare                                   |
| $a$                | intero        | Base della moltiplicazione modulare ( $\gcd(a, N) = 1$ ) |
| $n_{\text{count}}$ | intero        | Qubit del registro di controllo                          |
| $M_{\text{shots}}$ | intero        | Shot per esecuzione del simulatore                       |
| $\epsilon_{1q}$    | adimensionale | Tasso di errore depolarizzante su gate a 1 qubit         |
| $\epsilon_{2q}$    | adimensionale | Tasso di errore depolarizzante su gate a 2 qubit         |
| $T_1$              | ns            | Tempo di rilassamento (amplitude damping)                |
| $T_2$              | ns            | Tempo di dephasing                                       |
| $p_{\text{ro}}$    | adimensionale | Probabilità di readout error                             |

Tabella C.1: Parametri di input del sistema sperimentale. I valori di  $\epsilon_{1q}$ ,  $\epsilon_{2q}$ ,  $T_1$ ,  $T_2$  e  $p_{\text{ro}}$  definiscono il noise model e vengono variati tra i use case per coprire scenari di rumore diversi.

## Output del Sistema

Per ogni use case e per ciascuno dei due metodi, il sistema produce le seguenti quantità:

- I fattori trovati  $p$  e  $q$  tali che  $p \cdot q = N$ , con verifica esplicita della correttezza ( $p \neq 1$ ,  $q \neq 1$ ,  $p \cdot q = N$ );
- Il numero di iterazioni necessarie per il primo risultato corretto;
- La distribuzione di frequenza completa degli output del registro di controllo su  $M_{\text{shots}}$  esecuzioni;
- Le metriche di confronto tra i due metodi definite nella Sezione 2.6.

Per il solo Metodo 2, vengono prodotte in aggiunta:

- L'accuratezza del classificatore e il punteggio F1 sul test set;
- La curva ROC con l'area sottostante (AUC).

# Appendice D

## Fase 1: la Campagna Classica nel Dettaglio

### D.1 Campagna Parametrica e Confronto con la Zero-Noise Extrapolation

Questa appendice riporta integralmente la campagna sperimentale parametrica su  $M_{\text{TOP4}}$  e il confronto quantitativo con la *Zero-Noise Extrapolation*, di cui il Capitolo 7 presenta la sintesi. Per ciascun parametro si confrontano esplicitamente *previsione teorica* ed *esito osservato*. Tutte le misure usano  $K_{\text{rep}} = 30$  ripetizioni e il test Mann-Whitney a una coda; la metodologia è a variazione singola (*one-factor-at-a-time*) rispetto alla configurazione di riferimento di UC1:  $N = 15$ ,  $a = 7$ ,  $n_{\text{count}} = 8$ ,  $\varepsilon_{1q} = 10^{-3}$ ,  $\varepsilon_{2q} = 10^{-2}$ ,  $T_1 = 100 \mu\text{s}$ ,  $T_2 = 80 \mu\text{s}$ ,  $p_{\text{ro}} = 2\%$ ,  $M_{\text{shots}} = 1024$ ,  $K = 4$ ,  $M_{\text{max}} = 50$ .

#### D.1.1 Variazione di K (numero di candidati per iterazione)

**Previsione.** Per  $N = 15$  con  $a = 7$ , il periodo è  $r = 4$  e le fasi QPE valide sono esattamente quattro:  $\{0, 64, 128, 192\}$  su  $2^8 = 256$  valori. La previsione era che  $K = r = 4$  costituisse la soglia minima per catturare tutte le fasi valide, e che per  $K < 4$  il tasso di successo degradasse proporzionalmente al numero di fasi escluse.

**Esito.** Sweep su  $K \in \{1, 2, 3, 4, 6, 8\}$  con rumore fisso a UC1:

Tabella D.1: Effetto del parametro  $K$  su  $\bar{M}$ , tasso di successo e  $\rho$  vs M1 ( $N = 15$ , UC1,  $K_{\text{rep}} = 30$ )

| $K$                       | $P_{\text{succ}}$                                                                    | $\bar{M}$ | $\sigma_M$ | $\rho$ vs M1 | p-value (vs M1) |
|---------------------------|--------------------------------------------------------------------------------------|-----------|------------|--------------|-----------------|
| 1 (= M1)                  | <i>baseline: <math>\bar{M}_1 = 1.97</math>, <math>P_{\text{succ}} = 100\%</math></i> |           |            |              |                 |
| 2                         | 100%                                                                                 | 1.00      | 0.00       | 1.967        | 0.003           |
| 3                         | 100%                                                                                 | 1.00      | 0.00       | 1.967        | 0.003           |
| 4 ( $= M_{\text{TOP4}}$ ) | 100%                                                                                 | 1.00      | 0.00       | 1.967        | 0.003           |
| 6                         | 100%                                                                                 | 1.00      | 0.00       | 1.967        | 0.003           |
| 8                         | 100%                                                                                 | 1.00      | 0.00       | 1.967        | 0.003           |

La soglia effettiva non è  $K = r = 4$  ma  $K = 2$ : il salto netto è tra  $K = 1$  (equivalente a M1,  $\bar{M} = 1.97$ ) e  $K = 2$  ( $\bar{M} = 1.00$  con deviazione standard nulla, cioè convergenza al primo tentativo in *ogni* ripetizione); per  $K \geq 2$  le prestazioni sono identiche e massime, e il fattore di riduzione si assesta a  $\rho = 1.967$ . La spiegazione è duplice: il rumore depolarizzante non distribuisce il segnale uniformemente sulle quattro fasi valide, ma tende a concentrarlo su uno o due valori dominanti dell'istogramma; inoltre `extract_factors` con `limit_denominator` è tollerante a fasi leggermente spostate, allargando il bacino di convergenza attorno a ciascun picco. Il criterio teorico  $K = r$  resta un limite superiore garantito, ma nella pratica  $K = 2$  è sufficiente per questa istanza; per  $r$  più grandi la soglia effettiva andrebbe verificata.

### D.1.2 Variazione di $\varepsilon_{2q}$ (tasso di errore a due qubit)

**Previsione.**  $\varepsilon_{2q}$  è il parametro di rumore dominante:  $P_{\text{surv}} = (1 - \varepsilon_{2q})^k$  con  $k = 166$ , il numero di porte del circuito traspilato soggette all'errore depolarizzante a due qubit (114 `cx` + 52 `cp`; si veda la Sezione 6.4.4). Ci si aspettava una **soglia critica** oltre la quale l'istogramma diventasse troppo piatto per identificare i candidati corretti, degradando  $\bar{M}_{\text{TOP4}}$ .

**Esito.** Sweep su tre ordini di grandezza, con  $P_{\text{surv}}$  da 85% a  $2.5 \times 10^{-8}$ :

Tabella D.2: Effetto di  $\varepsilon_{2q}$  su  $M_{\text{TOP4}}$  ( $K = 4$ ,  $K_{\text{rep}} = 30$ , altri parametri fissi a UC1)

| $\varepsilon_{2q}$ | $P_{\text{surv}}$     | $\bar{M}_1$ | $\bar{M}_{\text{TOP4}}$ | $\rho$ | p-value | $P_{\text{succ}}$ |
|--------------------|-----------------------|-------------|-------------------------|--------|---------|-------------------|
| $10^{-3}$          | 84.7%                 | 1.70        | 1.00                    | 1.700  | <0.001  | 100%              |
| $5 \times 10^{-3}$ | 43.5%                 | 1.97        | 1.00                    | 1.967  | <0.001  | 100%              |
| $10^{-2}$ (UC1)    | 18.9%                 | 1.97        | 1.00                    | 1.967  | <0.001  | 100%              |
| $2 \times 10^{-2}$ | 3.5%                  | 1.53        | 1.00                    | 1.533  | <0.001  | 100%              |
| $5 \times 10^{-2}$ | $2.00 \times 10^{-4}$ | 1.53        | 1.00                    | 1.533  | 0.0003  | 100%              |
| $10^{-1}$          | $2.54 \times 10^{-8}$ | 1.30        | 1.00                    | 1.300  | 0.006   | 100%              |

Nessuna soglia critica è stata rilevata:  $M_{\text{TOP4}}$  mantiene  $\bar{M} = 1.00$  e  $P_{\text{succ}} = 100\%$  su tutto il range, incluso  $\varepsilon_{2q} = 10^{-1}$  dove  $P_{\text{surv}} \approx 2.5 \times 10^{-8}$ . Il rumore depolarizzante, pur abbassando la probabilità *media* di sopravvivenza del segnale, non produce istogrammi uniformemente piatti per ogni realizzazione (seed): in una frazione significativa delle esecuzioni uno o più dei quattro candidati più frequenti corrisponde comunque a una fase QPE valida. TOP-K sfrutta questa struttura residua: non richiede che il segnale sia forte in media, ma solo che sia recuperabile *in quella specifica esecuzione*. La variazione di  $\rho$  (fra 1.30 e 1.97) riflette il comportamento non monotono di  $\bar{M}_1$ , non un degrado di  $M_{\text{TOP4}}$ : al crescere del rumore la baseline talvolta *migliora*, perché l'allargamento della distribuzione aumenta la probabilità che la moda cada nella banda di accettazione delle frazioni continue.

### D.1.3 Variazione di $M_{\text{shots}}$ (shot per iterazione)

**Previsione.** Con  $n_{\text{count}} = 8$  qubit il registro ha  $2^8 = 256$  celle: era attesa una soglia minima di  $M_{\text{shots}} \geq 4 \times 256 = 1024$  campioni, sotto la quale l'istogramma sarebbe troppo sparso per identificare i picchi in modo affidabile.

Tabella D.3: Effetto di  $M_{\text{shots}}$  su  $M_{\text{TOP4}}$  ( $K = 4$ ,  $K_{\text{rep}} = 30$ , UC1)

| $M_{\text{shots}}$ | $P_{\text{succ}}$ | $\bar{M}$ | $\sigma_M$ | $\rho$ vs M1 |
|--------------------|-------------------|-----------|------------|--------------|
| 128 (min. testato) | 100%              | 1.00      | 0.00       | 1.967        |
| 256                | 100%              | 1.00      | 0.00       | 1.967        |
| 512                | 100%              | 1.00      | 0.00       | 1.967        |
| 1024 (riferimento) | 100%              | 1.00      | 0.00       | 1.967        |
| 2048               | 100%              | 1.00      | 0.00       | 1.967        |

**Esito.** La previsione è smentita: anche con 128 shot — otto volte meno della soglia prevista —  $M_{\text{TOP4}}$  raggiunge  $\bar{M} = 1.00$  e  $P_{\text{succ}} = 100\%$ . Il campionamento uniforme di tutte le celle non è necessario perché i picchi QPE validi occupano poche posizioni fisse e ben separate: anche un istogramma sparso è sufficiente a individuarle. Il costo per iterazione è dunque fino a 8 volte inferiore al riferimento.

### D.1.4 Analisi Congiunta $K \times \varepsilon_{2q}$

L'analisi congiunta verifica se esiste un'interazione tra  $K$  e il livello di rumore: in regime di rumore elevato, un  $K$  maggiore potrebbe compensare il degrado del picco

QPE. Griglia  $K \in \{2, 4, 6, 8\} \times \varepsilon_{2q} \in \{5 \times 10^{-3}, 10^{-2}, 2 \times 10^{-2}, 5 \times 10^{-2}\}$ ,  $K_{\text{rep}} = 30$  per cella.

Tabella D.4:  $\bar{M}_{\text{TOPK}}$  per combinazioni di  $K$  e  $\varepsilon_{2q}$  ( $K_{\text{rep}} = 30$ ). In grassetto:  $\rho > 2$  con  $p < 0.05$ .

| $K$ | $\varepsilon_{2q}$ |                 |                    |                          |
|-----|--------------------|-----------------|--------------------|--------------------------|
|     | $5 \times 10^{-3}$ | $10^{-2}$ (UC1) | $2 \times 10^{-2}$ | $5 \times 10^{-2}$ (UC2) |
| 2   | <b>1.00</b>        | <b>1.00</b>     | <b>1.00</b>        | <b>1.00</b>              |
| 4   | <b>1.00</b>        | <b>1.00</b>     | <b>1.00</b>        | <b>1.00</b>              |
| 6   | <b>1.00</b>        | <b>1.00</b>     | <b>1.00</b>        | <b>1.00</b>              |
| 8   | <b>1.00</b>        | <b>1.00</b>     | <b>1.00</b>        | <b>1.00</b>              |

L'interazione è assente: ogni cella produce  $\bar{M} = 1.00$  con  $P_{\text{succ}} = 100\%$ . Non esiste un regime in cui un  $K$  più alto compensi un rumore più elevato, perché TOP-K non ne ha bisogno: anche a  $\varepsilon_{2q} = 5 \times 10^{-2}$  il picco corretto rientra già tra i primi due candidati.

### D.1.5 Parametri Secondari: $T_1/T_2$ , $\varepsilon_{1q}$ e $p_{\text{ro}}$

I tempi di coerenza, il tasso di errore a singolo qubit e l'errore di lettura erano attesi come parametri secondari per  $N = 15$ : il tempo di gate totale ( $\approx 8 \mu\text{s}$ ) è ben inferiore ai tempi di decoerenza tipici, le porte a singolo qubit sono confrontabili in numero con le 166 porte a due qubit ma con errore dieci volte minore, e  $p_{\text{ro}}$  produce solo un allargamento simmetrico dell'istogramma.

Tabella D.5: Effetto di  $T_1$  su  $M_{\text{TOP4}}$  ( $K = 4$ ,  $\varepsilon_{2q} = 10^{-2}$ ,  $K_{\text{rep}} = 30$ ,  $T_2 = 0.8 T_1$ )

| $T_1$ ( $\mu\text{s}$ ) | $T_2$ ( $\mu\text{s}$ ) | $P_{\text{succ}}$ | $\bar{M}$ | $\sigma_M$ | $\rho$ vs M1 |
|-------------------------|-------------------------|-------------------|-----------|------------|--------------|
| 20                      | 16                      | 100%              | 1.00      | 0.00       | 1.967        |
| 50                      | 40                      | 100%              | 1.00      | 0.00       | 1.967        |
| 100 (UC1)               | 80                      | 100%              | 1.00      | 0.00       | 1.967        |
| 200                     | 160                     | 100%              | 1.00      | 0.00       | 1.967        |
| 500                     | 400                     | 100%              | 1.00      | 0.00       | 1.967        |

Tabella D.6: Effetto di  $\varepsilon_{1q}$  su  $M_{\text{TOP4}}$  ( $K = 4$ ,  $\varepsilon_{2q} = 10^{-2}$ ,  $K_{\text{rep}} = 30$ )

| $\varepsilon_{1q}$           | $P_{\text{succ}}$ | $\bar{M}$ | $\sigma_M$ | $\rho$ vs M1 |
|------------------------------|-------------------|-----------|------------|--------------|
| $10^{-4}$                    | 100%              | 1.00      | 0.00       | 1.967        |
| $5 \times 10^{-4}$           | 100%              | 1.00      | 0.00       | 1.967        |
| $10^{-3}$ (UC1, riferimento) | 100%              | 1.00      | 0.00       | 1.967        |
| $5 \times 10^{-3}$           | 100%              | 1.00      | 0.00       | 1.967        |
| $10^{-2}$                    | 100%              | 1.00      | 0.00       | 1.967        |
| $2 \times 10^{-2}$           | 100%              | 1.00      | 0.00       | 1.967        |

Tabella D.7: Effetto di  $p_{\text{ro}}$  su  $M_{\text{TOP4}}$  ( $K = 4$ ,  $\varepsilon_{2q} = 10^{-2}$ ,  $K_{\text{rep}} = 30$ )

| $p_{\text{ro}}$ | $P_{\text{succ}}$ | $\bar{M}$ | $\sigma_M$ | $\rho$ vs M1 |
|-----------------|-------------------|-----------|------------|--------------|
| 0%              | 100%              | 1.00      | 0.00       | 1.967        |
| 1%              | 100%              | 1.00      | 0.00       | 1.967        |
| 2% (UC1)        | 100%              | 1.00      | 0.00       | 1.967        |
| 5%              | 100%              | 1.00      | 0.00       | 1.967        |
| 10%             | 100%              | 1.00      | 0.00       | 1.967        |
| 20%             | 100%              | 1.00      | 0.00       | 1.967        |

La previsione qualitativa (impatto marginale) è confermata, ma l'esito quantitativo è ancora più netto: l'impatto è *nulla* su tutto il range testato per tutti i parametri.  $T_1$  varia da 20 a 500  $\mu\text{s}$ ,  $\varepsilon_{1q}$  da  $10^{-4}$  a  $2 \times 10^{-2}$  (lo stesso ordine di grandezza di  $\varepsilon_{2q}$ ),  $p_{\text{ro}}$  da 0% a 20% (ben oltre i valori realistici  $\lesssim 3\%$  dei dispositivi attuali): in nessun caso  $\bar{M}_{\text{TOP4}}$  si discosta da 1.00. Un errore di lettura simmetrico allarga l'istogramma ma non sposta i picchi QPE; il basso numero di porte a singolo qubit rende  $\varepsilon_{1q}$  trascurabile; il tempo di gate complessivo è inferiore anche al minimo  $T_1$  testato.

### D.1.6 Dettaglio del Confronto con Zero-Noise Extrapolation

La ZNE [30] opera in due fasi. Nella prima, il circuito viene eseguito a più livelli di rumore amplificato (noise scaling): si moltiplicano i parametri di errore  $\varepsilon_{2q}$  e  $\varepsilon_{1q}$  per fattori  $\lambda \in \{1, 2, 3, \dots\}$ , ottenendo istogrammi progressivamente più degradati. Nella seconda, si applica la *Richardson extrapolation* per stimare l'istogramma al rumore ideale  $\lambda = 0$ :

- **ZNE-2** (estrapolazione lineare, 2 livelli):  $P_0(k) = 2 P_{\lambda=1}(k) - P_{\lambda=2}(k)$
- **ZNE-3** (Richardson quadratica, 3 livelli):  $P_0(k) = 3 P_{\lambda=1}(k) - 3 P_{\lambda=2}(k) + P_{\lambda=3}(k)$



L'istogramma estrapolato  $P_0$  viene quindi usato per identificare i candidati più frequenti (TOP-1) e tentare l'estrazione dei fattori. Il costo per iterazione è  $\lambda_{\max} \times M_{\text{shots}}$ : con ZNE-2, 2048 shot per iterazione; con ZNE-3, 3072 shot.

L'esito del confronto (Tabella 7.7 nel Capitolo 7) è che la ZNE non danneggia il risultato — tutte le strategie raggiungono il 100% di successo — ma neppure lo migliora:  $\bar{M}_{\text{ZNE-2}} = 2.03$  e  $\bar{M}_{\text{ZNE-3}} = 1.57$  contro  $\bar{M}_1 = 1.97$  della baseline, differenze non significative (rispettivamente  $p = 0.728$  e  $p = 0.250$ ) su  $K_{\text{rep}} = 30$  ripetizioni. Il costo, invece, è certo: 4 164 e 4 813 shot medi per fattorizzazione contro i 2 014 della baseline e i 1 024 di  $M_{\text{TOP4}}$ .

L'inefficacia è spiegabile strutturalmente, ed è istruttiva per il seguito della tesi. La ZNE è progettata per stimare valori di aspettazione di osservabili scalari (es.  $\langle Z \rangle$ ), dove la relazione fra intensità del rumore e output è regolare e l'estrapolazione è stabile. Nel caso di Shor l'output è una distribuzione di probabilità su  $2^8 = 256$  stati: l'estrapolazione Richardson applicata componente per componente produce valori negativi in molte celle — fisicamente privi di significato — che vengono tagliati e rinormalizzati, un'operazione non lineare che l'analisi di errore dell'estrapolazione non contempla. Ma la ragione più profonda è un'altra: *non c'è alcun bias sistematico da rimuovere*. La ZNE corregge lo spostamento medio indotto dal rumore, e su questo compito quello spostamento non è ciò che fa fallire l'estrazione — la sweep di  $\varepsilon_{2q}$  ha mostrato che la moda resta nella banda di accettazione delle frazioni continue anche quando  $P_{\text{surv}}$  scende a  $6 \times 10^{-6}$ . Spendere shot per stimare e sottrarre un bias irrilevante è lavoro sprecato.  $M_{\text{TOP4}}$  segue la logica opposta: invece di correggere l'istogramma, accetta il rumore come dato di fatto e amplia la ricerca ai  $K$  candidati più probabili.

## D.1.7 Analisi di Sensibilità ai Parametri e Scelta del Livello di Ottimizzazione

### Analisi di Sensibilità ai Parametri di Rumore

Prima di fissare l'approccio definitivo, è stato condotto uno studio empirico sistematico per determinare quali parametri del modello di rumore influenzano effettivamente le prestazioni dell'algoritmo di Shor su  $N=15$ . Lo sweep è stato eseguito variando un parametro per volta mantenendo fissi tutti gli altri ai valori del profilo NISQ-realistico (Tabella 2.1), con  $K=30$  ripetizioni per punto e  $\text{SHOTS}=1024$ .

| Parametro                         | Valore base          | Range testato                 | Effetto su $\bar{M}_1$ |
|-----------------------------------|----------------------|-------------------------------|------------------------|
| $\varepsilon_{1q}$ (gate 1-qubit) | $10^{-3}$            | $[10^{-4}, 2 \times 10^{-2}]$ | <b>Nessuno</b>         |
| $T_1/T_2$ (decoerenza)            | 100/80 $\mu\text{s}$ | $[20, 500]$ $\mu\text{s}$     | <b>Nessuno</b>         |
| $p_{\text{ro}}$ (readout error)   | 0.02                 | $[0, 0.20]$                   | <b>Nessuno</b>         |
| $\varepsilon_{2q}$ (gate CX)      | $10^{-2}$            | $[10^{-3}, 10^{-1}]$          | <b>Dominante</b>       |

Tabella D.8: Risultati dell’analisi di sensibilità ai parametri di rumore per  $N=15$ ,  $a=7$ ,  $n_{\text{count}}=8$ . Solo  $\varepsilon_{2q}$  influenza le prestazioni di  $M_1$ .

I risultati mostrano con nettezza che **nessun parametro del modello di rumore degrada la convergenza in modo apprezzabile**. Errori sui gate a singolo qubit, tempi di decoerenza  $T_1/T_2$  e readout error producono  $\bar{M}_1 = 1.0$  con success rate = 100% sull’intero range testato, indistinguibili dal caso ideale; il tasso di errore dei gate a due qubit  $\varepsilon_{2q}$  — l’unico che lascia una traccia — fa oscillare  $\bar{M}_1$  fra 1.3 e 2.0 senza alcun andamento monotono e senza mai far scendere il tasso di successo sotto il 100%, come mostra la Tabella D.9.

| $\varepsilon_{2q}$ | $P_{\text{surv}}$    | $\bar{M}_1$ | $\sigma_{M_1}$ | Success rate | TOP-4 $\bar{M}$ |
|--------------------|----------------------|-------------|----------------|--------------|-----------------|
| $10^{-3}$          | $8.5 \times 10^{-1}$ | 1.70        | 0.94           | 100%         | 1.00            |
| $5 \times 10^{-3}$ | $4.4 \times 10^{-1}$ | 1.97        | 1.47           | 100%         | 1.00            |
| $10^{-2}$          | $1.9 \times 10^{-1}$ | 1.97        | 1.66           | 100%         | 1.00            |
| $2 \times 10^{-2}$ | $3.5 \times 10^{-2}$ | 1.53        | 0.62           | 100%         | 1.00            |
| $5 \times 10^{-2}$ | $2.0 \times 10^{-4}$ | 1.53        | 1.28           | 100%         | 1.00            |
| $10^{-1}$          | $2.5 \times 10^{-8}$ | 1.30        | 0.78           | 100%         | 1.00            |

Tabella D.9: Sweep di  $\varepsilon_{2q}$  su UC1 ( $N = 15$ ,  $a = 7$ ,  $K_{\text{rep}} = 30$ ).  $P_{\text{surv}} = (1 - \varepsilon_{2q})^{166}$  è la probabilità che nessuna delle porte soggette all’errore a due qubit subisca errore; si veda la nota seguente sul conteggio. Entrambe le strategie mantengono success rate = 100% su tutto il range, e  $\bar{M}_1$  resta compreso fra 1.3 e 2.0 anche là dove  $P_{\text{surv}}$  scende a due parti su cento milioni.

### Come va contato $P_{\text{surv}}$ .

Il modello di rumore adottato (Sezione 6.9) applica l’errore depolarizzante a due qubit non alle sole porte `cx`, ma all’insieme `[cx, swap, cp]`. L’esponente di  $P_{\text{surv}}$  è quindi il numero *complessivo* di porte soggette a quell’errore, non il conteggio delle `cx`. Per il circuito di UC1 traspilato a `optimization_level=2` la composizione è 114 `cx` + 52 `cp` + 0 `swap`, da cui  $k = 166$  e  $P_{\text{surv}} = (1 - \varepsilon_{2q})^{166}$ . Le porte `cp` provengono dalla QFT inversa, che il transpiler conserva nel gate set nativo anziché decomporle: trascurarle sottostima l’errore accumulato di un terzo abbondante. La distinzione è

tanto più rilevante per le istanze maggiori, dove la decomposizione di Beauregard costruisce l'aritmetica modulare interamente nel dominio della QFT e le `cx` arrivano a superare di tre volte le `cx` (Capitolo 7, Tabella 7.1).

Il dato più istruttivo della tabella è il confronto fra la seconda colonna e le successive. Passando da  $\varepsilon_{2q} = 10^{-3}$  a  $\varepsilon_{2q} = 10^{-1}$ , la probabilità che il circuito attraversi tutte le sue porte a due qubit senza alcun errore crolla dall'85% a due parti su cento milioni: in altre parole, nel regime peggiore *praticamente ogni singola esecuzione* contiene almeno un errore. Ciononostante  $\bar{M}_1$  non peggiora — anzi, decresce leggermente — e il tasso di successo resta pieno. La spiegazione sta nella natura della QPE: il segnale non è concentrato in un unico esito che il rumore può distruggere, ma distribuito su un picco largo attorno ai valori  $k \approx j 2^n / r$ , e la procedura delle frazioni continue tollera uno scostamento apprezzabile dal massimo esatto. Un errore che sposta la misura di qualche unità lascia il periodo recuperabile. È lo stesso meccanismo che, portato alle sue conseguenze, rende efficace la strategia TOP-K.

Questo risultato ha un'interpretazione fisica precisa anche per gli altri parametri. Il circuito di Shor per  $N=15$  con la decomposizione a permutazione (`c_amod15`) ha profondità ridotta: in queste condizioni il tempo totale di esecuzione è sufficientemente breve da rendere la decoerenza ( $T_1$ ,  $T_2$ ) trascurabile rispetto al contributo dei gate a due qubit. Analogamente, gli errori sui gate a singolo qubit e il readout error si trovano in un regime in cui il loro effetto è oscurato dall'errore CX. La fonte di degradazione dominante è quindi il numero e la qualità dei gate CX.

**Implicazioni per le scelte implementative.** Questa analisi ha tre conseguenze dirette:

1. **La decomposizione Beauregard è la leva più efficace.** Ridurre  $\varepsilon_{2q}$  non è controllabile (è una proprietà del backend), ma ridurre il *numero* di gate CX è possibile a livello di implementazione. La decomposizione Beauregard (Sezione 6.4.1) fa esattamente questo, portando  $N=21$  da  $\sim 10\,040$  gate CX (UnitaryGate naïve) a  $\sim 2\,594$  (Beauregard).
2. **Readout mitigation e ottimizzazioni  $T_1/T_2$  sono inutili per  $N=15$ .** Il risultato empirico conferma che nessuno dei due approcci porta benefici misurabili nel regime  $N=15$ . Adottarli avrebbe aggiunto complessità senza impatto sulle metriche.
3. **La ZNE è inefficace su questo compito.** Il confronto sperimentale (Sezione 6.4.3 e Capitolo 7) mostra che ZNE-2 e ZNE-3 non riducono in modo

statisticamente significativo il numero di iterazioni, pur richiedendo da due a tre volte più shot per il campionamento ai livelli di rumore amplificato: il costo è certo, il beneficio non si manifesta. Il motivo è coerente con quanto appena osservato — non c'è un bias sistematico da estrapolare via, perché la distribuzione rumorosa conserva già il segnale che serve.

4. **L'optimization\_level ha effetto trascurabile per N=15.** È stato condotto un ulteriore sweep variando il livello di ottimizzazione del transpiler Qiskit da 0 a 3. I risultati sono riportati in Tabella D.10.

| Livello      | cx  | cp | swap | $k$ | Profondità | $P_{\text{surv}}$ ( $\varepsilon_{2q} = 10^{-2}$ ) |
|--------------|-----|----|------|-----|------------|----------------------------------------------------|
| 0            | 168 | 28 | 4    | 200 | 319        | 13.4%                                              |
| 1            | 162 | 28 | 4    | 194 | 313        | 14.2%                                              |
| 2 (adottato) | 114 | 52 | 0    | 166 | 311        | 18.9%                                              |
| 3            | 114 | 52 | 0    | 166 | 311        | 18.9%                                              |

Tabella D.10: Sweep di `optimization_level` sul circuito di UC1 ( $N = 15$ ,  $a = 7$ );  $k = \text{cx} + \text{cp} + \text{swap}$  è il numero di porte soggette all'errore a due qubit. La tabella mostra perché il conteggio delle sole `cx` è fuorviante: passando dal livello 1 al livello 2 le `cx` scendono di quarantotto unità ( $162 \rightarrow 114$ ), ma quasi metà della riduzione è compensata dalla comparsa di ventiquattro `cp` in più, e il guadagno effettivo su  $P_{\text{surv}}$  è di soli 4.7 punti percentuali anziché dei 12 che il solo conteggio `cx` suggerirebbe. Il livello 3 non apporta alcun miglioramento ulteriore. Si riportano le sole metriche di transpilazione: le metriche di convergenza raccolte in questo sweep non sono comparabili con quelle degli altri, perché l'implementazione usata al suo interno seleziona i candidati con una sogliatura al 30% del massimo anziché la sola moda, e non corrisponde quindi al Metodo 1 definito nella Sezione 6.5.

Si adotta il livello 2 per tutti gli esperimenti, in quanto raggiunge il valore minimo di  $k$  senza il costo della ricerca esaustiva del livello 3, che su questo circuito non trova alcun margine ulteriore. Il guadagno complessivo è però modesto — 17% di porte rumorose in meno fra il livello 0 e il livello 2 — e resta di gran lunga inferiore a quello ottenibile cambiando decomposizione. Il dato conferma per via indipendente ciò che la barriera di scalabilità del Capitolo 7 mostrerà: la leva dominante sul numero di porte a due qubit è la *scelta della decomposizione*, non il livello di ottimizzazione del transpiler.

#### Nota sulla dipendenza dalla versione del transpiler.

La ripartizione fra `cx` e `cp` ai livelli 2 e 3 dipende dalla versione di Qiskit: le

campagne di questa tesi sono state eseguite con **Qiskit 2.x**, mentre versioni precedenti della stessa pipeline producevano 162 **cx** anche al livello 2. Il valore di  $k$ , e con esso  $P_{\text{surv}}$ , ne risente assai meno del conteggio delle sole **cx** — 166 contro 194, ossia 18.9% contro 14.2% — il che è un’ulteriore ragione per riportare  $k$  anziché il numero di **cx**. Ogni valore di  $P_{\text{surv}}$  nel seguito si riferisce a  $k$ ; il dato va inteso come proprietà della coppia (circuito, transpiler) e non del solo algoritmo.

La strategia TOP-4 — che mantiene success rate = 100% sull’intero range di  $\varepsilon_{2q}$  — emerge come la scelta ottimale per  $N=15$ . Il classificatore ML del Metodo 2 si inserisce in questo framework come strumento per ridurre ulteriormente il numero di iterazioni necessarie prima di convergere a un risultato affidabile, completando la catena di ottimizzazione descritta nella sezione seguente.

## D.2 Il Classificatore ML: Architettura, Addestramento e Metriche

Questa appendice riporta il dettaglio del classificatore ML valutato nella prima fase sperimentale (Capitolo 7): architettura, procedura di addestramento, metriche di classificazione e — nella Sezione D.2.2 — l’audit che ne ha chiarito il comportamento. Il verdetto operativo, ossia che il classificatore a valle dell’esecuzione non riduce le iterazioni rispetto alla sola ricerca multi-candidato TOP-4, è dimostrato nel corpo del capitolo tramite l’analisi di ablazione; qui se ne ricostruisce la causa.

### D.2.1 L’Ipotesi alla Prova: il Classificatore ML

L’ipotesi formalizzata nel Capitolo 2 era che un classificatore ML, addestrato a riconoscere gli istogrammi privi di segnale QPE, riducesse le iterazioni scartando le esecuzioni inutili: quantitativamente,  $\bar{M}_2 \approx 3$  e  $\rho = \bar{M}_1/\bar{M}_2 > 1$  con  $p < 0.05$  (Mann-Whitney). Il disegno sperimentale include fin dall’inizio la variante di ablazione  $M_{\text{TOP4}}$ : poiché il Metodo 2 combina due componenti (filtro ML + ricerca TOP-4), solo il confronto a tre permette di attribuire un eventuale guadagno all’una o all’altra.

**Architettura e addestramento.** Il Metodo 2 opera su due livelli: un *gate di qualità* — il classificatore riceve il vettore di distribuzione normalizzato  $\mathbf{x} \in \mathbb{R}^{256}$  e predice se l’istogramma contiene segnale recuperabile — e una *ricerca multi-candidato*:

se il classificatore approva, si tentano i 4 candidati più frequenti. Per ciascun use case è stato generato un dataset di 2000 campioni con noise model variato del  $\pm 50\%$  intorno al valore nominale, ottenendo il 74.2% di positivi per UC1 e l'83.2% per UC2. Tre architetture sono state confrontate — Random Forest, SVM con kernel RBF, MLP (256, 128) — con split 80/20 stratificato e selezione per F1-score.

Tabella D.11: Metriche dei classificatori sul test set (20% del dataset)

| Use Case | Modello                            | F1           | Accuratezza  | AUC-ROC      |
|----------|------------------------------------|--------------|--------------|--------------|
| UC1      | <b>Random Forest (selezionato)</b> | <b>0.949</b> | <b>0.922</b> | <b>0.964</b> |
|          | SVM                                | 0.855        | 0.748        | 0.929        |
|          | MLP                                | 0.919        | 0.885        | 0.952        |
| UC2      | <b>SVM (selezionato)</b>           | <b>0.979</b> | <b>0.965</b> | <b>0.987</b> |
|          | Random Forest                      | 0.976        | 0.960        | 0.982        |
|          | MLP                                | 0.977        | 0.963        | 0.987        |




Figura D.1: Curve ROC dei classificatori selezionati: Random Forest per UC1 (AUC=0.964) e SVM per UC2 (AUC=0.987). La linea tratteggiata rappresenta il classificatore casuale (AUC=0.5).

Come *classificatori*, i modelli funzionano molto bene: F1 fino a 0.98 e AUC fino a 0.99. Ma le metriche di classificazione dicono soltanto che il modello sa distinguere le due classi che gli sono state presentate, e non dicono nulla su *quali* classi siano. L'ablazione del Capitolo 7 ha mostrato che il filtraggio non riduce le iterazioni rispetto alla sola ricerca multi-candidato; la sezione seguente stabilisce perché.

## D.2.2 Audit delle Etichette: che Cosa il Classificatore ha Effettivamente Appreso

La coesistenza di metriche eccellenti e di un guadagno operativo nullo è sufficientemente anomala da richiedere una verifica diretta, anziché una spiegazione narrativa. Poiché i modelli addestrati sono stati archiviati assieme al proprio test set, è possibile *ricalcolare* le etichette a partire dagli istogrammi salvati e confrontarle con quelle memorizzate. È quanto fa lo script `audit_etichette_classificatore.py`, il cui esito è riportato nella Tabella D.12.

La regola di etichettatura documentata prevede  $\text{TOP\_K} = 16$ : un istogramma è positivo se almeno una delle sedici misure più frequenti conduce ai fattori corretti.

Tabella D.12: Concor stanza fra le etichette memorizzate nel test set e quelle ricalcolate dagli istogrammi con diverse regole di etichettatura. La regola documentata è TOP-16; le etichette effettive corrispondono a TOP-1.

| Regola usata per il ricalcolo | UC1                    | UC2                    |
|-------------------------------|------------------------|------------------------|
| TOP-1 (la sola moda)          | <b>399/400 (99.8%)</b> | <b>396/400 (99.0%)</b> |
| TOP-2                         | 297/400 (74.2%)        | 333/400 (83.2%)        |
| TOP-4                         | 297/400 (74.2%)        | 333/400 (83.2%)        |
| TOP-16 (regola documentata)   | 297/400 (74.2%)        | 333/400 (83.2%)        |

Le etichette effettivamente usate per l'addestramento coincidono con la regola TOP-1, non con TOP-16: la concordanza è del 99.8% contro il 74.2% per UC1, e del 99.0% contro l'83.2% per UC2 — dove il valore più basso non è altro che la frequenza di base della classe positiva, cioè quanto si otterrebbe etichettando tutto come positivo. Il parametro è stato evidentemente modificato nel codice dopo la generazione del dataset, senza rigenerarlo.

La conseguenza va enunciata con precisione, perché non è quella che il nome della variabile suggerisce. Poiché fra i quattro picchi della QPE l'unico che non conduce ai fattori è l'esito banale  $y = 0$  (fase nulla, scartata per costruzione dalla funzione di estrazione), etichettare con TOP-1 equivale a etichettare con la domanda: *la moda dell'istogramma cade sulla cella 0?* La verifica lo conferma senza eccezioni: dei 103 campioni negativi di UC1 tutti e 103 hanno moda  $y = 0$ , e così tutti e 67 quelli di UC2.

Tabella D.13: Struttura degli istogrammi della classe negativa. Su UC1 essi conservano il segnale QPE praticamente intatto: la differenza rispetto ai positivi non è la presenza del segnale, ma quale dei quattro picchi risulti il più alto.

|                                                      | <b>UC1</b> | <b>UC2</b> |
|------------------------------------------------------|------------|------------|
| Massa media sui quattro picchi $\{0, 64, 128, 192\}$ | 0.758      | 0.294      |
| Entropia media dell'istogramma (uniforme = 8 bit)    | 3.66 bit   | 6.37 bit   |
| Campioni negativi con moda $y = 0$                   | 103/103    | 67/67      |

Per UC1 il dato della Tabella D.13 è dirimente: gli istogrammi “negativi” concentrano il 75.8% della propria massa sui quattro picchi della QPE e hanno entropia 3.66 bit su 8 — valori indistinguibili da quelli della classe positiva. Non sono affatto istogrammi privi di segnale: sono istogrammi in cui il segnale c’è tutto, e in cui il picco più alto è quello privo di contenuto informativo. La Figura D.2 mostra un campione rappresentativo della classe negativa e rende la situazione immediata.






Figura D.2: Campione della classe negativa del dataset di UC1 (quello di massa mediana sui picchi). I quattro picchi della QPE sono tutti presenti e di altezza confrontabile; il più alto — e quindi la moda, l’unico candidato che la regola TOP-1 valuta — è l’esito  $y = 0$ , che corrisponde a fase nulla e che la funzione di estrazione scarta per costruzione. Gli altri tre, in seconda, terza e quarta posizione, conducono tutti alla fattorizzazione corretta (3, 5). Il campione è stato etichettato negativo pur contenendo il segnale intatto: è la ragione per cui il classificatore ha appreso a riconoscere la posizione dell’argmax anziché la presenza del segnale. Figura rigenerabile da `figure_src/gen_audit_classificatore.py`.

Il caso illustrato merita un’osservazione ulteriore, perché mostra quanto sia fragile la distinzione su cui il modello è stato addestrato. In quel campione l’esito  $y = 0$  e l’esito  $y = 128$  raccolgono **esattamente lo stesso numero di conteggi**, 202 su 1024: quale dei due risulti la moda non è deciso dai dati ma dal criterio di spareggio della funzione che ne calcola il massimo. E non è un caso isolato: su 103 campioni negativi, 14 presentano un pareggio esatto fra  $y = 0$  e il picco utile più alto, 29 differiscono di al più un conteggio, e lo scarto mediano è di quattro conteggi su circa duecento.

In oltre un quarto dei casi, dunque, l’etichetta che separa la classe positiva dalla negativa è determinata da uno o due shot di differenza — cioè da rumore di campionamento, non dal rumore quantistico che il classificatore avrebbe dovuto

diagnosticare. Le metriche del modello misurano la sua capacità di riprodurre questa distinzione.

**Perché questo spiega tutti e tre gli esiti osservati.** L’audit ricompone in un’unica causa i tre fatti che il Capitolo 7 registra separatamente.

- **Le metriche sono eccellenti perché il compito è quasi banale.** Predire se l’argmax di un vettore cade su una cella prefissata è una funzione elementare dell’input, non il riconoscimento di una firma di rumore.  $F1 = 0.95$  misura la capacità del modello di individuare il massimo di 256 numeri, non la sua capacità di diagnosticare la corruzione dell’informazione quantistica.
- **Il contributo operativo è nullo perché la ricerca TOP-4 copre già quel caso.** Quando la moda è  $y = 0$  i picchi utili occupano le posizioni successive, e TOP-4 li raggiunge per costruzione. Il classificatore scarta l’iterazione; la ricerca multi-candidato la risolve. I due componenti agiscono sullo stesso identico insieme di esecuzioni, ed è per questo che l’ablazione su UC1 non rileva differenza significativa ( $p = 0.849$ ).
- **Su UC2 il filtro diventa dannoso per la stessa ragione.** Scartare un’iterazione recuperabile ha un costo: bisogna eseguirne un’altra. È esattamente ciò che si osserva, con  $\bar{M}$  che risale da 1.00 a 1.57 ( $p < 0.001$ ).

**Il problema di classificazione, così come documentato, non esiste.** Resta da chiedersi che cosa accadrebbe addestrando il classificatore sulla regola dichiarata anziché su quella applicata. La rigenerazione dei dataset con  $TOP\_K = 16$ , a parità di ogni altro parametro, produce **2000 campioni positivi su 2000 per entrambi gli use case**: la classe negativa è vuota e la procedura di addestramento si interrompe segnalando l’assenza di una seconda classe. Che l’esito sia identico su UC2, il cui livello di rumore è cinque volte superiore, è già di per sé indicativo. Il risultato non è un artefatto dello schema di seeding — la rigenerazione ripetuta con il seeding originale dà lo stesso esito — né della versione del transpiler, verificata riportando il livello di rumore a quello che riproduce la profondità efficace precedente.

L’interpretazione è la seguente: al livello di rumore di UC1, e con una ricerca che consideri anche solo i primi sedici candidati, *non esiste alcun istogramma da scartare*. La domanda a cui il classificatore avrebbe dovuto rispondere non ha istanze negative, e quindi non è una domanda. Il filtro a valle non è ridondante per una qualche

insufficienza dell'architettura scelta o della quantità di dati: è ridondante perché il rumore depolarizzante, su questo circuito e a questa profondità, non produce mai la condizione che esso dovrebbe rilevare.

### Perché la Regola TOP-16 non Può Produrre Negativi

Costatare che la classe negativa è vuota lascia aperta la domanda su *dove* cominci a popolarsi: è quella soglia a delimitare il regime in cui un filtro a valle avrebbe qualcosa da apprendere. La ricerca della soglia, spingendo  $\varepsilon_{2q}$  ben oltre qualunque valore fisicamente sensato, dà l'esito riportato nella Tabella D.14.

Tabella D.14: Frazione di istogrammi privi di segnale recuperabile nei primi sedici candidati, in funzione di  $\varepsilon_{2q}$  (200 campioni per punto, regola TOP-16). La colonna  $f$  riporta la frazione coerente efficace misurata indipendentemente (Sezione 7.6.1).

| $\varepsilon_{2q}$       | rispetto a UC1 | $P_{\text{surv}}$     | $f$   | negativi |
|--------------------------|----------------|-----------------------|-------|----------|
| $5 \times 10^{-2}$ (UC2) | 5×             | $2.0 \times 10^{-4}$  | 0.372 | 0.0%     |
| $8 \times 10^{-2}$       | 8×             | $9.7 \times 10^{-7}$  | —     | 0.0%     |
| $10^{-1}$                | 10×            | $2.5 \times 10^{-8}$  | 0.158 | 0.0%     |
| $1.5 \times 10^{-1}$     | 15×            | $1.9 \times 10^{-12}$ | —     | 0.0%     |
| $2 \times 10^{-1}$       | 20×            | $8.2 \times 10^{-17}$ | 0.032 | 0.5%     |
| $3 \times 10^{-1}$       | 30×            | $1.9 \times 10^{-26}$ | 0.008 | 0.5%     |

La soglia non esiste. Portando il tasso di errore a trenta volte il valore dei dispositivi attuali — dove la frazione coerente efficace è scesa allo 0.8% e il segnale QPE è quindi quasi del tutto perduto — i negativi restano lo 0.5%, esattamente come a venti volte. La saturazione indica che il fenomeno non dipende dal rumore, e la sua causa è nella regola di etichettatura stessa.

**Il conto che lo spiega.** La funzione di estrazione applica le frazioni continue con `limit_denominator( $N$ )`, che mappa sul periodo  $r = 4$  non i soli quattro picchi esatti ma un'intera banda di fasi attorno a ciascuno. Enumerando i 256 esiti possibili per  $N = 15$ ,  $a = 7$ ,  $n_{\text{count}} = 8$ , si trova che 63 **di essi** — il 24.6% — **conducono ai fattori corretti**. Ne segue che, per un istogramma *completamente privo di segnale* e dunque uniforme, la probabilità che nessuno dei sedici valori più frequenti sia utile vale

$$\frac{\binom{256-63}{16}}{\binom{256}{16}} = 0.9\%. \quad (\text{D.1})$$

La regola TOP-16 etichetta quindi come positivo il 99.1% degli istogrammi *anche in assenza totale di informazione*, per puro effetto combinatorio: pescando sedici celle

su un insieme in cui un quarto è utile, è quasi impossibile mancarle tutte. La classe negativa non può superare lo 0.9% a nessun livello di rumore — ed è precisamente lo 0.5% misurato ai due punti estremi.

Il medesimo calcolo, ripetuto al variare di  $K$ , mostra che la scelta di questo parametro non è una sfumatura di severità ma determina l'ordine di grandezza del problema posto.

Tabella D.15: Frazione massima di campioni negativi ottenibile con la regola TOP- $K$  su un istogramma privo di segnale, calcolata come  $\binom{256-63}{K}/\binom{256}{K}$ . Il valore osservato è quello del dataset di UC1.

| Regola | Tetto ai negativi | Osservato |
|--------|-------------------|-----------|
| TOP-1  | 75.4%             | 25.8%     |
| TOP-2  | 56.8%             | —         |
| TOP-4  | 32.1%             | —         |
| TOP-16 | 0.9%              | 0.5%      |

Il 25.8% osservato nel dataset originale si colloca ben sotto il tetto del 75.4% proprio perché il segnale era presente: la moda cadeva sempre su uno dei quattro picchi, e di questi il solo  $y = 0$  fallisce, da cui una frazione negativa di circa un quarto. Il tetto sarebbe raggiunto solo se l'istogramma fosse privo di struttura. La Figura D.3 riassume la situazione.




Figura D.3: Frazione massima di campioni negativi ottenibile con la regola TOP- $K$ , calcolata su un istogramma privo di segnale. Poiché 63 dei 256 esiti possibili conducono ai fattori, il tetto decade rapidamente con  $K$ : passare da  $K = 1$  a  $K = 16$  lo abbatta di quasi due ordini di grandezza. I due punti segnati sono le frazioni osservate — 25.8% con la regola effettivamente usata per l’addestramento, 0.5% con quella documentata. Il primo sta sotto il proprio tetto perché il segnale era presente; il secondo vi aderisce, perché a quel valore di  $K$  l’esito non dipende quasi più dal segnale. Figura rigenerabile da `figure_src/gen_audit_classificatore.py`.

**Il contrasto con la regola effettivamente usata.** Lo stesso conto spiega, per differenza, l’origine del 25.8% di negativi del dataset originale. Con TOP-1 il solo candidato valutato è la moda, che cade sempre su uno dei quattro picchi  $\{0, 64, 128, 192\}$  (Capitolo 7): dei quattro, il solo  $y = 0$  fallisce, e la frazione negativa attesa è quindi dell’ordine di un quarto. È esattamente quanto si osserva. Le due regole non differiscono per una sfumatura di severità: l’una produce una classe negativa di un quarto del dataset, l’altra non può produrne più dell’uno per cento.

**Conclusione sul perimetro di validità.** Ne discende l’enunciato più preciso che questi dati consentono, e non è quello che ci si aspetterebbe. Il problema di classificazione su cui la prima fase della tesi ha investito non manca di istanze negative perché il rumore sia troppo blando: *non ne ha per costruzione*, perché la domanda “esiste un candidato utile fra i sedici più frequenti?” ha risposta affermativa quasi sempre, indipendentemente da quanto il segnale sia degradato. La regola dichiarata

è quasi vacua, quella effettivamente applicata chiedeva invece qualcosa di banale e già coperto dalla ricerca multi-candidato. In nessuna delle due formulazioni esiste un problema di classificazione sensato da porre a valle dell'esecuzione — ed è questa, in ultima analisi, la ragione per cui la seconda fase del lavoro sposta l'apprendimento sulla sindrome, dove le due classi sono definite dalla fisica del codice e non da una convenzione di post-processing.

È il risultato negativo nella sua forma più netta, e delimita con precisione il regime in cui vale: non “l'apprendimento automatico non serve alla mitigazione degli errori quantistici”, bensì *un filtro applicato a valle di un output già ricco di struttura ridondante non ha nulla da apprendere che la struttura non fornisca già gratuitamente*. È esattamente questa constatazione a motivare lo spostamento della seconda fase del lavoro sulla sindrome, dove l'informazione è disponibile *durante* il calcolo e non dopo (Capitoli 8–10, e in particolare la decodifica appresa della Sezione 9.6).

# Appendice E

## Fase 2: la Campagna QEC nel Dettaglio

### E.1 La Decodifica Appresa: la Campagna Completa

La sezione precedente ha mostrato che il modello di rumore usato per *simulare* il codice è un'idealizzazione. Esiste però una seconda idealizzazione, indipendente dalla prima e altrettanto conseguente, che riguarda il modello di rumore usato per *decodificare*. Il MWPM non è un algoritmo generico: presuppone che gli errori si organizzino in un grafo, ossia che ogni meccanismo d'errore accenda al più due detection events e sia quindi rappresentabile come un arco. È questa proprietà — la **decomponibilità in archi** — a rendere il problema della decodifica un accoppiamento di peso minimo, ed è ciò che la libreria richiede esplicitamente quando si costruisce il modello d'errore con `decompose_errors=True`. Un errore correlato che colpisca simultaneamente due qubit dati adiacenti accende invece fino a quattro detector e non ammette alcun arco che lo rappresenti: non viola l'ipotesi di Pauli, che resta soddisfatta, ma viola quella di decomponibilità. Le due idealizzazioni sono distinte e vanno tenute separate.

Questa distinzione individua con precisione la domanda a cui la presente sezione risponde: *esiste un regime in cui un decoder **appreso dai dati** — che non assume alcun modello, ma lo ricava dai campioni — fa meglio del decoder analitico?* La domanda chiude anche il cerchio metodologico dell'intera tesi. Il Capitolo 7 ha stabilito che l'apprendimento automatico applicato *a valle* dell'esecuzione non aggiunge nulla; qui lo stesso strumento — un percettrone multistrato di `scikit-learn`, la medesima tecnologia del classificatore giudicato superfluo — viene applicato alla **sindrome**, cioè in un punto della pipeline in cui l'informazione strutturale non è ancora stata

distrutta. Cambia il punto di applicazione, non la tecnologia: è esattamente il confronto che permette di attribuire l'esito al *dove*, e non al *come*.

### E.1.1 Disegno sperimentale

Il dato di addestramento non richiede alcuna infrastruttura aggiuntiva: è già ciò che Stim produce per stimare  $p_L$ . Il campionatore restituisce la matrice dei detection events e il corrispondente esito dell'osservabile logico, che sono rispettivamente le variabili indipendenti e l'etichetta del problema di apprendimento supervisionato:

```
det, obs = sampler.sample(shots, separate_observables=True)
# X = det (detection events) -> sindrome misurata
# y = obs (logical observable) -> flip logico da predire
```

Listing E.1: Il dataset del decoder appreso coincide con l'output del campionatore di Stim: `det` è la sindrome osservata, `obs` l'esito logico da predire. Il decoder analitico e quello appreso ricevono quindi esattamente la stessa informazione.

Il modello è un MLP con due strati nascosti (128, 64), attivazione ReLU, ottimizzatore Adam e arresto anticipato su una frazione di validazione interna; il decoder di riferimento è PyMatching sullo stesso insieme di test. Tutte le stime adottano il codice ruotato in base  $Z$  con  $\text{rounds} = d$  e rumore *circuit-level*, come nella campagna della Sezione 9.4. La Tabella E.1 riassume i quattro esperimenti.

|     | Domanda                                    | Condizione                      | Campioni                  |
|-----|--------------------------------------------|---------------------------------|---------------------------|
| E1  | la rete sostituisce il matching?           | rumore nominale, modello esatto | $4 \times 10^5$ per punto |
| E1b | quanto costa in dati il pareggio?          | $d = 3, p = 3 \times 10^{-3}$   | fino a $8 \times 10^5$    |
| E2  | e se il rumore esce dal modello?           | crosstalk correlato             | $4 \times 10^5$ per punto |
| E4  | e se la si affianca invece di sostituirla? | crosstalk correlato             | $8 \times 10^5$ per punto |

Tabella E.1: I quattro esperimenti sulla decodifica appresa. E3, discusso nella Sezione E.1.4, riusa la configurazione di E2 senza nuovi campionamenti.

### E.1.2 E1 — la sostituzione a parità di modello

Il primo esperimento pone il confronto nelle condizioni più favorevoli al decoder analitico: rumore uniforme e modello d'errore esatto, cioè esattamente ciò per cui il MWPM è costruito. Su quattordici configurazioni ( $d = 3, 5$ ; sette valori di  $p$ ) la rete **non supera mai** il matching con significatività statistica. A distanza 3 lo affianca, con un rapporto  $p_L^{\text{MWPM}}/p_L^{\text{rete}}$  che sale da 0.83 a  $p = 2 \times 10^{-3}$  fino a 1.01 a  $p = 10^{-2}$ ; a distanza 5 resta indietro di un ordine di grandezza (da 0.05 a 0.29).



L'andamento monotono suggerisce la spiegazione, che il pannello (b) della Figura E.1 verifica direttamente: la rete è limitata dal **volume di dati**, non dalla capacità del modello. Fissando  $d = 3$  e  $p = 3 \times 10^{-3}$  e facendo variare il solo insieme di addestramento, il rapporto cresce in modo regolare da 0.50 ( $2.5 \times 10^4$  campioni) a 1.02 ( $8 \times 10^5$  campioni). L'ultimo punto misura  $p_L = 3.98 \times 10^{-3}$  contro  $4.04 \times 10^{-3}$  del matching: un sorpasso nominale che, su un insieme di test di  $10^5$  campioni, vale 0.2 deviazioni standard e **non è statisticamente significativo**. Il risultato di E1 è dunque un pareggio, e il suo contenuto informativo è il prezzo di quel pareggio: dell'ordine di  $10^5$ – $10^6$  campioni a distanza 3, con un fabbisogno che cresce rapidamente con  $d$  — coerente con il fatto che i decoder neurali allo stato dell'arte ricorrono ad architetture ricorrenti e a volumi di dati di diversi ordini di grandezza superiori [22, 41].




Figura E.1: (a) Errore logico del decoder appreso e del MWPM in funzione dell'errore fisico, per  $d = 3$  e  $d = 5$ , con modello d'errore esatto fornito al matching. La rete affianca il matching a distanza 3 e resta al di sopra a distanza 5. (b) Errore logico della rete al crescere dell'insieme di addestramento ( $d = 3$ ,  $p = 3 \times 10^{-3}$ ): l'avvicinamento al matching è monotono e il pareggio si raggiunge fra  $3 \times 10^5$  e  $8 \times 10^5$  campioni. Rigenerabile da `figure_src/gen_qec_neural.py`.

### E.1.3 E2 — quando il rumore esce dal modello del decoder

Il secondo esperimento rimuove l'ipotesi di decomponibilità. Al circuito viene aggiunto un canale correlato a due qubit fra i **qubit dati fisicamente adiacenti** sulla griglia, una volta per ciclo di sindrome e con intensità  $p_{ct}$ : è il modello elementare del **crosstalk**, la quarta fonte fisica di rumore discussa nel Capitolo 4, che l'accoppiamento capacitivo residuo produce fra qubit vicini. L'errore fisico resta fissato a

$p = 3 \times 10^{-3}$ , sotto la soglia misurata nella Sezione 9.4. Si confrontano tre bracci: il matching con il modello *nominale* (rumore uniforme — ciò che la calibrazione del dispositivo dichiara), il matching con il modello del circuito *reale* (che include il crosstalk), e la rete addestrata sui campioni effettivamente osservati.

Il crosstalk degrada la decodifica in modo severo: a  $p_{ct} = 5 \times 10^{-3}$  l'errore logico a  $d = 3$  passa da  $3.8 \times 10^{-3}$  a  $3.1 \times 10^{-2}$ , quasi un ordine di grandezza, pur restando l'errore fisico invariato. In questo regime la rete supera il matching su tutte e quattro le intensità testate a distanza 3, con guadagni fra 1.14 e 1.19 (Tabella E.2). A distanza 5 il vantaggio non si manifesta: la rete perde, per la stessa ragione di E1 — lo spazio delle sindromi cresce più rapidamente della sua capacità di generalizzazione.

| $d$ | $p_{ct}$           | nessuna corr. | MWPM nominale  | MWPM reale     | rete           |
|-----|--------------------|---------------|----------------|----------------|----------------|
| 3   | $5 \times 10^{-3}$ | 0.0845        | 0.03097        | 0.05656        | <b>0.02707</b> |
|     | $1 \times 10^{-2}$ | 0.1163        | 0.05966        | 0.08975        | <b>0.05012</b> |
|     | $2 \times 10^{-2}$ | 0.1746        | 0.11184        | 0.15107        | <b>0.09547</b> |
|     | $4 \times 10^{-2}$ | 0.2652        | 0.20806        | 0.25481        | <b>0.17568</b> |
| 5   | $5 \times 10^{-3}$ | 0.2007        | <b>0.03521</b> | 0.02796        | 0.08266        |
|     | $1 \times 10^{-2}$ | 0.2648        | 0.08655        | <b>0.06526</b> | 0.13957        |
|     | $2 \times 10^{-2}$ | 0.3565        | 0.19933        | <b>0.15662</b> | 0.28906        |
|     | $4 \times 10^{-2}$ | 0.4459        | 0.37458        | <b>0.32515</b> | 0.44634        |

Tabella E.2: Errore logico  $p_L$  in presenza di crosstalk fra qubit dati adiacenti, a errore fisico costante  $p = 3 \times 10^{-3}$ . “Nessuna correzione” è la frequenza con cui l’osservabile logico risulta alterato in assenza di decodifica. A distanza 3 la rete domina entrambe le varianti del matching; a distanza 5 il quadro si inverte.

**Un’osservazione inattesa: conoscere il rumore non basta.** Il braccio con il modello d’errore *reale* — quello che conosce il crosstalk — si comporta in modo opposto alle due distanze, ed è il risultato più istruttivo dell’esperimento. A  $d = 3$  è il **peggiore** dei tre ( $5.7 \times 10^{-2}$  contro  $3.1 \times 10^{-2}$  del modello nominale a  $p_{ct} = 5 \times 10^{-3}$ ): fornire al matching l’informazione corretta lo peggiora. La ragione è strutturale e non contraddittoria. Poiché l’errore correlato non è rappresentabile come arco, la libreria è costretta a scomporlo in archi equivalenti, e su un grafo piccolo come quello di distanza 3 gli archi spurî introdotti dalla scomposizione sviano l’accoppiamento più di quanto l’informazione aggiuntiva lo guidi. A  $d = 5$ , dove il grafo è più ricco e la scomposizione pesa relativamente meno, il bilancio si inverte e il modello reale torna a essere il migliore.

Ne discende un enunciato che vale la pena isolare, perché delimita esattamente ciò che un decoder analitico può e non può fare: *quando la classe di errori non è esprimibile nella struttura del decoder, il limite non è la calibrazione ma la struttura stessa* — e migliorare la stima del rumore può non produrre alcun beneficio, o risultare controproducente.




Figura E.2: Errore logico in funzione dell'intensità del crosstalk, a errore fisico costante  $p = 3 \times 10^{-3}$ . A distanza 3 la rete (rosso) domina il matching sia con modello nominale (blu) sia con modello reale (arancio), che risulta il peggiore; a distanza 5 l'ordine si inverte. La linea tratteggiata inferiore indica l'errore logico del matching in assenza di crosstalk, cioè il livello che la decodifica raggiungerebbe se il modello fosse corretto.

#### E.1.4 E3 — la rete come validatore della correzione

I due esperimenti precedenti valutano la rete come *sostituto* del decoder. Una domanda diversa, e operativamente più modesta, è se la rete sappia riconoscere gli shot in cui il matching ha sbagliato — cioè se possa **confermare o negare** la correzione proposta, senza doverla rimpiazzare. Si definisce allora la confidenza che la rete assegna alla risposta effettivamente data dal matching, e si verifica quanto una confidenza bassa predica un fallimento reale.

Nella configurazione  $d = 3$ ,  $p_{ct} = 10^{-2}$ , in cui il matching sbaglia 5 966 shot su  $10^5$ , il flag così costruito discrimina i fallimenti con  $AUC = 0.941$ . La Tabella E.3 ne riporta il compromesso: abbassando la soglia si segnalano meno shot con precisione crescente, fino a individuare l'85.9% di errori veri segnalando appena lo 0.59% delle esecuzioni.

| Soglia di confidenza | Shot segnalati | Precision    | Recall |
|----------------------|----------------|--------------|--------|
| 0.5                  | 2.92%          | 0.664        | 0.324  |
| 0.3                  | 1.54%          | 0.783        | 0.202  |
| 0.2                  | 1.16%          | 0.825        | 0.160  |
| 0.1                  | 0.59%          | <b>0.859</b> | 0.085  |

Tabella E.3: Capacità della rete di segnalare gli shot in cui il MWPM ha sbagliato ( $d = 3$ ,  $p_{ct} = 10^{-2}$ ,  $AUC = 0.941$ ). La precisione cresce al restringersi della segnalazione: segnalando lo 0.59% degli shot, l'85.9% delle segnalazioni corrisponde a un fallimento reale.




Figura E.3: Precision e recall del flag in funzione della soglia di confidenza, con la frazione di shot segnalati (barre, asse destro). Il flag non sostituisce la decodifica: la annota.

### E.1.5 E4 — il decoder ibrido

L'esito di E3 suggerisce la costruzione che chiude la sezione. Se la rete riconosce i fallimenti del matching senza saper decodificare meglio di esso, allora il suo impiego corretto non è sostituirlo ma **correggerlo**. Si definisce quindi un decoder **ibrido** in forma residuale:

$$\hat{y}_{\text{ibrido}} = \hat{y}_{\text{MWPM}} \oplus \left[ \Pr(\text{MWPM sbaglia} \mid \text{sindrome}) \geq \tau \right], \quad (\text{E.1})$$

dove  $\oplus$  è la somma modulo 2 e la rete riceve in ingresso la sindrome e la decisione del matching. La soglia di ribaltamento  $\tau$  è scelta su un insieme di **validazione separato** e poi applicata invariata all'insieme di test: sceglierla sul test costituirebbe una fuga di informazione, e su guadagni dell'ordine di pochi punti percentuali sarebbe un vizio sufficiente a invalidare il risultato. Fra le soglie candidate figura il valore che non ribalta mai, cosicché il criterio di validazione può sempre ricadere sul matching puro quando nessun ribaltamento conviene.

La formulazione ha una motivazione precisa, oltre alla convenienza pratica: alla rete non si chiede più di riprodurre da zero il calcolo di parità che il matching già esegue correttamente nella grande maggioranza dei casi, ma soltanto di modellarne il *residuo*, che è un evento raro e strutturato. È un compito più facile, ed è per questo che riesce dove la sostituzione fallisce.

| $d$ | $p_{ct}$           | MWPM    | rete sola | ibrido         | ribalta | McNemar              |
|-----|--------------------|---------|-----------|----------------|---------|----------------------|
| 3   | 0                  | 0.00415 | 0.00409   | 0.00417        | 0.10%   | $p = 0.67$           |
|     | $5 \times 10^{-3}$ | 0.03089 | 0.02680   | <b>0.02607</b> | 1.19%   | $3 \times 10^{-87}$  |
|     | $1 \times 10^{-2}$ | 0.05829 | 0.04917   | <b>0.04851</b> | 2.69%   | $1 \times 10^{-156}$ |
|     | $2 \times 10^{-2}$ | 0.11144 | 0.09248   | <b>0.09183</b> | 5.38%   | $2 \times 10^{-312}$ |
|     | $4 \times 10^{-2}$ | 0.20750 | 0.17615   | <b>0.17455</b> | 11.04%  | $< 10^{-320}$        |
| 5   | 0                  | 0.00165 | 0.01900   | 0.00165        | 0.00%   | —                    |
|     | $5 \times 10^{-3}$ | 0.03561 | 0.06311   | <b>0.03521</b> | 0.32%   | $1 \times 10^{-3}$   |
|     | $1 \times 10^{-2}$ | 0.08704 | 0.12874   | <b>0.08428</b> | 1.17%   | $3 \times 10^{-30}$  |
|     | $2 \times 10^{-2}$ | 0.20231 | 0.25198   | <b>0.19662</b> | 2.88%   | $6 \times 10^{-51}$  |
|     | $4 \times 10^{-2}$ | 0.37581 | 0.44182   | <b>0.37385</b> | 2.96%   | $4 \times 10^{-7}$   |
| 7   | 0                  | 0.00055 | 0.06888   | 0.00055        | 0.00%   | —                    |
|     | $5 \times 10^{-3}$ | 0.03707 | 0.24671   | 0.03707        | 0.00%   | —                    |
|     | $1 \times 10^{-2}$ | 0.11319 | 0.36749   | 0.11318        | 0.00%   | $p = 0.32$           |
|     | $2 \times 10^{-2}$ | 0.29048 | 0.46219   | 0.29048        | 0.00%   | —                    |
|     | $4 \times 10^{-2}$ | 0.46741 | 0.49980   | 0.46741        | 0.00%   | —                    |

Tabella E.4: Errore logico del decoder ibrido (E.1) confrontato con il MWPM e con la rete usata come sostituto. “Ribalta” è la frazione di shot in cui la rete inverte la decisione del matching. Il valore di significatività è quello del test di McNemar, appaiato sugli stessi campioni: poiché i due decoder differiscono *soltanto* sugli shot ribaltati, le coppie discordanti coincidono con essi e il test è esatto.

L’ibrido riduce l’errore logico in tutte e otto le configurazioni con crosstalk a distanza 3 e 5, con guadagni del 18–21% nel primo caso e dell’1–3% nel secondo, tutti significativi al test di McNemar. Il dettaglio delle coppie discordanti rende l’effetto leggibile: a  $d = 3$  e  $p_{ct} = 4 \times 10^{-2}$  la rete rompe 7745 shot che il matching

aveva risolto correttamente e ne aggiusta 14335, un rapporto di quasi due a uno; a  $d = 5$  il bilancio si stringe (2769 contro 3160), da cui il guadagno più contenuto ma comunque netto.

Due proprietà meritano attenzione perché riguardano il comportamento del sistema fuori dal regime per cui è stato addestrato. La prima è che la frazione di ribaltamenti **scala con l'intensità del crosstalk** (dallo 0.10% all'11.04% a distanza 3): la rete non interviene a caso, ma in misura proporzionale a quanto il modello del matching è sbagliato. La seconda è il comportamento in assenza di crosstalk, dove il matching è già adeguato e non c'è nulla da correggere: a  $d = 5$  la rete effettua **zero ribaltamenti** e l'ibrido coincide cifra per cifra con il MWPM, mentre a  $d = 3$  ribalta lo 0.10% degli shot con effetto statisticamente nullo ( $p = 0.67$ ). Il decoder ibrido *degrada con grazia*: riconosce di non avere nulla da aggiungere e si fa da parte. Va detto con esattezza che questa garanzia riguarda il criterio di validazione e non ogni singolo punto dell'insieme di test — il valore leggermente superiore a  $d = 3$ ,  $p_{ct} = 0$  ne è un esempio, entro il rumore statistico — sicché la formulazione corretta è che l'ibrido non risulta *mai peggiore del matching in modo statisticamente rilevabile*.




Figura E.4: Errore logico dei tre decoder in funzione dell'intensità del crosstalk. L'ibrido (rosso) è il migliore a entrambe le distanze; la rete usata come sostituto (arancio) domina il matching a  $d = 3$  ma lo perde a  $d = 5$ , dove l'ibrido continua invece a guadagnare.

**Il limite: il vantaggio non sopravvive alla distanza 7.** Il dato più importante della Tabella E.4 è però l'ultimo blocco, e va enunciato senza attenuazioni. A distanza 7 l'ibrido **non ribalta alcuno shot** in nessuna delle cinque configurazioni: la soglia scelta in validazione è ogni volta quella corrispondente a “non ribaltare mai”, e il decoder ibrido coincide con il MWPM cifra per cifra. Il guadagno svanisce, e la

progressione lungo le tre distanze è inequivocabile: 18–21% a  $d = 3$ , 1–3% a  $d = 5$ , esattamente zero a  $d = 7$ .

Due meccanismi possono spiegarlo, e vanno separati perché conducono a rimedi diversi. Il primo è la **scarsità di esempi**: l’evento da riconoscere è il fallimento del matching, la cui frequenza è  $p_L$ , e  $p_L$  decresce esponenzialmente con  $d$ . In assenza di crosstalk, a  $d = 7$  si hanno  $p_L = 5.5 \times 10^{-4}$  e  $8 \times 10^5$  shot, ossia 264 esempi positivi nella partizione di addestramento, per un ingresso a 336 dimensioni. Il secondo è la **capacità rappresentativa**: la rete densa impiegata tratta i detector come dimensioni indipendenti, e ciò che distingue le due classi di errore su un reticolo grande è una correlazione a lungo raggio fra detector distanti.

Un primo indizio viene dal semplice conteggio. La spiegazione per scarsità è esatta nella configurazione senza crosstalk, dove i fallimenti del matching sono effettivamente poche centinaia; ma nelle altre quattro configurazioni a  $d = 7$  la rete dispone da  $1.8 \times 10^4$  a  $2.2 \times 10^5$  esempi positivi — fino a duecentomila — e continua a non ribaltare alcuno shot. La spiegazione copre dunque una configurazione su cinque.

L’indizio non basta però a stabilire la causa, perché fra  $d = 5$  (che funziona) e  $d = 7$  (che non funziona) cambiano *due* cose insieme: la distanza del codice e il numero di detector. L’esperimento E9 le separa, sfruttando il fatto che il numero di detector è il prodotto fra gli stabilizzatori per ciclo e il numero di cicli, e può quindi essere variato a distanza fissa. Ne risulta un incrocio  $2 \times 2$  le cui celle diagonali distinguono le due ipotesi, riportato nella Tabella E.5.

| $d$ | cicli | detector   | $p_{ct} = 0.005$ |                   | $p_{ct} = 0.02$ |                   |
|-----|-------|------------|------------------|-------------------|-----------------|-------------------|
|     |       |            | es. pos.         | residuo           | es. pos.        | residuo           |
| 7   | 3     | <b>144</b> | 5 933            | si astiene        | 61 900          | <b>interviene</b> |
| 7   | 7     | 336        | 17 665           | si astiene        | 139 275         | si astiene        |
| 5   | 14    | 336        | 48 657           | si astiene        | 188 582         | si astiene        |
| 5   | 5     | <b>120</b> | 17 235           | <b>interviene</b> | 96 167          | <b>interviene</b> |

Tabella E.5: Esperimento E9: incrocio fra distanza del codice e numero di detector, ottenuto variando il numero di cicli di estrazione della sindrome. “Es. pos.” è il numero di fallimenti del MWPM disponibili all’addestramento su  $4.8 \times 10^5$  shot; “residuo” indica se il criterio di validazione seleziona una soglia che ribalta almeno uno shot su diecimila. Le righe centrali sono le celle diagonali, quelle che distinguono le ipotesi: a distanza 5 con 336 detector e  $1.9 \times 10^5$  esempi il residuo si astiene, a distanza 7 con 144 detector e tre volte meno esempi interviene. Il comportamento segue la colonna, non la riga.

L’esito è netto su entrambe le diagonali e va letto per colonne. A 336 detector il

residuo si astiene sempre, a qualunque distanza e con qualunque numerosità — fino a  $1.9 \times 10^5$  esempi positivi; a 120 e 144 detector interviene, anche a distanza 7 e anche con tre volte meno esempi. **L’ipotesi della distanza è confutata, quella della larghezza dell’ingresso è confermata.**

Una sfumatura completa l’enunciato e lo rende più preciso. A 144 detector con soli 5 933 esempi positivi il residuo si astiene: la numerosità è dunque un vincolo reale, al margine inferiore. Non è però il vincolo che opera nell’esperimento E4 a distanza 7, dove gli esempi erano  $1.4 \times 10^5$  e la rete si asteneva comunque. La formulazione corretta è che disporre di abbastanza esempi è *necessario ma non sufficiente*, e che a parità di numerosità sufficiente è la larghezza dell’ingresso a decidere.

**Che cosa significhi esattamente “si astiene” (E12).** Il verbo va però disinnescato, perché astenersi è l’esito di una *selezione*: fra le soglie candidate figura quella corrispondente a “non ribaltare mai”, e che vinca in validazione significa che agire non conviene, non che non vi sia nulla da vedere. La distinzione non è oziosa, perché le due letture conducono a rimedi opposti — un’architettura diversa nella prima, una regola di decisione diversa nella seconda. L’esperimento E12 la risolve misurando l’AUC del residuo, che quantifica quanto la rete *ordini* i fallimenti del matching indipendentemente da qualunque soglia, e affiancando alla soglia scelta onestamente in validazione una soglia *oracolo*, la migliore sul test set stesso: inutilizzabile in pratica, ma limite superiore assoluto di ciò che qualunque regola di decisione potrebbe ottenere.

| detector | <i>d</i> | cicli | AUC   | guadagno onesto | guadagno oracolo |
|----------|----------|-------|-------|-----------------|------------------|
| 24       | 3        | 3     | 0.912 | 1.2215          | 1.2233           |
| 120      | 5        | 5     | 0.769 | 1.0206          | 1.0215           |
| 144      | 7        | 3     | 0.788 | 1.0066          | 1.0066           |
| 336      | 7        | 7     | 0.621 | 1.0000          | 1.0000           |
| 336      | 5        | 14    | 0.573 | 1.0000          | 1.0003           |

Tabella E.6: Esperimento E12 a  $p_{ct} = 2 \times 10^{-2}$ . L’AUC è calcolata sul test set con bersaglio “il MWPM ha sbagliato”. Il guadagno oracolo usa la soglia migliore sul test set stesso e non è quindi realizzabile: serve unicamente a stabilire quanto del divario sia imputabile alla calibrazione. Ai livelli di crosstalk più bassi il quadro è il medesimo, con AUC sistematicamente più alte (0.958 a 24 detector, 0.771 a 336).

Il risultato smentisce entrambe le letture immediate. **La rete non è cieca:** a 336 detector l’AUC vale 0.57–0.77, ben sopra il caso, e la rete ordina dunque i fallimenti del matching assai meglio del lancio di una moneta. **Ma non si tratta neppure di**



**calibrazione:** il guadagno oracolo è 1.0000, sicché nemmeno scegliendo la soglia sui dati di valutazione si otterrebbe alcunché.

La spiegazione sta nella forma stessa della correzione residuale, ed è quantitativa. Il ribaltamento è *simmetrico*: ribaltare uno shot che il matching aveva risolto costa esattamente quanto ribaltarne uno che aveva sbagliato rende. Perché l'operazione sia in attivo occorre dunque che fra gli shot ribaltati la **precisione superi il cinquanta per cento** — una soglia netta, non un ottimo graduale. L'AUC necessaria a raggiungerla dipende dal tasso di base: a 24 detector e crosstalk  $5 \times 10^{-3}$  il tasso di base è del 3.1% e un'AUC di 0.958 concentra i fallimenti abbastanza da superare la soglia, con un guadagno del 19%; a 336 detector, a parità di tasso di base, un'AUC di 0.771 richiederebbe un fattore di concentrazione quattordici volte superiore a quello che produce. Nessuna soglia porta la precisione sopra il cinquanta per cento, e il guadagno è allora *esattamente* 1.000 — non approssimativamente: è questa discontinuità a spiegare il salto brusco osservato lungo la Tabella E.5.

Ne discendono due conseguenze. La prima è che **l'astensione del criterio di validazione è corretta e non conservativa**: la soglia oracolo conferma che intervenire non converrebbe, e il metodo si comporta esattamente come dichiarato al momento della sua costruzione. La seconda riguarda il rimedio, e ne precisa il criterio di successo: un'architettura convoluzionale o a grafo è utile se e soltanto se innalza l'AUC quanto basta a riportare la precisione sopra la soglia del cinquanta per cento, che è una condizione verificabile in anticipo su una rete addestrata — assai più informativa dell'osservazione che il modello “non regge”.

Questa è la delimitazione del risultato di M10, e conviene formularla in positivo. Il guadagno del decoder ibrido è reale e statisticamente schiacciante — a  $d = 3$  il test di McNemar dà  $p < 10^{-320}$  — ma vive nel regime in cui la sindrome è stretta abbastanza da lasciare alla rete densa una discriminazione sufficiente a superare la soglia di precisione. Poiché è proprio la crescita della distanza a costituire la strategia della correzione d'errore scalabile, il metodo così com'è non accompagna il codice nel regime che conta. Il rimedio indicato dalla diagnosi non è raccogliere più campioni — ne bastavano già — ma innalzare la discriminazione a parità di larghezza dell'ingresso, il che significa cambiare architettura: una rete convoluzionale o a grafo, che condivida i pesi fra regioni equivalenti del reticolo anziché trattare i 336 detector come dimensioni indipendenti, sfrutta la simmetria traslazionale del problema e rappresenta con pochi parametri le correlazioni locali che la rete densa deve stimare una per una. È l'estensione naturale, e la si indica fra gli sviluppi futuri (Capitolo 11).

### E.1.6 E6 — e se il modello del decoder fosse semplicemente sbagliato?

Gli esperimenti fin qui condotti concedono al MWPM un vantaggio che l'hardware non offre: il detector error model che ne pesa gli archi è generato da Stim *dal circuito stesso*, ed è quindi una descrizione esatta del rumore. Un decoder in produzione lavora invece su un modello ricavato dalla calibrazione del dispositivo — misurata a intervalli, soggetta a deriva, inevitabilmente diversa dal rumore del momento. Se il vantaggio del modello appreso nascesse da questa discrepanza, sarebbe un vantaggio molto più generale di quello osservato con il crosstalk, perché la mis-calibrazione è la condizione ordinaria di ogni QPU.

L'esperimento la isola: il circuito viene campionato con il rumore reale, mentre il matching è costruito su un modello in cui l'errore di *misura* è sbagliato di un fattore  $(1 + \delta)$  e quello di gate resta corretto.

**Perché la perturbazione dev'essere sbilanciata.** Un primo tentativo scalava tutte le probabilità di errore dello stesso fattore, e non produceva alcun effetto misurabile: il costo rilevato era 1.000, 1.004 e 1.000 per  $\delta$  pari a 0, +100% e -50%. La ragione è istruttiva e merita di essere esplicitata, perché delimita ciò che una calibrazione errata può e non può fare. Il MWPM minimizza il peso totale del matching, e il peso di un arco vale  $\log \frac{1-p_e}{p_e} \approx -\log p_e$  per  $p_e$  piccolo: moltiplicare tutte le  $p_e$  per una costante trasla *tutti* i pesi della stessa quantità, e un matching di peso minimo è invariante rispetto a una traslazione uniforme. Ciò che rende il matching vulnerabile non è dunque sbagliare la *scala* del rumore, ma il suo *bilanciamento*: il rapporto fra archi temporali, che rappresentano errori di misura, e archi spaziali, che rappresentano errori sui dati. È questo rapporto che l'esperimento perturba.

| $d$ | $\delta$ | MWPM esatto | MWPM sbagliato | costo        | rete    | rete/MWPM |
|-----|----------|-------------|----------------|--------------|---------|-----------|
| 3   | -80%     | 0.00407     | 0.00415        | 1.018        | 0.00525 | 0.79      |
|     | -50%     | 0.00435     | 0.00435        | 1.000        | 0.00493 | 0.88      |
|     | 0        | 0.00427     | 0.00427        | 1.000        | 0.00558 | 0.77      |
|     | +100%    | 0.00387     | 0.00382        | 0.987        | 0.00443 | 0.86      |
|     | +300%    | 0.00388     | 0.00362        | 0.931        | 0.00429 | 0.84      |
|     | +900%    | 0.00385     | 0.00392        | 1.017        | 0.00463 | 0.85      |
| 5   | -80%     | 0.00147     | 0.00153        | 1.034        | 0.02982 | 0.05      |
|     | -50%     | 0.00172     | 0.00173        | 1.010        | 0.02855 | 0.06      |
|     | 0        | 0.00163     | 0.00163        | 1.000        | 0.02784 | 0.06      |
|     | +100%    | 0.00174     | 0.00175        | 1.005        | 0.02774 | 0.06      |
|     | +300%    | 0.00169     | 0.00167        | 0.985        | 0.02888 | 0.06      |
|     | +900%    | 0.00159     | 0.00191        | <b>1.199</b> | 0.03052 | 0.06      |

Tabella E.7: Errore logico del MWPM quando il modello che ne pesa gli archi attribuisce all’errore di misura il valore  $p(1 + \delta)$  anziché quello vero. La colonna “costo” è il rapporto fra l’errore logico con modello sbagliato e quello con modello esatto; “rete/MWPM” confronta il decoder appreso con il matching mis-calibrato — valori inferiori a 1 indicano che la rete è peggiore. Errore fisico reale  $p = 3 \times 10^{-3}$ ,  $4 \times 10^5$  campioni per configurazione.

L’esito è netto in entrambe le direzioni. Il MWPM si rivela **notevolmente robusto**: sbagliando l’errore di misura di un fattore cinque in difetto o dieci in eccesso, l’errore logico cambia tipicamente dell’1-3%, e in due configurazioni *migliora* leggermente. L’unico caso in cui la mis-calibrazione morde davvero è  $d = 5$  con  $\delta = +900\%$ , dove il costo sale al 20%: sovrastimare di un ordine di grandezza l’errore di misura induce il matching a preferire spiegazioni temporali degli eventi rilevati anche quando la spiegazione corretta è spaziale. Ma occorre appunto un errore di calibrazione di un ordine di grandezza perché l’effetto sia visibile.

La rete, dal canto suo, **non batte il matching in nessuna delle dodici configurazioni**, neppure quelle in cui esso lavora sul modello sbagliato. A  $d = 3$  resta indietro del 15-25%; a  $d = 5$  è peggiore di un fattore venti, in coerenza con il crollo osservato nell’esperimento precedente.

**Che cosa questo precisa del criterio.** Il risultato è negativo, ma corregge un’imprecisione nel modo in cui il criterio della tesi era stato finora formulato. Si era detto che il modello appreso produce valore dove il metodo analitico è “cieco” rispetto a una parte dell’informazione; questo esperimento mostra che la cecità rilevante non è quella dei *parametri* ma quella della *struttura*. Un modello con i parametri sbagliati continua a rappresentare le stesse classi di errore, e il matching che ne

deriva resta quasi ottimale perché la geometria del problema — quali eventi rilevati siano plausibilmente connessi — non cambia. Un modello che non contempla affatto una classe di errore, come il crosstalk fra qubit di dato adiacenti dell'esperimento E2, sbaglia invece la geometria stessa, e lì il margine esiste. La formulazione corretta del criterio è dunque: *l'apprendimento paga quando la classe di errore non è rappresentabile nella struttura del decoder, non quando è rappresentata con parametri imprecisi.*

Ne discende anche un'indicazione pratica di segno opposto a quella che ci si potrebbe attendere: investire in una calibrazione più accurata del modello di rumore, entro un ordine di grandezza, non produce guadagni apprezzabili sulla decodifica. È un'osservazione che vale la pena tenere presente perché la calibrazione periodica è un costo operativo reale nei dispositivi attuali.

### E.1.7 E7 — e se si scegliesse semplicemente un decoder analitico migliore?

Resta l'obiezione più severa che si possa muovere a tutto l'impianto della sezione. Il MWPM è lo standard di fatto, ma non è il miglior decoder analitico disponibile: esso richiede che ogni meccanismo di errore sia decomponibile in archi di un grafo, e il crosstalk fra qubit di dato adiacenti viola precisamente questa ipotesi. Un decoder che non la richieda — **BP+OSD**, ossia *belief propagation* seguita da *ordered statistics decoding*, che opera direttamente sulla matrice di parità del detector error model [61, 62] — potrebbe catturare da solo il margine attribuito all'apprendimento. Se così fosse, il risultato di E4 non misurerebbe il valore di un modello appreso ma il costo di una scelta subottimale del decoder di riferimento.

Il confronto è condotto sugli stessi circuiti e con la stessa mis-informazione: entrambi i decoder analitici ricevono il DEM *nominale*, privo di crosstalk, che è quanto un decoder reale avrebbe a disposizione. La significatività è valutata con il test di McNemar, appaiato sugli stessi shot.

| $d$ | $p_{ct}$           | MWPM    | BP+OSD  | BP+OSD/MWPM  | ibrido/MWPM  | McNemar              |
|-----|--------------------|---------|---------|--------------|--------------|----------------------|
| 3   | 0                  | 0.00428 | 0.00374 | <b>1.146</b> | 0.993        | $1 \times 10^{-9}$   |
|     | $5 \times 10^{-3}$ | 0.03193 | 0.03286 | 0.972        | <b>1.185</b> | $3 \times 10^{-7}$   |
|     | $1 \times 10^{-2}$ | 0.05912 | 0.06034 | 0.980        | <b>1.202</b> | $5 \times 10^{-7}$   |
|     | $2 \times 10^{-2}$ | 0.11176 | 0.11340 | 0.986        | <b>1.213</b> | $2 \times 10^{-6}$   |
|     | $4 \times 10^{-2}$ | 0.20811 | 0.20826 | 0.999        | <b>1.189</b> | $p = 0.77$           |
| 5   | 0                  | 0.00192 | 0.00143 | <b>1.339</b> | 1.000        | $2 \times 10^{-7}$   |
|     | $5 \times 10^{-3}$ | 0.03565 | 0.02807 | <b>1.270</b> | 1.011        | $2 \times 10^{-113}$ |
|     | $1 \times 10^{-2}$ | 0.08638 | 0.07348 | <b>1.176</b> | 1.033        | $3 \times 10^{-140}$ |
|     | $2 \times 10^{-2}$ | 0.19998 | 0.18288 | <b>1.094</b> | 1.029        | $6 \times 10^{-108}$ |
|     | $4 \times 10^{-2}$ | 0.37561 | 0.36788 | <b>1.021</b> | 1.005        | $2 \times 10^{-12}$  |

Tabella E.8: Confronto fra il MWPM, il decoder BP+OSD e il decoder ibrido appreso, tutti sul medesimo modello di rumore nominale. Le due colonne di guadagno sono rapporti rispetto al MWPM: valori superiori a 1 indicano un errore logico minore. In grassetto, per ciascuna riga, il migliore fra i due approcci alternativi. Il valore di significatività si riferisce al confronto BP+OSD contro MWPM. Errore fisico  $p = 3 \times 10^{-3}$ ,  $2 \times 10^5$  campioni per configurazione.

Il primo dato da registrare è che **BP+OSD è effettivamente un decoder migliore**: sul rumore nominale, quello per cui il modello è corretto, riduce l'errore logico del 14.6% a distanza 3 e del 33.9% a distanza 5, con significatività schiacciante. Il vantaggio cresce con la distanza, come atteso: più il codice è grande, più numerose sono le configurazioni di errore degeneri che il matching, vincolato alla decomposizione in archi, non sa distinguere.

Il secondo dato è però quello che conta, ed è la struttura delle due colonne di guadagno letta lungo la colonna  $p_{ct}$ .

*Il guadagno di BP+OSD **decresce** al crescere del crosstalk; quello del decoder ibrido **cresce**.*




Figura E.5: Guadagno rispetto al MWPM dei due approcci alternativi, in funzione dell'intensità del crosstalk. La linea tratteggiata è il MWPM stesso. BP+OSD (blu) parte dal guadagno massimo, quando il modello di rumore che riceve è corretto, e lo perde man mano che il crosstalk lo rende incompleto; il decoder ibrido (rosso) parte da zero, perché a modello corretto non ha nulla da aggiungere, e guadagna in misura crescente. A distanza 3 le due curve si incrociano immediatamente; a distanza 5 il vantaggio iniziale di BP+OSD è così ampio da mantenerlo davanti anche eroso. Figura rigenerabile da `figure_src/gen_confronto_decoder.py`.

A distanza 5 il vantaggio di BP+OSD scende monotonamente da 1.339 a 1.021 mentre il crosstalk aumenta; a distanza 3 esso si annulla immediatamente, e il decoder diventa lievemente *peggiore* del matching. Specularmente, il guadagno dell'ibrido è nullo in assenza di crosstalk e sale fino a 1.213. I due metodi non competono sullo stesso asse: **BP+OSD sfrutta meglio il modello che riceve, il decoder appreso cattura ciò che al modello sfugge**. Il primo rende al massimo quando il modello è corretto e si degrada man mano che diventa incompleto — perché fidarsi più a fondo di una descrizione sbagliata è un danno, non un vantaggio; il secondo rende zero quando il modello è corretto, perché non c'è nulla da aggiungere, e cresce esattamente nella misura in cui il modello si allontana dal dispositivo.

Ne discende una conclusione più articolata di quella che l'esperimento si proponeva di verificare, e va enunciata riconoscendo entrambi i suoi lati. Da un lato l'obiezione è **in parte fondata**: a distanza 5, dove il vantaggio di partenza di BP+OSD è ampio, esso resta superiore all'ibrido in tutte le configurazioni, e adottare un decoder analitico migliore rende più che addestrare una rete. Chi disponga di un budget di ingegneria limitato dovrebbe spenderlo lì per primo, ed è una raccomandazione pratica che questa tesi non avrebbe potuto formulare senza l'esperimento. Dall'altro lato l'obiezione **non elimina il risultato**: a distanza 3 l'ibrido guadagna 18–21%

proprio dove BP+OSD perde.

Resta da chiarire che cosa significhi “agire su assi ortogonali”. L’inferenza immediata è che i due guadagni siano *sommabili*, e che costruire il residuo appreso sopra BP+OSD anziché sopra il matching debba produrre il prodotto dei due — ossia, a distanza 5 e crosstalk  $5 \times 10^{-3}$ , un guadagno di  $1.289 \times 1.010 = 1.302$ . È una previsione quantitativa, e l’esperimento successivo la mette alla prova anziché darla per buona.

### **E.1.8 E8 — le due sorgenti si sommano davvero? E10 — il pavimento comune**

**La previsione e il suo esito.** L’esperimento E8 sostituisce il decoder di base della (E.1): il residuo appreso viene costruito sopra BP+OSD anziché sopra il matching, e i quattro bracci — MWPM, BP+OSD, ciascuno con e senza residuo — sono misurati *sui medesimi campioni*, il che rende ogni confronto appaiato ed elimina il disallineamento fra le campagne precedenti. Le due ipotesi in gioco erano dichiarate prima dell’esecuzione: quella *moltiplicativa*, per cui il combinato approssima il prodotto; e quella di *saturazione*, per cui il residuo trova sopra BP+OSD assai meno di quanto trovasse sopra il matching, perché una parte di ciò che recuperava era semplicemente il costo di un decoder analitico subottimale. La seconda è l’ipotesi sfavorevole al risultato di questa sezione, ed è quella che i dati sostengono.

| $d$ | $p_{ct}$ | BP+OSD | MWPM+res | combinato | prodotto previsto |
|-----|----------|--------|----------|-----------|-------------------|
| 3   | 0        | 1.181  | 1.079    | 1.190     | 1.274             |
| 3   | 0.005    | 0.985  | 1.192    | 1.183     | 1.173             |
| 3   | 0.01     | 0.982  | 1.205    | 1.203     | 1.183             |
| 3   | 0.02     | 0.985  | 1.211    | 1.200     | 1.193             |
| 3   | 0.04     | 0.997  | 1.184    | 1.177     | 1.180             |
| 5   | 0        | 1.180  | 1.000    | 1.180     | 1.180             |
| 5   | 0.005    | 1.289  | 1.010    | 1.289     | 1.302             |
| 5   | 0.01     | 1.196  | 1.026    | 1.200     | 1.228             |
| 5   | 0.02     | 1.093  | 1.028    | 1.104     | 1.123             |
| 5   | 0.04     | 1.024  | 1.007    | 1.024     | 1.032             |

Tabella E.9: Esperimento E8. Tutti i guadagni sono rapporti  $p_L^{\text{MWPM}}/p_L^{\text{metodo}}$  misurati sui medesimi  $8 \times 10^5$  campioni per configurazione,  $2 \times 10^5$  dei quali di test. “Combinato” è il residuo appreso costruito sopra BP+OSD; “prodotto previsto” è il valore che l’ipotesi moltiplicativa richiede. Il combinato non lo raggiunge mai quando entrambi i componenti hanno un guadagno reale, e coincide invece con il migliore dei due singoli.

Il confronto decisivo è nelle righe in cui *entrambi* i componenti guadagnano. A distanza 3 ve n’è una sola, quella senza crosstalk: il prodotto richiede 1.274, il combinato si ferma a 1.190, ossia esattamente il guadagno di BP+OSD da solo — e il residuo, sopra BP+OSD e senza crosstalk, ribalta lo 0.04% delle predizioni con  $p = 0.58$ , cioè non trova nulla. Nelle altre righe di quel blocco il “prodotto” è soddisfatto soltanto perché degenerare: con BP+OSD a 0.98 esso coincide per costruzione con il guadagno del residuo. A distanza 5, dove BP+OSD conserva un vantaggio ampio anche sotto crosstalk, tutte e cinque le righe sono informative e tutte e cinque smentiscono la previsione: lo scarto dal prodotto è negativo ovunque, da  $-0.007$  a  $-0.027$ , e il residuo migliora BP+OSD in modo statisticamente significativo in *una sola* configurazione su cinque, e ivi dell’uno per cento.

*Il decoder combinato eguaglia sempre il migliore dei due singoli, mai il loro prodotto. Le due sorgenti di guadagno non sono sommabili: sono alternative.*

**Perché: esiste un pavimento comune.** L’esperimento E10 individua la ragione. Sei bracci sono misurati sui medesimi campioni a distanza 3, in ordine crescente di informazione utilizzata: il decoder *banale* che predice sempre l’assenza di flip logico, la rete usata *da sola* senza alcun modello analitico, il MWPM, BP+OSD, e i due residui costruiti sui due decoder analitici.



| $p_{ct}$ | banale  | MWPM    | BP+OSD  | rete sola | MWPM+res | BP+OSD+res | disp. |
|----------|---------|---------|---------|-----------|----------|------------|-------|
| 0        | 0.04863 | 0.00432 | 0.00367 | 0.00431   | 0.00405  | 0.00354    | 19.4% |
| 0.005    | 0.08369 | 0.03106 | 0.03195 | 0.02704   | 0.02676  | 0.02677    | 1.0%  |
| 0.01     | 0.11611 | 0.05928 | 0.06035 | 0.04965   | 0.04885  | 0.04982    | 2.0%  |
| 0.02     | 0.17464 | 0.11169 | 0.11292 | 0.09222   | 0.09108  | 0.09156    | 1.2%  |
| 0.04     | 0.26492 | 0.20753 | 0.20819 | 0.17565   | 0.17413  | 0.17536    | 0.9%  |

Tabella E.10: Esperimento E10: errore logico dei sei bracci a distanza 3, tutti sugli stessi  $8 \times 10^5$  campioni. La colonna “disp.” è la dispersione relativa fra i tre bracci di fondo — rete sola, MWPM+residuo, BP+OSD+residuo. In presenza di crosstalk essi convergono entro il 2% pur partendo da metodi radicalmente diversi; in sua assenza divergono del 19% e si ordinano per qualità intrinseca del decoder.

Il quadro si legge in due regimi, ed è la struttura stessa del risultato.

A *modello corretto* (prima riga) il pavimento non esiste: i metodi si ordinano per qualità, BP+OSD davanti a tutti con  $3.54 \times 10^{-3}$  e la rete sola ultima con  $4.31 \times 10^{-3}$ , e la dispersione fra i bracci di fondo è del 19%. Qui l’unica cosa che conta è quanto bene si sfrutti il modello, e il residuo appreso non ha nulla da aggiungere.

A *modello strutturalmente incompleto* (le altre quattro righe) i tre bracci di fondo collassano entro lo 0.9–2.0% l’uno dall’altro, mentre i due decoder analitici da cui provengono restano il 16–18% sopra. Vi arriva anche la rete usata da sola, che non dispone di alcun decoder analitico: il pavimento non è dunque una proprietà del metodo di decodifica, ma **dell’informazione contenuta nella sindrome**. Sotto crosstalk ciascuno di questi metodi la estrae per intero, e incontra lo stesso limite.

L’onestà richiede una precisazione sulla parola “coincidono”. Il test di McNemar fra la rete sola e il MWPM+residuo dà  $p = 7.8 \times 10^{-4}$ ,  $8.2 \times 10^{-4}$  e  $2.6 \times 10^{-3}$  ai tre livelli superiori di crosstalk: con  $2 \times 10^5$  campioni di test si risolve anche uno scarto dell’uno per cento, e quelle differenze residue sono *reali*. Ciò che si afferma è più debole e più preciso: i tre metodi atterrano entro l’1–2% l’uno dall’altro, e tale scarto è un ordine di grandezza inferiore al divario che separa tutti e tre dal decoder analitico da cui partono.

Il fallimento di E8 discende allora da E10 senza bisogno di ulteriori ipotesi: impilare i due metodi non porta sotto il pavimento, perché il pavimento non appartiene a nessuno dei due.

**Il pavimento è del problema o del modello? (E11)** Alla lettura appena data si può muovere un’obiezione che va presa sul serio, perché è la stessa che questa sezione muove agli altri risultati. I tre bracci che convergono contengono *tutti e tre*

la medesima rete, un percettrone  $(128, 64)$  addestrato sugli stessi  $4.8 \times 10^5$  campioni: che convergano potrebbe significare soltanto “questo è quanto estrae questa rete”, e il pavimento sarebbe una proprietà del modello, non del problema. Per distinguere le due letture occorrono metodi più potenti di quel percettrone. L’esperimento E11 ne mette due alla prova, a distanza 3 e sui medesimi campioni.

Il primo è una rete con la stessa ricetta ma architettura  $(512, 256, 128)$ , ossia circa quaranta volte i parametri. Il secondo è il **decoder empirico a massima verosimiglianza**: per ogni sindrome osservata in addestramento si predice l’osservabile di maggioranza, con ricaduta sul MWPM per le sindromi mai viste. Quest’ultimo non stima parametri — memorizza — e non ha dunque alcun limite di capacità.

| $p_{ct}$ | pavimento | rete 40× | residuo 40× | tabella empirica | copertura |
|----------|-----------|----------|-------------|------------------|-----------|
| 0.005    | 0.02688   | 0.02687  | 0.02617     | 0.02765          | 98.1%     |
| 0.01     | 0.04935   | 0.04920  | 0.04850     | 0.05032          | 97.4%     |
| 0.02     | 0.09251   | 0.09222  | 0.09169     | 0.09499          | 95.6%     |
| 0.04     | 0.17602   | 0.17463  | 0.17377     | 0.18324          | 91.3%     |

Tabella E.11: Esperimento E11, distanza 3. “Pavimento” è il valore di E10 ricalcolato sugli stessi campioni. “Copertura” è la frazione di shot di test la cui sindrome era già stata osservata in addestramento, e misura quanto la tabella empirica sia effettivamente una tabella anziché un MWPM travestito.

L’obiezione è **respinta**: la rete con quaranta volte i parametri atterra sul pavimento entro lo 0.8%, e la tabella empirica — che di capacità ne ha infinita — risulta addirittura dal 2 al 4% peggiore. Il pavimento non è dunque il tetto dell’architettura scelta.

Sarebbe però scorretto concluderne che esso coincida con il limite informativo della sindrome, e la ragione sta nella tabella stessa. La sua copertura è alta (91–98%) ma la sua *profondità* non lo è: a crosstalk  $4 \times 10^{-2}$  le sindromi distinte osservate sono 63 180 su  $4.8 \times 10^5$  campioni di addestramento, ossia circa sette osservazioni per sindrome, e un voto di maggioranza su sette campioni è in larga parte rumore. La tabella non fallisce perché l’informazione manchi, ma perché a questa numerosità non riesce a stimarla; essa mette dunque alla prova l’ipotesi della capacità — e la scarta — senza stabilire alcun limite superiore informativo. Nella stessa direzione va notato che il residuo costruito sulla rete grande scende dell’1–3% sotto il pavimento in tutti e quattro i punti, in modo piccolo ma sistematico: il pavimento non è perfettamente duro.

L'enunciato che i dati sostengono è pertanto il seguente, e va tenuto entro questi limiti: *il pavimento è robusto a un aumento di quaranta volte della capacità del modello e a un'alternativa non parametrica, e non è quindi un artefatto dell'architettura; se esso coincida con il limite informativo della sindrome resta una questione aperta, che solo una decodifica esatta a massima verosimiglianza potrebbe chiudere.*

### E.1.9 E5 — il decoder è trasferibile fra dispositivi?

Gli esperimenti precedenti addestrano e valutano il decoder sul *medesimo* profilo di rumore. È una scelta che lascia aperta l'obiezione più concreta che si possa muovere a un decoder appreso: se il modello funzionasse soltanto sul profilo su cui è stato addestrato, andrebbe riaddestrato per ogni esemplare di QPU e a ogni deriva di calibrazione, e il costo pratico ne annullerebbe il vantaggio. La domanda decisiva è dunque se la rete abbia appreso una *regola* o le idiosincrasie di un profilo.

La verifica consiste nell'addestrare su un'intensità di rumore correlato e valutare su un'altra, senza alcun riaddestramento. Il confronto ha due termini di riferimento: il MWPM, che non si addestra e resta quindi invariante, e la rete addestrata sullo stesso profilo di test, che rappresenta il limite superiore ottenibile conoscendo perfettamente il dominio.

| Addestrata su               | Valutata su $p_{ct}$ |                |                    |                    |
|-----------------------------|----------------------|----------------|--------------------|--------------------|
|                             | $5 \times 10^{-3}$   | $10^{-2}$      | $2 \times 10^{-2}$ | $4 \times 10^{-2}$ |
| $5 \times 10^{-3}$          | <i>0.02804</i>       | 0.05000        | 0.09684            | 0.18749            |
| $10^{-2}$                   | <b>0.02800</b>       | <i>0.04912</i> | 0.09492            | 0.18140            |
| $2 \times 10^{-2}$          | 0.02814              | 0.04915        | <i>0.09286</i>     | 0.17800            |
| $4 \times 10^{-2}$          | 0.02841              | <b>0.04878</b> | 0.09312            | <i>0.17643</i>     |
| MWPM (nessun addestramento) | 0.03232              | 0.05742        | 0.11172            | 0.20853            |

Tabella E.12: Errore logico dell'ibrido al variare del profilo di addestramento e di quello di valutazione. In corsivo la diagonale (addestramento e test sullo stesso profilo), in grassetto i due casi in cui una rete *trasferita* supera quella addestrata in casa. Tutte e dodici le configurazioni fuori diagonale battono comunque il MWPM.

L'esito è netto: **tutte e dodici** le reti trasferite mantengono il vantaggio sul decoder analitico, e il costo del trasferimento — il peggioramento medio rispetto alla rete addestrata sul profilo di test — è dell'1.6%. In due casi la rete trasferita risulta addirittura migliore di quella addestrata in casa, differenza che rientra nella variabilità statistica ma che conferma l'assenza di una dipendenza sistematica dal profilo di addestramento.

La regola appresa non è dunque il profilo di rumore, ma qualcosa di più generale: verosimilmente la struttura delle configurazioni di sindrome che il matching interpreta male, la quale dipende dalla geometria del codice e dalla natura correlata dell'errore più che dalla sua intensità. Ne discende che il modello non richiede riaddestramento a ogni ricalibrazione del dispositivo — il che rimuove l'ostacolo pratico principale all'impiego di un decoder appreso, e distingue nettamente questo risultato da quello della prima fase, dove il classificatore richiedeva una fase di addestramento dedicata proprio per essere poi giudicato inutile.

### E.1.10 Bilancio

I sette esperimenti convergono su una conclusione che è più informativa di un semplice confronto fra decoder, e che i due controlli finali hanno reso più precisa anziché più debole. **Sostituire** il decoder analitico con una rete non conviene: a parità di modello di rumore la rete pareggia a distanza 3 — al prezzo di  $10^5$ – $10^6$  campioni — e perde al crescere della distanza. **Affiancarlo** sì: un decoder ibrido in cui la rete impara soltanto *quando ribaltare* la decisione del matching riduce l'errore logico del 18–21% a distanza 3 e dell'1–3% a distanza 5 in presenza di rumore correlato, e ricade sul matching quando il rumore è quello previsto.

Il guadagno compare dunque a due condizioni congiunte, e gli esperimenti E6 ed E7 permettono di enunciarle con precisione. La prima è che il rumore *esca dalla struttura* del modello del decoder — non che il modello sia mal calibrato: perturbandone i parametri fino a un ordine di grandezza l'errore logico varia dell'1–3%, e la rete non vince in nessuna delle dodici configurazioni. La seconda è che il reticolo resti *rappresentabile* dal modello appreso: a distanza 7, su 336 detector trattati come dimensioni indipendenti, l'ibrido si astiene dall'intervenire in tutte e cinque le configurazioni — anche là dove dispone di oltre duecentomila esempi positivi, sicché il limite è di architettura e non di numerosità (Tabella E.5).

A queste due condizioni se ne aggiunge una terza, emersa dal confronto con BP+OSD, che riguarda la scelta del termine di paragone. Il guadagno dell'ibrido va misurato contro il *miglior* decoder analitico disponibile, non contro quello standard: a distanza 5 BP+OSD recupera assai più margine dell'ibrido, e chi disponga di un budget di ingegneria limitato dovrebbe spenderlo lì per primo. Le due sorgenti di guadagno restano ortogonali — quella analitica decresce al crescere del rumore correlato, quella appresa cresce — ma non per questo sommabili: E8 ed E10 mostrano che entrambe conducono al medesimo pavimento, e che impilarle non porta al di

sotto di esso. La costruzione corretta è dunque *scegliarne una in base al regime*, non cumularle: il miglior decoder analitico dove il modello è corretto, il residuo appreso dove non lo è — e in quest’ultimo caso quale sia il decoder analitico sottostante cessa di contare.

Il perimetro va dichiarato. L’architettura impiegata è una rete densa di capacità modesta, deliberatamente scelta per continuità con lo strumento della prima fase sperimentale: i decoder allo stato dell’arte adottano architetture ricorrenti e convoluzionali che sfruttano la località del codice e la struttura temporale dei cicli di sindrome [22], e i risultati qui riportati non vanno letti come una stima del potenziale della decodifica appresa, ma come una verifica del *principio* su un’istanza trattabile. Le distanze esplorate arrivano a  $d = 7$  — dove, come mostrato, il vantaggio si annulla — l’errore fisico è fissato a un solo valore sotto soglia, e il rumore correlato modellato resta di tipo Pauli: gli errori coerenti e il leakage discussi nella Sezione 9.5 costituiscono un asse ulteriore, sul quale ci si attende che il vantaggio del decoder appreso sia maggiore, non minore, poiché è lì che il modello analitico è più lontano dalla fisica.

Resta il fatto metodologico che collega questa sezione al Capitolo 7 e che il Capitolo 10 riprenderà: in entrambe le fasi sperimentali di questo lavoro il **complemento a basso costo ha battuto la sostituzione ambiziosa**. Nella prima, la ricerca multi-candidato TOP-4 ha battuto il classificatore che avrebbe dovuto filtrare l’output; nella seconda, una rete che si limita a segnalare quando il decoder sbaglia batte la rete che pretende di sostituirlo. L’apprendimento automatico non è né inutile né risolutivo: produce valore esattamente dove dispone di informazione che nessun metodo più semplice è in grado di sfruttare.

## E.2 Compilazione Consapevole della Struttura: un’Esplorazione

Il criterio stabilito nel Capitolo 12 — un modello appreso produce valore dove il metodo esistente è strutturalmente cieco a una classe di informazione — ha la forma di una regola generale, e come tale può essere messo alla prova su casi che il corpo della tesi non ha trattato. Questa appendice riporta una di queste prove, condotta sulla **terza posizione** in cui è possibile intervenire sull’effetto del rumore.

Il lavoro principale ne ha esplorate due: *dopo* l’esecuzione, dove il Capitolo 7 ha dimostrato che non resta informazione da sfruttare; *durante* il calcolo, con la

correzione d'errore dei Capitoli 8–10. Ne resta una terza: *prima* dell'esecuzione, nel modo in cui il circuito viene mappato sui qubit fisici del dispositivo. È l'unica che agisce sull'hardware NISQ odierno senza richiedere il regime sotto-soglia, ed è l'unica che sfugge per costruzione al risultato negativo della prima fase — non ricostruisce l'informazione perduta, ma riduce la probabilità che venga perduta.

### E.2.1 La Previsione e il suo Fondamento

Il transpiler di Qiskit non è ingenuo rispetto al rumore: ai livelli di ottimizzazione superiori sceglie la mappatura tenendo conto dei tempi di coerenza e degli errori per arco. Esistono inoltre strumenti dedicati al solo ordinamento dei layout, che assegnano a ciascuno un punteggio di fedeltà ricavato dai dati di calibrazione, e ranker appresi che li superano. Qualunque proposta va confrontata con questi, non con il layout predefinito: superare quest'ultimo dimostrerebbe soltanto che il transpiler svolge il proprio compito.

Il margine ipotizzato sta altrove. Tutti quei metodi ottimizzano la **fedeltà del circuito**; per l'algoritmo di Shor, però, l'obiettivo non è la fedeltà ma che *escano i fattori*, e le due cose non coincidono per ragioni strutturali: i qubit di conteggio portano la fase da cui si estrae il periodo e sono gli unici misurati, mentre il registro di lavoro viene scartato; e il post-processing con frazioni continue tollera fasi lievemente spostate. Il transpiler ignora questa asimmetria perché minimizza un costo generico, indipendente dall'algoritmo. Da qui la previsione, conforme al criterio del Capitolo 12: *esiste un margine accessibile a chi conosce la struttura di Shor e inaccessibile a un criterio di sola fedeltà.*

**Condizione sperimentale necessaria.** La verifica richiede rumore **eterogeneo per qubit e per arco**: sotto rumore uniforme non esiste informazione topologica da sfruttare, e un esito nullo sarebbe conseguenza del disegno anziché proprietà del metodo. Si adottano perciò i dati di calibrazione reali di un processore a 127 qubit, la cui disomogeneità è considerevole: fra il qubit migliore e il peggiore l'errore di lettura varia di un fattore 171, l'errore di gate a due qubit di un fattore 288 e il tempo di coerenza  $T_2$  di un fattore 185.

## E.2.2 Primo Esperimento: la Fedeltà è un Buon Criterio di Scelta?

Si campionano sessanta sottoinsiemi connessi di dodici qubit fisici. Per ciascuno si costruisce il modello di rumore dai parametri reali di quei qubit e di quegli archi, si traspara il circuito di Shor per  $N = 15$  e si misurano due grandezze: il **punteggio di fedeltà**  $s = 1 - \prod_x (1 - e_x)$  calcolato dai soli dati di calibrazione, senza eseguire nulla, e la **probabilità di successo** della fattorizzazione, misurata su 8 192 campioni.

| Grandezza                                                   | Valore                        |
|-------------------------------------------------------------|-------------------------------|
| Sottografi valutati                                         | 60                            |
| $P_{\text{success}}$ minima / mediana / massima             | 0.196 / 0.549 / 0.631         |
| <b>Forbice fra migliore e peggiore</b>                      | <b>43.5 punti percentuali</b> |
| Correlazione di Spearman (fedeltà, successo)                | −0.460                        |
| $P_{\text{success}}$ del layout migliore <i>per fedeltà</i> | 0.611                         |
| $P_{\text{success}}$ del layout migliore <i>in assoluto</i> | 0.631                         |
| <b>Perdita usando il criterio di fedeltà</b>                | <b>1.9 punti percentuali</b>  |

Tabella E.13: Scelta del layout su calibrazione reale. La forbice fra il migliore e il peggiore sottografo è larghissima, ma il criterio di fedeltà — pur essendo un predittore mediocre — seleziona un layout quasi ottimale.

Il risultato è duplice e va letto per intero. Da un lato **la scelta del layout conta enormemente**: fra il sottografo migliore e il peggiore corrono più di quaranta punti percentuali di probabilità di successo — più di quanto qualunque tecnica esaminata in questa tesi abbia mai recuperato. Dall’altro, **il criterio di fedeltà quella scelta la compie già bene**: sbaglia di meno di due punti su quarantatré, e tale perdita è per di più sovrastimata, poiché il “migliore su sessanta” è il massimo di sessanta stime rumorose ed è quindi affetto da distorsione di selezione.

Ne discende una distinzione che vale la pena isolare, perché è la stessa che il Capitolo 7 ha incontrato in forma speculare: il punteggio di fedeltà è un *predittore* mediocre — con una correlazione di rango di −0.46 spiega meno di un terzo della variabilità — ma un *selettore* efficace. Nella prima fase sperimentale il classificatore era eccellente come predittore e inutile come decisore; qui accade l’opposto. In entrambi i casi la lezione è che **la qualità di una stima e la sua utilità operativa sono grandezze distinte**, e che confonderle porta a conclusioni sbagliate in entrambe le direzioni.

**Quali grandezze predicono davvero il successo.** L'analisi delle singole componenti chiarisce il quadro e riserva una sorpresa.

| Grandezza del layout                  | Correlazione di Spearman con $P_{\text{success}}$ |
|---------------------------------------|---------------------------------------------------|
| Errore di lettura medio               | <b>−0.564</b>                                     |
| Errore di gate a due qubit medio      | −0.541                                            |
| Errore di lettura del qubit peggiore  | −0.518                                            |
| <i>Punteggio di fedeltà composito</i> | −0.460                                            |
| $T_2$ medio                           | +0.221                                            |
| Profondità del circuito traspilato    | +0.098                                            |
| Numero di porte a due qubit (routing) | +0.032                                            |

Tabella E.14: Il punteggio composito predice *peggio* del solo errore di lettura, di cui è funzione: l'aggregazione moltiplicativa diluisce il segnale anziché concentrarlo. I tempi di coerenza risultano quasi irrilevanti, in accordo indipendente con la campagna parametrica della Sezione D.1.

Tre osservazioni. La prima è che il punteggio composito predice *peggio* del singolo ingrediente da cui dipende: aggregare moltiplicativamente tutti i contributi di errore diluisce l'informazione che conta. La seconda è che l'errore di lettura domina — ed è coerente con la struttura dell'algoritmo, poiché gli unici qubit misurati sono gli otto di conteggio. La terza è una conferma incrociata di un risultato già acquisito: i tempi di coerenza risultano quasi ininfluenti, esattamente come la campagna parametrica della Sezione D.1 aveva trovato per via del tutto indipendente, con strumenti e modello di rumore diversi.

### E.2.3 Secondo Esperimento: Conta il Ruolo Assegnato ai Qubit?

Il primo esperimento ha variato *quale* gruppo di dodici qubit utilizzare, lasciando al transpiler la scelta del ruolo da assegnare a ciascuno. Non ha quindi messo alla prova l'ipotesi di partenza, che riguarda proprio l'assegnazione dei ruoli. Il secondo esperimento colma questa lacuna: si **fissa il sottografo** e si varia **soltanto** quali qubit fisici ricevano il registro di conteggio, confrontando l'assegnazione ai qubit a lettura migliore con quella ai qubit a lettura peggiore, con la scelta libera del transpiler e con permutazioni casuali. Il confronto è appaiato: stesso sottografo, stessi campioni, stesso seme.



**L'intervento non è affidabile, e i dati lo rivelano.** Il protocollo prevedeva un controllo di verifica: misurare, dopo la traspilazione, l'errore di lettura medio dei qubit fisici su cui le misure *effettivamente* cadono, per accertare che la manipolazione avesse avuto l'effetto voluto. Il controllo ha rivelato che l'intervento riesce solo in circa metà dei casi. La ragione è strutturale: imporre la mappatura iniziale non determina la mappatura *finale*, perché l'instradamento inserisce porte di scambio che permutano i qubit lungo il circuito. Su circuiti con oltre quattrocento porte a due qubit la permutazione è sostanziale, e il qubit che porta il registro di conteggio al momento della misura non è quello a cui era stato assegnato in partenza.

Il confronto fra le due strategie intenzionali, di conseguenza, non mette alla prova l'ipotesi: su dodici sottografi l'assegnazione ai qubit a lettura migliore prevale in sei casi su dodici, con una differenza appaiata media di +4.3 punti percentuali ma un rapporto  $t$  di 1.29, non significativo. L'esito non è una smentita: è una misura priva di potere informativo, perché la variabile indipendente non è stata controllata.

**L'analisi corretta.** Si abbandona quindi l'intervento e si utilizza la grandezza effettivamente misurata — l'errore di lettura dei qubit realmente misurati — correlandola con la probabilità di successo su tutte le sessanta esecuzioni. Per isolare l'effetto del *ruolo* da quello del gruppo di qubit impiegato, entrambe le variabili sono centrate sulla media del proprio sottografo, ottenendo una correlazione parziale che controlla per il sottografo.

| Grandezza                            | Correlazione grezza<br>(sottografi confusi) | Correlazione parziale<br>(entro sottografo) |
|--------------------------------------|---------------------------------------------|---------------------------------------------|
| Errore di lettura dei qubit misurati | -0.685                                      | <b>-0.465</b>                               |
| Numero di porte di instradamento     | -0.081                                      | -0.188                                      |

Tabella E.15: Correlazione di Spearman con la probabilità di successo, su 60 esecuzioni e 12 sottografi. La correlazione parziale isola l'effetto dell'assegnazione dei ruoli, a parità di gruppo di qubit fisici impiegato.

Tre elementi convergono. Il primo: a sottografo fissato, la sola riassegnazione dei ruoli fa variare la probabilità di successo di **13.2 punti percentuali in media**, con un massimo di 36.4 — non è dunque una variabile marginale. Il secondo: la correlazione parziale con l'errore di lettura dei qubit misurati è -0.465, mentre quella con il costo di instradamento è meno della metà: *a parità di sottografo è la lettura, non il routing, a governare l'esito*. Il terzo, non parametrico e quindi indipendente da assunzioni di forma: in **sei sottografi su dodici** la configurazione con l'errore di

lettura più basso è anche quella che ottiene il successo massimo, contro i 2.4 attesi per puro caso fra cinque configurazioni ( $p = 0.019$ ).

| Strategia di assegnazione              | $P_{\text{success}}$ media | Porte di instradamento |
|----------------------------------------|----------------------------|------------------------|
| Conteggio sui qubit a lettura migliore | $0.482 \pm 0.025$          | 431                    |
| Scelta libera del transpiler           | $0.468 \pm 0.034$          | <b>353</b>             |
| Permutazione casuale (media)           | 0.444                      | 438                    |
| Conteggio sui qubit a lettura peggiore | $0.438 \pm 0.035$          | 427                    |

Tabella E.16: L'ordinamento medio segue la direzione prevista, ma le differenze non raggiungono la significatività con dodici sottografi. Si noti che il transpiler ottiene il costo di instradamento nettamente più basso senza ottenere il successo più alto: ottimizza la grandezza che sa misurare, non quella che conta per l'algoritmo.

## E.2.4 Un Terzo Caso: la Ricerca Multi-Candidato a Livello Logico

Il Capitolo 11 propone come estensione naturale l'applicazione della strategia TOP-K allo Shor logico, dove essa non dovrebbe più compensare il rumore fisico dei gate — compito del codice correttore — ma l'errore logico residuo. La verifica è riportata qui perché il suo esito, negativo, è istruttivo quanto i precedenti.

| Errore logico $p_L$ | Per singola misura | TOP-4 | TOP-1 |
|---------------------|--------------------|-------|-------|
| 0                   | 0.751              | 1.000 | 0.700 |
| $2 \times 10^{-3}$  | 0.699              | 1.000 | 0.000 |
| $5 \times 10^{-3}$  | 0.674              | 1.000 | 0.000 |
| $10^{-2}$           | 0.620              | 1.000 | 0.000 |
| $2 \times 10^{-2}$  | 0.562              | 1.000 | 0.000 |
| $5 \times 10^{-2}$  | 0.402              | 1.000 | 0.700 |
| $10^{-1}$           | 0.283              | 1.000 | 0.000 |
| $2 \times 10^{-1}$  | 0.245              | 1.000 | 1.000 |

Tabella E.17: Frazione di iterazioni risolte al variare dell'errore logico per gate ( $N = 15, 30$  iterazioni da 1024 shot per punto). La metrica per singola misura decresce in modo monotono di oltre cinquanta punti percentuali; la strategia TOP-4 resta invece a 1.000 su tutto l'intervallo.

La strategia TOP-4 risolve la totalità delle iterazioni per ogni valore di  $p_L$  esaminato, compreso quello a cui la probabilità per singola misura è già scesa al livello del caso: l'escursione della curva è *esattamente nulla*. Il criterio non discrimina, e non perché la strategia sia particolarmente efficace, ma perché l'istanza è degenerare

— con periodo  $r = 4$  una frazione elevata degli esiti conduce ai fattori attraverso le frazioni continue, sicché è sufficiente guardare quattro candidati per trovarne uno valido quale che sia il livello di rumore.

La colonna TOP-1 mostra il rovescio della stessa medaglia, con un andamento erratico che non dipende dal rumore: la misura più frequente coincide spesso con l'esito  $y = 0$ , che non porta informazione sul periodo ed è scartato per costruzione. È la medesima osservazione riportata nel Capitolo 7 a livello fisico, e conferma che la differenza fra TOP-1 e TOP-K non è primariamente una questione di robustezza al rumore, ma di quale candidato la strategia guardi per primo.

Ne segue che la proposta del Capitolo 11 non è, come poteva sembrare, un'estensione a basso costo: richiede un'istanza con periodo meno degenera, e ricade quindi nella barriera di scalabilità. Le due limitazioni — degenerazione dell'istanza piccola e intrattabilità di quelle grandi — non sono indipendenti, ma lo stesso ostacolo che si manifesta due volte.

### E.2.5 Conclusione: il Criterio va Precisato

I due esperimenti restituiscono un esito che non è né una conferma né una smentita, e la distinzione merita di essere formulata con precisione perché è proprio ciò che rende il caso istruttivo.

**Il meccanismo ipotizzato esiste.** A parità di gruppo di qubit fisici, il ruolo assegnato a ciascuno muove la probabilità di successo di oltre tredici punti percentuali in media; la grandezza che governa quel movimento è l'errore di lettura dei qubit effettivamente misurati — coerentemente con la struttura dell'algoritmo, dove gli unici qubit letti sono quelli del registro di conteggio — e non il costo di instradamento. L'asimmetria fra registro di conteggio e registro di lavoro, che il criterio di sola fedeltà ignora, è dunque reale e misurabile.

**Ma non è sfruttabile con lo strumento ovvio.** Imporre la mappatura iniziale non basta a determinare quali qubit portino il conteggio al momento della misura, perché l'instradamento li permuta. Controllare davvero la variabile richiederebbe di vincolare anche l'instradamento, e ogni vincolo aggiuntivo si paga in porte: il transpiler, lasciato libero, ottiene un costo di instradamento inferiore di circa un quinto rispetto a qualunque assegnazione imposta. È questo il compromesso che il primo esperimento aveva già lasciato intravedere, e che spiega perché il criterio di sola fedeltà — pur essendo un predittore mediocre — si riveli un selettore difficile da battere: bilancia implicitamente due grandezze in tensione fra loro.

**Che cosa se ne ricava per il criterio del Capitolo 12.** Il criterio afferma che un modello appreso produce valore dove il metodo esistente è strutturalmente cieco a una classe di informazione. Il caso qui esaminato ne mostra il limite: l'informazione mancava davvero, ed era davvero rilevante, eppure il guadagno non si è materializzato. La condizione va perciò integrata:

non basta che l'informazione sia *assente* dal metodo esistente e *predittiva* dell'esito; occorre anche che sia **sfruttabile senza costi compensativi**, ossia che agire su di essa non degradi un'altra grandezza che concorre al medesimo risultato.

I due casi favorevoli incontrati nel corpo della tesi soddisfano la condizione aggiuntiva, e si vede ora che non è un caso: la ricerca multi-candidato non modifica il circuito e non costa nulla oltre al tentativo aggiuntivo, mentre la rete che corregge il decoder agisce dopo la decodifica, senza toccare né il circuito né la sindrome. Entrambe intervengono *a valle* di ciò che hanno migliorato, e non ne alterano le condizioni. La mappatura consapevole della struttura, al contrario, agisce *a monte* e modifica l'oggetto stesso su cui poi misura il guadagno: è questa la ragione strutturale per cui il vantaggio si annulla.

**Perimetro.** L'esplorazione riguarda una sola istanza ( $N = 15$ ), un solo dispositivo e dodici sottografi; con questa numerosità l'ordinamento medio fra strategie segue la direzione prevista ma non raggiunge la significatività statistica, ed è possibile che un campione più ampio, unito a un controllo effettivo dell'instradamento, riveli un effetto che qui resta sotto la soglia di rilevabilità. Ciò che l'esperimento stabilisce con sicurezza è di natura diversa e non dipende dalla potenza statistica: la scelta della mappatura è di gran lunga la leva più influente fra quelle esaminate in questa tesi — oltre quaranta punti percentuali fra la migliore e la peggiore — e il criterio di sola fedeltà, per quanto imperfetto, la sfrutta già quasi interamente.

# Bibliografia

- [1] Richard P. Feynman. “Simulating Physics with Computers”. In: *International Journal of Theoretical Physics* 21.6–7 (1982), pp. 467–488. DOI: 10.1007/BF02650179.
- [2] David Deutsch. “Quantum Theory, the Church-Turing Principle and the Universal Quantum Computer”. In: *Proceedings of the Royal Society of London. Series A* 400.1818 (1985), pp. 97–117. DOI: 10.1098/rspa.1985.0070.
- [3] Dewang Sun, Naifeng Zhang e Franz Franchetti. “Optimization and Performance Analysis of Shor’s Algorithm in Qiskit”. In: *IEEE High Performance Extreme Computing Conference (HPEC)*. Available at [https://users.ece.cmu.edu/~franzf/papers/hpec\\_2023\\_Quantum\\_final.pdf](https://users.ece.cmu.edu/~franzf/papers/hpec_2023_Quantum_final.pdf). IEEE, 2023.
- [4] IBM Quantum. *Shor’s Algorithm – IBM Quantum Documentation*. <https://quantum.cloud.ibm.com/docs/en/tutorials/shors-algorithm>. Tutorial ufficiale IBM per l’implementazione dell’algoritmo di Shor con Qiskit Runtime su hardware reale (ibm\_marrakesh). Include Dynamical Decoupling e Gate Twirling come tecniche di soppressione del rumore. 2024.
- [5] J. A. Bravo-Montes et al. “A Methodology to Select and Adjust Quantum Noise Models Through Emulators: Benchmarking Against Real Backends”. In: *EPJ Quantum Technology* 11 (2024). Metodologia sistematica per la selezione e calibrazione di noise model per emulatori rispetto a backend reali IBM. Benchmark su ibm\_perth (7 qubit), p. 71. DOI: 10.1140/epjqt/s40507-024-00284-4.
- [6] Lieven M. K. Vandersypen et al. “Experimental Realization of Shor’s Quantum Factoring Algorithm Using Nuclear Magnetic Resonance”. In: *Nature* 414 (2001), pp. 883–887. DOI: 10.1038/414883a.

- [7] Unathi Skosana e Mark Tame. “Demonstration of Shor’s Factoring Algorithm for  $N = 21$  on IBM Quantum Processors”. In: *Scientific Reports* 11 (2021), p. 16599. DOI: 10.1038/s41598-021-95973-w.
- [8] Peter W. Shor. “Algorithms for Quantum Computation: Discrete Logarithms and Factoring”. In: *Proceedings of the 35th Annual Symposium on Foundations of Computer Science (FOCS)*. IEEE, 1994, pp. 124–134. DOI: 10.1109/SFCS.1994.365700.
- [9] Wojciech Hubert Zurek. “Decoherence, einselection, and the quantum origins of the classical”. In: *Reviews of Modern Physics* 75.3 (2003), pp. 715–775. DOI: 10.1103/RevModPhys.75.715.
- [10] Fabrice Boudot et al. “Factoring RSA-250”. In: *Cryptology ePrint Archive* (2020). Report 2020/697, <https://eprint.iacr.org/2020/697>.
- [11] Stéphane Beauregard. “Circuit for Shor’s Algorithm Using  $2n + 3$  Qubits”. In: *Quantum Information and Computation* 3.2 (2003). arXiv:quant-ph/0205095. Ottimizzazione del circuito originale di Shor: riduce il numero di qubit da  $O(n)$  a  $2n + 3$  tramite addizione modulare in-place, pp. 175–185.
- [12] John Preskill. “Quantum Computing in the NISQ Era and Beyond”. In: *Quantum* 2 (2018), p. 79. DOI: 10.22331/q-2018-08-06-79.
- [13] William K. Wootters e Wojciech H. Zurek. “A Single Quantum Cannot be Cloned”. In: *Nature* 299 (1982), pp. 802–803. DOI: 10.1038/299802a0.
- [14] Mohan Sarovar et al. “Detecting crosstalk errors in quantum information processors”. In: *Quantum* 4 (2020), p. 321. DOI: 10.22331/q-2020-09-11-321.
- [15] Michael A. Nielsen e Isaac L. Chuang. *Quantum Computation and Quantum Information*. 10th Anniversary Edition. Cambridge, UK: Cambridge University Press, 2000. ISBN: 978-1107002173.
- [16] Dorit Aharonov e Michael Ben-Or. “Fault-Tolerant Quantum Computation with Constant Error Rate”. In: *SIAM Journal on Computing* 38.4 (2008). Versione preliminare presentata a STOC 1997; preprint arXiv:quant-ph/9906129, pp. 1207–1282. DOI: 10.1137/S0097539799359385.
- [17] Peter W. Shor. “Scheme for Reducing Decoherence in Quantum Computer Memory”. In: *Physical Review A* 52.4 (1995), R2493–R2496. DOI: 10.1103/PhysRevA.52.R2493.

- [18] Andrew M. Steane. “Error Correcting Codes in Quantum Theory”. In: *Physical Review Letters* 77.5 (1996), pp. 793–797. DOI: 10.1103/PhysRevLett.77.793.
- [19] A. R. Calderbank e Peter W. Shor. “Good Quantum Error-Correcting Codes Exist”. In: *Physical Review A* 54.2 (1996), pp. 1098–1105. DOI: 10.1103/PhysRevA.54.1098.
- [20] Austin G. Fowler et al. “Surface Codes: Towards Practical Large-Scale Quantum Computation”. In: *Physical Review A* 86.3 (2012), p. 032324. DOI: 10.1103/PhysRevA.86.032324.
- [21] Giacomo Torlai e Roger G. Melko. “Neural Decoder for Topological Codes”. In: *Physical Review Letters* 119.3 (2017), p. 030501. DOI: 10.1103/PhysRevLett.119.030501.
- [22] Johannes Bausch et al. “Learning High-Accuracy Error Decoding for Quantum Processors”. In: *Nature* 635 (2024). AlphaQubit: decoder neurale sviluppato da Google DeepMind e Google Quantum AI. Supera i decoder analitici classici su hardware Sycamore a 241 qubit, pp. 834–840. DOI: 10.1038/s41586-024-08148-8.
- [23] Qiskit contributors. *Qiskit: An Open-source Framework for Quantum Computing*. <https://qiskit.org>. 2023. DOI: 10.5281/zenodo.2573505.
- [24] Graychii. *Shor Algorithm Implementation*. <https://github.com/Graychii/Shor-Algorithm-Implementation>. Implementazione Python dell’algoritmo di Shor su Qiskit. 2023.
- [25] Craig Gidney. “Stim: a fast stabilizer circuit simulator”. In: *Quantum* 5 (2021), p. 497. DOI: 10.22331/q-2021-07-06-497.
- [26] Oscar Higgott. *PyMatching: A Python package for decoding quantum codes with minimum-weight perfect matching*. arXiv:2105.13082. 2021. arXiv: 2105.13082.
- [27] Fabian Pedregosa et al. “Scikit-learn: Machine Learning in Python”. In: *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.
- [28] Haoran Liao et al. *Machine Learning for Practical Quantum Error Mitigation*. 2023. arXiv: 2309.17368.

- [29] Adriano Barenco et al. “Elementary gates for quantum computation”. In: *Physical Review A* 52.5 (1995). Dimostra che qualsiasi operatore unitario su  $k$  qubit può essere decomposto in  $O(4^k)$  porte elementari; fondamento teorico per la complessità della decomposizione UnitaryGate, pp. 3457–3467. DOI: 10.1103/PhysRevA.52.3457.
- [30] Kristan Temme, Sergey Bravyi e Jay M. Gambetta. “Error Mitigation for Short-Depth Quantum Circuits”. In: *Physical Review Letters* 119.18 (2017). Articolo fondativo della Zero-Noise Extrapolation (ZNE): propone l’amplificazione controllata del rumore seguita da estrapolazione a zero rumore per stimare l’output ideale di un circuito NISQ, p. 180509. DOI: 10.1103/PhysRevLett.119.180509.
- [31] Joschka Roffe. “Quantum error correction: an introductory guide”. In: *Contemporary Physics* 60.3 (2019), pp. 226–245. DOI: 10.1080/00107514.2019.1667078.
- [32] Daniel Gottesman. “Stabilizer Codes and Quantum Error Correction”. Tesi di dott. California Institute of Technology, 1997. arXiv: quant-ph/9705052.
- [33] A. Yu. Kitaev. “Fault-tolerant quantum computation by anyons”. In: *Annals of Physics* 303.1 (2003), pp. 2–30. DOI: 10.1016/S0003-4916(02)00018-0.
- [34] Raul Conchello Vendrell et al. *Plaquette: A hardware-aware design platform for fault-tolerant quantum computers*. arXiv:2607.08767. 2026. arXiv: 2607.08767.
- [35] Craig Gidney e Martin Ekerå. “How to factor 2048 bit RSA integers in 8 hours using 20 million noisy qubits”. In: *Quantum* 5 (2021), p. 433. DOI: 10.22331/q-2021-04-15-433.
- [36] Craig Gidney. *How to factor 2048 bit RSA integers with less than a million noisy qubits*. arXiv:2505.15917. 2025. arXiv: 2505.15917.
- [37] Prakash Murali et al. “Noise-Adaptive Compiler Mappings for Noisy Intermediate-Scale Quantum Computers”. In: *Proceedings of the 24th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. 2019, pp. 1015–1029. DOI: 10.1145/3297858.3304075.
- [38] Swamit S. Tannu e Moinuddin K. Qureshi. “Not All Qubits Are Created Equal: A Case for Variability-Aware Policies for NISQ-Era Quantum Computers”. In: *Proceedings of the 24th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. 2019, pp. 987–999. DOI: 10.1145/3297858.3304007.



- [39] Alberto Peruzzo et al. “A variational eigenvalue solver on a photonic quantum processor”. In: *Nature Communications* 5 (2014), p. 4213. DOI: 10.1038/ncomms5213.
- [40] Edward Farhi, Jeffrey Goldstone e Sam Gutmann. *A Quantum Approximate Optimization Algorithm*. 2014. arXiv: 1411.4028.
- [41] Johannes Bausch, Andrew W. Senior et al. *Learning to Decode the Surface Code with a Recurrent, Transformer-Based Neural Network*. Decoder transformer per surface code; supera i decoder state-of-the-art su hardware Google Sycamore per distanze 3–11. 2023. arXiv: 2310.05900.
- [42] IBM Quantum. *IBM Quantum Roadmap 2025: Path to Fault-Tolerant Quantum Computing*. <https://www.ibm.com/roadmaps/quantum/2025/>. Processori Loon, Nighthawk e target Quantum Starling 2029. 2025.
- [43] Thomas Monz et al. “Realization of a Scalable Shor Algorithm”. In: *Science* 351.6277 (2016), pp. 1068–1070. DOI: 10.1126/science.aad9480.
- [44] Aditya Singh, Aakash Khochare e Subhadeep Palit. *Practical Challenges in Executing Shor’s Algorithm on Existing Quantum Platforms*. 2025. arXiv: 2512.15330.
- [45] Oded Regev. *An Efficient Quantum Factoring Algorithm*. 2023. arXiv: 2308.06572.
- [46] Lov K. Grover. “A Fast Quantum Mechanical Algorithm for Database Search”. In: *Proceedings of the 28th Annual ACM Symposium on Theory of Computing (STOC)*. ACM, 1996, pp. 212–219. DOI: 10.1145/237814.237866.
- [47] Charles H. Bennett et al. “Strengths and Weaknesses of Quantum Computing”. In: *SIAM Journal on Computing* 26.5 (1997), pp. 1510–1523. DOI: 10.1137/S0097539796300933.
- [48] Christof Zalka. “Grover’s Quantum Searching Algorithm is Optimal”. In: *Physical Review A* 60.4 (1999), pp. 2746–2751. DOI: 10.1103/PhysRevA.60.2746.
- [49] Google Quantum AI. *Cirq: A Python Framework for Writing, Manipulating, and Running Quantum Circuits*. <https://quantumai.google/cirq>. Framework open-source Google per processori superconduttori Sycamore. 2024.

- [50] Ville Bergholm et al. *PennyLane: Automatic Differentiation of Hybrid Quantum-Classical Computations*. arXiv:1811.04968. Framework Xanadu orientato a circuiti variazionali e quantum machine learning. 2022.
- [51] John S. Bell. “On the Einstein Podolsky Rosen Paradox”. In: *Physics* 1.3 (1964), pp. 195–200. DOI: 10.1103/PhysicsPhysiqueFizika.1.195.
- [52] Alain Aspect, Philippe Grangier e Gérard Roger. “Experimental Realization of Einstein-Podolsky-Rosen-Bohm Gedankenexperiment: A New Violation of Bell’s Inequalities”. In: *Physical Review Letters* 49.2 (1982), pp. 91–94. DOI: 10.1103/PhysRevLett.49.91.
- [53] Brian D. Josephson. “Possible New Effects in Superconductive Tunnelling”. In: *Physics Letters* 1.7 (1962), pp. 251–253. DOI: 10.1016/0031-9163(62)91369-0.
- [54] Jens Koch et al. “Charge-insensitive Qubit Design Derived from the Cooper Pair Box”. In: *Physical Review A* 76.4 (2007), p. 042319. DOI: 10.1103/PhysRevA.76.042319.
- [55] Ronald L. Rivest, Adi Shamir e Leonard Adleman. “A Method for Obtaining Digital Signatures and Public-Key Cryptosystems”. In: *Communications of the ACM* 21.2 (1978), pp. 120–126. DOI: 10.1145/359340.359342.
- [56] Arjen K. Lenstra e Hendrik W. Lenstra Jr. “The Development of the Number Field Sieve”. In: *Lecture Notes in Mathematics*. Vol. 1554. Springer-Verlag, 1993. DOI: 10.1007/BFb0091537.
- [57] National Security Agency. *Commercial National Security Algorithm Suite 2.0 (CNSA 2.0)*. [https://media.defense.gov/2022/Sep/07/2003071834/-1/-1/0/CSA\\_CNSA\\_2.0\\_ALGORITHMS\\_.PDF](https://media.defense.gov/2022/Sep/07/2003071834/-1/-1/0/CSA_CNSA_2.0_ALGORITHMS_.PDF). Cybersecurity Advisory, settembre 2022. Fissa le scadenze di migrazione verso algoritmi resistenti ai computer quantistici entro il 2030–2035. 2022.
- [58] National Institute of Standards and Technology. *Post-Quantum Cryptography Standards: FIPS 203, 204, 205*. <https://csrc.nist.gov/pubs/fips/203/final>. FIPS 203 (ML-KEM), FIPS 204 (ML-DSA), FIPS 205 (SLH-DSA). Pubblicazione formale agosto 2024. 2024.

- [59] Apple Security Engineering and Architecture. *iMessage with PQ3: The new state of the art in quantum-secure messaging*. <https://security.apple.com/blog/imessage-pq3/>. Febbraio 2024. Primo protocollo di messaggistica con crittografia post-quantistica di livello 3, basato su ML-KEM per lo scambio di chiavi ibride. 2024.
- [60] Frank Arute et al. “Quantum Supremacy Using a Programmable Superconducting Processor”. In: *Nature* 574 (2019), pp. 505–510. DOI: 10.1038/s41586-019-1666-5.
- [61] Pavel Panteleev e Gleb Kalachev. “Degenerate Quantum LDPC Codes With Good Finite Length Performance”. In: *Quantum* 5 (2021), p. 585. DOI: 10.22331/q-2021-11-22-585.
- [62] Joschka Roffe et al. “Decoding Across the Quantum Low-Density Parity-Check Code Landscape”. In: *Physical Review Research* 2.4 (2020), p. 043423. DOI: 10.1103/PhysRevResearch.2.043423.

# Ringraziamenti

Desidero ringraziare in primo luogo il mio relatore, **Ing. Floriano Caprio**, per la disponibilità, la pazienza e la guida preziosa fornita durante l'intero percorso di sviluppo di questo lavoro. I suoi consigli e la sua competenza sono stati fondamentali per orientarmi in un campo così vasto e in continua evoluzione.

Ringrazio l'**Università Campus Bio-Medico di Roma** per il percorso formativo offerto, che mi ha fornito gli strumenti teorici e pratici per affrontare questa tesi.

Un ringraziamento speciale va alla mia **famiglia**, che ha rappresentato un punto fermo e una fonte inesauribile di sostegno morale durante gli anni di studio.

Ringrazio infine tutti i **colleghi e amici** che hanno condiviso con me questo percorso, rendendo più leggere le giornate di studio e ricerca.

*Claudio Dragotta*

*Roma, 2026*