

Shor's Algorithm under Noise: Machine-Learning Ablation, Quantum Error Correction, and Approximate QFT

Laureando: Claudio Dragotta

Relatore: Prof. Paolo Soda

Correlatore: Ing. Floriano Caprio

Sessione di Laurea: Ottobre — A.A. 2025/2026

1 Introduzione e obiettivi

L'algoritmo di Shor consente di fattorizzare numeri interi in tempo polinomiale rispetto alla lunghezza binaria dell'input, con implicazioni per la sicurezza dei sistemi crittografici fondati sulla difficoltà della fattorizzazione [1]. La realizzazione di questo vantaggio teorico richiede tuttavia un controllo degli errori compatibile con la profondità dei circuiti. Errori nelle operazioni, decoerenza e lettura imperfetta possono alterare la distribuzione delle misure e compromettere l'informazione necessaria alla ricerca dell'ordine moltiplicativo [2].

La tesi sviluppa uno studio simulativo volto a stabilire quali interventi migliorino effettivamente l'affidabilità della computazione e rispetto a quali riferimenti. Il percorso comprende due fasi principali: la valutazione del post-processing classico degli esiti di Shor, con uno studio di ablazione del contributo del machine learning, e la caratterizzazione di codici di correzione quantistica e decoder delle sindromi. Completano il lavoro un'analisi separata della sensibilità di Shor agli errori di porta e una campagna sull'ottimizzazione circuitale mediante trasformata di Fourier quantistica approssimata, o AQFT.

I tre ambiti di intervento — selezione degli esiti, protezione dell'informazione e riduzione del costo circuitale — sono collegati da un criterio comune: confrontare ogni soluzione con un riferimento esplicito, isolare il contributo dei singoli componenti e misurare il beneficio mediante indicatori coerenti con il compito. Le campagne rimangono distinte: non costituiscono un'esecuzione integrata di Shor protetta da correzione d'errore.

2 Materiali e metodi

2.1 Implementazione, validazione e definizione del successo

Scelta una base a coprime con il numero N da fattorizzare, la successione $a^x \bmod N$ è periodica; il periodo, detto ordine r , è il minimo intero positivo per cui $a^r \equiv 1 \pmod{N}$. La parte quantistica lo stima con stima di fase e QFT inversa; la parte classica ricava i fattori per approssimazione razionale e massimo comune divisore, e li verifica.

L'istanza principale è $N = 15$, $a = 7$, con otto qubit di controllo e quattro di lavoro; l'ordine è $r = 4$ e gli esiti ideali del registro di controllo sono 0, 64, 128 e 192. Ogni esecuzione con misura, detta *shot*, restituisce un solo esito; molti shot formano l'istogramma su cui opera il post-processing. Il successo è il recupero di fattori non banali, non la ricostruzione esatta dell'ordine. Vi conducono tre dei quattro picchi ideali, con probabilità complessiva del 75%. La verifica classica è però permissiva e accetta

63 dei 256 valori, tanto che esiti del tutto uniformi darebbero comunque un successo di $63/256 \approx 24,61\%$. Questo riferimento dipende dall'istanza e dal post-processing, non misura la fedeltà dello stato quantistico e ricorda che fattorizzazioni corrette sopravvivono anche a una distribuzione che ha perso gran parte della propria struttura. La correttezza dei circuiti è verificata indipendentemente dal successo della fattorizzazione, controllando operatori modulari, ripristino dei qubit ausiliari e accordo con le distribuzioni teoriche. Le istanze $N = 21$, $a = 2$ e $N = 35$, $a = 6$, validate idealmente, usano l'aritmetica reversibile di Beauregard [3]; solo $N = 21$ entra nelle prove rumorose esplorative sull'AQFT. Si impiegano Qiskit/Aer, scikit-learn, Stim e PyMatching [4–7], registrando versioni, parametri, semi casuali e identificativi dei circuiti.

2.2 Post-processing, classificazione e mitigazione

Tre strategie, con estrattore dei fattori e regola dei pareggi comuni, operano sugli stessi istogrammi, uno per iterazione quantistica, da 1.024 shot ciascuno. TOP-1 (Metodo 1) verifica il solo esito più frequente; TOP-4 fino a quattro candidati ordinati per frequenza; il Metodo 2 applica TOP-4 solo se un classificatore predice il successo del candidato dominante. Il confronto fra Metodo 2 e TOP-4 senza filtro è lo studio di ablazione, che stabilisce se il vantaggio venga dal modello appreso o dal semplice provare più candidati. Due scenari illustrativi, UC1 di riferimento e UC2 di stress, includono depolarizzazione, rilassamento termico ed errori di lettura; per ciascuno, 2.000 istogrammi con parametri variati entro $\pm 50\%$ del nominale sono divisi 60%/20%/20% fra addestramento, selezione e verifica. Random forest, support vector machine (SVM) e perceptron multistrato sono confrontati su F1; il modello scelto è valutato su 400 istogrammi indipendenti per scenario. La metrica primaria è il numero di iterazioni per ottenere i fattori, non l'accuratezza del classificatore né il tempo di calcolo. Si usano 30 repliche appaiate per scenario e al massimo 50 iterazioni, con valore convenzionale 51 se i fattori non arrivano entro il limite, e test di Wilcoxon–Pratt con correzione di Holm. La zero-noise extrapolation (ZNE) a due e tre livelli scala in simulazione i soli parametri depolarizzanti.

2.3 Correzione quantistica e decodifica delle sindromi

Nella correzione quantistica l'informazione di un qubit logico è distribuita su più qubit fisici; si misurano parità, dette sindromi, che segnalano gli errori senza leggere l'informazione logica, e un decoder sceglie la correzione. Si studiano codice a ripetizione, Steane $[[7, 1, 3]]$ e surface code [8, 9] in circuiti di memoria, misurando la probabilità di fallimento logico p_L , cioè che l'informazione resti errata dopo la decodifica.

Il surface code ruotato usa le distanze $d = 3, 5, 7, 9$ (la distanza indica quanti errori il codice tollera), memorie in base X e Z e d cicli di sindrome, con rumore su operazioni, preparazione e misura. Il decoder di riferimento, minimum-weight perfect matching (MWPM), è confrontato sugli stessi eventi di rilevazione con una rete neurale autonoma e un decoder ibrido, che non decodifica da zero ma apprende quando la decisione del matching è probabilmente errata e la inverte, con soglia d'intervento scelta in validazione

e fissata sul test. Al rumore nominale si aggiunge crosstalk fra qubit adiacenti; si controllano calibrazione del modello, dimensione dell'ingresso della rete e confronto con il decoder analitico BP+OSD (belief propagation e ordered statistics decoding) [10].

2.4 Sensibilità di Shor agli errori di porta

Un esperimento distinto applica errori di Pauli indipendenti dopo le porte compilate, escluse le rotazioni virtuali RZ, con 20 repliche da 4.096 shot per valore. La probabilità totale di errore non identità, p_g , è un proxy per porta, non convertibile nel fallimento logico p_L dei circuiti di memoria senza compilazione fault-tolerant completa.

2.5 Ottimizzazione mediante QFT approssimata

L'AQFT elimina le rotazioni controllate di piccolo angolo della QFT, perdendo precisione ma riducendo porte e profondità, e con esse le occasioni in cui il rumore agisce. Si distingue il troncamento della QFT inversa finale di Shor per $N = 15$ da quello delle trasformate interne all'aritmetica modulare per $N = 21$; benchmark separati di stima di fase usano registri da sei, otto e dieci qubit, con tre fasi per dimensione. Il rumore usa infedeltà delle porte ed errori di lettura della calibrazione offline FakeSherbrooke, senza T_1/T_2 aggiuntivi, a parità di layout e semi casuali. Il grado di troncamento è scelto su campioni di selezione e valutato su campioni di verifica disgiunti (nel pilota $N = 15$, 8.192 shot per configurazione, divisi a metà).

3 Risultati

3.1 Validazione e contributo del post-processing

Le verifiche ideali dell'aritmetica danno una distanza di variazione totale dalla distribuzione teorica di $1,38 \times 10^{-9}$ per $N = 21$ e $2,50 \times 10^{-13}$ per $N = 35$, e attestano la correttezza funzionale, non le prestazioni sotto rumore.

In UC1/UC2 le SVM selezionate raggiungono F1 pari a 0,919/0,923 e area sotto la curva ROC pari a 0,965/0,958, ma la capacità predittiva non riduce il costo operativo. TOP-4 richiede in media 1,00 iterazioni in entrambi gli scenari, contro 1,37/1,50 di TOP-1 ($p_{Holm} = 0,0024/0,0015$); il Metodo 2 richiede 1,50/1,37 iterazioni, non migliora significativamente TOP-1 ed è peggiore della propria ablazione TOP-4 ($p_{Holm} = 0,0033/0,0096$). Il beneficio appartiene quindi alla ricerca multi-candidato. Il filtro interviene su dati già acquisiti e può scartare istogrammi che TOP-4 avrebbe utilizzato con successo. Nemmeno la ZNE migliora lo scenario di riferimento e, a due e tre livelli, richiede in media 3.072 e 4.813 shot, contro 1.399 di TOP-1 e 1.024 di TOP-4. Questi esiti valgono per metodi, istanza e rumore esaminati e non provano un'inefficacia generale del machine learning o della mitigazione.

3.2 Protezione della memoria e decodifica ibrida

Il codice a ripetizione riproduce, entro l'incertezza Monte Carlo, la legge $p_L = 3p^2 - 2p^3$. Per Steane la dipendenza dall'errore fisico è circa quadratica (pendenza logaritmica

1,94) e l'intersezione fra p_L e p cade intorno a 0,08, una pseudo-soglia del modello con errori sui dati e sindrome ideale e non la soglia operativa di un'architettura fault-tolerant. Nel surface code, sotto soglia aumentare la distanza riduce l'errore logico, sopra soglia lo aumenta; il fit sotto soglia dà circa 0,86% in base Z e 0,81% in base X, per il circuito di memoria, il rumore e il decoder adottati.

Con rumore nominale la rete autonoma non supera significativamente MWPM nelle quattordici configurazioni iniziali. Il quadro cambia con correlazioni fra qubit adiacenti che il grafo del matching non rappresenta adeguatamente, e in questo regime il decoder ibrido riduce l'errore logico. Per esempio, a $d = 3$, $p = 0,003$ e intensità di crosstalk 0,01, p_L passa da 0,05829 con MWPM a 0,04851 con l'ibrido, una riduzione relativa di circa il 16,8% (Tabella 5.9 della tesi), significativa al test appaiato di McNemar; con d cicli il beneficio è più contenuto a distanza 5 e non significativo a distanza 7. A distanza 5, nelle configurazioni considerate, BP+OSD supera l'ibrido basato su MWPM, e le prove che variano separatamente distanza e cicli mostrano il ruolo della dimensione dell'ingresso della rete. Il contributo appreso dipende quindi da struttura del rumore, riferimento analitico e rappresentazione dei dati, non dalla sola distanza del codice.

3.3 Successo di fattorizzazione e riferimento uniforme

Senza rumore il successo per singolo shot è 74,89% (intervallo di confidenza al 95% [74,59%; 75,18%]), coerente con il 75% atteso. Al crescere di p_g l'andamento è compatibile con una funzione non crescente e, per $p_g = 0,5$, il successo è 24,59%, prossimo al riferimento uniforme del 24,61% (Sezione 2.1). Il solo numero di fattorizzazioni corrette non dice perciò quanta informazione quantistica resti nel circuito.

3.4 Efficacia e limiti della QFT approssimata

Nel pilota di Shor per $N = 15$, l'AQFT selezionata aumenta la probabilità di successo per shot dal 47,92% al 62,79% (+14,87 punti percentuali sui dati indipendenti di verifica, intervallo di confidenza Newcombe al 95% [12,73; 16,99] punti), mentre le porte a due qubit ECR scendono da 362 a 279 e la profondità da 1.351 a 1.141. Il beneficio riguarda la fattorizzazione, non solo la stima di fase isolata.

Per $N = 21$ il troncamento delle QFT interne all'aritmetica riduce le porte ECR da 49.661 a 23.178, ma il successo ideale scende dal 46,67% al 40,13%; nei tre confronti rumorosi tutti gli intervalli delle differenze comprendono lo zero. Con 128 shot di verifica per variante e livello di rumore la capacità di rilevare effetti piccoli è limitata, e l'assenza di vantaggio non dimostra l'inefficacia dell'approssimazione. Nei nove benchmark di stima di fase le differenze sono tutte favorevoli alla variante selezionata e sei intervalli individuali al 95% escludono lo zero; il massimo incremento è 12,55 punti percentuali su dieci qubit ([9,77; 15,30]). I confronti sono esplorativi, senza correzione simultanea dei nove intervalli; il grado di troncamento migliore fra quelli provati è due o tre, non necessariamente costante per registri arbitrariamente grandi.

4 Discussione e conclusioni

Il post-processing usa meglio l'informazione delle misure, ma non modifica lo stato quantistico. L'ablazione del classificatore è un risultato metodologico: metriche predittive elevate non garantiscono un minor costo di fattorizzazione. Nella decodifica accade il contrario, perché la sindrome contiene informazione strutturata sugli errori e l'approccio ibrido funziona proprio dove il decoder analitico non rappresenta alcune correlazioni del rumore, benché il beneficio vada confrontato con altri decoder analitici. Il valore di un modello appreso dipende dunque dall'informazione che riceve e da ciò che la baseline lascia inutilizzato; poiché i due impieghi riguardano compiti e dati diversi, la differenza non è attribuibile alla sola fase in cui interviene il machine learning.

Per $N = 15$ l'AQFT dà un risultato positivo distinto, con meno porte associate a un maggior successo. L'ordine $r = 4$ produce fasi rappresentabili esattamente con due bit del registro di controllo, perciò le rotazioni eliminate non veicolano informazione utile e il troncamento costa poco in precisione. Per $N = 21$, con $r = 6$, le fasi non sono esattamente rappresentabili e l'aritmetica è più complessa, per cui il beneficio non si trasferisce automaticamente. Il grado di approssimazione va scelto secondo istanza e regime di rumore, e verificato su dati distinti da quelli usati per sceglierlo.

Le conclusioni restano circoscritte alle simulazioni. Il post-processing riguarda $N = 15$ con rumore uniforme e stazionario, la QEC circuiti di memoria separati, le prove AQFT una sola calibrazione offline e poche istanze e fasi. Non si dimostra un'esecuzione fault-tolerant completa di Shor, né si prevedono le risorse per la fattorizzazione su scala crittografica. Il contributo è una caratterizzazione quantitativa e riproducibile delle condizioni di utilità dei componenti studiati, da estendere con verifica su hardware, variazione indipendente di N e dell'ordine r e integrazione fra operazioni logiche protette, decodifica e ottimizzazione aritmetica. Nel perimetro studiato emerge una regola comune: aggiungere complessità ha senso solo se permette di sfruttare informazione che la baseline non usa, o se riduce un costo del circuito maggiore della perdita introdotta.

5 Riferimenti bibliografici essenziali

- [1] P. W. Shor, "Algorithms for Quantum Computation: Discrete Logarithms and Factoring", *Proc. 35th Annual Symposium on Foundations of Computer Science (FOCS)*, pp. 124–134, 1994.
- [2] J. Preskill, "Quantum Computing in the NISQ Era and Beyond", *Quantum*, 2, 79, 2018.
- [3] S. Beauregard, "Circuit for Shor's Algorithm Using $2n + 3$ Qubits", *Quantum Information and Computation*, 3(2), pp. 175–185, 2003.
- [4] Qiskit contributors, *Qiskit: An Open-source Framework for Quantum Computing*, Zenodo, doi:10.5281/zenodo.2573505, 2023.
- [5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python", *Journal of Machine Learning Research*, 12, pp. 2825–2830, 2011.
- [6] C. Gidney, "Stim: A Fast Stabilizer Circuit Simulator", *Quantum*, 5, 497, 2021.
- [7] O. Higgott, "PyMatching: A Python package for decoding quantum codes with minimum-weight perfect matching", arXiv:2105.13082, 2021.
- [8] A. M. Steane, "Error Correcting Codes in Quantum Theory", *Physical Review Letters*, 77(5), pp. 793–797, 1996.
- [9] A. G. Fowler et al., "Surface Codes: Towards Practical Large-Scale Quantum Computation", *Physical Review A*, 86(3), 032324, 2012.
- [10] J. Roffe et al., "Decoding Across the Quantum Low-Density Parity-Check Code Landscape", *Physical Review Research*, 2(4), 043423, 2020.